



Latent diffusion



Table of Contents

01

Introduction

02

Method

03

Experiments

Mặc dù **Diffusion Models (DM)** tận dụng Denoising Autoencoders (DAE) đạt được kết quả tốt nhất trong nhiều tác vụ, chúng vẫn có những hạn chế:

- Việc huấn luyện và đánh giá DM trực tiếp trong không gian pixel đòi hỏi chi phí tính toán cao và tốn nhiều thời gian.
- Mặc dù cơ chế "classifier guidance" cho phép tạo ảnh có điều kiện mà không cần huấn luyện lại, vẫn cần tìm giải pháp tối ưu hơn.

- **Latent Diffusion Model (LDM):** Đề xuất phương pháp huấn luyện DM hiệu quả trong không gian tiềm ẩn, giảm chi phí tính toán và tăng tốc độ suy luận.
- **Hiệu suất cạnh tranh:** LDM đạt hiệu suất cao trên nhiều tác vụ (inpainting, tổng hợp có điều kiện, siêu phân giải) so với DM trên pixel.
- **Cross-Attention:** Phát triển cơ chế cross-attention để DM linh hoạt với nhiều loại điều kiện (text, nhãn lớp, bounding box...).
- **Mô hình mở:** Cung cấp mô hình LDM và autoencoder đã huấn luyện, có thể tái sử dụng.

Tiến bộ: Tổng hợp ảnh phát triển nhanh (GANs, VAEs, DMs).

Thách thức:

- **GANs:** Chất lượng cao nhưng mode collapse, khó mở rộng.
- **AR Models:** Chi tiết nhưng tốn tài nguyên, suy luận chậm.
- **DMs:** Chất lượng tốt nhưng chi phí tính toán cao.

Mục tiêu: Giảm chi phí tính toán của DM, vẫn đảm bảo chất lượng.

-> **Giải pháp:** Latent Diffusion Models (LDMs) chuyển khuếch tán sang không gian tiềm ẩn.

So sánh LDM với:


- **GANs:** Tạo ảnh tốt nhưng không ổn định, khó huấn luyện.
- **VAEs:** Hiệu quả nén nhưng chất lượng ảnh thấp hơn GAN.
- **ARMs:** Độ chính xác cao nhưng tốn tài nguyên.
- **DMs:** Khắc phục nhược điểm GANs/ARMs, nhưng tính toán tốn kém.
- **Two-Stage Image Synthesis (VQ-VAE, VQGAN):** Giảm chi phí nhưng nén mạnh gây mất chi tiết.

Latent Diffusion Models (LDMs) khắc phục được nhược điểm của các phương pháp trên bằng cách:

- Áp dụng khuếch tán trong không gian tiềm ẩn để giảm chi phí tính toán.
- Sử dụng kiến trúc UNet với cross-attention, giúp linh hoạt hơn trong việc điều kiện hóa quá trình tạo ảnh (ví dụ: văn bản, bố cục hình ảnh).
- Duy trì độ chi tiết và độ trung thực của hình ảnh cao mà không cần nén quá mức như các mô hình hai giai đoạn khác.

02 | Method - Diffusion


Denoising Diffusion Probabilistic Models



02 | Method - Diffusion

Denoising diffusion models consist of two processes:

- Forward diffusion process that gradually adds noise to input
- Reverse denoising process that learns to generate data by denoising



02 | Method - Diffusion




x_{t-1}



ϵ_{t-1}

$$\sqrt{1 - \beta_t}x_{t-1} + \sqrt{\beta_t}\epsilon_{t-1}$$



x_t


Variance schedule: $\{\beta_t \in (0, 1)\}_{t=1}^T$

Gaussian noise: $\{\epsilon_t \in \mathcal{N}(0, 1)\}_{t=1}^T$

$$q(\mathbf{x}_t | \mathbf{x}_{t-1}) = \mathcal{N}(\mathbf{x}_t; \sqrt{1 - \beta_t}\mathbf{x}_{t-1}, \beta_t\mathbf{I})$$

02 | Method - Diffusion

What happen to a distribution in the forward diffusion?



$$\mathbf{x}_0 \sim \mathcal{P}$$

$$\mathbf{x}_t = \sqrt{1 - \beta_t} \mathbf{x}_{t-1} + \sqrt{\beta_t} \epsilon \sim q(\mathbf{x}_t | \mathbf{x}_{t-1}) = \mathcal{N}(\sqrt{1 - \beta_t} \mathbf{x}_{t-1}, \beta_t I)$$

$$\beta_t \in (0, 1) \rightarrow \mathbf{x}_t | \mathbf{x}_0 \xrightarrow{\mathcal{D}} \mathcal{N}(0, I)$$

$$T \text{ đủ lớn } (1000 \rightarrow 4000) : \mathbf{x}_t \sim \mathcal{N}(0, I)$$

02 | Method - Diffusion

Forward Diffusion Process

A nice property of the above process is that we can sample x_t at any arbitrary time step t

Let $\alpha_t = 1 - \beta_t$ and $\bar{\alpha}_t = \prod_{i=1}^t \alpha_i$:

$$\begin{aligned}x_t &= \sqrt{\alpha_t}x_{t-1} + \sqrt{1 - \alpha_t}\epsilon_{t-1} \\&= \sqrt{\alpha_t}(\sqrt{\alpha_{t-1}}x_{t-2} + \sqrt{1 - \alpha_{t-1}}\epsilon_{t-2}) + \sqrt{1 - \alpha_t}\epsilon_{t-1} \\&= \sqrt{\alpha_t\alpha_{t-1}}x_{t-2} + \sqrt{\alpha_t(1 - \alpha_{t-1})}\epsilon_{t-2} + \sqrt{1 - \alpha_t}\epsilon_{t-1} \\&= \sqrt{\alpha_t\alpha_{t-1}}x_{t-2} + \sqrt{1 - \alpha_t\alpha_{t-1}}\bar{\epsilon}_{t-2} \\&= \dots \\&= \sqrt{\bar{\alpha}_t}x_0 + \sqrt{1 - \bar{\alpha}_t}\bar{\epsilon}\end{aligned}$$
$$\begin{cases} \sqrt{\alpha_t(1 - \alpha_{t-1})}\epsilon_{t-2} = \mathcal{N}(0, \alpha_t(1 - \alpha_{t-1})) \\ \sqrt{1 - \alpha_t}\epsilon_{t-1} = \mathcal{N}(0, 1 - \alpha_t) \end{cases}$$

02 | Method - Diffusion

Reverse Denoising Process


Recall, that the diffusion parameters are designed such that $q(\mathbf{x}_T) \approx \mathcal{N}(\mathbf{x}_T; \mathbf{0}, \mathbf{I})$

Generation:

Sample $\mathbf{x}_T \sim \mathcal{N}(\mathbf{x}_T; \mathbf{0}, \mathbf{I})$

Iteratively sample $\mathbf{x}_{t-1} \sim \underbrace{q(\mathbf{x}_{t-1}|\mathbf{x}_t)}_{\text{True Denoising Dist.}}$

Diffused Data Distributions



02 | Method - Diffusion

Reverse Denoising Process

$$\begin{aligned} q(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0) &= q(\mathbf{x}_t|\mathbf{x}_{t-1}, \mathbf{x}_0) \frac{q(\mathbf{x}_{t-1}|\mathbf{x}_0)}{q(\mathbf{x}_t|\mathbf{x}_0)} \\ &\propto \exp \left(-\frac{1}{2} \left(\frac{(\mathbf{x}_t - \sqrt{\alpha_t} \mathbf{x}_{t-1})^2}{\beta_t} + \frac{(\mathbf{x}_{t-1} - \sqrt{\bar{\alpha}_{t-1}} \mathbf{x}_0)^2}{1 - \bar{\alpha}_{t-1}} - \frac{(\mathbf{x}_t - \sqrt{\bar{\alpha}_t} \mathbf{x}_0)^2}{1 - \bar{\alpha}_t} \right) \right) \\ &= \exp \left(-\frac{1}{2} \left(\frac{\mathbf{x}_t^2 - 2\sqrt{\alpha_t} \mathbf{x}_t \mathbf{x}_{t-1} + \alpha_t \mathbf{x}_{t-1}^2}{\beta_t} + \frac{\mathbf{x}_{t-1}^2 - 2\sqrt{\bar{\alpha}_{t-1}} \mathbf{x}_0 \mathbf{x}_{t-1} + \bar{\alpha}_{t-1} \mathbf{x}_0^2}{1 - \bar{\alpha}_{t-1}} - \frac{(\mathbf{x}_t - \sqrt{\bar{\alpha}_t} \mathbf{x}_0)^2}{1 - \bar{\alpha}_t} \right) \right) \\ &= \exp \left(-\frac{1}{2} \left(\left(\frac{\alpha_t}{\beta_t} + \frac{1}{1 - \bar{\alpha}_{t-1}} \right) \mathbf{x}_{t-1}^2 - \left(\frac{2\sqrt{\alpha_t}}{\beta_t} \mathbf{x}_t + \frac{2\sqrt{\bar{\alpha}_{t-1}}}{1 - \bar{\alpha}_{t-1}} \mathbf{x}_0 \right) \mathbf{x}_{t-1} + C(\mathbf{x}_t, \mathbf{x}_0) \right) \right) \end{aligned}$$

$$y = \frac{1}{\sigma \sqrt{2\pi}} e^{-\frac{(x - \mu)^2}{2\sigma^2}}$$

$$\mu_{\theta}(\mathbf{x}_t, t) = \frac{1}{\sqrt{\alpha_t}} \left(\mathbf{x}_t - \frac{1 - \alpha_t}{\sqrt{1 - \bar{\alpha}_t}} \epsilon_{\theta}(\mathbf{x}_t, t) \right)$$

02 | Method - Diffusion

Reverse Denoising Process

$$q(\mathbf{x}_{t-1} | \mathbf{x}_t, \mathbf{x}_0) = \mathcal{N}(\mathbf{x}_{t-1}; \frac{1}{\sqrt{\alpha_t}} \left(\mathbf{x}_t - \frac{1 - \alpha_t}{\sqrt{1 - \bar{\alpha}_t}} \boldsymbol{\epsilon}_{\theta}(\mathbf{x}_t, t) \right), \boldsymbol{\Sigma}_{\theta}(\mathbf{x}_t, t))$$




x_{t-1}



ϵ_{t-1}


$$\sqrt{1 - \beta_t} x_{t-1} + \sqrt{\beta_t} \epsilon_{t-1}$$




x_t

02 | Method - Diffusion

Diffusion




UNet



02 | Method - Diffusion

Summary Training and Sample Generation

Data



Noise

Algorithm 1 Training

- 1: **repeat**
- 2: $\mathbf{x}_0 \sim q(\mathbf{x}_0)$
- 3: $t \sim \text{Uniform}(\{1, \dots, T\})$
- 4: $\epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$
- 5: Take gradient descent step on
$$\nabla_{\theta} \left\| \epsilon - \epsilon_{\theta} \left(\sqrt{\bar{\alpha}_t} \mathbf{x}_0 + \sqrt{1 - \bar{\alpha}_t} \epsilon, t \right) \right\|^2$$
- 6: **until** converged


Algorithm 2 Sampling

- 1: $\mathbf{x}_T \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$
- 2: **for** $t = T, \dots, 1$ **do**
- 3: $\mathbf{z} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$
- 4: $\mathbf{x}_{t-1} = \frac{1}{\sqrt{\alpha_t}} \left(\mathbf{x}_t - \frac{1 - \alpha_t}{\sqrt{1 - \bar{\alpha}_t}} \epsilon_{\theta}(\mathbf{x}_t, t) \right) + \sigma_t \mathbf{z}$
- 5: **end for**
- 6: **return** $\mathbf{x}_0$

02 | Method - Latent Diffusion

Diffusion

Diffusion





02 | Method - Latent Diffusion


Diffusion + Latent Space

Diffusion

AutoEncoder




02 | Method - Latent Diffusion




- **down samples factor:** $f = \frac{H}{h} = \frac{W}{w} = 2^m, m \in \mathbb{N}$
- **image:** $\mathbf{x} \in \mathbb{R}^{H \times W \times 3}$
- **encoder:** $\mathcal{E}(\mathbf{x}) = \mathbf{z} \in \mathbb{R}^{h \times w \times c}$
- **decoder:** $\mathcal{D}(\mathbf{z}) = \mathcal{D}(\mathcal{E}(\mathbf{x})) \in \mathbb{R}^{H \times W \times 3}$

02 | Method - Latent Diffusion




Interpolation:


$$\mathbf{z} = \alpha \times \mathbf{z}_1 + (1 - \alpha) \times \mathbf{z}_2$$



02 | Method - Latent Diffusion




02 | Method - Latent Diffusion




$$\mathcal{L}_{\text{Autoencoder}} = \min_{\mathcal{E}, D} \max_{\psi} (L_{\text{rec}}(x, D(\mathcal{E}(x))) - L_{\text{adv}}(D(\mathcal{E}(x))) + \log D_{\psi}(x) + L_{\text{reg}}(x; \mathcal{E}, D))$$

02 | Method - Latent Diffusion




$$\mathcal{L}_{DM} = \mathbb{E}_{\mathbf{x}, \epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I}), t} [\| \epsilon - \epsilon_\theta(\mathbf{x}_t, t) \|_2^2]$$

02 | Method - Latent Diffusion



$$\mathcal{L}_{LDM} = \mathbb{E}_{\mathcal{E}(\mathbf{x}), \epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I}), t} [\| \epsilon - \epsilon_\theta(\mathbf{z}_t, t,) \|_2^2]$$

02 | Method - Latent Diffusion



$$\text{Attention}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{softmax}\left(\frac{\mathbf{Q}\mathbf{K}^\top}{\sqrt{d}}\right) \cdot \mathbf{V}$$

where $\mathbf{Q} = \mathbf{W}_Q^{(i)} \cdot \varphi_i(\mathbf{z}_i)$, $\mathbf{K} = \mathbf{W}_K^{(i)} \cdot \tau_\theta(y)$, $\mathbf{V} = \mathbf{W}_V^{(i)} \cdot \tau_\theta(y)$

$$\mathcal{L}_{SDM} = \mathbb{E}_{\mathcal{E}(\mathbf{x}), y, \epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I}), t} [\| \epsilon - \epsilon_\theta(\mathbf{z}_t, t, \tau_\theta(y)) \|_2^2]$$

03 | Experiments

01

Perceptual Compression Tradeoff

02

Unconditional Image Generation

03

Conditional Latent Diffusion

04

Super-Resolution

05

Inpainting

03 | Experiments - Perceptual Compression Tradeoff

Mục tiêu:

- Tìm ra tỷ lệ nén f tối ưu cho LDM
- So sánh hiệu suất LDM với các tỷ lệ nén khác nhau của $f \in \{1, 2, 4, 8, 16, 32\}$

Thực nghiệm:

- Dữ liệu: Imagenet
- Các mô hình được huấn luyện trong 2 triệu bước (thiết lập như nhau)
- Đánh giá: FID, IS





Imagenet

03 | Perceptual Compression Tradeoff - Inception Score

Input: ảnh




Inception




Kiểm tra chất lượng ảnh sinh ra qua mạng Inception, nếu ảnh rõ, tốt thì mạng sẽ phân loại tốt

03 | Perceptual Compression Tradeoff - Inception Score

Similar labels sum to give focussed distribution



Different labels sum to give uniform distribution



Đa dạng dữ liệu $\Leftrightarrow$ Tổng xác suất dạng uniform


03 | Perceptual Compression Tradeoff - Inception Score

Kullback-Leibler divergence

$$D_{KL}(P||Q) = \int P(x) \log \frac{P(x)}{Q(x)} dx$$

2 distribution giống nhau thì $KL = 0$, càng khác nhau thì KL càng lớn

- Giá trị 1 ảnh qua mạng Inception là label distribution.
- Giá trị đã normalize tổng label distribution là marginal distribution.



03 | Perceptual Compression Tradeoff - Fréchet Inception Distance


Đo lường sự khác biệt giữa phân phối đặc trưng của ảnh sinh ra và ảnh thật, thông qua mạng Inception.

$$FID = \|\mu_x - \mu_g\|_2^2 + \text{Tr}(\Sigma_x + \Sigma_g - 2(\Sigma_x \Sigma_g)^{\frac{1}{2}})$$

Ý nghĩa:

- Ảnh sinh ra có chất lượng cao và tương tự ảnh thật, μ_g và μ_r sẽ gần nhau, tương tự cho Σ_g và Σ_r .
- Ảnh sinh ra đa dạng và không lặp lại thì ma trận Σ_g sẽ bao phủ một không gian tương tự như Σ_r .

03 | Perceptual Compression Tradeoff



LDM-1 (hay pixel-based diffusion model) yêu cầu thời gian đào tạo lớn hơn đáng kể so với các mô hình có hệ số nén lớn hơn (LDM- $\{4-16\}$).


Việc nén quá nhiều như LDM-32 hạn chế chất lượng của ảnh do mất mát thông tin.

LDM-4 và LDM-8 là lựa chọn tối ưu khi cả FID và IS đang tốt nhất.


03 | Perceptual Compression Tradeoff



03 | Perceptual Compression Tradeoff



CelebA-HQ



ImageNet

LDM-4 và -8 đạt được sự cân bằng tối ưu giữa tốc độ suy luận và chất lượng ảnh so với tỷ lệ nén khác (chất lượng tốt đồng thời duy trì tốc độ suy luận nhanh hơn so với LDM-1)

03 | Experiments - Unconditional Image Generation

Mục tiêu:

- Đánh giá khả năng của LDMs trong việc tạo ảnh không có điều kiện đầu vào
- So sánh hiệu suất của LDMs với các phương pháp SOTA khác trên nhiều tập dữ liệu

Phương pháp:


- Dữ liệu: CelebA-HQ, FFHQ, LSUN-Churches, LSUN-Bedrooms
- Kiến trúc: LDM-4 và LDM-8
- Đánh giá: FID, Precision, Recall

03 | Unconditional Image Generation

CelebA-HQ 256×256				FFHQ 256×256			
Method	FID ↓	Prec. ↑	Recall ↑	Method	FID ↓	Prec. ↑	Recall ↑
DC-VAE [61]	15.8	-	-	ImageBART [21]	9.57	-	-
VQGAN+T. [23] (k=400)	10.2	-	-	U-Net GAN (+aug) [75]	10.9 (7.6)	-	-
PGGAN [38]	8.0	-	-	UDM [42]	5.54	-	-
LSGM [90]	7.22	-	-	StyleGAN [40]	<u>4.16</u>	<u>0.71</u>	<u>0.46</u>
UDM [42]	<u>7.16</u>	-	-	ProjectedGAN [74]	3.08	0.65	<u>0.46</u>
<i>LDM-4</i> (ours, 500-s [†])	5.11	0.72	0.49	<i>LDM-4</i> (ours, 200-s)	4.98	0.73	0.50

LSUN-Churches 256×256				LSUN-Bedrooms 256×256			
Method	FID ↓	Prec. ↑	Recall ↑	Method	FID ↓	Prec. ↑	Recall ↑
DDPM [29]	7.89	-	-	ImageBART [21]	5.51	-	-
ImageBART [21]	7.32	-	-	DDPM [29]	4.9	-	-
PGGAN [38]	6.42	-	-	UDM [42]	4.57	-	-
StyleGAN [40]	4.21	-	-	StyleGAN [40]	2.35	0.59	<u>0.48</u>
StyleGAN2 [41]	<u>3.86</u>	-	-	ADM [15]	<u>1.90</u>	0.66	0.51
ProjectedGAN [74]	1.59	<u>0.61</u>	<u>0.44</u>	ProjectedGAN [74]	1.52	<u>0.61</u>	0.34
<i>LDM-8*</i> (ours, 200-s)	4.02	0.64	0.52	<i>LDM-4</i> (ours, 200-s)	2.95	0.66	<u>0.48</u>

03 | Unconditional Image Generation




03 | Experiments - Conditional Latent Diffusion


Mục tiêu:

- Đánh giá khả năng của LDMs trong việc tạo ảnh với điều kiện đầu vào
- So sánh hiệu suất của LDMs với các phương pháp SOTA khác trên nhiều tập dữ liệu

Text-to-Image Synthesis on LAION. 1.45B Model.




Text prompt(Laion database)




Layout prompt(Coco)

| Experiments - Conditional Latent Diffusion

Các điều kiện như văn bản, bản đồ ngữ nghĩa và nhãn lớp ..., được ghép nối tiếp với biểu diễn tiềm ẩn của hình ảnh đầu vào để giải quyết các bài toán sinh ảnh có điều kiện.



Experiments - Text-to-image



03 | Experiments - Text-to-image

	COCO256 × 256	OpenImages 256 × 256	OpenImages 512 × 512
Method	FID↓	FID↓	FID↓
LostGAN-V2 [87]	42.55	-	-
OC-GAN [89]	41.65	-	-
SPADE [62]	<u>41.11</u>	-	-
VQGAN+T [37]	56.58	<u>45.33</u>	<u>48.11</u>
<i>LDM-8</i> (100 steps, ours)	42.06 [†]	-	-
<i>LDM-4</i> (200 steps, ours)	40.91*	32.02	35.80

| Experiments - Semantic synthesis

Mục tiêu: Tác giả sử dụng mô hình để tạo ra ảnh độ phân giải cao từ semantic maps.



| Experiments - Semantic synthesis

- Mô hình được huấn luyện trên các cặp ảnh phong cảnh và **bản đồ ngữ nghĩa** (cung cấp một biểu diễn có cấu trúc của cảnh như: vị trí đối tượng, ranh giới).
- Các bản đồ ngữ nghĩa được giảm kích thước và ghép nối tiếp với biểu diễn tiềm ẩn của hình ảnh đầu vào.
- Mô hình được huấn luyện trên hình ảnh có độ phân giải 256^2 nhưng có thể tổng quát hóa lên các độ phân giải cao hơn.

Experiments - Semantic synthesis

Method	COCO256 × 256	OpenImages 256 × 256	OpenImages 512 × 512
	FID↓	FID↓	FID↓
LostGAN-V2 [87]	42.55	-	-
OC-GAN [89]	41.65	-	-
SPADE [62]	<u>41.11</u>	-	-
VQGAN+T [37]	56.58	<u>45.33</u>	<u>48.11</u>
<i>LDM-8</i> (100 steps, ours)	42.06 [†]	-	-
<i>LDM-4</i> (200 steps, ours)	40.91*	32.02	35.80

So sánh trên tập dữ liệu Image-net val.


| Experiments - Super-Resolution with Latent Diffusion Models

Mục tiêu: Sử dụng các mô hình khuếch tán tiềm ẩn (LDMs) vào tác vụ **siêu phân giải** (tạo ra các hình ảnh có độ phân giải cao từ các hình ảnh đầu vào có độ phân giải thấp.)



Experiments - Super-Resolution with Latent Diffusion Models

Tác giả sử dụng phương pháp nội suy nhị phân để giảm độ phân giải hình ảnh gốc xuống 4 lần (4×-downsampling) để tạo ra các hình ảnh độ phân giải thấp (LR) từ hình ảnh độ phân giải cao (HR) ban đầu. Sau đó phép ghép nối tiếp được sử dụng để nối các hình ảnh độ phân giải thấp với biểu diễn tiềm ẩn của hình ảnh đầu vào.



bilinear resampling:

$$DN_E = \Delta x DN_B + (1 - \Delta x) DN_A$$

$$DN_F = \Delta x DN_D + (1 - \Delta x) DN_C$$

$$DN(x, y) = \Delta y DN_F + (1 - \Delta y) DN_E$$

3 | Experiments - Super-Resolution with Latent Diffusion Models

- Mô hình được huấn luyện trên **bộ dữ liệu ImageNet**, theo quy trình xử lý dữ liệu của **SR3**. Điều này đảm bảo tính nhất quán trong việc so sánh giữa LDM-SR và SR3.

Method	FID ↓	IS ↑	PSNR ↑	SSIM ↑	N_{params}	$[\frac{\text{samples}}{s}](*)$
Image Regression [72]	15.2	121.1	27.9	0.801	625M	N/A
SR3 [72]	5.2	180.1	<u>26.4</u>	<u>0.762</u>	625M	N/A
<i>LDM-4</i> (ours, 100 steps)	<u>2.8[†]</u> / <u>4.8[‡]</u>	166.3	24.4 $\pm$ 3.8	0.69 $\pm$ 0.14	169M	4.62
emphLDM-4 (ours, big, 100 steps)	2.4[†] / 4.3[‡]	<u>174.9</u>	24.7 $\pm$ 4.1	0.71 $\pm$ 0.15	552M	4.5
<i>LDM-4</i> (ours, 50 steps, guiding)	4.4 [†] /6.4 [‡]	153.7	25.8 $\pm$ 3.7	0.74 $\pm$ 0.12	<u>184M</u>	0.38

Kết quả siêu phân giải từ 64x64 px lên 256x256 px trên tập ImageNet-Val.

4 | Experiments - Inpainting with Latent Diffusion Models

Mục tiêu: Sử dụng các mô hình khuếch tán tiềm ẩn (LDMs) vào tác vụ **khôi phục hình ảnh** (khôi phục lại cái khu vực hình ảnh đã bị xóa (masked / corrupted) để thu được ảnh hoàn chỉnh.)



4 | Experiments - Inpainting with Latent Diffusion Models

Tác giả crop đi vài phần của ảnh gốc để tạo các hình ảnh bị khuyết và các mask. Sau đó phép ghép nối tiếp được sử dụng để nối các hình ảnh độ phân giải thấp với biểu diễn tiềm ẩn của hình ảnh đầu vào.



4 | Experiments - Inpainting with Latent Diffusion Models

Bộ dữ liệu: Mô hình được huấn luyện trên bộ dữ liệu Places, một bộ dữ liệu lớn chứa các hình ảnh cảnh quan.

Quy trình huấn luyện và đánh giá tuân theo giao thức của LaMa, một mô hình điền khuyết sota sử dụng Fast Fourier Convolutions.

Method	40-50% masked		All samples	
	FID ↓	LPIPS ↓	FID ↓	LPIPS ↓
<i>LDM-4</i> (ours, big, w/ ft)	9.39	<u>0.246</u> ± 0.042	1.50	<u>0.137</u> ± 0.080
<i>LDM-4</i> (ours, big, w/o ft)	12.89	0.257 ± 0.047	2.40	<u>0.142</u> ± 0.085
<i>LDM-4</i> (ours, w/ attn)	11.87	0.257 ± 0.042	2.15	<u>0.144</u> ± 0.084
<i>LDM-4</i> (ours, w/o attn)	12.60	0.259 ± 0.041	2.37	<u>0.145</u> ± 0.084
LaMa [88] [†]	12.31	0.243 ± 0.038	2.23	0.134 ± 0.080
LaMa [88]	12.0	0.24	2.21	<u>0.14</u>
CoModGAN [107]	<u>10.4</u>	0.26	<u>1.82</u>	0.15
RegionWise [52]	21.3	0.27	4.75	0.15
DeepFill v2 [104]	22.1	0.28	5.20	0.16
EdgeConnect [58]	30.5	0.28	8.37	0.16

Place test-set

