

ĐẠI HỌC QUỐC GIA HÀ NỘI
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ

Lê Thanh Hà

THỊ GIÁC MÁY

NHÀ XUẤT BẢN ĐẠI HỌC QUỐC GIA HÀ NỘI

31	MỤC LỤC.....	2
32	DANH MỤC HÌNH.....	6
33	DANH MỤC BẢNG	7
34	DANH MỤC TỪ VIẾT TẮT	8
35	KÝ HIỆU TOÁN HỌC.....	9
36	LỜI NÓI ĐẦU.....	10
37	CHƯƠNG 1. GIỚI THIỆU CÁC ỨNG DỤNG THỊ GIÁC MÁY.....	13
38	1.1. Thị giác máy và các bài toán thị giác máy.....	13
39	1.1.1. Thị giác máy là gì?.....	13
40	1.1.2. Các bài toán thị giác máy	13
41	1.1.3. Thị giác sinh học và thị giác máy	14
42	1.2. Một số ứng dụng thực tiễn của thị giác máy.....	15
43	1.2.1. Y tế.....	16
44	1.2.2. Giao thông.....	16
45	1.2.3. An ninh	17
46	1.2.4. Môi trường và tài nguyên thiên nhiên	18
47	1.2.5. Văn hóa	18
48	Kết chương.....	19
49	CHƯƠNG 2. NHẬN THỨC THỊ GIÁC NGƯỜI.....	20
50	2.1. Ánh sáng và màu sắc.....	20
51	2.1.1. Ánh sáng là gì?	20
52	2.1.2. Nguồn phát sáng	22
53	2.1.3. Màu sắc	25
54	2.2 Cấu trúc phân cấp của nhận thức thị giác của người.....	26
55	2.3. Các chức năng thị giác.....	27
56	2.3.1. Chuyển đổi ánh sáng thành tín hiệu điện não.....	27
57	2.3.2. Phát hiện đặc trưng sơ cấp.....	34

58	2.3.3. Thị giác sinh học và các bài toán nhận thức bậc cao	37
59	Kết chương	39
60	Tài liệu tham khảo	40
61	Bài tập	42
62	CHƯƠNG 3. THU NHẬN VÀ HÌNH THÀNH HÌNH ẢNH.....	43
63	3.1. Khái niệm ảnh	43
64	3.2. Thu nhận ảnh	43
65	3.2.1. Nhận biết màu sắc.....	44
66	3.2.2. Nhận biết không gian	45
67	3.3. Biểu diễn ảnh (Không gian, thời gian, cường độ)	49
68	3.3.1. Ảnh 2 chiều (2D image).....	50
69	3.3.2. Ảnh 3 chiều (3D image).....	50
70	3.2.3. Đám mây điểm (cloudpoint)	52
71	3.2.4. Lưới hóa (meshing).....	52
72	3.4. Mô hình camera	53
73	3.4.1. Pinhole camera	53
74	3.4.2. Camera với thấu kính.....	57
75	3.4.2. Tham số camera.....	59
76	3.4.3. Xác định tham số camera	63
77	3.4.4. Camera song khung hình với không gian 3D	65
78	Kết chương	70
79	Tài liệu tham khảo	70
80	Bài tập	71
81	CHƯƠNG 4. THỊ GIÁC MÁY KINH ĐIỂN.....	72
82	4.1. Khái niệm đặc trưng ảnh	72
83	4.2. Đặc trưng sơ cấp	73
84	4.2.1. Cạnh (Edge).....	73
85	4.2.2. Điểm đặc trưng (Interesting point) và Góc (Corner)	82
86	4.2.3. Blob.....	86
87	4.3. Đặc trưng hình dạng	91
88	4.3.1. Trích rút đặc trưng đường bao.....	91
89	4.3.2. Trích rút đặc trưng Hu moments (Hu moments).....	93
90	4.4. Đặc trưng kết cấu (Texture)	96

91	4.4.1. Mẫu nhị phân cục bộ (local binary patterns - LBP)	96
92	4.4.2. Ma trận đồng xuất hiện mức xám (GLCM)	99
93	4.4.3. Hệ bộ lọc Gabor (Gabor filter banks)	104
94	4.4.4. Dựa trên gradient (SIFT, HoG)	108
95	4.5. Khai phá ngữ nghĩa thị giác	112
96	4.5.1. So khớp mô hình (model fitting)	113
97	4.5.2. Theo dõi đối tượng (tracking)	120
98	4.5.3. Căn chỉnh ảnh	126
99	4.5.4. Phân loại ảnh	131
100	4.5.5. Phát hiện và nhận dạng đối tượng trong ảnh	138
101	4.5.6. Tái tạo cấu trúc 3D	142
102	Kết chương	148
103	Tài liệu tham khảo	149
104	Bài tập	152
105	CHƯƠNG 5. THỊ GIÁC MÁY DỰA TRÊN HỌC SÂU	153
106	5.1. Giới thiệu học sâu	153
107	5.1.1. Khái niệm học máy	154
108	5.1.2. Mạng neuron nhân tạo	155
109	5.1.3. Khái niệm học sâu	164
110	5.2. Mạng neuron sâu	165
111	5.2.1. Mạng tích chập (convolutional neuron network - CNN)	165
112	5.2.2. Vision transformers	184
113	5.2.3. Mạng hồi quy	199
114	5.2.4. Huấn luyện mạng học sâu	199
115	5.3. Một số mạng chức năng	200
116	5.3.1. Mạng so khớp mô hình	200
117	5.3.2. Mạng bám theo đối tượng	200
118	5.3.3. Mạng căn chỉnh ảnh	200
119	5.3.4. Mạng phân loại ảnh	200
120	5.3.5. Mạng phát hiện và nhận dạng đối tượng	200
121	5.3.6. Mạng tái tạo cấu trúc 3D	200
122	5.3.7. Mạng sinh ảnh	200
123	5.4. Mô hình nền thị giác (vision foundation models)	200

124	Kết chương	200
125	Tài liệu tham khảo	201
126	Bài tập	203
127	PHỤ LỤC 1. NỀN TẢNG TOÁN HỌC	204
128	P1.1. Không gian tỉ lệ	204
129	P1.1.1. Định nghĩa gian tỉ lệ là gì.....	205
130	P1.1.2. Chuẩn hóa đạo hàm	205
131	P1.1.3. Tự động chọn tham số tỉ lệ	207
132	P1.2. Không gian đẳng cấu	208
133	PHỤ LỤC 2. DỰ ÁN THỰC HÀNH.....	209
134	P2.1.	209
135	P1.2.	209
136	P1.3.	209
137		
138		

139

DANH MỤC HÌNH

140 **Hình 1.1.** Mô hình truyền thông con người. **Error! Bookmark not defined.**

141 **Hình 4.1.** Niên biểu các chuẩn nén video từ năm 1988 đến nay.**Error!**

142 **Bookmark not defined.**

143

144

DRAFT

145

DANH MỤC BẢNG

146

147

148

149

Bảng 1.1. Mô hình truyền thông con người. **Error! Bookmark not defined.**

150

DANH MỤC TỪ VIẾT TẮT

Từ viết tắt

Thuật ngữ tiếng Anh

Thuật ngữ tiếng Việt

AI

Artificial intelligence

Trí tuệ nhân tạo

151

152

KÝ HIỆU TOÁN HỌC

Ký hiệu	Ý nghĩa
$*$	Toán tử nhân chập giữa hai hàm, ví dụ $I(x, y) * h(x, y)$.
$\otimes$	Nhân ngoài.
$\leftarrow$	Gán giá trị cho biến, ví dụ $x \leftarrow x + y$ có nghĩa là giá trị của biến x được tăng thêm y .
$\lfloor x \rfloor$	Phần nguyên dưới của x , ví dụ $\lfloor 5.9 \rfloor = 5$ và $\lfloor -3.3 \rfloor = -4$.
$I(x, y)$	Ảnh hai chiều thường có thể là ảnh liên tục
$I[x, y]$	Ảnh hai chiều được biểu diễn dưới dạng mảng số rời rạc
$\nabla I(x, y)$	Ký hiệu gradient
$G(x, y; \sigma)$	Hàm Gaussian
$L(x, y; \sigma)$	Biểu diễn đa tỉ lệ của một ảnh cho trước

Với sự phát triển mạnh mẽ các công nghệ cảm biến, công nghệ lưu trữ, các hệ thống thị giác máy có thể thu nhận và lưu trữ hình ảnh ở nhiều dải phổ của ánh sáng trong khoảng thời gian dài, trên một không gian rộng lớn. Được trang bị công cụ xử lý ảnh mạnh mẽ và khả năng suy diễn tinh vi, những hệ thống này có thể thực hiện các chức năng nhận thức, trong nhiều trường hợp, là tương tự hoặc vượt xa con người. Chúng có thể cung cấp các thông tin phụ trợ giúp bác sỹ ra y lệnh chính xác hơn, chúng có thể nhanh chóng phát hiện vết xước rất mảnh trên bề mặt sản phẩm, chúng có thể tự động theo vết người hoặc phương tiện giao thông khả nghi trên toàn thành phố, chúng có thể bắt bám các đối tượng nguy hiểm đang chuyển động rồi ra lệnh tấn công hoặc đánh chặn, chúng có thể ra phát hiện và phản ứng với những rủi ro tiềm tàng. Hơn thế nữa, chúng có thể cung cấp nhận thức thông minh tức thời cho các cơ cấu chấp hành dựa trên các nền tảng cơ khí, điện tử hoặc sinh học để tạo ra những thực thể có trí thông minh và năng lực hoạt động vượt xa khả năng tưởng tượng của chính giống loài đã tạo ra chúng.

Với tiềm năng ứng dụng to lớn và tác động tới hầu như mọi lĩnh vực của hoạt động con người như vậy, lĩnh vực Thị giác máy đòi hỏi nguồn nhân lực có chuyên môn sâu ngày càng lớn để đáp ứng nhu cầu thực tiễn đang gia tăng. Nhiều cơ sở giáo dục đã bổ sung môn học Thị giác máy vào chương trình đào tạo đại học và sau đại học. Tuy nhiên, việc thiếu nguồn học liệu trong nước tạo ra khó khăn trong quá trình đào tạo và ảnh hưởng ít nhiều tới chất lượng đào tạo.

Nhiều người học hoặc kỹ sư công nghệ thường đồng nhất các khái niệm của các môn học *Thị giác máy* và *Xử lý ảnh*. Mặc dù có những mảng kiến thức chung giữa hai mô học này vì chúng có chung đối tượng nghiên cứu là ảnh số. Tuy nhiên, Xử lý ảnh lấy dữ liệu ảnh số làm trung tâm để phát triển các kỹ thuật phương pháp nhằm tác động và biến đổi ảnh cho một mục đích cụ thể ví dụ khử nhiễu, tăng cường độ sắc nét, ... Trong khi đó, Thị giác máy coi thông tin và tri thức chứa đựng trong ảnh là đối tượng nghiên cứu để phát triển các phương pháp, kỹ thuật nhằm rích rút, liên hệ, suy luận ... để thực hiện các chức năng nhận thức cấp cao khác. Chính cái tên Thị giác máy phần nào đã ngụ ý rằng nó được phát triển để thực hiện các chức năng nhận thức tương tự như Thị giác người, những điều này hoàn toàn không có trong các khái niệm của Xử lý ảnh.

Một vấn đề khác là, nhiều người tìm cách giải quyết các bài toán có yếu tố thị giác máy thuần túy bằng cách áp dụng trực tiếp các phương pháp xử lý, kỹ

thuật phân tích, mô hình học máy lên một loại dữ liệu đa phương tiện được gọi là ảnh. Việc thiếu hụt những kiến thức lý thuyết nền tảng của Thị giác máy khiến họ gặp nhiều khó khăn trong việc tối ưu hóa hệ thống, đặc biệt trong các môi trường ánh sáng không ổn định, đối tượng cần xử lý thay đổi trạng thái, vị trí bất thường... Tóm lại, trong rất nhiều trường hợp các bài toán thị giác máy không thể được giải quyết triệt để chỉ bằng cách áp dụng các công cụ khoa học dữ liệu lên dữ liệu ảnh.

Với kinh nghiệm giảng dạy môn học Thị giác máy hơn 15 năm cùng với kiến thức thu được trong quá trình nghiên cứu và phát triển các phương pháp và ứng dụng thị giác máy hơn 20 năm, tôi đã đúc kết để xuất bản cuốn giáo trình này nhằm trang bị cho người học mảng kiến thức trong lĩnh vực thị giác máy. Cuốn sách dẫn dắt người học từ các nguyên lý cơ bản để giải các bài toán thị giác máy: đặc điểm và nguyên tắc hoạt động tâm sinh lý của hệ thị giác người trong việc chuyển đổi ánh sáng thu nhận được từ mắt thành các khái niệm trong não người; sự liên quan giữa các phương pháp hiển thị hình ảnh và trích rút đặc trưng thị giác từ ảnh với các nguyên tắc hoạt động của thị giác người; kết hợp hiệu quả giữa mô hình học máy cả kinh điển và hiện đại để giải quyết các bài toán thị giác máy.

Cuốn sách bao gồm 5 chương

Chương 1. Giới thiệu các ứng dụng thị giác máy giới thiệu khái niệm thị giác máy, các nhóm bài toán cốt lõi và mối liên hệ giữa thị giác sinh học với thị giác máy. Nội dung làm rõ vai trò của thị giác máy trong việc trích xuất, phân tích và hiểu thông tin từ dữ liệu hình ảnh và video. Chương cũng trình bày tổng quan các ứng dụng tiêu biểu của thị giác máy trong y tế, giao thông, an ninh, môi trường và văn hóa. Qua đó, chương đặt nền tảng bối cảnh ứng dụng cho toàn bộ nội dung sách.

Chương 2. Nhận thức thị giác người tập trung phân tích cơ chế nhận thức thị giác của con người, bắt đầu từ bản chất của ánh sáng và màu sắc đến cấu trúc phân cấp của hệ thị giác. Nội dung trình bày quá trình chuyển đổi ánh sáng thành tín hiệu thần kinh và cách não bộ xử lý các đặc trưng thị giác sơ cấp. Các chức năng thị giác bậc cao được giới thiệu như nền tảng sinh học cho nhiều bài toán thị giác máy. Chương đóng vai trò cầu nối giữa thị giác sinh học và các mô hình thị giác nhân tạo.

Chương 3. Thu nhận và hình thành hình ảnh trình bày các khái niệm cơ bản về ảnh số, quá trình thu nhận ảnh và các phương pháp biểu diễn ảnh trong không gian, thời gian và cường độ. Nội dung bao gồm các dạng dữ liệu thị giác phổ biến như ảnh 2D, ảnh 3D, đám mây điểm và mô hình lưới. Chương cũng giới thiệu chi tiết mô hình camera, các tham số nội tại – ngoại tại và bài toán hiệu chuẩn camera. Đây là nền tảng toán học và hình học cho các thuật toán thị giác máy phía sau.

Chương 4. Thị giác máy kinh điển trình bày các phương pháp thị giác máy kinh điển dựa trên trích rút và phân tích đặc trưng ảnh. Nội dung bao quát các nhóm đặc trưng quan trọng như đặc trưng sơ cấp, hình dạng, kết cấu và đặc trưng dựa trên

230 gradient. Trên cơ sở đó, chương phân tích các bài toán thị giác mức cao như so khớp
231 mô hình, theo dõi đối tượng, căn chỉnh ảnh, phân loại, phát hiện và tái tạo cấu trúc
232 3D. Chương nhấn mạnh vai trò của các phương pháp truyền thống trong việc xây
233 dựng nền tảng lý thuyết cho thị giác máy hiện đại.

234 *Chương 5. Thị giác máy dựa trên học sâu* tập trung vào các kiến trúc chủ đạo như
235 mạng tích chập, vision transformers và các phương pháp huấn luyện mạng sâu.
236 Chương trình bày cách các mô hình học sâu được áp dụng cho từng bài toán thị giác
237 cụ thể, từ phân loại, phát hiện đến tái tạo 3D và sinh ảnh. Cuối chương, khái niệm
238 mô hình nền thị giác được giới thiệu như xu hướng phát triển mới của thị giác máy
239 hiện đại.

240

241 Tác giả

242

243

CHƯƠNG 1. GIỚI THIỆU CÁC ỨNG DỤNG THỊ GIÁC MÁY

Thị giác người mặc dù là một hệ thống cho phép con người nhanh chóng nhận biết vật thể và bối cảnh tổng thể của môi trường xung quanh thông qua khả năng suy luận ngữ cảnh và thích nghi linh hoạt với điều kiện môi trường phức tạp. Tuy nhiên, thị giác người cũng tồn tại nhiều hạn chế như dễ mệt mỏi, chịu ảnh hưởng mạnh bởi cảm xúc chủ quan, khó duy trì độ chính xác cao trong các nhiệm vụ lặp đi lặp lại, tốc độ xử lý và ghi nhớ chi tiết hạn chế và bị giới hạn tầm nhìn cả về không gian và dải phổ ánh sáng có thể nhìn thấy. Những điểm yếu này đang dần được khắc phục và thay thế bởi các phương pháp thị giác máy.

1.1. Thị giác máy và các bài toán thị giác máy

1.1.1. Thị giác máy là gì?

Thị giác máy (computer vision) là một lĩnh vực nghiên cứu nhằm phát triển các mô hình toán học, thuật toán và hệ thống tính toán cho phép máy tính tự động suy diễn thông tin có ý nghĩa từ dữ liệu hình ảnh bao gồm ảnh tĩnh và ảnh động (video). Với khả năng xử lý khối lượng lớn dữ liệu ảnh–video với độ chính xác ổn định, làm việc liên tục, mở rộng sang nhiều dải phổ (hồng ngoại, X-quang, radar...), thị giác máy ngày càng tiệm cận khả năng nhận thức ở mức cao. Tuy nhiên, thị giác máy không phải là vấn đề dễ giải vì đây là bài toán nghịch đảo (inverse problem), trong đó ta phải tìm cách khôi phục các đại lượng như liên quan vật thể và bối cảnh của môi trường thông qua một số phép đo rất hạn chế (ảnh hoặc video). Do đó, ta buộc phải dựa vào các mô hình vật lý, xác suất, học máy, ... được xây dựng dựa trên các quan sát hoặc phân tích các bộ/mẫu dữ liệu cho trước để giải đoán/dự đoán các nghiệm khả dĩ.

1.1.2. Các bài toán thị giác máy

Các bài toán trong thị giác máy rất đa dạng nhưng có thể quy về một số nhóm tiêu biểu, phản ánh những mức độ và chức năng khác nhau cũng như khả năng áp dụng vào những ứng dụng thực tiễn. Một số nhóm bài toán tiêu biểu trong thị giác máy bao gồm:

Sơ khớp mô hình nhận đầu vào là các đặc trưng của ảnh như điểm ảnh, điểm cạnh, điểm biên, ... cùng với một mô hình giản lược nhằm mô tả mối liên hệ giữa các đặc trưng và cho đầu ra là một bộ tham số của mô hình phù hợp nhất với dữ

liệu. Khó khăn thường gặp với các bài toán so khớp mô hình là dữ liệu thường có nhiều, mô hình quá giản lược khó áp dụng trong thực tiễn.

Theo dõi đối tượng nhận đầu vào một chuỗi ảnh hoặc video cùng với thông tin vị trí của một vùng hoặc mối đối tượng cần theo dõi và cho đầu ra là quỹ đạo (vị trí) của đối tượng theo thời gian. Khó khăn gặp phải với các bài toán theo dõi đối tượng là đối tượng có chuyển động phức tạp, thay đổi hình dạng khi di chuyển, nhiều dữ liệu hoặc đối tượng bị che khuất trong một khoảng thời gian dài.

Căn chỉnh ảnh nhận đầu vào hai hoặc nhiều ảnh được chụp ở một khung cảnh trong thời gian, vị trí khác nhau và cho đầu ra là phép biến đổi hình học đưa các ảnh về cùng một hệ tọa độ. Một ứng dụng thường thấy của bài toán căn chỉnh ảnh là ảnh panorama. Khó khăn thường thấy của các bài toán căn chỉnh ảnh là sự thay đổi của khung cảnh, ánh sáng giữa các lần chụp, vị trí giữa các khung hình cũng như sự biến dạng phức tạp cũng như thiếu đặc trưng kết cấu ổn định để ước lượng được chính xác phép biến đổi hình học.

Phân loại ảnh nhận đầu vào là một hoặc nhiều ảnh và cho đầu ra là nhãn lớp biểu diễn nội dung của ảnh. Khó khăn chính của các bài toán phân loại ảnh một mặt là sự đa dạng rất lớn của các ảnh trong cùng một lớp và mặt khác là các ảnh thuộc các lớp khác nhau có sự tương đồng. Bên cạnh đó nhiều nền (không thuộc đối tượng của nhãn) và lượng dữ liệu huấn luyện lớn cũng là những thách thức.

Phát hiện và nhận dạng đối tượng nhận đầu vào là ảnh cho đầu ra là vị trí và nhãn của đối tượng xuất hiện trong ảnh. Khó khăn của các bài toán thuộc nhóm này là ảnh thường chứa nhiều đối tượng với kích thước khác nhau, các đối tượng có thể chồng lấp, che khuất lẫn nhau.

Tái tạo cấu trúc 3D nhận đầu vào là một hoặc nhiều ảnh của cùng một cảnh và cho đầu ra là mô hình 3D của cảnh hoặc đối tượng. Khó khăn chính đến từ chính bản chất của bài toán, đây là bài toán nghịch đảo thiếu thông tin. Bên cạnh đó, các nền, nhiều so khớp/đo đạc và sự che khuất các thành phần của đối tượng cũng là những khó khăn lớn mà nhóm bài toán này cần giải quyết.

1.1.3. Thị giác sinh học và thị giác máy

Thị giác sinh học là nguồn cảm hứng cho sự ra đời và phát triển của thị giác máy, bắt nguồn từ việc nghiên cứu cách hệ thống thị giác của con người và động vật tiếp nhận, xử lý và diễn giải thông tin hình ảnh thông qua từng tầng, từ phát hiện tín hiệu cục bộ, trích lọc đặc trưng, đến tích hợp ngữ cảnh và suy luận ở mức cao. Việc hiểu một cách xuyên suốt thông tin thị giác được xử lý từ võng mạc, vỏ não thị giác sơ cấp đến các vùng nhận thức bậc cao cung cấp một khuôn khổ tự nhiên để liên hệ tới các kỹ thuật *thị giác máy kinh điển* và *thị giác máy dựa trên học sâu*.

Thị giác máy kinh điển hình thành với các mô hình toán học và hình học trực quan, tập trung vào thiết kế thủ công các đặc trưng, quy tắc và thuật toán nhằm mô phỏng từng bước xử lý thị giác, như phát hiện biên, trích xuất đặc trưng và suy luận

hình học. Cách tiếp cận này dựa trên giả thiết rằng cấu trúc của thế giới thị giác có thể được suy luận từ ảnh thông qua việc thiết kế thủ công các đặc trưng và thuật toán xử lý từng bước, chẳng hạn như phát hiện biên, trích xuất điểm đặc trưng, so khớp và suy luận. Các phương thị giác máy pháp kinh điển thường nhấn mạnh tính diễn giải và sự hiểu biết rõ ràng về mối quan hệ giữa đầu vào và đầu ra, đóng vai trò nền tảng cho nhiều bài toán quan trọng như căn chỉnh ảnh, theo dõi đối tượng, định vị và tái tạo cấu trúc 3D. Mặc dù gặp hạn chế trong các bài toán ngữ nghĩa phức tạp, thị giác máy kinh điển vẫn giữ vai trò cốt lõi trong việc cung cấp cơ sở lý thuyết và thuật toán cho các hệ thống thị giác hiện đại.

Thị giác máy dựa trên học sâu là bước phát triển tiếp theo của thị giác máy, kế thừa và mở rộng các nguyên lý cốt lõi của thị giác máy kinh điển trong bối cảnh dữ liệu lớn và năng lực tính toán mạnh. Thay vì thiết kế thủ công các đặc trưng và quy tắc xử lý, các mô hình học sâu học trực tiếp biểu diễn đặc trưng và mối quan hệ từ dữ liệu thông qua các kiến trúc mạng nơ-ron nhiều tầng, đặc biệt là mạng tích chập và các mô hình transformer. Tuy khác biệt về phương pháp tiếp cận, thị giác máy học sâu vẫn phản ánh nhiều ý tưởng nền tảng của thị giác máy kinh điển như xử lý phân cấp, tính bất biến theo dịch chuyển và tỉ lệ, cũng như sự kết hợp giữa thông tin cục bộ và toàn cục. Sự chuyển dịch từ mô hình hóa tường minh sang học biểu diễn đã giúp thị giác máy đạt được những bước tiến vượt bậc trong các bài toán ngữ nghĩa phức tạp, đồng thời làm rõ mối quan hệ giữa các phương pháp kinh điển và học sâu trong các hệ thống thị giác hiện đại.



Hình 1.1. Thị giác máy và Trí tuệ nhân tạo.


1.2. Một số ứng dụng thực tiễn của thị giác máy

Dựa trên sơ đồ Hình 1.1, có thể thấy dữ liệu và các mô hình học máy giữ vai trò trung tâm, là nền tảng cốt lõi cho mọi ứng dụng thực tiễn của thị giác máy. Từ

dữ liệu ảnh, video được các mô hình học máy và học sâu học biểu diễn thành các đặc trưng cho phép hệ thống thực hiện các tác vụ như nhận dạng, phân tích, suy luận và ra quyết định. Từ đó, thị giác máy được tích hợp vào nhiều lĩnh vực quan trọng: y tế (hỗ trợ chẩn đoán hình ảnh, phát hiện bệnh), giao thông (giám sát, phát hiện sự cố, xe tự hành), an ninh – quốc phòng (giám sát thông minh, nhận dạng), tài chính (xác thực sinh trắc, phát hiện gian lận), giáo dục (phân tích hành vi học tập, lớp học thông minh), môi trường (giám sát biến đổi, phát hiện ô nhiễm), văn hóa – du lịch và nhân văn (số hóa di sản, phân tích tư liệu), cũng như các hệ thống tự động hóa và robot. Như vậy, chính sự kết hợp chặt chẽ giữa dữ liệu quy mô lớn, mô hình học máy và quy trình xử lý tự động đã tạo nên sức lan tỏa của thị giác máy, biến tri thức thị giác thành giá trị ứng dụng cụ thể trong đời sống và xã hội.

1.2.1. Y tế

Chẩn đoán hình ảnh là một trong những trụ cột quan trọng của y học hiện đại liên quan mật thiết đến các kỹ thuật như X-quang, CT, MRI và siêu âm. Trong thực tế lâm sàng, bác sĩ phải xử lý khối lượng lớn ảnh y khoa với yêu cầu cao về độ chính xác, tính nhất quán và tốc độ ra quyết định. Đối với ảnh X-quang ngực, việc phát hiện sớm các tổn thương như viêm phổi, xơ phổi hay nốt bất thường là nhiệm vụ thường xuyên nhưng chịu ảnh hưởng mạnh bởi: Kinh nghiệm bác sĩ, chất lượng ảnh và số lượng bệnh nhân trong bệnh viện. Ở đây, thị giác máy được ứng dụng nhằm hỗ trợ chẩn đoán, cung cấp công cụ phân tích tự động, giúp giảm tải cho bác sĩ và tăng khả năng phát hiện sớm.




Hình 1.2. Thị giác máy trong một ứng dụng y tế.

Hình 1.2 mô tả luồng thông tin khi áp dụng thị giác máy cho một ứng dụng chẩn đoán hình ảnh y tế trong thực tế. Trong đó ảnh đầu vào được đưa vào khối Phân loại ảnh nhằm xác định loại ảnh. Nếu nội dung ảnh này thuộc nhóm ảnh X-Quang phổi thì được chuyển sang khối Phát hiện/nhận dạng vùng tổn thương. Khối này thực hiện phân tích và trích rút thông tin từ ảnh để biết được vị trí vùng tổn thương và giải đoán được loại tổn thương phổi có thể có trong ảnh.

1.2.2. Giao thông

Trong các đô thị lớn, bài toán quản lý giao thông (để giảm thiểu ùn tắc và tai nạn) đặt ra yêu cầu cấp thiết về các hệ thống giám sát tự động. Các camera giao thông được lắp đặt rộng rãi, tạo ra dòng dữ liệu video liên tục, vượt quá khả năng phân tích thủ công của con người. Thị giác máy có thể hỗ trợ trong quản lý giao thông bao gồm: tự động phát hiện loại và đếm phương tiện; theo dõi chuyển động

phương tiện theo thời gian; ước lượng mật độ, tốc độ; phát hiện bất thường; ... Từ đó hỗ trợ điều khiển đèn tín hiệu, quản lý luồng xe và nâng cao an toàn giao thông.



Hình 1.3. Thị giác máy trong giao thông.

Hình 1.3 cho thấy luồng thông tin của khi áp dụng thị giác máy cho bài toán theo dõi đường chuyển động của phương tiện giao thông dựa trên camera quan sát. Đầu vào là một chuỗi ảnh được thu nhận từ một camera cố định trên cao. Từng khung hình được đưa qua khối Phát hiện đối tượng để xác định vị trí của một phương tiện. Chuỗi ảnh cùng với mỗi vị trí khởi đầu của mỗi phương tiện được đưa qua khối theo dõi đối tượng giúp xác định được hướng và vận tốc di chuyển của từng phương tiện.

1.2.3. An ninh

Đô thị hóa làm gia tăng các rủi ro về an ninh, trật tự xã hội. Hệ thống camera giám sát (closed-circuit television – CCTV) đã được triển khai rộng rãi tại: sân bay, nhà ga; khu dân cư, trung tâm thương mại; cơ quan, khu vực trọng yếu;... Tuy nhiên, lượng video thu thập được là rất lớn và liên tục, khiến việc giám sát thủ công gần như bất khả thi. Bài toán đặt ra là cần các hệ thống tự động phát hiện, nhận dạng và theo dõi tự động để hỗ trợ lực lượng an ninh trong: phát hiện đối tượng khả nghi; truy vết sau sự cố; cảnh báo sớm hành vi bất thường,... Ở đây, thị giác máy đóng vai trò hạ tầng trí tuệ cốt lõi cho các hệ thống an ninh thông minh.




Hình 1.4. Thị giác máy trong an ninh.

Hình 1.4 là luồng thông tin ứng dụng Thị giác máy trong an ninh đô thị. Trong đó, chuỗi ảnh từ camera quan sát ban đêm được đưa qua khối Phát hiện đối tượng. Phạm vi về không gian cảnh báo thâm nhập được xác định bởi đường màu đỏ trên hình. Nếu có một đối tượng (người/vật) khả nghi xuất hiện trong phạm vi trên, hệ thống tự động ra tín hiệu cảnh báo bằng cách bật đèn, kêu chuông hoặc thông báo tới chủ nhà.

1.2.4. Môi trường và tài nguyên thiên nhiên

Đất đai và tài nguyên thiên nhiên (nước, rừng, ...) đóng vai trò sống còn đối với phát triển kinh tế – xã hội. Tuy nhiên, đô thị hóa và các hiện tượng tự nhiên cực đoan đang gây ra những biến động mạnh mẽ về diện tích đất, nước, rừng, ... Việc giám sát truyền thống (đo đạc tại chỗ) gặp hạn chế về chi phí, độ phủ không gian và tần suất. Ở đây, các công nghệ viễn thám và ảnh thám không kết hợp với thị giác máy cho phép: quan sát tài nguyên trên diện rộng; theo dõi biến động dài hạn theo thời gian; ... để cung cấp dữ liệu định lượng cho các đơn vị quản lý.




Hình 1.5. Thị giác máy trong quản lý đất đai.

Hình 1.5 cho thấy một ví dụ đơn giản của thị giác máy trong hỗ trợ công tác quản lý đất đai. Đầu vào là 2 ảnh viễn thám được chụp ở khoảng thời gian khác nhau được đưa vào khối Căn chỉnh ảnh. Do hai ảnh được chụp ở khoảng thời gian khác nhau, ở vị trí cảm biến khác nhau nên khối Căn chỉnh ảnh cần thực hiện thuật toán nhằm căn chỉnh (align) một ảnh theo tọa độ của ảnh còn lại. Sự biến động bề mặt đất (vùng được tô màu xanh dương) được xác định bằng cách so sánh trực tiếp hai ảnh sau khi đã được căn chỉnh.

1.2.5. Văn hóa

Di sản văn hóa vật thể như công trình kiến trúc, tượng điêu khắc, phù điêu, bia đá hay mộc bản mang giá trị lịch sử, nghệ thuật và khoa học đặc biệt. Tuy nhiên, dưới tác động của thời gian, điều kiện môi trường, thiên tai và các yếu tố con người, nhiều di sản đang dần xuống cấp, hư hỏng hoặc có nguy cơ biến mất vĩnh viễn. Các phương pháp bảo tồn truyền thống, chủ yếu dựa trên tư liệu 2D và đo đạc thủ công,

khó có khả năng lưu giữ đầy đủ hình dạng không gian và các chi tiết hình học tinh vi của hiện vật. Do đó, việc ứng dụng thị giác máy cho phép khôi phục và số hóa di sản dưới dạng mô hình 3D có độ chính xác cao, tạo ra một phương thức bảo tồn không xâm lấn, có khả năng lưu trữ lâu dài, hỗ trợ nghiên cứu, phục dựng và phổ biến giá trị di sản trong giáo dục và trưng bày số.



Hình 1.6. Thị giác máy trong bảo tồn văn hóa.

Hình 1.6 là một ví dụ của ứng dụng thị giác máy trong bảo tồn văn hóa. Trong đó các hình ảnh chụp của một vật thể hình khối (được đưa vào khối Tái tạo cấu trúc 3D và thu được một mô hình 3D của vật thể. Mô hình 3D hoàn chỉnh vừa bảo toàn hình dạng không gian vừa giữ được đặc trưng thị giác của vật thể phục vụ lưu trữ, phân tích và trực quan hóa.

Kết chương

Chương này đã giới thiệu những khái niệm và nội dung cơ bản của thị giác máy, bao gồm các bài toán thị giác máy tiêu biểu và mối liên hệ với thị giác sinh học, đồng thời minh họa vai trò của thị giác máy thông qua một số ứng dụng thực tiễn tiêu biểu trong y tế, giao thông, an ninh, môi trường – tài nguyên thiên nhiên và văn hóa. Qua đó, chương giúp người học hình thành cái nhìn tổng quan về phạm vi, ý nghĩa và tiềm năng ứng dụng của thị giác máy trong các hệ thống thông minh hiện đại. Những nội dung này đóng vai trò nền tảng, tạo tiền đề cho việc nghiên cứu sâu hơn các phương pháp và kỹ thuật thị giác máy sẽ được trình bày trong các chương tiếp theo.

Chức năng nhận thức của hệ thị giác người là tiếp nhận và chuyển đổi một phần dải sóng điện từ, hay ánh sáng, thành thông tin có ý nghĩa, phục vụ cho sự tồn tại, sinh sản và các hoạt động nhận thức của con người. Khi ánh sáng đi vào mắt, nó kích thích các tế bào thụ cảm trên võng mạc, làm phát sinh các tín hiệu thần kinh. Những tín hiệu này được truyền qua các lớp tế bào trung gian và tiếp tục dẫn lên các trung tâm xử lý của hệ thần kinh thị giác. Trên cơ sở thông tin thu nhận từ ánh sáng, hệ thần kinh thực hiện các quá trình phân tích, suy luận và ra quyết định. Ở mỗi giai đoạn xử lý, thông tin thị giác được biểu diễn ở mức độ trừu tượng ngày càng cao, đồng thời ngày càng phù hợp và hữu ích hơn đối với cá thể sinh học.


Chương này trình bày khái quát về bản chất của ánh sáng, các nguồn phát sáng, cơ chế thu nhận ánh sáng của mắt người, cũng như quá trình ánh sáng được từng bước chuyển hóa thành thông tin trong hệ thị giác thông qua các giai đoạn xử lý khác nhau.

2.1. Ánh sáng và màu sắc

2.1.1. Ánh sáng là gì?

Từ khoảng thế kỷ V trước Công nguyên, các triết gia Hy Lạp cổ đại đã bắt đầu nhận thấy mối liên hệ giữa mắt người và các sự vật trong môi trường xung quanh. Một số học giả thời kỳ này cho rằng quá trình nhìn xảy ra do mắt phát ra một dạng “lửa” hay dòng năng lượng nào đó truyền tới các vật thể và cảm nhận chúng. Tuy nhiên, đến thế kỷ IV trước Công nguyên, Aristotle đã bác bỏ quan điểm này bằng lập luận nổi tiếng rằng: nếu thị giác được hình thành từ việc mắt phát ra lửa giống như ánh sáng từ một chiếc đèn lồng, thì con người đã có thể nhìn thấy trong bóng tối.

Bước tiến quan trọng tiếp theo xuất hiện vào khoảng thế kỷ XI sau Công nguyên, khi Alhazen – nhà vật lý học người Ả Rập – khẳng định rằng thị giác hình thành nhờ ánh sáng truyền từ các vật thể tới mắt người, chứ không phải theo chiều ngược lại. Đến năm 1604, Johannes Kepler đã hoàn thiện mô hình thị giác mà đến nay vẫn được chấp nhận rộng rãi: ánh sáng được phát ra từ các nguồn sáng, sau đó bị phản xạ hoặc khúc xạ bởi bề mặt các vật thể trước khi đi vào mắt người (Kepler 1604). Theo quan điểm này, ánh sáng phát ra từ nguồn sáng về bản chất là không mang màu sắc, và màu sắc chỉ xuất hiện khi ánh sáng tương tác với bề mặt của các đối tượng khác nhau.




Hình 2.1. Thí nghiệm ánh sáng của Newton.

Nhiều thập kỷ sau đó, Isaac Newton đã thực hiện một thí nghiệm kinh điển giúp làm sáng tỏ bản chất của ánh sáng. Trong một căn phòng tối, ông cho ánh sáng Mặt Trời đi qua một khe hẹp rồi truyền qua lăng kính và quan sát thấy ánh sáng trắng bị tách thành một dải liên tục gồm nhiều màu sắc khác nhau (Hình 2.1). Đặc biệt, mỗi ánh sáng màu thu được không thể tiếp tục bị phân tách thành các màu khác khi đi qua thêm lăng kính khác. Từ các quan sát này, Newton cho rằng ánh sáng có những đặc điểm riêng biệt so với sóng thông thường, do nó không bị uốn cong quanh vật cản như sóng âm hay sóng nước. Vì vậy, trong công trình công bố năm 1704, ông đã ủng hộ quan điểm ánh sáng là dòng các hạt, với các màu sắc khác nhau tương ứng với các hạt có tính chất khác nhau (Newton 1704).

Khoảng một thế kỷ sau, Thomas Young đã đưa ra những bằng chứng thuyết phục cho bản chất sóng của ánh sáng thông qua các hiện tượng giao thoa và phản xạ trên các lớp nước hoặc dầu mỏng (Young 1804). Đến giữa thế kỷ XIX, cùng với nhiều kết quả thực nghiệm khác, quan điểm coi ánh sáng là một dạng sóng đã được cộng đồng khoa học rộng rãi chấp nhận.

Một câu hỏi nền tảng khác, có vai trò quan trọng trong việc hiểu bản chất của thị giác, là: “Ánh sáng được tạo ra từ đâu?”. Câu hỏi này chỉ được giải thích một cách thuyết phục vào thế kỷ XIX, khi nhà vật lý lý thuyết James Clerk Maxwell đề xuất rằng ánh sáng thực chất chỉ là một phần rất nhỏ trong một dải liên tục rộng lớn hơn nhiều, được gọi là phổ bức xạ điện từ (Maxwell, 1865). Theo đó, tất cả các dạng bức xạ điện từ — bao gồm tia gamma, tia X, tia tử ngoại, ánh sáng, tia hồng ngoại và sóng vi ba — đều có cùng bản chất vật lý và lan truyền trong môi trường chân không với cùng một vận tốc, xấp xỉ 299 792 458 mét mỗi giây. Do đó, ánh sáng không có sự khác biệt cơ bản nào về mặt vật lý so với các thành phần còn lại của phổ bức xạ điện từ; sự khác biệt chủ yếu nằm ở khả năng cảm nhận của hệ thị giác con người.

Cụ thể, mắt người chỉ có thể đáp ứng với các bức xạ điện từ có bước sóng nằm trong khoảng xấp xỉ 370 nm đến 730 nm. Dải bước sóng này được gọi là ánh sáng nhìn thấy, hay vùng khả kiến của phổ điện từ. Các bức xạ nằm ngoài khoảng này, dù vẫn tồn tại và mang năng lượng, không thể được con người cảm nhận trực tiếp bằng thị giác. Minh họa trực quan cho mối quan hệ giữa ánh sáng nhìn thấy và toàn bộ phổ bức xạ điện từ được trình bày trong Hình 2.2.




Hình 2.2. Phổ bức xạ điện từ.

2.1.2. Nguồn phát sáng

Bức xạ điện từ được phát ra khi các hạt tích điện, chủ yếu là electron, chuyển động hoặc thay đổi trạng thái năng lượng. Dựa trên cơ chế này, các nguồn phát sáng nhân tạo được chia thành hai nhóm chính: *phát sáng nhiệt* (incandescence) và *phát quang* (luminescence). Hai loại nguồn sáng này có đặc trưng phổ khác nhau, từ đó ảnh hưởng trực tiếp đến đặc tính phản xạ của vật chất và tín hiệu ánh sáng thu nhận được. Vì vậy, việc hiểu rõ bản chất của nguồn chiếu sáng là cơ sở quan trọng để phân tích và đánh giá tác động của chúng đối với hệ thị giác người cũng như các hệ thống thị giác máy.

2.1.2.1. Phát sáng nhiệt



Hình 2.3. Quang phổ của ánh sáng mặt trời (a) và của đèn sợi tóc (b).


Phát sáng nhiệt (incandescence) dựa trên hiện tượng bức xạ điện từ sinh ra từ chuyển động nhiệt của các hạt tích điện trong vật chất. Ở nhiệt độ phòng, phần lớn bức xạ này nằm trong dải hồng ngoại (infrared), khi vật chất bị nung nóng đến khoảng trên 525°C , phổ phát xạ bắt đầu mở rộng sang vùng ánh sáng nhìn thấy.

Trong tự nhiên, các nguồn phát sáng nhiệt dễ thấy nhất là Mặt Trời và lửa, trong khi đó, nguồn nhân tạo điển hình là bóng đèn sợi đốt. Đèn sợi đốt sử dụng dòng điện để làm nóng sợi filament (một sợi kim loại mảnh) đến nhiệt độ cao, khiến nó phát sáng. Nhờ cấu tạo đơn giản và chi phí thấp, đèn sợi đốt từng được sử dụng rộng rãi. Tuy nhiên, hiệu suất phát sáng rất thấp: chỉ dưới 5% năng lượng điện được chuyển hóa thành ánh sáng, phần còn lại thất thoát dưới dạng nhiệt. Ánh sáng phát ra từ đèn sợi đốt có phổ liên tục, bao gồm nhiều bước sóng khác nhau (Hình 2.3(b)), tạo cảm giác gần với ánh sáng tự nhiên của Mặt Trời (Hình 2.3(a)). Dù vậy, do khó kiểm soát phổ phát xạ và hiệu năng kém, đèn sợi đốt đã dần được thay thế bởi các nguồn sáng khác có hiệu suất cao hơn và dễ điều chỉnh màu sắc.

2.1.2.2. Phát quang

Phát quang (luminescence) là hiện tượng phát xạ bức xạ điện từ do electron chuyển dịch giữa các mức năng lượng khác nhau trong nguyên tử hoặc phân tử, sau khi được kích thích bởi các tác nhân bên ngoài. Cơ chế phát xạ này cho phép các nguồn sáng phát quang có hiệu suất phát sáng cao, ít sinh nhiệt, và tuổi thọ lớn. Đặc biệt, bước sóng phát xạ có thể được lựa chọn và điều chỉnh thông qua thành phần và tỷ lệ các hợp chất phát quang được pha trộn, cho phép tạo ra ánh sáng với màu sắc mong muốn một cách linh hoạt.

Những ưu điểm này khiến các nguồn sáng phát quang dần thay thế các nguồn phát sáng nhiệt trong cả dân dụng lẫn công nghiệp. Trong các phần tiếp theo, chúng ta sẽ xem xét một số loại nguồn sáng phát quang tiêu biểu đã và đang được sử dụng rộng rãi trong thực tiễn.



Hình 2.4. Quang phổ của đèn huỳnh quang.

A) Đèn huỳnh quang

Huỳnh quang (fluorescence) là một dạng phát quang trong đó electron hấp thụ một photon, chuyển lên mức năng lượng cao, rồi nhanh chóng trở về mức thấp hơn bằng cách phát xạ một photon khác. Thông thường, bước sóng photon phát xạ


dài hơn bước sóng photon kích thích do có sự hao hụt năng lượng trong quá trình chuyển mức.

Đèn huỳnh quang, thường có dạng ống, chứa khí trơ và hơi thủy ngân ở áp suất thấp, với lớp phủ huỳnh quang ở mặt trong. Khi hoạt động, nguyên tử thủy ngân phát xạ tia tử ngoại (UV); bức xạ này được lớp huỳnh quang hấp thụ và chuyển đổi thành ánh sáng nhìn thấy. So với đèn sợi đốt, đèn huỳnh quang có hiệu suất cao hơn khoảng bốn lần và tuổi thọ lớn hơn từ 10 đến 20 lần. Về phổ phát xạ, đèn sợi đốt có phổ liên tục, trải rộng, trong khi đèn huỳnh quang có phổ gồm một số đỉnh hẹp (xem Hình 2.4).

B) Màn hình CRT

Phát quang âm cực (cathodoluminescence) là hiện tượng phát quang xảy ra khi chùm electron năng lượng cao va chạm vào vật liệu phát quang (ví dụ các hợp chất photpho), khiến vật liệu này phát xạ photon trong vùng ánh sáng nhìn thấy. Bước sóng phát xạ có thể được điều chỉnh thông qua việc lựa chọn hợp chất photpho phù hợp.

Ứng dụng điển hình của cơ chế này là màn hình CRT (cathode-ray tube). Trong hệ thống CRT, ống phóng tia âm cực tạo ra chùm electron và các trường điện-từ được dùng để điều khiển, quét chùm tia này tới từng vị trí trên màn hình phủ lớp photpho. Bằng cách lựa chọn các vật liệu photpho phát xạ tương ứng với ba màu cơ bản *red*, *green* và *blue*, hệ thống có thể tổng hợp màu và tạo nên màn hình màu.




Hình 2.5. Quang phổ của Led đơn sắc (a) và Led trắng (b).

C) Điốt phát sáng LED

Điốt phát sáng (light emitting diode – LED) là một thiết bị bán dẫn phát ra ánh sáng khi có dòng điện chạy qua. Về nguyên lý, dòng điện kích thích electron chuyển dịch giữa các dải năng lượng trong vật liệu bán dẫn, tạo ra các lỗ trống. Khi electron tái hợp với lỗ trống ở mức năng lượng thấp hơn, năng lượng dư thừa được giải phóng dưới dạng một photon. Do đó, bước sóng của ánh sáng phát ra phụ thuộc trực tiếp vào độ rộng vùng cấm năng lượng của vật liệu bán dẫn.

Tùy theo vật liệu và điện áp làm việc, LED có thể phát xạ tia hồng ngoại gần (NIR), ánh sáng nhìn thấy, hoặc tia cực tím; phổ phát xạ của LED đơn sắc được minh họa trong Hình 2.5(a). LED ánh sáng trắng có thể được tạo ra theo hai cách: kết hợp các LED đơn sắc (red, green, blue) hoặc sử dụng lớp huỳnh quang chuyển đổi bức xạ từ LED (thường là xanh lam hoặc cực tím) thành ánh sáng trắng, như minh họa trong Hình 2.5(b).

2.1.3. Màu sắc



Hình 2.6. Mắt người nhìn thấy màu sắc của một vật thể.

Ánh sáng với quang phổ xác định được phát ra từ nguồn sáng, lan truyền trong không gian và tương tác với bề mặt vật thể. Tùy thuộc vào tính chất vật lý, hóa học và cấu trúc bề mặt tại vị trí chiếu sáng, bức xạ tới có thể truyền qua, bị hấp thụ hoặc phản xạ trở lại môi trường xung quanh (xem Hình 2.6). Ánh sáng phản xạ có thể chứa một phần hoặc toàn bộ các thành phần phổ của ánh sáng tới. Hệ thị giác người tiếp nhận một phần ánh sáng phản xạ này, chuyển đổi thành tín hiệu điện-thần kinh, truyền tới trung tâm xử lý thị giác và từ đó hình thành cảm nhận màu sắc của vật thể. Do vậy, màu sắc được cảm nhận không chỉ phụ thuộc vào đặc tính phản xạ của bề mặt vật thể, mà còn phụ thuộc chặt chẽ vào quang phổ của nguồn chiếu sáng. Hệ quả là cùng một vật thể có thể được cảm nhận với những màu sắc khác nhau khi đặt trong các điều kiện chiếu sáng khác nhau.

2.1.3.1. Màu sắc là một cảm giác

Mặc dù nhận thấy rằng các bước sóng khác nhau có thể tạo ra những cảm nhận màu khác nhau trong thị giác người nhưng các kết quả thực nghiệm cho thấy chỉ riêng bước sóng ánh sáng là chưa đủ để mô tả một cách đầy đủ nhận thức màu sắc của con người. Quay lại với thí nghiệm lăng kính Newton. Khi đi qua lăng kính, ánh sáng trắng bị phân tách thành một dải màu liên tục giống cầu vồng. Các màu này không thể tiếp tục phân rã thành những màu đơn giản hơn nên Newton đã đặt tên theo thứ tự: *red* (đỏ), *orange* (cam), *yellow* (vàng), *green* (lục), *blue* (lam), *indigo* (chàm) và *violet* (tím).

Bằng thực nghiệm, có thể tạo ra ánh sáng màu cam theo hai cách khác nhau: (i) sử dụng ánh sáng cam đơn sắc tương ứng với một bước sóng xác định trong phổ nhìn thấy, hoặc (ii) phối trộn ánh sáng đỏ và ánh sáng vàng. Mặc dù cả hai cách đều

tạo ra cảm nhận màu cam giống nhau trong não người, nhưng bản chất vật lý của chúng là khác nhau. Cụ thể, ánh sáng cam đơn sắc khi đi qua lăng kính vẫn giữ nguyên màu cam, trong khi ánh sáng cam được tạo bởi phối trộn sẽ bị phân tách thành các thành phần đỏ và vàng.

Một ví dụ khác là màu cánh sen (*magenta*), có thể được tạo ra bằng cách phối trộn ánh sáng đỏ và ánh sáng tím. Đáng chú ý, không tồn tại bước sóng đơn sắc nào trong phổ điện từ tương ứng với màu magenta. Màu này chỉ xuất hiện trong cảm nhận thị giác như là kết quả của sự phối hợp các kích thích màu khác nhau, chứ không phải từ một thành phần phổ riêng biệt. Điều này cho thấy nhận thức màu sắc của con người không chỉ phụ thuộc vào bước sóng ánh sáng, mà còn phụ thuộc vào cơ chế xử lý của hệ thị giác.

2.1.3.2. Bộ màu cơ bản

Từ những quan sát trên có thể thấy một số màu có thể được tạo ra bằng cách phối trộn hợp lý các màu khác, trong khi một số màu không thể thu được từ phép phối trộn, mà ngược lại được dùng làm cơ sở để tạo ra các màu còn lại. Tập hợp các màu có vai trò nền tảng này được gọi là bộ màu cơ bản (*primary colors*). Tùy theo nguyên lý tạo màu và bối cảnh ứng dụng, người ta sử dụng những bộ màu cơ bản khác nhau. Chẳng hạn, bộ (*red, green, blue*) thường được dùng trong các hệ thống phát sáng và hiển thị, trong khi bộ (*cyan, magenta, yellow*) được sử dụng phổ biến trong in ấn và tái tạo màu bằng mực. Việc lựa chọn bộ màu cơ bản phù hợp đóng vai trò then chốt trong thiết kế và phân tích các hệ thống xử lý màu cho cả thị giác người và thị giác máy.


2.2 Cấu trúc phân cấp của nhận thức thị giác của người

Khoa học thần kinh đã có nhiều nghiên cứu nhằm làm rõ cách thức não người xử lý thông tin thị giác. Cho đến nay, một trong những khung lý thuyết được chấp nhận rộng rãi là lý thuyết *luồng thị giác* (*visual streams*) do Melvyn A. Goodale và David A. Milner đề xuất (1992). Lý thuyết này cho rằng các chức năng thị giác được phân công và xử lý tại những vùng khác nhau của vỏ não, thay vì tập trung tại một khu vực duy nhất.

Quá trình xử lý thị giác bắt đầu khi ánh sáng đi vào mắt, được thủy tinh thể hội tụ và tạo ảnh trên võng mạc. Tại đây, các *thụ thể ánh sáng* (*photoreceptor*) chuyển đổi tín hiệu quang học thành tín hiệu điện-thần kinh. Những xử lý thị giác cơ bản nhất đã được thực hiện ngay ở mức này, bao gồm tách *độ sáng* và *sắc độ*, phát hiện biên/cạnh (chưa gán hướng), trước khi thông tin được truyền lên các cấu trúc não cao hơn thuộc vỏ não thị giác.

Trên đường dẫn từ võng mạc tới vùng xử lý thị giác trung ương, khoảng 80% tín hiệu được chuyển tới *nhân gối bên* (*lateral geniculate nucleus – LGN*), trong khi 20% còn lại đi tới *đồi thị trên* (*superior colliculus – SC*) (Erika, 2016). SC chủ yếu đảm

nhiệm vai trò định hướng vận động mắt và chú ý thị giác, còn LGN hoạt động như một trạm trung chuyển, tổ chức và điều phối thông tin thị giác trước khi truyền tới vùng *thị giác sơ cấp* (primary visual cortex – V1). Sơ đồ các đường dẫn này được minh họa trong Hình 2.7.



Hình 2.7. Luồng hành động và luồng nhận thức trong hệ thị giác người (Lê 2025).

Vùng thị giác sơ cấp (V1) đảm nhiệm việc xử lý các đặc trưng thị giác cơ bản, như xác định hướng của cạnh, hướng và sự chuyển động, cũng như khởi đầu quá trình hợp nhất thông tin từ hai mắt (Andrej, 2021). Thông tin sau đó được truyền tới vùng *thị giác thứ cấp* (secondary visual cortex – V2). Tại V2, tín hiệu từ V1 tiếp tục được xử lý ở mức độ phức tạp cao hơn, bao gồm phân biệt màu sắc, tần số không gian, mẫu hình hình học và định hướng của đối tượng (Anzai, 2007). Hai vùng V1 và V2 thường được gọi chung là vùng *xử lý thị giác sớm* (early visual cortex).

Đầu ra của V2 được phân tách và truyền vào hai luồng xử lý thị giác mức cao: *luồng hành động* (action pathway) và *luồng nhận thức* (perception pathway). Luồng hành động bao gồm các vùng như V5/MT, MST và vỏ não đỉnh, chịu trách nhiệm xử lý các thuộc tính động trong không gian như hướng và vận tốc chuyển động, nhằm trả lời các câu hỏi kiểu “đối tượng đang ở đâu?” hoặc “làm thế nào để tương tác/nắm bắt đối tượng?”. Thông tin từ luồng này được truyền trực tiếp tới các vùng não điều khiển vận động.


Ngược lại, *luồng nhận thức* bao gồm các vùng V4, TEO/PIT và TE/AIT, liên quan đến nhận thức thị giác cấp cao như hình dạng, khuôn mặt, chữ viết và nhận dạng đối tượng. Sự phân tách chức năng này phản ánh rõ ràng cách não người tổ chức và xử lý thông tin thị giác theo mục đích hành động và nhận thức, như được tóm tắt trong Bảng 2.1.

2.3. Các chức năng thị giác

2.3.1. Chuyển đổi ánh sáng thành tín hiệu điện não

Khi ánh sáng đi qua *đồng tử* (iris), *thủy tinh thể* (lens) hội tụ ánh sáng tạo thành một ảnh thật trên *võng mạc* (retina) và võng mạc thực hiện các bước xử lý ảnh đầu

688 tiên trước khi truyền tín hiệu tới não, Hình 2.8. Người không có tật quang học về
 689 mắt (cận thị, viễn thị, loạn thị, ...) khi nhìn các vật ở xa, thủy tinh thể ở trạng phẳng
 690 nhất hội tụ một ảnh sắc nét của đối tượng trên võng mạc. Khi nhìn các vật ở gần *cơ*
 691 *vòng* (ciliary) co lại làm tăng độ cong của thủy tinh thể để tạo nên ảnh sắc nét trên
 692 võng mạc. Cơ chế điều tiết này nếu nhìn theo khía cạnh vật lý quang học thì thủy
 693 tinh thể của mắt người đóng vai trò như một thấu kính lồi mà tiêu cự của nó được
 694 điều chỉnh bởi một cơ sinh học nhằm đảm bảo một ảnh thật sắc nét luôn được hội
 695 tụ trên võng mạc khi người quan sát đối tượng ở các khoảng cách khác nhau.



Hình 2.8. Mắt và thụ thể (clevelandclinic.org).

2.3.1.1. Võng mạc


Võng mạc là lớp các tế bào bao phủ phía sau nhãn cầu lần lượt gồm có: lớp *tế bào hạch* (retina ganglion cells - RGC), lớp *tế bào lưỡng cực* (bipolar cells), lớp *tế bào ngang* (horizontal cells) và ngoài cùng là lớp *thụ thể ánh sáng* (photoreceptor). Các thụ thể ánh sáng chứa các hóa chất hấp thụ ánh sáng và *sắc tố* (pigment) sinh ra tín hiệu thần kinh khi hấp thụ ánh sáng. Các sắc tố thay đổi cấu hình khi chúng hấp thụ ánh sáng, việc này kích hoạt một phản ứng hóa học làm mở một kênh ion và tạo ra một tín hiệu điện. Thụ thể ánh sáng còn được gọi là các *tế bào thần kinh cảm giác* (sensory neuron) sinh ra và truyền các xung tín hiệu điện tới các neuron lân cận dưới dạng các tín hiệu hóa học để *kích thích* (excitatory) các neuron kế tiếp sinh ra tín hiệu điện tương tự hoặc *ức chế* (inhibitory) các neuron kế tiếp phản ứng lại các neuron khác. Những tín hiệu này được truyền từ thụ thể ánh sáng qua tế bào ngang, tế bào lưỡng cực tới RGC để kết thúc bước xử lý thị giác đầu tiên. Các tín hiệu tiếp tục được gửi lên não thông qua dây thần kinh thị giác. Nơi các dây thần

712 kinh thị giác đi ra khỏi nhãn cầu không có các thụ thể ánh sáng được gọi là điểm
713 mù.

714 2.3.1.2. Thụ thể ánh sáng


715 Mắt người có hai loại *thụ thể ánh sáng* (photoreceptors) gọi là *tế bào que* (rods)
716 và *tế bào nón* (cones). Cones ít nhạy cảm với ánh sáng rods nên được sử dụng để
717 nhìn ban ngày (nhiều ánh sáng). Rods nhạy cảm hơn nên được sử dụng để nhìn ban
718 đêm (môi trường ánh sáng yếu). Cones và rods không phân bố đồng đều trên võng
719 mạc, cones tập trung ở *điểm vàng* (fovea) trong khi rods chiếm ưu thế ở vùng ngoại
720 vi phía ngoài điểm vàng. Mỗi thụ thể ánh sáng không truyền đi lượng ‘màu’ của
721 ánh sáng chiếu vào mà chỉ truyền đi *tín hiệu nhị phân* (binary signal) cho biết nó có
722 được kích thích bởi ánh sáng hay không. Do đó mức độ nhạy cảm của từng loại thụ
723 thể ánh sáng không phụ thuộc vào ‘*năng lực phản ứng*’ của từng thụ thể mà phụ
724 thuộc vào số lượng hay mật độ của từng loại thụ thể.

725 Có hai khái niệm liên quan trực tiếp đến cảm nhận ánh sáng của thị giác người
726 là *độ sáng* (luminance) và *sắc độ* (chrominance). Hai khái niệm này không được hiểu
727 là độ đo lượng ánh sáng theo nghĩa là các đại lượng vật lý mà chúng được định
728 nghĩa là mức độ mắt người phản ứng với ánh sáng, do con người đánh giá một cách
729 chủ quan. Khi cùng quan sát một vật thể, độ sáng và sắc độ cảm nhận của từng
730 người có thể khác nhau.



731
732 Hình 2.9. Mức độ phản ứng tế bào que và tế bào nón theo bước sóng ánh
733 sáng.


734 Độ sáng phát sinh từ lớp RGC bằng việc tổng hợp số lượng các cones và rods
735 được kích thích. Do đó, ta vẫn cảm nhận được được độ sáng trong cả môi trường
736 ban ngày và ban đêm. Rods nhạy cảm với dải sóng ngắn (blue hoặc green) hơn
737 cones và ít nhạy cảm với dải sóng dài (yellow hoặc red) hơn cones, Hình 2.9. Vì thế,
738 khi môi trường được chuyển từ ánh sáng ban ngày sang ban đêm, dường như ta sẽ
739 cảm thấy màu xanh thì sáng hơn còn màu đỏ thì tối đi do việc quan sát được chuyển
740 từ cones sang rods.



Hình 2.10. Mức độ phản ứng của các loại tế bào nón theo bước sóng ánh sáng.


Cảm nhận độ sáng cũng không đồng đều với các bước sóng ánh sáng, cụ thể như sau. Có ba loại cones là S (short), M (middle) và L (long) với các sắc tố khác nhau giúp chúng phản ứng (response) với các dải phổ ánh sáng tương ứng với các màu mà hệ thị giác cảm nhận được là *blue*, *green* và *red*, Hình 2.10. Số lượng cones L gấp đôi số lượng cones M và 1% trong tổng số cones thuộc loại S. Do đó, ánh sáng đỏ kích thích hệ thị giác người mạnh hơn gấp nhiều lần ánh sáng xanh lục do số lượng cones L (phản ứng mạnh trong dải màu đỏ) nhiều hơn nhiều lần số lượng cones S và M.

Hình 2.10 cho thấy nếu chỉ sử dụng một loại cones sẽ gây ra sự không rõ ràng trong cảm nhận màu sắc. Ví dụ, 200 photon có bước sóng 730nm tạo ra sự kích thích lên cones L tương đương với 100 photon có bước sóng 680nm. Về mặt lý thuyết, ta chỉ cần 2 loại cones có phân bố mức độ phản ứng với ánh sáng một cách phù hợp có thể giúp cho hệ thị giác cảm nhận được toàn bộ bước sóng trong một dải ánh sáng cố định. Tuy nhiên, tiến hóa đã cho con người và ba loại tế bào nón để cảm nhận màu sắc, trong đó loại L lệch một chút sang vùng đỏ hơn so với loại M. Có lẽ, nhu cầu cần phân biệt quả chín màu vàng, màu đỏ khỏi những tán lá cây màu xanh đã thúc đẩy sự quá trình tiến hóa này.




Hình 2.11. Mức độ hội tụ (degree of convergence).

Do các số lượng các thụ thể ánh sáng rất nhiều nên chúng buộc phải chia sẻ kết nối với nhau ở các tầng thị giác tiếp theo. Mức độ chia sẻ kết nối được gọi là độ hội tụ (degree of convergence). Hình 2.11 trực quan hóa mức độ hội tụ. Càng nhiều photoreceptors kết nối tới một RGC, RGC đó càng nhạy cảm với ánh sáng. Dải màu vàng biểu thị khu vực photoreceptor được kích thích bởi ánh sáng. Ở đây, khi mỗi tế bào thụ cảm được kích thích bởi ánh sáng, nó sẽ tạo ra một *phản ứng* (fire) của tế bào hạch mà nó nối tới. RGC có độ tụ lớn (a) phản ứng mạnh hơn RGC có độ tụ nhỏ (b) và (c).




Hình 2.12. Mức độ tổng hợp không gian (spatial summation).

Những tế bào RGC có độ hội tụ lớn thường có mức độ tổng hợp không gian (spatial summation) rộng hơn. Như minh họa trong Hình 2.12, mức độ phản ứng của RGC phụ thuộc vào tổng lượng ánh sáng tác động lên các photoreceptor nối tới nó. Do liên kết với nhiều photoreceptor, một RGC có khả năng tích hợp tín hiệu trên một vùng không gian lớn hơn, từ đó “nhìn thấy” và phản ứng với các kích thích diện rộng thay vì các chi tiết cục bộ.



Hình 2.13. Độ sắc nét (acuity).

Ngược lại, các RGC có độ hội tụ nhỏ chỉ thực hiện tổng hợp không gian trên vùng hẹp, nhưng bù lại cung cấp khả năng phân biệt không gian cao hơn (độ sắc nét – acuity). Như minh họa trong Hình 2.13, mức độ phản ứng của RGC thay đổi theo vị trí các photoreceptor được chiếu sáng, cho phép hệ thị giác phân giải tốt hơn các chi tiết không gian nhỏ.



Hình 2.12. Trường cảm thụ (receptive field) của tế bào hạch độ sáng và sắc độ (Jon Arnold Images Ltd/Alamy).

2.3.1.3. Trường cảm thụ

Thông thường, nhiều photoreceptor lân cận cùng kết nối tới một RGC. Khi ánh sáng kích thích một hoặc nhiều thụ thể trong nhóm này, tín hiệu được tích hợp và tạo ra phản ứng của RGC, sau đó truyền lên não. Vùng không gian mà kích thích ánh sáng có khả năng gây ra phản ứng của một RGC được gọi là trường cảm thụ (receptive field).


Hình 2.12 minh họa trường cảm thụ của hai loại RGC chính: RGC độ sáng (parasol) và RGC sắc độ (midget). Các trường cảm thụ này chồng lấn lên nhau và phủ kín võng mạc, không tồn tại vùng “trống” không được cảm nhận. Điều này cho thấy mỗi photoreceptor đều tham gia vào việc kích thích ít nhất một tế bào hạch. Lưu ý trong Hình 2.12 rằng, điểm nhìn của mắt được đặt vào khuôn mặt tượng Nhân sư. Gần điểm nhìn trung tâm, trường cảm thụ nhỏ và dày đặc hơn, cho phép độ phân giải không gian cao. Ngược lại, ở vùng ngoại vi, trường cảm thụ lớn hơn nhưng kém sắc nét hơn. Trường cảm thụ của tế bào hạch độ sáng thường rộng hơn nhưng có độ phân giải thấp hơn so với tế bào hạch sắc độ do mức độ hội tụ photoreceptor lớn hơn.

Nếu so sánh với camera, mỗi RGC có thể xem như một điểm ảnh (pixel) với trường cảm thụ tương ứng diện tích ảnh mà pixel đó thu nhận. Võng mạc vì thế tạo ra một hệ cảm biến không đồng nhất về độ phân giải: vùng trung tâm có độ phân giải cao, đặc biệt cho ảnh màu, trong khi vùng ngoại vi ưu tiên phân biệt cường độ sáng và chuyển động.

2.3.1.4. Ước chế bên

Trường cảm thụ của hầu hết các tế bào hạch chia làm hai phần, phần tâm (center) và phần ngoại vi (surround), được gọi là tổ chức tâm/ngoại vi (center/surround organization). Thực tế là tế bào hạch không kết nối trực tiếp tới các thụ thể mà qua các lớp trung gian là tế bào ngang (horizontal cells) và tế bào lưỡng cực (bipolar cells), xem Hình 2.8. Có hai loại tế bào lưỡng cực là ON và OFF. Mỗi tế bào lưỡng cực kết nối tới một tế bào hạch để tạo thành một trường cảm thụ tương ứng, gọi tắt là On-center và Off-center. Hình 2.13 cho thấy mức độ phản ứng của tế bào hạch OFF-Center khi trường cảm ứng được kích thích. Khi ánh sáng trải

đều trên toàn bộ trường cảm thụ, tế bào hạch có mức độ phản ứng thấp. Khi phần tâm không được kích thích, mức độ phản ứng tăng lên mạnh, khi cả phần tâm và phần ngoại vi được kích thích, tế bào hạch có mức độ phản ứng ở mức trung bình. Với tế bào hạch ON-Center hiệu ứng cũng xảy ra tương tự nhưng ngược lại khi kích thích ánh sáng vào trường cảm thụ của tế bào hạch.



Hình 2.13. Mức độ phản ứng của tế bào hạch OFF-Center.


Hiện tượng này gọi là *ức chế bên* (lateral inhibition) do cơ chế kết nối đặc biệt của các lớp tế bào trung gian (ngang và lưỡng cực) gây ra. Kết quả là những tế bào hạch mà trường cảm thụ của nó có sự thay đổi lớn về ánh sáng sẽ có mức độ phản ứng rất cao, ngược lại, chúng phản ứng rất yếu nếu ánh sáng kích thích đồng đều. Thực tế, ức chế bên đóng vai trò quan trọng trong nhận thức thị giác vì nó giúp tăng độ tương phản và độ phân giải hình ảnh và xảy ra ở nhiều tầng của nhận thức thị giác.

2.3.1.5. Phân tách độ sáng/sắc độ

Có hai loại GLC chính là Parasol chiếm khoảng 5% và Midget chiếm khoảng 90% và các loại còn lại chiếm khoảng 5% tổng số GLC. Hai loại tế bào này đóng vai trò quan trọng trong quá trình phân tách ánh sáng thành độ sáng (luminance) và sắc độ (chrominance) và là điểm khởi đầu cho hai luồng xử lý thông tin thị giác tương ứng là Luồng hành động và luồng nhận thức.

Tế bào Parasol có trường cảm thụ rộng do có nhiều photoreceptor bao gồm cả hai loại rods và cones kết nối tới. Do số lượng của từng loại cones được phân đều cho vùng tâm và ngoại vi của trường cảm thụ nên Parasol không thể phân biệt được phổ của ánh sáng. Do đó, nó chỉ xử lý và truyền đi thông tin về độ sáng. Người ta còn gọi là *kênh black-white*.

Mức độ phản ứng của ba loại cones S, M và L phụ thuộc vào cả bước sóng và cường độ ánh sáng. Để nhận biết sắc độ mắt ta phải so sánh số lượng các cones được kích thích (excited cones) của mỗi loại với hai loại còn lại. Sự kết hợp này đã cho chúng ta khả năng nhận biết được những màu sắc đơn phổ (chỉ gồm 1 bước sóng) và đa phổ (gồm nhiều bước sóng). Để thực hiện được việc này, ta cần đến sự hỗ trợ của Midget.



Hình 2.14. Trường thụ cảm ON-Center của tế bào hạch Midget nhận biết màu.

Tế bào Midget chiếm khoảng 90% tổng số lượng các GLC. Midget có trường thụ cảm hẹp do chỉ được một số ít các cones kết nối tới và để nhận biết được sắc độ, các tế bào Midget có thể lựa chọn các loại cảm thụ khác nhau kết nối tới vùng tâm và vùng ngoại vi trong trường cảm thụ của mình. Hình 2.14 cho thấy trường cảm thụ của một tế bào Midget loại Red-On-Center nhận kết nối từ các thụ thể nón L (red) cho vùng tâm, và các thụ thể M (green) vùng ngoại vi. Nếu chỉ có vùng tâm được kích thích bởi ánh sáng phổ đỏ thì tế bào hạch phản ứng rất mạnh. Mức độ phản ứng bị giảm đi một chút nếu phần ngoại được kích thích bởi ánh sáng phổ đỏ hoặc bị ức chế rất mạnh bởi ánh sáng phổ lục. Tương tự ta có tế bào Midget loại Blue-On-Center với thụ thể nón S (blue) ở tâm và thụ thể L (red) và M (green) ở ngoại vi. Ở đây khi trộn màu red với green ta được màu yellow. Như vậy cơ chế ức chế bên đã giúp bù trừ các cặp phổ từ các thụ thể ánh sáng khác nhau. Cụ thể, Midget đã tạo ra và truyền lên trung ương não hai thành phần của hai cặp phổ đối kháng (Red-Green) và (Blue-Yellow). Người ta còn gọi hai thành phần này là *kênh red-green* và *kênh blue-yellow*.

Có thể nói ánh sáng tiếp xúc với võng mạc là một đại lượng liên tục theo không gian, phổ, cường độ và thời gian đã được rời rạc hóa và giản lược khi được chuyển đổi thành điện não trên võng mạc. Khi mà khoảng không gian liên tục của ảnh chiếu lên võng mạc được cảm thụ bởi từng thụ thể ánh sáng (rời rạc hóa không gian). Có 4 loại thụ thể ánh sáng (1 loại que, và 3 loại nón) nhạy cảm với 4 dải tần số khác nhau của ánh sáng trực tiếp chuyển ánh sáng thành tín hiệu điện não (rời rạc hóa phổ). Mỗi thụ thể chỉ truyền đi trạng thái được kích thích hay không được kích thích sau đó được tế bào hạch tổng hợp thành mức độ phản ứng (firing rate) dưới dạng các xung điện não (rời rạc hóa cường độ sáng và thời gian). Cơ chế ức chế bên góp phần giản lược hóa lượng thông tin được gửi lên não bằng cách chỉ quan tâm đến những phần ánh sáng biến đổi mạnh như phần biên/rìa của đối tượng và bù trừ các cặp phổ đối kháng.


2.3.2. Phát hiện đặc trưng sơ cấp

2.3.2.1. Phát hiện vùng có ánh sáng biến đổi mạnh (cạnh)


Trong xử lý ảnh và thị giác máy, *cạnh* (edge) là những vị trí trong ảnh có sự biến đổi mạnh của cường độ sáng, thường tương ứng với ranh giới của các đối

tượng và chứa nhiều thông tin về cấu trúc hình học. Vì vậy, phát hiện cạnh là bước xử lý cơ bản trong nhiều bài toán như phân đoạn và nhận dạng ảnh.

Dưới góc nhìn thị giác sinh học, Hình 2.15 cho thấy tế bào hạch RGC phản ứng mạnh khi trường cảm thụ của nó bao phủ các vùng có độ tương phản cao giữa sáng và tối, tương tự như các cạnh trong ảnh. Ngược lại, khi kích thích ánh sáng tương đối đồng đều, mức độ phản ứng giảm đáng kể. Sự tương đồng này cho thấy khái niệm cạnh trong thị giác máy có cơ sở sinh học, đồng thời giải thích vì sao các vùng có biến đổi cường độ mạnh được ưu tiên khai thác trong các phương pháp phát hiện cạnh của xử lý ảnh số.



Hình 2.15. Mức độ phản ứng của RGC ở những vùng có ánh sáng biến đổi mạnh.



Hình 2.16. Phản ứng của một neuron với thanh sáng xuất hiện trong trường cảm thụ với các hướng khác nhau.

2.3.2.2. Phát hiện hướng của cạnh


Các neuron ở võng mạc, LGN và lớp 4C của V1 chủ yếu phản ứng với sự xuất hiện của các điểm sáng trong trường cảm thụ. Tuy nhiên, tại các lớp cao hơn của V1 (đặc biệt là lớp 2 và lớp 3), xuất hiện những neuron có cơ chế phản ứng khác biệt. Các neuron này không chỉ phản ứng với điểm sáng đơn lẻ, mà còn được kích thích mạnh bởi các thanh sáng hoặc cạnh xuất hiện ở trường cảm thụ của chúng. Đáng chú ý, chỉ những thanh sáng có hướng nhất định mới gây ra phản ứng mạnh, trong khi các hướng khác tạo phản ứng yếu hoặc không gây kích thích (Hubel, 1968). Những neuron như vậy được gọi là neuron chọn lọc hướng, hay neuron có khả năng phát hiện hướng của cạnh.

Hình 2.16 minh họa phản ứng của một neuron khi xuất hiện các thanh sáng có hướng khác nhau trong trường cảm thụ. Trong ví dụ này, neuron phản ứng mạnh nhất với thanh sáng nghiêng khoảng 120° ngược chiều kim đồng hồ, và phản ứng giảm dần khi hướng của thanh lệch khỏi hướng tối ưu; thậm chí không phản ứng với thanh sáng có hướng vuông góc.

Các neuron lân cận nhau phản ứng với cạnh có các hướng khác nhau. Hình 2.17 cho thấy các neuron phản ứng với hướng các cạnh. Khi xem xét liên tiếp các neuron dọc theo một đường thẳng dài khoảng 2mm trong lớp 2 của V1 ta nhận thấy rằng hướng các cạnh mà các neuron này phản ứng mạnh nhất thay đổi theo hướng kim đồng hồ. Ví dụ, neuron ở vị trí 0.1mm phản ứng mạnh với cạnh có hướng -60° . Các neuron ở vị trí tiếp theo phản ứng mạnh với cạnh có các hướng thay đổi dần theo chiều kim đồng hồ.

2.3.2.3. Phát hiện hướng di chuyển của cạnh

Không chỉ dừng lại việc phát hiện hướng, các neuron tầng 4B của V1 còn có khả năng phát hiện hướng di chuyển của cạnh thông qua việc tích hợp tín hiệu không-thời gian từ các neuron chọn lọc hướng ở các lớp trước đó. Khi một cạnh chuyển động đi qua trường cảm thụ (xem Hình 2.17), các phần khác nhau của cạnh sẽ kích hoạt neuron theo một trình tự thời gian đặc trưng, chỉ tạo ra phản ứng mạnh khi trình tự này phù hợp với hướng chuyển động tối ưu. Nhờ đó, neuron tầng 4B không chỉ nhạy với hướng của cạnh, mà còn chọn lọc theo hướng chuyển động. Thông tin này sau đó được truyền tới vùng MT/V5, nơi các thuộc tính chuyển động được xử lý ở mức cao hơn.




Hình 2.17. Neuron tầng 4B phản ứng với hướng di chuyển của cạnh.

2.3.2.4. Đường viền chủ quan

Có thể thấy rằng các neuron ở vùng V1 (đặc biệt là các lớp 4C và 4B) chủ yếu nhạy với cạnh thật, tức là các biên được xác định bởi sự thay đổi đột ngột của cường độ sáng hoặc tương phản cục bộ trong trường cảm thụ. Tuy nhiên, thế giới vật lý có cấu trúc ba chiều (3D), trong khi hình ảnh thu được trên võng mạc chỉ là một phép chiếu hai chiều (2D). Do đó, hệ thị giác phải xử lý ảnh 2D này để *tái tạo* (reconstruct) lại cấu trúc 3D của môi trường, dẫn tới nhiều bài toán suy luận mang tính nhập

những. Một trong những bài toán quan trọng là việc phát hiện các cạnh không tồn tại vật lý, tức các cạnh không được tạo ra bởi sự biến đổi trực tiếp của cường độ ánh sáng. Những cạnh như vậy được gọi là *cạnh ảo* (illusory edges) hay *đường viền chủ quan* (subjective contours).



Hình 2.18. Các ví dụ về các đường viền chủ quan (Kanizsa 1955).

Hình 2.18 minh họa các ví dụ kinh điển về đường viền chủ quan do Gaetano Kanizsa đề xuất. Ở hình bên trái, hệ thị giác tự động hoàn thiện các đường viền để nhận thức một hình tam giác nằm phía trước và che khuất một phần của ba hình tròn. Tương tự, ở hình bên phải, các đường viền chủ quan được “điền vào” để tạo cảm nhận về một hình vuông nổi lên phía trên các hình tròn xung quanh.

Các nghiên cứu sinh lý thần kinh của von der Heydt (1984, 1989), Peterhans (1989) và Zhou (2000) cho thấy nhiều neuron ở vùng V2 phát xung mạnh khi quan sát các kích thích tạo ảo giác đường viền, mặc dù tại vị trí tương ứng của trường cảm thụ không hề tồn tại cạnh vật lý. Đáng chú ý, mức độ đáp ứng của neuron thay đổi đồng biến với độ mạnh–yếu của cảm nhận cạnh ảo: khi cấu hình kích thích bị điều chỉnh làm ảo giác biến mất, phản ứng của neuron cũng suy giảm rõ rệt. Những kết quả này chỉ ra rằng V2 không chỉ mã hóa tương phản cục bộ như V1, mà còn tích hợp thông tin ngữ cảnh ở phạm vi rộng hơn để suy ra sự tồn tại của một đường biên. Đường biên này không tồn tại trong kích thích vật lý, mà chỉ hình thành trong nhận thức của chủ thể, vì vậy được gọi là đường viền chủ quan.

2.3.3. Thị giác sinh học và các bài toán nhận thức bậc cao

Phần này trình bày tóm lược mối liên hệ giữa các bài toán thị giác máy bậc cao và các cơ chế nhận thức – thần kinh đã được phát hiện trong thị giác sinh học (Marr, 1982; DiCarlo, Zoccolan, & Rust, 2012). Qua đó cho thấy nhiều bài toán cốt lõi của thị giác máy không phải là những khái niệm thuần túy kỹ thuật, mà phản ánh trực tiếp các chiến lược xử lý thông tin mà não người đã tiến hóa để giải quyết.

2.3.3.1. So khớp mô hình (Phát hiện đối tượng đơn giản)

Trong thị giác sinh học, việc phát hiện và nhận dạng các đối tượng đơn giản thường được nghiên cứu dọc theo luồng nhận thức (Hình 2.7), đặc biệt từ V1 → V2 → V4 → IT. Các nghiên cứu điện sinh lý ở vùng inferotemporal cortex (IT) cho thấy neuron tại đây phản ứng chọn lọc với các hình dạng và tổ hợp đặc trưng, đồng thời

thể hiện tính bất biến tương đối đối với vị trí, kích thước và góc nhìn của đối tượng. Điều này gợi ý một cơ chế so khớp không gian–đặc trưng mang tính phân cấp, thay vì so khớp tín hiệu trực tiếp. Các mô hình tính toán như HMAX đã được đề xuất nhằm mô phỏng nguyên lý này, trong đó các đặc trưng đơn giản được kết hợp dần thành các biểu diễn phức tạp hơn. Như vậy, so khớp mô hình trong thị giác máy có thể được xem là một phép xấp xỉ của quá trình tích hợp đặc trưng phân cấp trong vỏ não thị giác (Tanaka, 1996; Riesenhuber & Poggio, 1999).

2.3.3.2. Theo dõi đối tượng

Theo dõi đối tượng trong thị giác sinh học gắn liền chặt chẽ với nghiên cứu về *smooth pursuit eye movements* (SPEM). Các vùng như MT và MST trong luồng hành động (Xem Hình 2.7) đóng vai trò trung tâm trong việc ước lượng vận tốc và hướng chuyển động của đối tượng, trong khi các vùng vận động mắt sử dụng thông tin này để duy trì hình ảnh mục tiêu trên điểm vàng (trên võng mạc)). Các nghiên cứu cho thấy hệ thống theo dõi không chỉ phản ứng thụ động với chuyển động tức thời, mà còn có khả năng dự đoán quỹ đạo ngắn hạn của mục tiêu. Điều này tương đồng với các thuật toán theo dõi đối tượng trong thị giác máy, nơi trạng thái đối tượng được cập nhật liên tục thông qua mô hình động và quan sát mới. Do đó, theo dõi đối tượng trong thị giác sinh học có thể được xem như một vòng lặp khép kín giữa ước lượng, dự đoán và hiệu chỉnh (Krauzlis, 2004; Lisberger, 2010).

2.3.3.3. Căn chỉnh ảnh

Trong não người, bài toán căn chỉnh ảnh xuất hiện một cách tự nhiên khi mắt liên tục thực hiện các chuyển động saccade (chuyển động giật nhanh), làm cho ảnh trên võng mạc thay đổi đột ngột. Căn chỉnh ảnh giúp khung cảnh vẫn được thị giác người cảm nhận ổn định. Cơ chế then chốt để giải quyết bài toán này là *tái lập bản đồ không gian* (spatial remapping) được thực hiện ở các vùng vỏ não đỉnh (parietal cortex). Quá trình này có thể được hiểu như việc căn chỉnh các “khung hình” liên tiếp để duy trì một hệ tọa độ thống nhất trong não người. Từ góc nhìn thị giác máy, đây chính là bài toán registration/alignment, trong đó các phép biến đổi hình học được ước lượng để đưa nhiều ảnh về cùng một hệ quy chiếu (Duhamel, Colby, & Goldberg, 1992; Cavanagh et al., 2010).

2.3.3.4. Phân loại ảnh

Các nghiên cứu về phân loại cực nhanh (ultra-rapid categorization) cho thấy con người có thể phân loại cảnh hoặc ảnh (ví dụ: có hay không có động vật) chỉ trong vài trăm mili-giây. Điều này cho thấy quá trình phân loại có thể được thực hiện chủ yếu bằng một luồng xử lý dọc theo luồng nhận thức với rất ít hoặc không cần thông tin phản hồi. Các neuron ở các mức cao hơn của hệ thống thị giác mã hóa thông tin ở mức khái quát, phù hợp cho việc gán nhãn phân loại. Kết quả này có sự tương đồng rõ rệt với các mô hình CNN hiện đại, trong đó các tầng sâu mã hóa

1009 thông tin ngữ nghĩa phục vụ cho bài toán phân loại ảnh (Thorpe, Fize, & Marlot,
1010 1996; Fabre-Thorpe, 2011).

1011 2.3.3.5. Phát hiện và nhận dạng đối tượng

1012 Phát hiện và nhận dạng đối tượng trong thị giác sinh học thường được nghiên
1013 cứu trong bối cảnh *tìm kiếm dựa trên thông tin thị giác* (visual search) và *cơ chế chú ý*
1014 (attention). Các kết quả nghiên cứu cho thấy hệ thị giác kết hợp giữa xử lý song
1015 song ở giai đoạn sớm và sự điều hướng chú ý có định hướng ở giai đoạn sau để tìm
1016 mục tiêu trong môi trường phức tạp. Các nghiên cứu thần kinh chỉ ra vai trò của
1017 các vùng như *vùng chức năng ở thùy trán* (FEF) và *vùng vỏ não đỉnh* (parietal cortex)
1018 trong việc điều khiển sự chú ý không gian và lựa chọn đối tượng. Nhận dạng đối
1019 tượng sau khi được phát hiện lại chủ yếu dựa trên các vùng chuyên biệt của luồng
1020 nhận thức (xem Hình 2.7). Điều này phản ánh rõ sự tách biệt nhưng phối hợp hoạt
1021 động giữa phát hiện và nhận dạng đối tượng, tương tự các quy trình hai giai đoạn
1022 (phát hiện và nhận dạng đối tượng) trong thị giác máy (Wolfe, 1994; Buschman &
1023 Miller, 2007).

1024 2.3.3.6. Tái tạo cấu trúc 3D

1025 Tái tạo cấu trúc 3D là một trong những bài toán nhận thức phức tạp nhất của
1026 thị giác sinh học. Các nghiên cứu cho thấy thông tin *thị sai* (disparity) giữa hai mắt
1027 được xử lý từ rất sớm ở V1, nhưng các biểu diễn 3D có ý nghĩa hình học hơn, như
1028 hướng và độ nghiêng của bề mặt, lại xuất hiện ở các vùng cao hơn như CIP trong
1029 thùy đỉnh. Ngoài ra, cấu trúc 3D còn được suy ra từ chuyển động (structure-from-
1030 motion), với sự tham gia của các vùng MT+/V5 và mạng lưới chẩm–đỉnh. Những
1031 phát hiện này cho thấy não kết hợp nhiều nguồn tín hiệu khác nhau để suy ra hình
1032 dạng và cấu trúc không gian, một nguyên lý nền tảng cho các hệ thống tái tạo 3D
1033 trong thị giác máy (Cumming & Parker, 1997; Orban, 2011).

1034 **Kết chương**

1035 Chương này đã trình bày các nền tảng cốt lõi của nhận thức thị giác người, từ
1036 bản chất của ánh sáng và màu sắc đến cấu trúc phân cấp và các chức năng xử lý thị
1037 giác. Qua đó, chương làm rõ cách hệ thị giác chuyển đổi tín hiệu vật lý của ánh sáng
1038 thành các biểu diễn thần kinh phục vụ tri giác.

1039 Ở các mức xử lý thấp, võng mạc và các vùng thị giác sớm đảm nhiệm việc mã
1040 hóa cường độ sáng, màu sắc và độ tương phản, đồng thời phát hiện các đặc trưng
1041 sơ cấp như biên, hướng và chuyển động. Những cơ chế này tạo nền tảng cho các
1042 biểu diễn thị giác phức tạp hơn ở các mức cao. Ở mức cao hơn, thị giác trở thành
1043 một quá trình chủ động và mang tính nhận thức, chịu ảnh hưởng của chú ý, trí nhớ
1044 và mục tiêu hành động. Các chức năng như theo dõi chuyển động và nhận dạng đối

tượng cho thấy thị giác không chỉ ghi nhận hình ảnh mà còn diễn giải và tổ chức thông tin không gian để hỗ trợ hành vi.

Những kiến thức trong chương này là cơ sở quan trọng cho xử lý ảnh và thị giác máy tính, khi nhiều khái niệm sinh học như không gian màu, trích xuất đặc trưng và xử lý phân cấp đã truyền cảm hứng trực tiếp cho các mô hình tính toán sẽ được trình bày trong các chương tiếp theo.

Tài liệu tham khảo

Anzai, A., Peng, X., & Van Essen, D. C. (2007). Neurons in monkey visual area V2 encode combinations of orientations. *Nature Neuroscience*.
<https://doi.org/10.1038/nn1975>

Barton, J. J. S. (2014). Visual motion and space perception. In *Encyclopedia of the Neurological Sciences* (2nd ed.). Academic Press.

Brown, D. C. (1966). Decentering distortion of lenses. *Photogrammetric Engineering*, 32(3), 444–462.

Buschman, T. J., & Miller, E. K. (2007). Top-down versus bottom-up control of attention in the prefrontal and posterior parietal cortices. *Science*, 315(5820), 1860–1862.

Cavanagh, P., Hunt, A. R., Afraz, A., & Rolfs, M. (2010). Visual stability based on remapping of attention pointers. *Trends in Cognitive Sciences*, 14(4), 147–153.

Cumming, B. G., & Parker, A. J. (1997). Responses of primary visual cortical neurons to binocular disparity. *Nature*, 389(6648), 280–283.

DiCarlo, J. J., Zoccolan, D., & Rust, N. C. (2012). How does the brain solve visual object recognition? *Neuron*, 73(3), 415–434.

Duhamel, J. R., Colby, C. L., & Goldberg, M. E. (1992). The updating of the representation of visual space in parietal cortex by intended eye movements. *Science*, 255(5040), 90–92.

Ellis, E. M., Gauvain, G., Sivyer, B., & Murphy, G. J. (2016). Shared and distinct retinal input to the mouse superior colliculus and dorsal lateral geniculate nucleus. *Journal of Neurophysiology*.

Fabre-Thorpe, M. (2011). The characteristics and limits of rapid visual categorization. *Frontiers in Psychology*, 2, Article 243.

Fechteler, P., Eisert, P., & Rurainsky, J. (2007). Fast and high resolution 3D face scanning. In *Proceedings of the IEEE International Conference on Image Processing (ICIP 2007)*.

Gegenfurtner, K. (2003). Cortical mechanisms of colour vision. *Nature Reviews Neuroscience*, 4, 563–572.

- 1081 Goldman, R. (1990). Intersection of two lines in three space (p. 304). Academic
1082 Press.
- 1083 Goodale, M. A., & Milner, A. D. (1992). Separate visual pathways for
1084 perception and action. *Trends in Neurosciences*, 15(1), 20–25.
1085 [https://doi.org/10.1016/0166-2236\(92\)90344-8](https://doi.org/10.1016/0166-2236(92)90344-8)
- 1086 Hubel, D. H., & Wiesel, T. N. (1968). Receptive fields and functional
1087 architecture of monkey striate cortex. *Journal of Physiology*.
1088 <https://doi.org/10.1113/jphysiol.1968.sp008455>
- 1089 Jiang, R., Andolina, I. M., Li, M., & Tang, S. (2021). Clustered functional
1090 domains for curves and corners in cortical area V4. *eLife*, 10, e63798.
1091 <https://doi.org/10.7554/eLife.63798>
- 1092 Kanizsa, G. (1955). Quasi-percettivi in campi con stimolazione omogenea.
1093 *Rivista di Psicologia*, 49, 7–30.
- 1094 Kepler, J. (1604). *Optics: Paralipomena to Witelo and the Optical Part of*
1095 *Astronomy*. Green Lion Press.
- 1096 Krauzlis, R. J. (2004). Recasting the smooth pursuit eye movement system.
1097 *Journal of Neurophysiology*, 91(2), 591–603.
- 1098 Kral, A., Aplin, F., & Maier, H. (2021). *Prostheses for the brain: Introduction to*
1099 *neuroprosthetics (Chapter 12: Visual neuroprostheses)*. Elsevier.
- 1100 Lê, T. H. (2025). *Giáo trình Truyền thông đa phương tiện*. Nhà xuất bản Đại
1101 học Quốc gia Hà Nội.
- 1102 Lisberger, S. G. (2010). Visual guidance of smooth-pursuit eye movements:
1103 Sensation, action, and cognition. *Journal of Neuroscience*, 30(46), 14911–14918.
- 1104 Marr, D. (1982). *Vision: A computational investigation into the human*
1105 *representation and processing of visual information*. W. H. Freeman.
- 1106 Maxwell, J. C. (1865). A dynamical theory of the electromagnetic field.
1107 *Philosophical Transactions of the Royal Society of London*.
- 1108 Newton, I. (1704). *Opticks: Or, a treatise of the reflexions, refractions,*
1109 *inflexions and colours of light*. Octavo.
- 1110
- 1111 Orban, G. A. (2011). The extraction of 3D shape in the visual system of human
1112 and non-human primates. *Annual Review of Neuroscience*, 34, 361–388.
- 1113 Parker, A. (2007). Binocular depth perception and the cerebral cortex. *Nature*
1114 *Reviews Neuroscience*, 8, 379–391.
- 1115 Peterhans, E., & von der Heydt, R. (1989). Mechanisms of contour perception
1116 in monkey visual cortex. II. Contours bridging gaps. *Journal of Neuroscience*, 9,
1117 1749–1763.

Quian Quiroga, R., Boscaglia, M., Jonas, J., et al. (2023). Single neuron responses underlying face recognition in the human midfusiform face-selective cortex. *Nature Communications*, 14, Article 5661. <https://doi.org/10.1038/s41467-023-41466-0>

Rajalingham, R., & DiCarlo, J. J. (2019). Reversible inactivation of different millimeter-scale regions of primate IT results in different patterns of core object recognition deficits. *Neuron*, 102(2), 493–505.e5. <https://doi.org/10.1016/j.neuron.2019.02.001>

Riesenhuber, M., & Poggio, T. (1999). Hierarchical models of object recognition in cortex. *Nature Neuroscience*, 2(11), 1019–1025.

Tanaka, K. (1996). Inferotemporal cortex and object vision. *Annual Review of Neuroscience*, 19, 109–139.

Thorpe, S., Fize, D., & Marlot, C. (1996). Speed of processing in the human visual system. *Nature*, 381(6582), 520–522.

von der Heydt, R., Peterhans, E., & Baumgartner, G. (1984). Illusory contours and cortical neuron responses. *Science*, 224, 1260–1262. <https://doi.org/10.1126/science.6539501>

von der Heydt, R., & Peterhans, E. (1989). Mechanisms of contour perception in monkey visual cortex. I. Lines of pattern discontinuity. *Journal of Neuroscience*, 9, 1731–1748.

Wolfe, J. M. (1994). Guided Search 2.0: A revised model of visual search. *Psychonomic Bulletin & Review*, 1(2), 202–238.

Young, T. (1804). Bakerian lecture: Experiments and calculations relative to physical optics. *Philosophical Transactions of the Royal Society*.

Zhou, H., Friedman, H. S., & von der Heydt, R. (2000). Coding of border ownership in monkey visual cortex. *Journal of Neuroscience*, 20, 6594–6611.

Bài tập

1. Nêu sự khác nhau giữa khái niệm video và ảnh số?

1148

CHƯƠNG 3. THU NHẬN VÀ HÌNH THÀNH HÌNH ẢNH

1149 **3.1. Khái niệm ảnh**

1150 Dữ liệu ảnh nói chung thường được biểu diễn dưới dạng các tập hợp đa chiều
1151 để mô tả các yếu tố không gian, thời gian và các phần tử chứa giá trị số được gọi là
1152 điểm ảnh. Thông thường, giá trị của các điểm ảnh phản ánh năng lượng của ánh
1153 sáng. Khi được hiển thị, thiết bị (màn hình) ánh xạ giá trị mỗi điểm tới một phần tử
1154 phát sáng tùy thuộc vào vị trí không gian và thời gian của điểm ảnh. Ảnh không có
1155 yếu tố thời gian được gọi là *ảnh tĩnh* (still image) hoặc đơn giản là *ảnh* (image).

1156 Ảnh hai chiều (2D image) thường được biểu diễn dưới dạng mảng, trong đó
1157 mỗi chiều của mảng đại diện cho một trục không gian và mỗi điểm ảnh chứa các
1158 giá trị của phổ ánh sáng. Nếu điểm ảnh chỉ có 1 phổ ánh sáng thì ảnh được gọi là
1159 *ảnh đen trắng*, nếu có điểm ảnh chứa 3 phổ ánh sáng nhằm để khi hiển thị tạo được
1160 hình ảnh màu sắc trong thị giác người thì ảnh được gọi là *ảnh màu*. Nếu điểm ảnh
1161 có nhiều hơn ba giá trị phổ thì ảnh được gọi là *ảnh đa phổ* hoặc *siêu phổ*.

1162 Giá trị của điểm ảnh cũng trong ảnh hai chiều cũng có thể được sử dụng để
1163 miêu tả một chiều thứ ba trong không gian. Giá trị của điểm ảnh cho biết khoảng
1164 cách từ điểm quan sát tới đối tượng. Khi đó, ảnh được gọi là *ảnh độ sâu* hay còn gọi
1165 là *bản đồ độ sâu* (depthmap). Yếu tố không gian có thể được biểu diễn một cách tổng
1166 quát hơn bằng tập hợp các phần tử, trong đó mỗi phần tử chứa 3 giá trị tương ứng
1167 với 3 chiều không gian của phần tử và các giá trị màu của phần tử đó. Dạng biểu
1168 diễn này được gọi là *đám mây điểm* (point cloud).

1169 Yếu tố thời gian được sử dụng, đại lượng thời gian gán cho mỗi ảnh và tập
1170 hợp các ảnh được sắp xếp theo thứ tự thời gian được thu nhận được gọi là *ảnh động*
1171 hoặc video. Yếu tố thời gian trong video có thể được sử dụng để trích rút các thông
1172 tin về chuyển động của các đối tượng cũng như cho phép ước lượng các thành phần
1173 không gian chính xác và hiệu quả hơn.


1174 **3.2. Thu nhận ảnh**

1175 Có hai phương pháp để tạo ra ảnh: 1) thu nhận ảnh từ các thiết bị cảm biến và
1176 2) sinh ra ảnh bằng thuật toán. Phần này đề cập đến việc tạo ra ảnh từ các thiết bị
1177 cảm biến. Về bản chất, thiết bị cảm biến thực hiện các phép đo lường các đại lượng
1178 vật lý gồm có không gian, thời gian và ánh sáng. Do giới hạn kỹ thuật, rất khó để
1179 chế tạo một thiết bị có khả năng đồng thời đo lường cả ba đại lượng này. Do đó, tùy
1180 vào từng ứng dụng cụ thể người ta sử dụng các loại thiết bị thu nhận (camera) khác

1181 nhau. Trong tài liệu này ta sử dụng khái niệm camera cho các thiết bị thu nhận màu
1182 sắc hoặc độ sâu.

1183 3.2.1. Nhận biết màu sắc

1184 Mắt người nhìn thấy màu sắc của các vật thể xung quanh nhờ vào cơ chế phản
1185 xạ ánh sáng trên bề mặt vật thể. Có nghĩa là, để mắt người nhìn thấy đồ vật xung
1186 quanh ta cần một nguồn phát xạ ra sóng điện từ (mặt trời, bóng đèn, ...). Sóng điện
1187 từ lan truyền trong không gian và tiếp xúc với bề mặt đối tượng, một phần sóng đi
1188 xuyên qua vật thể, một phần bị vật thể hấp thụ và một phần sóng điện từ được bề
1189 mặt vật thể phản xạ ngược trở lại môi trường. Hệ thị giác người tiếp thu một phần
1190 nhỏ của phần sóng phản xạ từ bề mặt vật thể thông qua thủy tinh thể của mắt,
1191 chuyển đổi chúng thành tín hiệu điện não và hình thành nên hình ảnh của vật thể
1192 trong não người. Để đảm bảo tính chân thực của hình ảnh được thu nhận, các
1193 camera màu được thiết kế bao gồm các cảm biến ánh sáng hoạt động tương tự như
1194 cơ chế thu nhận hình ảnh của mắt người.



(b) Thu nhận màu sắc theo mẫu lọc Bayer

Hình 3.1. Thu nhận hình ảnh (Lê 2025).

1200 Cảm biến ánh sáng có nhiệm vụ chuyển đổi năng lượng ánh sáng chiếu vào
1201 bề mặt cảm biến thành hiệu điện thế, giá trị hiệu điện thế được lượng tử hóa thành


giá trị số và lưu vào một ô nhớ của thiết bị. Một bộ lọc tần số ánh sáng (tương ứng với các màu *red*, *green* và *blue*) có thể được áp dụng vào các cảm biến ánh sáng để chúng chỉ nhạy với một phổ tần số xác định (Hình 2.1). Để tạo ra ảnh hai chiều, một mảng (array) các cảm biến được thiết lập. Mỗi cảm biến tương ứng với một điểm ảnh. Ảnh màu được tạo ra bằng cách kết hợp các cảm biến nhạy với các phổ khác nhau như (*red*, *green* và *blue*). Chi tiết về camera và các cảm biến màu có thể được tham khảo trong cuốn giáo trình Xử lý ảnh và giáo trình Truyền thông đa phương tiện do xuất bản bởi Nhà xuất bản Đại học Quốc gia của cùng tác giả (Lê 2015).

3.2.2. Nhận biết không gian

Nhận biết không gian là khả năng phân biệt về khoảng cách giữa vật tới camera và giữa các vật thể với nhau. Hơn thế nữa, nhận biết không gian còn cho biết các đặc điểm cấu trúc không gian trên bề mặt của đối tượng như độ cao thấp, độ gồ gề hay trơn nhẵn. Bài toán nhận biết không gian có thể được thu gọn thành việc xác định khoảng cách từ camera tới một điểm trên bề mặt vật thể. Có nhiều phương pháp để ước lượng khoảng cách giữa camera tới vật thể, trong thị giác máy phổ biến ba phương pháp sau:

3.2.2.1. Dựa trên cảm biến chủ động

Cảm biến nhận biết không gian chủ động hoạt động dựa trên nguyên tắc phát ra một chùm tia (sóng điện từ hoặc sóng siêu âm) và theo dõi tín hiệu phản xạ trở lại từ bề mặt của đối tượng. Cảm biến sử dụng sóng siêu âm thường được sử dụng trong các ứng dụng định vị của robot hoặc thăm dò trong các điều kiện đặc biệt như bề mặt đáy biển hoặc cấu trúc bất thường trong lòng đất. Cảm biến sử dụng sóng điện từ thường được sử dụng trong các ứng dụng đòi hỏi tốc độ và độ chính xác cao như đo lường tốc độ chuyển động hoặc ước lượng cấu trúc 3D của vật thể.



Hình 3.2. Minh họa nguyên lý Time-of-Flight.

Camera time-of-flight (ToF), Hình 2.2, là một trong những cảm biến chủ động đo độ sâu gồm có 2 module chính. Module phát chùm ánh sáng hồng ngoại và module thu nhận tia hồng ngoại được phản xạ ngược trở lại từ bề mặt đồ vật. Khoảng cách từ camera tới đồ vật được tính bằng một nửa quãng đường ánh sáng

đi được trong khoảng thời gian từ lúc phát tia hồng ngoại và nhận được tín hiệu phản xạ. Các module thu nhận tia hồng ngoại phản xạ cũng có thể được bố trí dưới dạng mảng như cảm biến ánh sáng, nhờ đó camera ToF có thể chụp được ảnh độ sâu (*depth image* hoặc *depthmap*). Hình 2.3 hiển thị cặp ảnh màu và ảnh độ sâu tương ứng.

Ưu điểm của các cảm biến chủ động để đo độ sâu là có thể hoạt động trong phạm vi khoảng cách tương đối lớn với độ chính xác cao do có thể chủ động được công suất của nguồn phát sóng. Tuy nhiên, do các module thu nhận chỉ được thiết kế phù hợp với tính chất của sóng của nguồn phát, nên các thiết bị camera ToF không thể thu nhận màu sắc của đối tượng.



Hình 3.3. Ảnh màu (a) và ảnh độ sâu tương ứng (b).

Do các giới hạn trên, ứng dụng chủ yếu của các phương pháp nhận biết không gian sử dụng cảm biến chủ động là trong các ứng dụng thị giác robot.

3.2.2.2. Dựa trên cảm biến thụ động

Cảm biến nhận biết không gian thụ động hoạt động như các camera màu thông thường và các khoảng cách được tính toán từ các ảnh màu được chụp đối tượng ở các vị trí hoặc thời gian khác nhau. Nguyên lý cơ bản của ước lượng độ sâu từ ảnh màu là tính toán dựa trên *thị sai* (disparity) trong *ảnh nổi* (stereo vision). Ảnh nổi gồm một cặp ảnh trái và phải được thu nhận mô phỏng theo thị giác người khi nhìn bằng hai mắt.

Để thu nhận ảnh nổi, người ta cần sử dụng camera nổi (stereo camera). Camera nổi (Hình 3.4) có cấu tạo bao gồm hai camera màu có trục đặt song song và khoảng cách giữa hai camera tương tự như khoảng cách giữa hai mắt người. Hai camera hoạt động đồng bộ với nhau về thời gian để hai ảnh được tạo ra có sự chênh lệch về thời gian chụp là nhỏ nhất để giảm thiểu sự sai khác do chuyển động. Ngoài việc sử dụng ảnh nổi để ước lượng ảnh độ sâu thông qua thị sai, ảnh nổi có thể được sử dụng trong các hệ thống *thực tại ảo* (virtual reality – VR) hoặc truyền hình 3D bằng cách kết hợp với kỹ thuật hiển thị (kính lọc ảnh hoặc màn hình lenticular) nhằm hiển thị riêng biệt ảnh trái tới mắt trái và ảnh phải tới mắt phải của người xem, từ

đó hiệu ứng hình ảnh 3D được hình thành trong não người như cách mà hai mắt người quan sát thế giới thực.



Hình 3.4. Ví dụ về camera nổi.

Thực tế cho thấy chất lượng ảnh độ sâu ước lượng được từ ảnh nổi phụ thuộc vào sự đồng bộ khi ảnh nổi được chụp và sự đồng bộ này đòi hỏi sự phức tạp trong cấu trúc và cách chế tạo camera nổi. Do đó, gần đây nhiều phương pháp thị giác máy được phát triển nhằm ước lượng ảnh độ sâu chỉ từ một ảnh màu duy nhất hoặc từ các ảnh màu được thu nhận liên tiếp (video). Nhóm các phương pháp này sẽ được đề cập ở phần sau của giáo trình.

Ưu điểm của các phương pháp nhận biết không gian chỉ sử dụng cảm biến thụ động là có thể đồng thời thu nhận được độ sâu và màu sắc của vật thể. Tuy nhiên, do độ chính xác của giá trị độ sâu phụ thuộc vào chất lượng hình ảnh. Ta sẽ quay lại vấn đề này ở các phần sau.


Hiện nay các kỹ thuật nhận biết không gian sử dụng cảm biến thụ động thường được sử dụng để khôi phục 3D cho các vật thể hoặc công trình kiến trúc trong các lĩnh vực bảo tồn di sản và văn hóa.

3.2.2.3. Dựa trên ánh sáng có cấu trúc


Nhận biết không gian dựa trên ánh sáng có cấu trúc (structured light) sử dụng kết hợp các kỹ thuật của cảm biến chủ động và cảm biến thụ động. Trong đó một thiết bị chiếu sáng (projector) phát ra chuỗi hình ảnh có cấu trúc cố định (đường sọc ngang, đường sọc dọc hoặc các điểm chấm có mẫu cho trước) và các camera màu thu nhận hình ảnh phản xạ từ bề mặt vật thể. Tùy thuộc vào cấu trúc không gian của bề mặt vật thể và hướng nhìn của camera thu nhận mà cấu trúc ánh sáng thu nhận bị biến dạng. Dựa vào các đặc điểm biến dạng này mà hệ thống máy tính có thể ước lượng được độ sâu và cấu trúc không gian bề mặt của vật thể. Xem Hình 3.5.

Hình 3.6 trực quan hóa điểm chiếu (projected point) giữa projector và hình ảnh thu được từ camera. Độ sâu tại mỗi điểm này được tính toán điểm giao giữa hai đường thẳng trong không gian ba chiều cùng với tham số nội (intrinsic parameter) và tham số ngoại (extrinsic parameter) của projector và camera. Hai bộ

tham số này thu được thông qua quá trình hiệu chỉnh camera (camera calibration) được đề cập chi tiết trong phần tiếp theo.



Hình 3.5. Ánh sáng có cấu trúc dạng sọc dọc giúp nhận biết không gian (bifab.io) và hình ảnh của một camera quét 3D (3D scanner) thực tế (metron3d.com).



Hình 3.6. Trục quan hóa điểm chiếu (Philipp 2007).

Ưu điểm của phương pháp này là không đòi hỏi ánh sáng môi trường, vật thể có thể được đặt trong bóng tối hoặc trong môi trường sáng nhẹ. Tuy nhiên, tính chất phản xạ ánh sáng của bề mặt vật thể ảnh hưởng nhiều tới chất lượng ảnh độ sâu. Ví dụ các chất liệu trong suốt như thủy tinh ít phản xạ ánh sáng hoặc tạo ra vùng phản xạ ánh sáng toàn phần và các chất liệu màu đen hoàn toàn không tạo ra hiệu ứng phản xạ ánh sáng. Để giải quyết vấn đề này, người ta có thể sử dụng sử dụng loại

1306 ánh sáng khác nhau như: ánh sáng trắng, hồng ngoại, đỏ hoặc xanh. Mỗi loại ánh
1307 sáng có đặc điểm và khả năng ứng dụng riêng, xem Bảng 3.1.

1308 Bảng 3.1. Các loại ánh sáng được sử dụng trong máy quét 3D.

Tiêu chí	Bước sóng	Độ phân giải quét	Khả năng quét vật tối	Giá thành thiết bị	Ứng dụng phổ biến	An toàn cho mắt
Ánh sáng đỏ (Red Laser)	~650 nm	Trung bình	Dễ bị nhiễu	Thường rẻ hơn	Quét vật lớn, đơn giản	Có thể nguy hiểm
Ánh sáng xanh (Blue Laser)	~450 nm	Cao	Tốt hơn	Thường cao hơn	Quét khuôn mẫu, linh kiện	Tương đối an toàn
Ánh sáng hồng ngoại (Infrared)	~850–940 nm (vô hình)	Cao	Rất tốt	Trung bình đến cao	Quét người, môi trường tối	Rất an toàn
Ánh sáng trắng (White LED)	~400–700 nm	Trung bình	Kém hơn	Thấp đến trung bình	Quét sản phẩm, vật sáng	Rất an toàn

1309

1310 Trong một số trường hợp bề mặt đồ vật có màu đen và gần như không phản
1311 xạ ánh sáng, khi đó có thể sử dụng một loại bột dễ bay hơi phun phủ lên bề mặt đồ
1312 vật để nhất thời tăng cường hiệu ứng phản xạ giúp cho thu nhận ánh sáng có cấu
1313 trúc dễ dàng hơn từ đó ước lượng được cấu trúc không gian bề mặt đối tượng dễ
1314 dàng hơn.

1315 3.3. Biểu diễn ảnh (Không gian, thời gian, cường độ)

1316 Hình ảnh vật thể sau khi thu nhận (số hóa) cần được biểu diễn dưới dạng các
1317 giá trị số trong bộ nhớ máy tính sao cho chúng dễ dàng truy cập, xử lý, hiển thị và
1318 truyền tải. Có 4 yếu liên quan đến hình ảnh vật thể được thu nhận: không gian, thời
1319 gian, bước sóng ánh sáng và cường độ ánh sáng. Do giới hạn công nghệ cùng tính
1320 tiện lợi cho các ứng dụng, việc biểu diễn ảnh thường không cố gắng bao gồm toàn
1321 bộ các yếu tố trên.

3.3.1. Ảnh 2 chiều (2D image)

Đây là loại biểu diễn dữ liệu hình ảnh thông dụng nhất, trong đó các phần tử được gọi là *điểm ảnh* (pixel) được bố trí thành dạng lưới (mảng) hai chiều. Mỗi chiều của lưới đại diện cho một chiều của không gian. Thông thường, kích thước của lưới tương ứng với kích thước bộ cảm biến của camera. Mỗi phần tử điểm ảnh chứa các giá trị số mà thiết bị thu nhận trả về. Phụ thuộc vào tính chất của phần tử điểm ảnh mà ta có các khái niệm ảnh khác nhau:

Ảnh đa cấp xám (graylevel image): Điểm ảnh là một giá trị của cường độ ánh sáng.

Ảnh màu (color image): Điểm ảnh là một vector ba thành phần, mỗi thành phần tương ứng với cường độ của một bước sóng ánh sáng như red, green và blue.

Ảnh độ sâu (depthmap): Điểm ảnh là một giá trị thể hiện khoảng cách từ camera tới đồ vật.

3.3.2. Ảnh 3 chiều (3D image)


Khái niệm ảnh 3 chiều là ảnh 2 chiều được bổ sung thêm 1 chiều. Chiều này có thể là thời gian, bước sóng ánh sáng hoặc một chiều không gian khác. Tùy thuộc vào tính chất của chiều này mà ta có các loại dữ liệu ảnh khác nhau:

3.3.2.1. Video

Video là một loại ảnh 3 chiều trong đó có 2 chiều không gian và 1 chiều thời gian. Chiều thời gian được tạo lập bằng cách tập hợp các ảnh màu 2 chiều hoặc ảnh độ sâu được thu nhận tuần tự cách nhau một khoảng thời gian cố định. Dữ liệu video thường được sử dụng nhiều trong các ứng dụng dân dụng và là đối tượng chính trong lĩnh vực nghiên cứu truyền thông đa phương tiện. Tham khảo Mục 2.6.2 trong cuốn Giáo trình Truyền thông đa phương tiện của cùng tác giả (Lê 2025).

3.3.2.2. Ảnh đa phổ


Ảnh đa phổ là một loại ảnh 3 chiều trong đó có 2 chiều không gian và 1 chiều phổ ánh sáng. Chiều phổ được tạo lập bằng tập hợp các ảnh đa cấp xám 2 chiều được thu nhận ở các bước sóng khác nhau, xem Hình 3.7. Loại ảnh này thường được sử dụng trong các ứng dụng viễn thám hoặc các ứng dụng chuyên dụng khác nhằm phân tích/khảo sát các thành phần vật chất khác nhau. Mỗi loại vật chất hoặc hợp chất hóa học sẽ phản ứng mạnh với một dải phổ ánh sáng nhất định.




Hình 3.7. Ảnh đa phổ (www.cell.com).

3.3.2.3. Ảnh cắt lớp

Ảnh cắt lớp là một loại ảnh 3 chiều trong đó cả 3 chiều đều là không gian. Một ví dụ điển hình trong trường hợp này là ảnh *cộng hưởng từ* (Magnetic Resonance Imaging – MRI) và được sử dụng nhiều trong lĩnh vực y tế, Hình 3.8. Khi đó mỗi phần tử ảnh được gắn vào một lưới 3 chiều và được gọi là *voxel*, Hình 3.9.



Hình 3.8. Ảnh cộng hưởng từ (bitfab.io).



Hình 3.9. Lưới 3 chiều Voxel (pixels.com và www.ovito.org).

Dữ liệu ảnh 2D và 3D sắp xếp các phần tử điểm ảnh vào các lưới hai chiều hoặc ba chiều. Cách biểu diễn này tiện lợi cho việc truy xuất từng phần tử ảnh trong mỗi tương quan với các điểm ảnh lân cận nhưng không hiệu quả về bộ nhớ do nhiều phần tử điểm ảnh dư thừa. Số lượng điểm ảnh tăng theo cấp số nhân với độ phân giải ảnh.

3.2.3. Đám mây điểm (cloudpoint)

Đám mây điểm (cloudpoint) là một cách để biểu diễn dữ liệu ảnh 3D trong đó cả 3 chiều đều là không gian. Thay bằng sử dụng cấu trúc dữ liệu dạng mảng 3 chiều để lưu trữ các phần tử điểm ảnh, đám mây điểm đơn giản lưu giữ một danh sách các phần tử điểm ảnh một cách độc lập, mỗi phần tử được đánh kèm theo tọa độ 3 chiều tương ứng. Ví dụ file *a.txt* mô tả bộ dữ liệu đám mây điểm trong đó mỗi điểm ảnh gồm 2 phần: phần không gian (X, Y, Z) và phần màu sắc (R, G, B).

File: *a.txt*

Vertices:

ID	X	Y	Z	R	G	B
0	0.125	1.563	3.782	255	100	80
1	0.130	1.570	3.790	254	102	81
2	0.135	1.576	3.797	253	105	83
3	0.140	1.582	3.804	252	107	84
4	0.145	1.588	3.812	251	110	86
5	0.150	1.594	3.820	250	112	88 0.88
6	0.155	1.600	3.828	249	115	90 0.82

Cách biểu diễn ảnh này mặc dù tiết kiệm được không gian bộ nhớ khi độ phân giải ảnh tăng nhưng gây bất tiện cho việc xử lý và hiển thị ảnh. Các phương pháp xử lý ảnh thường ít khi chỉ quan tâm đến duy nhất một phần tử điểm ảnh, mà thường đồng thời muốn biết một nhóm các điểm ảnh lân cận với nhau về không gian. Khi hiển thị ảnh, mặc dù đám mây điểm có thể cho phép quan sát các cấu trúc bên trong đối tượng, tuy nhiên, nhiều ứng dụng chỉ yêu cầu hiển thị hình ảnh bề mặt của đối tượng và thuật toán tái tạo bề mặt đối tượng rất khó hoạt động khi không biết mối tương quan không gian giữa các phần tử ảnh. Do đó, trong thực tiễn người ta thường biến đổi đám mây điểm về dạng dữ liệu lưới hóa (meshing).

3.2.4. Lưới hóa (meshing)

Các hệ thống thu nhận ảnh 3D nêu trên chỉ cho ra dữ liệu là các đám mây điểm hoặc ảnh độ sâu và như đã phân tích ở phần trước, dữ liệu đám mây điểm gây khó khăn cho các pha phân tích và hiển thị hình ảnh. Để giải quyết vấn đề này, phương pháp lưới hóa (meshing) nhằm bổ trợ cho đám mây điểm các liên kết giữa các phần

từ điểm ảnh lân cận để tạo nên bề mặt của đối tượng. Ví dụ file *b.txt* bổ trợ thông tin lưới bề mặt cho file *a.txt* bằng cách bổ sung các mặt tam giác kết nối 3 điểm lân cận với nhau.

File *b.txt*:

Faces (Meshed triangles) :

Face_ID	Point1_ID	Point2_ID	Point3_ID
0	0	1	2
1	1	2	3
2	2	3	4
3	3	4	5
4	4	5	6

Hình 3.10 minh họa trực quan 3 cách biểu diễn ảnh 3D. Trong đó hình bên trái là dạng đám mây điểm có nhiều chấm nhỏ, mỗi chấm tương ứng với một phần tử điểm ảnh có ba thành phần tọa độ không gian. Hình ở giữa là biểu diễn dưới dạng mảng 3 chiều với mỗi phần tử là voxel chiếm thể tích tương ứng với độ phân giải của mảng. Và hình bên phải là biểu diễn dưới dạng lưới hóa, trong đó các phần tử điểm ảnh lân cận được kết nối với nhau tạo thành hình mắt lưới trên bề mặt vật thể. Các điểm trung gian trong lưới có thể được nội suy từ các điểm lân cận và được ước lượng cường độ phản xạ ánh sáng khiến cho khối hình vật thể sống động hơn.

Point cloud

Voxel

Polygon mesh



3.10. Trực quan hóa 2 cách biểu diễn ảnh 3D.


3.4. Mô hình camera

Có thể thấy bài toán thu nhận ảnh nêu trên đều được thu gọn về việc xác định mối tương quan giữa một điểm trong không gian 3D thực với điểm ảnh của nó được chụp. Mô hình hóa sự tương quan này giúp xây dựng các phương pháp thị giác máy phân tích và hiểu được môi trường (không gian, thời gian và ánh sáng).

3.4.1. Pinhole camera


Pinhole camera (Hình 3.11) là một phương pháp toán học giúp mô hình hóa mối liên hệ giữa tọa độ của một điểm trong không gian ba chiều và hình ảnh của nó

trên mặt phẳng ảnh. Hệ thống camera này được thiết kế để thu nhận hình ảnh của một vật thể hoặc một khung cảnh từ không gian ba chiều thực tế. Cấu trúc của hệ thống camera này được đơn giản hóa thành một hộp kín có mặt song song, một mặt được đục một lỗ rất nhỏ (pinhole) để ánh sáng đi qua, mặt kia được sử dụng làm mặt phẳng ảnh (image plane). Hình dưới minh họa cách hoạt động của pinhole camera. Một vật thể 3D phát xạ/phản xạ ra các chùm tia sáng. Một số nhỏ các tia sáng đó đi qua pinhole và tạo thành 1 hình ảnh của đối tượng lên trên mặt phẳng ảnh. Đây là một ảnh thực, có chiều ngược lại so với vật thể 3D do tính chất đối xứng tâm qua pinhole. Có thể thấy rằng mỗi đối tượng 3D có thể tạo thành 1 hình ảnh của nó trên mặt phẳng ảnh, nhưng một hình ảnh trên mặt phẳng ảnh có thể kết quả chiếu sáng của nhiều đối tượng 3D.



Hình 3.11. Pinhole camera.


Do tính chất của phép chiếu hình học, kích thước và vị trí của các đối tượng 3D không được bảo toàn trên mặt phẳng ảnh. Hình 3.12 minh họa hình ảnh (A' , B' , C') của 3 đối tượng 3D (A , B , C). Có thể thấy, kích thước của A bằng C và B lớn nhất, khoảng cách của A và B đến tâm camera là như nhau. Tuy nhiên, trên mặt phẳng ảnh sự tương quan này không được bảo toàn, kích thước của B' bằng C' và đều lớn hơn A' . A' và C' dường như ngang hàng và gần với camera hơn B' . Thí nghiệm này phản ánh hiện tượng mắt người hay đánh giá sai vị trí và kích thước các sự vật khi lần đầu quan sát ở xa.



Hình 3.12. Kích thước và khoảng cách sự vật không được bảo toàn.

Parallel lines meet

Common to draw film plane
in front of the focal point.
Moving the film plane merely
scales the image.




Hình 3.13. Điểm tụ và đường tụ.

Một trong những phát hiện quan trọng của mô hình pinhole camera là khái niệm điểm tụ (vanishing point) và đường tụ (vanishing line). Phát hiện này đóng vai trò quan trọng trong nghệ thuật vẽ tranh phối cảnh nhằm đảm bảo tính logic về mặt hình học của các khối hình có các chi tiết song song với nhau như nhà cửa hay đèn đài. Hình 3.13 mô hình hóa điểm tụ và đường tụ trong đó mặt phẳng ảnh H được đặt vuông góc với mặt phẳng đối tượng Π . Trên mặt phẳng Π có một đường thẳng a kéo dài đến vô cùng (hướng kéo dài cùng hướng nhìn của camera). Các điểm chiếu của a lên mặt phẳng ảnh tạo ra một đường thẳng hội tụ tại một điểm điểm cố định A trên mặt phẳng ảnh. A được gọi là điểm tụ của đường thẳng a trên mặt phẳng ảnh.

Ta có thể tìm điểm tụ của đường thẳng a bằng cách vẽ một đường thẳng song song với a qua tâm O của pinhole camera. Nơi đường thẳng này giao với mặt phẳng ảnh chính là điểm tụ A của đường thẳng a . Bằng phương pháp hình học ta có thể chứng minh được A là điểm tụ và tất cả các đường thẳng 3D song song với a . Có thể dễ dàng thấy rằng, tập hợp các điểm tụ của các đường thẳng thuộc một mặt phẳng (ví dụ Π) sẽ tạo nên một đường thẳng trên mặt phẳng ảnh, đường thẳng này được gọi là đường tụ (vanishing line) của mặt phẳng Π .

Như vậy, mỗi mặt phẳng 3D sẽ có tương ứng một đường tụ trên mặt phẳng ảnh và tất cả các đường thẳng 3D song song với nhau đều có chung một điểm tụ trên mặt phẳng ảnh. Lợi dụng đặc điểm này, người ta có thể kiểm tra tính đúng đắn của một bức ảnh chụp, đặc biệt những ảnh chụp các công trình và kết cấu có nhiều chi tiết tạo ra các đường thẳng song song. Nếu các kết cấu được xác định là các đường thẳng song song trong không gian ba chiều thì các đường thẳng tương ứng của chúng trên ảnh sẽ hội tụ tại 1 điểm (điểm tụ). Người ta có thể kiểm tra tính chất này trên các ảnh chụp và có thể đặt nghi vấn về bức ảnh nếu các tính chất này không thỏa mãn. Xem Hình 3.14.

1482



1483

1484

Hình 3.14. Hình ảnh trực quan về điểm tụ và đường tụ.

1485

1486

1487

1488

1489

Một mô hình chính tắc cho pinhole camera có thể được phát triển như ở hình 3.15. Để đơn giản, ta định nghĩa hệ quy chiếu của thế giới 3D thống nhất với hệ quy chiếu của pinhole camera là O_{ijk} , với tâm O của trục tọa độ là khẩu độ (aperture) của camera, trục k hướng tới và vuông góc với mặt phẳng ảnh. Khoảng cách từ tâm O tới mặt phẳng ảnh được gọi là tiêu cự của máy ảnh và được ký hiệu là f .

1490

1491

1492

1493


1494

1495

Kí hiệu $P_c = [X \ Y \ Z]^T$ là một điểm 3D nằm trong thị trường của pinhole camera. Điểm P_c được chiếu lên mặt phẳng ảnh tạo ra điểm ảnh $p' = [x' \ y']^T$. Tương tự như vậy, tâm O của trục tọa độ có thể được chiếu lên mặt phẳng ảnh và được điểm C' . Lúc này đường thẳng nối điểm O và C' được gọi là trục quang học của hệ thống máy ảnh. Do tam giác $P'C'O$ đồng dạng với tam giác được tạo bởi P , O và $(0,0,Z)$, nên ta có mối liên hệ giữa :

1496

$$p' = [x' \ y']^T = \left[f \frac{x}{z} \ f \frac{y}{z} \right]^T, \quad (3.1)$$



1497

1498

Hình 3.15. Mô hình pinhole camera

1499

1500

Xét trường hợp điểm P_c thuộc một đường thẳng được mô tả dưới dạng tham số như sau:

1501

$$P_c = \begin{bmatrix} a_x t + b_x \\ a_y t + b_y \\ a_z t + b_z \end{bmatrix}, \quad (3.2)$$

1502 trong đó a_x, a_y, a_z là các hệ số định hướng của đường thẳng và b_x, b_y, b_z là các hệ
1503 số tịnh tiến để tạo ra các đường thẳng song song. Khi đó, điểm tụ của đường thẳng
1504 này được xác định:

$$1505 \quad \mathbf{p}'_v = \lim_{t \rightarrow \infty} \begin{bmatrix} f \frac{a_x t + b_x}{a_z t + b_z} \\ f \frac{a_y t + b_y}{a_z t + b_z} \end{bmatrix} = \begin{bmatrix} f \frac{a_x}{a_z} \\ f \frac{a_y}{a_z} \end{bmatrix} = f \cdot \begin{bmatrix} \frac{a_x}{a_z} \\ \frac{a_y}{a_z} \end{bmatrix}. \quad (3.3)$$

1506 Tọa độ điểm tụ chỉ phụ thuộc vào hướng của đường thẳng và các đường thẳng
1507 song song có chung cùng một hướng sẽ có cùng một điểm tụ trên mặt phẳng ảnh.

1508 Giả sử các hệ định hướng và hệ số tịnh tiến cần được lựa chọn sao cho P nằm
1509 trong một mặt phẳng cho trước, tức là ta có phương trình ràng buộc mặt phẳng sau
1510 sau:

$$1511 \quad (a_x t + b_x)X + (a_y t + b_y)Y + (a_z t + b_z)Z + d_0 = 0, \quad (3.4)$$

1512 trong đó d_0 là hệ số tịnh tiến mặt phẳng. Chia cả hai vế cho $(a_z t + b_z)$, ta được:

$$1513 \quad \frac{a_x t + b_x}{a_z t + b_z} X + \frac{a_y t + b_y}{a_z t + b_z} Y + Z + \frac{d_0}{(a_z t + b_z)} = 0.$$

1514 Khi $t \rightarrow \infty$, ràng buộc trên trở thành:


$$1515 \quad \frac{a_x}{a_z} X + \frac{a_y}{a_z} Y + Z = 0. \quad (3.5)$$

1516


1517 Ràng buộc này là một quan hệ tuyến tính giữa hai thành phần của điểm tụ $\mathbf{p}'_v$
1518 và tập hợp các điểm tụ $\mathbf{p}'_v$ thỏa mãn ràng buộc này ta được đường tụ (vanishing
1519 line) của mặt phẳng trong công thức (3.5).

1520 3.4.2. Camera với thấu kính

1521 Thiết kế pinhole camera đưa ra giả định khẩu độ của máy ảnh chỉ là 1 điểm.
1522 Trong thực tế giả định này không vững do một điểm không có diện tích thì không
1523 thể cho ánh sáng đi qua. Khẩu độ quá nhỏ không chỉ cho quá ít ánh sáng đi qua mà
1524 còn gây hiện tượng nhiễu xạ ánh sáng và làm mờ ảnh. Khẩu độ quá to khiến kích
1525 thước điểm sáng trên nền ảnh quá lớn và cũng làm mờ ảnh. Hình 3.16 là một ví dụ
1526 về ảnh thu nhận được tùy thuộc kích thước của khẩu độ.




Hình 3.16. Ảnh hưởng của khẩu độ đến độ nét của hình ảnh trên mặt phẳng ảnh.



Hình 3.17. Sử dụng thấu kính để thay thế pinhole.

Vấn đề liên quan đến khẩu độ của pinhole camera có thể được giải quyết bằng cách đặt một thấu kính hội tụ vào vị trí pinhole, Hình 3.17. Trong điều kiện lý tưởng là thấu kính hội tụ có độ dày không đáng kể, có thể hướng tất cả các tia sáng xuất

1534 phát từ điểm P vào một điểm duy nhất trên mặt phẳng ảnh p' . Khi đó phương trình
 1535 liên hệ giữa P và p' vẫn được bảo toàn như trong trường hợp pinhole camera. Tuy
 1536 nhiên, thực tế độ dày của thấu kính và đặc điểm của phổ ánh sáng tạo ra các hiệu
 1537 ứng quang sai:



1538
 1539 **Hình 3.18. Quang sai: (a) quang sai cầu (b) quang sai biến dạng (c) quang sai phổ.**

1540 Hình 3.18 cho thấy một số loại quang sai do ảnh hưởng của thấu kính. Quang
 1541 sai cầu (a) xảy ra khi thấu kính quá dày khiến cho việc hội tụ ánh sáng không đều
 1542 trên toàn bộ bề mặt thấu kính. Vùng màu xám cận trục hội tụ các tia sáng từ điểm
 1543 P tới điểm p' trên mặt phẳng ảnh. Nhưng những vùng còn lại hội tụ các tia sáng tới
 1544 các điểm phía trước (hoặc phía sau) của mặt phẳng ảnh khiến cho hình ảnh của
 1545 điểm P xuất hiện trên mặt phẳng ảnh như những đốm hình tròn và làm cho toàn bộ
 1546 ảnh bị mờ. Quang sai biến dạng (b) xảy ra do thiết kế hình học của thấu kính làm
 1547 cho việc hội tụ tia sáng không đồng nhất giữa các điểm ở gần trục quang học và ở
 1548 xa trục quang học. Hiện tượng này làm cho hình ảnh đối tượng bị biến dạng, đặc
 1549 biệt ở những vùng rìa của ảnh. Quang sai phổ (c) xảy ra do mức độ khúc xạ ánh
 1550 sáng phụ thuộc vào bước sóng (màu) ánh sáng.


1551 3.4.2. Tham số camera

1552 Hệ thống camera thực không chỉ thay thế pinhole bằng một thấu kính hội tụ
 1553 mà còn thay thế mặt phẳng ảnh pinhole C' bằng màng cảm biến ánh sáng vật lý (từ
 1554 giờ ta gọi chung là mặt phẳng ảnh vật lý) C . Mô hình hóa camera là việc xác định

các tham số cần thiết tham gia vào quá trình ánh xạ $\mathbb{R}^3 \rightarrow \mathbb{R}^2$ của 1 điểm trong không gian thực 3 chiều $\mathbf{P} = [X \ Y \ Z]^T$ tới một điểm ảnh $\mathbf{p} = [x \ y]^T$ trong không gian mặt phẳng ảnh vật lý C . Việc mô hình hóa này liên quan một loạt các tham số như tiêu cự thấu kính, kích thước điểm ảnh, điểm đặt tâm của camera, vị trí và hướng của camera.

Để đơn giản hóa, người ta chia thành hai bộ tham số: tham số nội và tham số ngoại. Tham số nội camera chỉ liên quan đến những yếu tố nội tại của camera như thấu kính, vị trí đặt của mặt phẳng ảnh vật lý so với thấu kính, ... tham số ngoại liên quan đến vị trí và độ xoay của camera so với môi hệ tọa độ thực (world coordinate).

3.4.2.1. Tham số nội camera



3.19. Mô hình hóa tham số nội camera.

Mô hình hóa tham số nội camera có thể được mô tả như trong Hình 3.19. Trong đó hệ tọa độ thực được đồng nhất với hệ tọa độ của camera O_{ijk} . Hệ tọa độ ảnh vật lý C_{xy} và điểm $\mathbf{p}$ trên hệ tọa độ ảnh là điểm được chiếu từ điểm $\mathbf{P}_c$ từ hệ quy chiếu camera O_{ijk} .

Để đơn giản việc mô hình hóa, ta bổ sung thêm hệ tọa độ ảnh của pinhole camera $\hat{C}_{\hat{x}\hat{y}}$ và đặt giả thuyết mặt phẳng xCy song song với mặt phẳng $\hat{x}\hat{C}\hat{y}$ và mặt phẳng iOj và trục Cx song song với trục $\hat{C}\hat{y}$ và trục Oi . Ký hiệu điểm $\hat{\mathbf{p}}$ là điểm chiếu của $\mathbf{P}_c$ trên mặt phẳng ảnh pinhole, khi đó ta có:

$$\hat{\mathbf{p}} = \begin{bmatrix} \hat{x} \\ \hat{y} \end{bmatrix} = \begin{bmatrix} f \frac{X}{Z} \\ f \frac{Y}{Z} \end{bmatrix} = \frac{1}{Z} \begin{bmatrix} f & 0 & 0 \\ 0 & f & 0 \end{bmatrix} \mathbf{P}_c. \quad (3.6)$$

Do tính chất vật lý của bộ cảm biến nên mặt phẳng ảnh thực có thể bị co giãn với các hệ số không đồng đều so với mặt phẳng ảnh pinhole, nên ta có liên hệ thông qua các hệ số co giãn (scale paramters) sau:

$$\mathbf{p} = \begin{bmatrix} k & 0 \\ 0 & l \end{bmatrix} \hat{\mathbf{p}} = \frac{1}{Z} \begin{bmatrix} k.f & 0 & 0 \\ 0 & l.f & 0 \end{bmatrix} = \frac{1}{Z} \begin{bmatrix} s_x & 0 & 0 \\ 0 & s_y & 0 \end{bmatrix} \mathbf{P}_c,$$

trong đó k và l là các hệ số co giãn (scale) tương ứng với các trục x và y giữa mặt phẳng ảnh vật lý và mặt phẳng ảnh pinhole. Bên cạnh đó, do giới hạn công nghệ

sản xuất các mảng cảm biến mà 2 trục của mặt phẳng vật lý có thể không hoàn toàn vuông góc với nhau, mà tạo với nhau một góc θ , khi đó ta có:

$$\mathbf{p} = \frac{1}{Z} \begin{bmatrix} s_x & -s_x \cdot \cot \theta & 0 \\ 0 & \frac{s_y}{\sin \theta} & 0 \end{bmatrix} \mathbf{P}_c$$

Bên cạnh đó, thông thường điểm đặt trục tọa độ mặt phẳng ảnh vật lý luôn có tâm ở một góc của ảnh còn điểm đặt trục tọa độ của mặt phẳng ảnh pinhole camera luôn ở tâm của ảnh, nên cần bổ sung tham số tịnh tiến (translation) sau:

$$\mathbf{p} = \frac{1}{Z} \left(\begin{bmatrix} s_x & -s_x \cdot \cot \theta & 0 \\ 0 & \frac{s_y}{\sin \theta} & 0 \end{bmatrix} \mathbf{P}_c + \begin{bmatrix} x_0 \\ y_0 \end{bmatrix} \right).$$

Khi viết dưới dạng ma trận chuyển đổi đồng cấu (homogeneous transformation matrices), ta được:


$$\begin{bmatrix} \frac{x}{Z} \\ \frac{y}{Z} \\ 1 \end{bmatrix} \sim \begin{bmatrix} x \\ y \\ Z \end{bmatrix} = \begin{bmatrix} s_x & -s_x \cdot \cot \theta & x_0 \\ 0 & \frac{s_y}{\sin \theta} & y_0 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} X \\ Y \\ Z \end{bmatrix} = \mathcal{K} \cdot \mathbf{P}_c, \quad (3.7)$$

và $\mathcal{K} = \begin{bmatrix} s_x & -s_x \cdot \cot \theta & x_0 \\ 0 & \frac{s_y}{\sin \theta} & y_0 \\ 0 & 0 & 1 \end{bmatrix}$ được gọi là ma trận tham số nội camera. Giả sử góc giữa hai trục của mặt phẳng vật lý $\theta = 90^\circ$, khi đó ta có:

$$\mathcal{K} = \begin{bmatrix} f_x & 0 & x_0 \\ 0 & f_y & y_0 \\ 0 & 0 & 1 \end{bmatrix}, \quad (3.8)$$

với f_x và f_y là các tiêu cự theo hai trục.

3.4.2.2. Tham số ngoại camera



Hình 3.20. Mô hình hóa tham số ngoại camera.

Mô hình hóa tham số ngoại camera là việc xác định các tham số liên hệ giữa vị trí và hướng nhìn của camera so với hệ tọa độ thực (world coordinate). Hình 3.20 cho thấy mối liên hệ giữa hệ tọa độ 3 chiều của camera và hệ tọa độ 3 chiều trong không gian thực (world coordinate). Do camera là có thể di chuyển và có thể thay đổi hướng nhìn trong không gian thực, ta cần 1 bộ tham số để mô tả mối liên hệ

giữa hai hệ tọa độ này, chúng được gọi là các tham số ngoại camera (extrinsic parameters).

Trong các ứng dụng thực tế, rất bất tiện để xác định tọa độ của một điểm trong không gian thực trực tiếp tới hệ tọa độ của camera. Do đó, ta cần 1 phép chuyển hệ tọa độ từ không gian thực $O_W i_w j_w k_w$ sang không gian camera $O_j i j k$.

Đầu tiên, ta giả 2 hệ tọa độ là đồng nhất tức là $O_W i_w j_w k_w \equiv O_j i j k$, khi đó:

$$\mathbf{P}_c = \mathbf{R} \cdot \mathbf{P}, \quad (3.9)$$

trong đó $\mathbf{P}_c$ và $\mathbf{P}$ là biểu diễn của cùng 1 điểm trong không gian camera và trong không gian thực, $\mathbf{R}$ là ma trận xoay (rotation matrix). Do hai hệ tọa độ là đồng nhất

nên ma trận xoay là ma trận đơn vị $\mathbf{R} = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}$.

Trong trường hợp hai hệ tọa độ có chung điểm gốc tọa độ, nhưng hệ tọa độ camera xoay theo một hướng khác so với hệ tọa độ thực. Không mất tính tổng quát, ta có thể phân rã thành độ xoay của từng trục. Ký hiệu α , β , và γ là góc xoay tương ứng với từng trục z, y và x. Khi đó ma trận xoay quay của từng trục $\mathbf{R}_x$, $\mathbf{R}_y$ và $\mathbf{R}_z$ được xác định như sau:

$$\mathbf{R}_x = \begin{bmatrix} 1 & 0 & 0 \\ 0 & \cos \gamma & -\sin \gamma \\ 0 & \sin \gamma & \cos \gamma \end{bmatrix}, \mathbf{R}_y = \begin{bmatrix} \cos \beta & 0 & \sin \beta \\ 0 & 1 & 0 \\ -\sin \beta & 0 & \cos \beta \end{bmatrix}$$

và

$$\mathbf{R}_z = \begin{bmatrix} \cos \alpha & -\sin \alpha & 0 \\ \sin \alpha & \cos \alpha & 0 \\ 0 & 0 & 1 \end{bmatrix}.$$

Khi đó ma trận chuyển được tính là tích của các ma trận xoay như sau:

$$\mathbf{R} = \mathbf{R}_x \cdot \mathbf{R}_y \cdot \mathbf{R}_z$$

$$= \begin{bmatrix} \cos \beta \cos \gamma & \sin \alpha \sin \beta \cos \gamma - \cos \alpha \sin \gamma & \cos \alpha \sin \beta \cos \gamma + \sin \alpha \sin \gamma \\ \cos \beta \sin \gamma & \sin \alpha \sin \beta \sin \gamma + \cos \alpha \cos \gamma & \cos \alpha \sin \beta \sin \gamma - \sin \alpha \cos \gamma \\ -\sin \beta & \sin \alpha \cos \beta & \cos \alpha \cos \beta \end{bmatrix}.$$

Có thể thấy thứ tự phép nhân (thứ tự xoay giữa các trục) không ảnh hưởng đến kết quả cuối của ma trận $\mathbf{R}$.

Cuối cùng, tọa độ camera tịnh tiến trong hệ tọa độ thực theo véc tơ $\mathbf{t} = [X_0 \ Y_0 \ Z_0]^T$, khi đó công thức chuyển đổi giữa hai hệ tọa độ như sau:

$$\mathbf{P}_c = \mathbf{R} \cdot \mathbf{P} + \mathbf{t}.$$

Viết lại công thức chuyển đổi dưới dạng ma trận chuyển đổi đồng cấu (homogeneous transformation matrices) ta được:

$$\mathbf{P}_c = [\mathbf{R} \ \mathbf{t}] \begin{bmatrix} \mathbf{P} \\ 1 \end{bmatrix}. \quad (3.10)$$

Trong đó $\mathbf{R}$ và $\mathbf{T}$ được gọi là ma trận tham số ngoại của camera. Cuối cùng, kết hợp chuyển đổi của ma trận tham số nội và ma trận tham số ngoại của camera ta được:

$$\begin{bmatrix} p \\ 1 \end{bmatrix} = \begin{bmatrix} \frac{x}{Z} \\ \frac{y}{Z} \\ 1 \end{bmatrix} \sim \begin{bmatrix} x \\ y \\ Z \end{bmatrix} = \mathcal{K}[\mathbf{R} \quad \mathbf{t}] \begin{bmatrix} \mathbf{P} \\ 1 \end{bmatrix} = \mathcal{M} \begin{bmatrix} \mathbf{P} \\ 1 \end{bmatrix}. \quad (3.11)$$

Có thể thấy rằng quá trình một đối tượng điểm trong không gian 3 chiều $\mathbf{P}$ khi được chụp bằng camera xuất hiện trên nền ảnh dưới dạng một điểm ảnh 2 chiều ở tọa độ $\mathbf{p}$ có thể được mô hình hóa bằng ma trận tham số camera $\mathcal{M}$, ma trận này được cấu thành bởi: ma trận tham số nội $\mathcal{K}$ có 5 tham số, ma trận xoay $\mathbf{R}$ có 3 tham số và vector tịnh tiến $\mathbf{t}$ có 3 tham số.

Giả sử ta có điểm $p_0 = [x_0 \ y_0]^T$ trên mặt phẳng ảnh, từ (3.11) ta tính được tọa độ điểm chiếu tương ứng của nó trong không gian thực là:

$$\mathbf{P} = \mathbf{R}^T \left(Z \mathcal{K}^{-1} \begin{bmatrix} x_0 \\ y_0 \\ 1 \end{bmatrix} - \mathbf{t} \right). \quad (3.12)$$


Do độ sâu Z chưa được xác định nên không thể biết được chính xác tọa độ điểm $\mathbf{P}$. Thay vào đó, $\mathbf{P}$ có thể là bất cứ điểm nào nằm trên tia:

$$\mathbf{r}(\lambda) = \lambda \mathbf{R}^T \mathcal{K}^{-1} \begin{bmatrix} x_0 \\ y_0 \\ 1 \end{bmatrix} - \mathbf{R}^T \mathbf{t}. \quad (3.13)$$

3.4.3. Xác định tham số camera

3.4.3.1. Hiệu chỉnh camera

Để mô hình hóa chính xác sự chuyển đổi hình ảnh từ môi trường 3D thực vào không gian ảnh, ta phải biết được các tham số nội. Với một camera cho trước, ta có thể hoặc không thể trực tiếp tiếp cận được các tham số này. Trong khi đó, ta luôn luôn có thể sử dụng camera để thu nhận ảnh. Câu hỏi đặt ra là, liệu ta có thể suy đoán được các tham số camera chỉ thông qua các hình ảnh được thu nhận từ camera đó? Qua trình suy đoán này được gọi là hiệu chỉnh camera (camera calibration).



Hình 3.21. Sắp đặt hiệu chỉnh camera.

Các kỹ thuật hiệu chỉnh camera thường dựa trên các sắp đặt sao cho có thể dễ dàng xác lập được các cặp điểm trong không gian thực $\mathbf{P}_i = [X_i \ Y_i \ Z_i]^T$ với hình ảnh của nó trong không gian ảnh $\mathbf{p} = [x_i \ y_i]$. Hình 3.21 là 1 ví dụ của sắp đặt hiệu chỉnh camera trong đó bên trái là một mẫu ba chiều đã xác lập gốc tọa độ O_W cùng với 3 trục i_W, j_W và k_W . Hình bên trái là một ảnh chụp mẫu. Ta có thể dễ dàng xác định các cặp điểm $(\mathbf{p}_i, \mathbf{P}_i)$ bằng mắt hoặc các cơ chế tự động. Gọi $\mathbf{m}_1, \mathbf{m}_2$ và $\mathbf{m}_3$ là 3 vector của ma trận tham số $\mathcal{M}$. Chuyển biểu diễn dưới dạng ma trận chuyển đồng cấu thành biểu diễn ma trận chuyển thông thường, với mỗi cặp $(\mathbf{p}_i, \mathbf{P}_i)$ ta có phương trình sau:

$$\mathbf{p}_i = \begin{bmatrix} x_i \\ y_i \end{bmatrix} = \begin{bmatrix} \mathbf{m}_1 \mathbf{P}_i \\ \mathbf{m}_3 \mathbf{P}_i \\ \mathbf{m}_2 \mathbf{P}_i \\ \mathbf{m}_3 \mathbf{P}_i \end{bmatrix}, \quad (3.14)$$

hay

$$x_i(\mathbf{m}_3 \mathbf{P}_i) - \mathbf{m}_1 \mathbf{P}_i = 0 \text{ và } y_i(\mathbf{m}_3 \mathbf{P}_i) - \mathbf{m}_2 \mathbf{P}_i = 0.$$


Có thể thấy rằng mỗi cặp $(\mathbf{p}_i, \mathbf{P}_i)$ có 2 phương trình ràng buộc để tìm ra ma trận tham số $\mathcal{M}$. Do ma trận $\mathcal{M}$ được cấu thành 11 tham số (5 tham số nội camera, 3 tham số cho góc quay camera và 3 tham số tịnh tiến camera), nên ta cần tối thiểu 6 cặp $(\mathbf{p}_i, \mathbf{P}_i)$ để xác định được ma trận chuyển $\mathcal{M}$. Giả sử ta có n cặp, khi đó ta có hệ phương trình sau:

$$\begin{bmatrix} \mathbf{P}_1^T & \mathbf{0}^T & -x_1 \mathbf{P}_1^T \\ \mathbf{0}^T & \mathbf{P}_1^T & -y_1 \mathbf{P}_1^T \\ \vdots & \vdots & \vdots \\ \mathbf{P}_n^T & \mathbf{0}^T & -x_n \mathbf{P}_n^T \\ \mathbf{0}^T & \mathbf{P}_n^T & -y_n \mathbf{P}_n^T \end{bmatrix} \begin{bmatrix} \mathbf{m}_1^T \\ \mathbf{m}_2^T \\ \mathbf{m}_3^T \end{bmatrix} = \mathcal{P} \cdot \mathcal{M} = \mathbf{0} \quad (3.15)$$


Với $n \geq 6$, hệ phương trình tuyến tính trên trở nên thừa điều kiện để giải $\mathcal{M}$. Có thể thấy $\mathcal{M} = \mathbf{0}$ là một nghiệm đương nhiên và duy nhất của hệ trên. Do đó, việc giải tìm $\mathcal{M}$ có thể được chuyển thành bài toán tối ưu sau:

$$\begin{aligned} & \underset{\mathcal{M}}{\text{Minimize}} \quad \|\mathcal{P} \cdot \mathcal{M}\|^2 \\ & \text{subject to} \quad \|\mathcal{M}\|^2 = 1. \end{aligned} \quad (3.16)$$

Bài toán tối ưu trên có thể giải được sử dụng phương pháp SVD (singular value decomposition) tham khảo ở **Mục 5.3** trong (Hartley 2004) và thu được các ma trận tham số nội $\mathcal{K}$, ma trận xoay $\mathbf{R}$ và vector tịnh tiến $\mathbf{t}$.



Hình 3.22. Mẫu hiệu chỉnh camera.



Hình 3.23. Trục quan tham số ngoại: (a) hệ tọa độ camera, (b) hệ tọa độ thực.

3.4.3.2. Tính toán ma trận tham số nội

Hầu hết các file ảnh ví dụ (.jpg) có lưu trữ một phần siêu dữ liệu (metadata) EXIF đặc tả thiết bị chụp ảnh như: Focal length (F_l – ví dụ 4.25 mm), kích thước cảm biến ($S_w \times S_h$ - ví dụ $6.16 \times 4.62\text{ mm}$) và độ phân giải của ảnh ($I_w \times I_h$ - ví dụ $1920 \times 1080\text{ px}$). Khi đó, các phần tử của ma trận tham số nội $\mathcal{K}$ có thể được tính như sau:


$$\mathcal{K} = \begin{bmatrix} f_x & 0 & x_0 \\ 0 & f_y & y_0 \\ 0 & 0 & 1 \end{bmatrix} = \begin{bmatrix} \frac{f_l \cdot I_w}{S_w} & 0 & \frac{I_w}{2} \\ 0 & \frac{f_l \cdot I_h}{S_h} & \frac{I_h}{2} \\ 0 & 0 & 1 \end{bmatrix} = \begin{bmatrix} 1324.68 & 0 & 960 \\ 0 & 993.51 & 540 \\ 0 & 0 & 1 \end{bmatrix}.$$

3.4.4. Camera song khung hình với không gian 3D

Bộ tham số (tham số nội, tham số ngoại) cung cấp một phép biến đổi một điểm ảnh 3D trong không gian thực vào mặt phẳng ảnh. Tuy nhiên, một điểm trên mặt

phẳng ảnh không cho ta biết cấu trúc 3D của không gian thực do thông tin 3D đã bị mất. Phần này ta sẽ xem xét khả năng tái tạo cấu trúc 3D thông qua hệ thống camera nhiều khung hình.

3.4.4.1. Camera song khung hình



Hình 3.24. Camera song khung hình.

Camera song khung hình thu nhận đồng thời hai hình ảnh ở hai hướng khác nhau, xem Hình 3.24. Giả sử hai camera đã được hiệu chỉnh với các ma trận tham số đã được thiết lập.

Ký hiệu:

- $\mathcal{M}_L = \mathcal{K}_L[\mathbf{R}_L \quad \mathbf{t}_L]$ là bộ tham số của camera trái,
- $\mathcal{M}_R = \mathcal{K}_R[\mathbf{R}_R \quad \mathbf{t}_R]$ là bộ tham số của camera phải,
- $\mathbf{P} = [X \ Y \ Z]^T$ là một điểm trong không gian thực và cần được xác định thông qua camera song khung hình,
- $\mathbf{p}_L$ và $\mathbf{p}_R$ là điểm ảnh của $\mathbf{P}$ lên ảnh trái và ảnh phải.

Ta có $\mathbf{P}$ đồng thời nằm trên tia:

$$\mathbf{r}_L(\lambda_L) = \lambda_L \mathbf{R}_L^T \mathcal{K}_L^{-1} \begin{bmatrix} \mathbf{p}_L \\ 1 \end{bmatrix} - \mathbf{R}_L^T \mathbf{t}_L \quad (3.17)$$

và tia:

$$\mathbf{r}_R(\lambda_R) = \lambda_R \mathbf{R}_R^T \mathcal{K}_R^{-1} \begin{bmatrix} \mathbf{p}_R \\ 1 \end{bmatrix} - \mathbf{R}_R^T \mathbf{t}_R. \quad (3.18)$$

Có nghĩa là để xác định được $\mathbf{P}$, ta cần tìm λ_L và λ_R sao cho:

$$\mathbf{r}_L(\lambda_L) - \mathbf{r}_R(\lambda_R) = 0. \quad (3.19)$$

Đặt:

- $\mathbf{c}_L = \mathbf{R}_L^T \mathbf{t}_L$ là tâm của camera trái,
- $\mathbf{c}_R = \mathbf{R}_R^T \mathbf{t}_R$ là tâm của camera phải,
- $\mathbf{e} = \mathbf{c}_R - \mathbf{c}_L$ là đoạn nối 2 tâm của 2 camera,
- $\mathbf{u}_L = \mathbf{R}_L^T \mathcal{K}_L^{-1} \begin{bmatrix} \mathbf{p}_L \\ 1 \end{bmatrix}$ là hướng của tia nối $\mathbf{c}_L$, $\mathbf{p}_L$ và $\mathbf{P}$, và
- $\mathbf{u}_R = \mathbf{R}_R^T \mathcal{K}_R^{-1} \begin{bmatrix} \mathbf{p}_R \\ 1 \end{bmatrix}$ là hướng của tia nối $\mathbf{c}_R$, $\mathbf{p}_R$ và $\mathbf{P}$.

Khi đó (3.19) trở thành:

$$\begin{bmatrix} \mathbf{u}_L & -\mathbf{u}_R \end{bmatrix} \begin{bmatrix} \lambda_L \\ \lambda_R \end{bmatrix} = \mathbf{e}. \quad (3.20)$$

Do $\begin{bmatrix} \mathbf{u}_L & -\mathbf{u}_R \end{bmatrix} \in \mathbb{R}^{3 \times 2}$ nên (3.18) chỉ có thể giải được bằng phương pháp bình phương tối thiểu, ta được:

$$\begin{bmatrix} \lambda_L \\ \lambda_R \end{bmatrix} = \left(\begin{bmatrix} \mathbf{u}_L \\ \mathbf{u}_R \end{bmatrix} \begin{bmatrix} \mathbf{u}_L & -\mathbf{u}_R \end{bmatrix} \right)^{-1} \cdot \begin{bmatrix} \mathbf{u}_L \\ \mathbf{u}_R \end{bmatrix} \cdot \mathbf{e}. \quad (3.21)$$

Viết tường minh ta được:

$$\lambda_L = \frac{u_{RR}u_{LE} - u_{LR}u_{RE}}{u_{LL}u_{RR} - (u_{LR})^2} \text{ và } \lambda_R = \frac{u_{LR}u_{LE} - u_{LL}u_{RE}}{u_{LL}u_{RR} - (u_{LR})^2}, \quad (3.22)$$

trong đó các giá trị trung gian là các tích vô hướng:

- $u_{LL} = \mathbf{u}_L \cdot \mathbf{u}_L$, $u_{RR} = \mathbf{u}_R \cdot \mathbf{u}_R$ và $u_{LR} = \mathbf{u}_L \cdot \mathbf{u}_R$.
- $u_{LE} = \mathbf{u}_L \cdot \mathbf{e}$ và $u_{RE} = \mathbf{u}_R \cdot \mathbf{e}$.

Điều đó có nghĩa là nếu biết các bộ tham số của camera trái $\mathcal{M}_L = \mathcal{K}_L[\mathbf{R}_L \ \mathbf{t}_L]$ và bộ tham số của camera phải $\mathcal{M}_R = \mathcal{K}_R[\mathbf{R}_R \ \mathbf{t}_R]$, có thể tính được tọa độ của điểm $\mathbf{P}$ trong không gian thực từ hai điểm ảnh $\mathbf{p}_L$ và $\mathbf{p}_R$ của hai ảnh.

Mục 3.4.4 hướng dẫn cách xác định bộ tham số camera $\mathcal{M}$ bằng việc sử dụng các mẫu hiệu chỉnh camera. Tuy nhiên, trong nhiều ứng dụng thực tế ta chỉ có dữ liệu ảnh nên chỉ có thể ước lượng các bộ tham số này một cách gián tiếp.

Theo định nghĩa, mặt epipolar là mặt phẳng đi qua 3 điểm $\mathbf{c}_L$, $\mathbf{c}_R$ và $\mathbf{P}$. Do $\mathbf{e}$ nằm trong mặt phẳng epipolar còn $\mathbf{u}_L$ và $\mathbf{u}_R$ đều song song với mặt phẳng này, nên tích có hướng của $\mathbf{e}$ với $\mathbf{u}_L$ (vector pháp tuyến của mặt phẳng epipolar) vuông góc với $\mathbf{u}_R$, hay:

$$(\mathbf{e} \times \mathbf{u}_L)^T \cdot \mathbf{u}_R = 0.$$

Ký hiệu $[\mathbf{e}]_{\times} = \begin{bmatrix} 0 & -e_z & e_y \\ e_z & 0 & -e_x \\ -e_y & e_x & 0 \end{bmatrix}$ là ma trận *phản đối xứng* (skew-symmetric) của vector $\mathbf{e} = [e_x \ e_y \ e_z]^T$, khi đó ta có:

$$\mathbf{u}_L^T \cdot [\mathbf{e}]_{\times} \cdot \mathbf{u}_R = 0. \quad (3.23)$$

Thay $\mathbf{u}_L$ và $\mathbf{u}_R$ bằng các biểu thức của tham số camera ta được:

$$\left(\mathbf{R}_L^T \cdot \mathcal{K}_L^{-1} \cdot \begin{bmatrix} \mathbf{p}_L \\ 1 \end{bmatrix} \right)^T \cdot [\mathbf{e}]_{\times} \cdot \mathbf{R}_R^T \mathcal{K}_R^{-1} \cdot \begin{bmatrix} \mathbf{p}_R \\ 1 \end{bmatrix} = 0,$$

viết lại ta được:

$$\begin{bmatrix} \mathbf{p}_L \\ 1 \end{bmatrix}^T \cdot \mathcal{K}_L^{-T} \cdot (\mathbf{R}_L \cdot [\mathbf{e}]_{\times} \cdot \mathbf{R}_R^T) \cdot \mathcal{K}_R^{-1} \cdot \begin{bmatrix} \mathbf{p}_R \\ 1 \end{bmatrix} = 0. \quad (3.24)$$

Đặt:

- $\mathbf{E} = \mathbf{R}_L \cdot [\mathbf{e}]_{\times} \cdot \mathbf{R}_R^T$ là ma trận Essential, và
- $\mathbf{F} = \mathcal{K}_L^{-T} \cdot \mathbf{E} \cdot \mathcal{K}_R^{-1}$ là ma trận Fundamental.

1748 ta có ràng buộc epipolar giữa hai hình chiếu của một điểm 3 chiều lên camera song
1749 khung hình như sau:

$$1750 \quad \begin{bmatrix} \mathbf{p}_L \\ 1 \end{bmatrix}^T \cdot \mathbf{F} \cdot \begin{bmatrix} \mathbf{p}_R \\ 1 \end{bmatrix} = 0. \quad (3.25)$$

1751 Viết chi tiết ta được:

$$1752 \quad \begin{bmatrix} x_L \\ y_L \\ 1 \end{bmatrix}^T \cdot \mathbf{F} \cdot \begin{bmatrix} x_R \\ y_R \\ 1 \end{bmatrix} = 0. \quad (3.26)$$

1753 Thuật toán 8-điểm trong (Hartley 1997) cho phép ước lượng được ma trận
1754 Fundamental $\mathbf{F}$ sử dụng 8 cặp điểm $(\mathbf{p}_L, \mathbf{p}_R)$ tương ứng từ 2 ảnh I_L và I_R .

1755 Nếu đã biết ma trận tham số nội $\mathcal{K}_L$ và $\mathcal{K}_R$ của hai camera (xem mục 3.4.4),
1756 ma trận Essential có thể được tính từ $\mathbf{F}$ theo công thức sau:

$$1757 \quad \mathbf{E} = \mathcal{K}_L^T \cdot \mathbf{F} \cdot \mathcal{K}_R. \quad (3.27)$$

1758 Trong nhiều trường hợp, hai camera có cấu hình tương tự nhau và có cùng một ma
1759 trận tham số nội $\mathcal{K}$, thì:

$$1760 \quad \mathbf{E} = \mathcal{K}^T \cdot \mathbf{F} \cdot \mathcal{K}. \quad (3.28)$$

1761 Ngoài ra, $\mathcal{K}_L$ và $\mathcal{K}_R$ có thể thu được bằng phương pháp tự hiệu chỉnh
1762 (autocalibration) trong Hartley (1997b). Trong đó, Hartley đã chứng minh rằng có
1763 thể tính được các ma trận tham số nội từ các phương trình Kruppa thông qua ma
1764 trận Fundamental $\mathbf{F}$.

1765 Hình 3.24 trực quan hóa mối liên quan giữa hai hình chiếu của một điểm ba
1766 chiều lên hai khung hình. Giả sử ta đã có ma trận $\mathbf{F}$ và hình chiếu của điểm ba chiều
1767 $\mathbf{P}$ lên camera trái (x_L, y_L) , ta có:

$$1768 \quad \begin{bmatrix} x_L \\ y_L \\ 1 \end{bmatrix}^T \cdot \mathbf{F} \cdot \begin{bmatrix} x_R \\ y_R \\ 1 \end{bmatrix} = \begin{bmatrix} a \\ b \\ c \end{bmatrix}^T \cdot \begin{bmatrix} x_R \\ y_R \\ 1 \end{bmatrix} = 0,$$


1769 hay

$$1770 \quad ax_R + by_R + c = 0$$

1771 là phương trình đường thẳng epipolar tương ứng của điểm (x_L, y_L) ở ảnh bên trái.

1772 Để dễ hiểu ta có thể hình dung một ví dụ như sau: Giả sử điểm 3 chiều $\mathbf{P}$
1773 chuyển động trên tia $\mathbf{u}_L$ (tia đi qua tâm $\mathbf{c}_L$ của camera trái). Ảnh của $\mathbf{P}$ tạo ra trên
1774 camera trái là một điểm duy nhất (x_L, y_L) . Nhưng nó sẽ tạo ra một đường thẳng trên
1775 camera trái, hướng và vị trí của đường thẳng này được xác định bởi ma trận $\mathbf{F}$.

1776 3.4.4.2. Stereo camera



Hình 3.4. Thị sai trong ảnh nổi.

Stereo camera (tham khảo mục 3.2.2.2) là trường hợp đặc biệt của camera song khung hình gồm một cặp camera đơn giống nhau được đặt song song với nhau và cách nhau một khoảng B (baseline). Do 2 camera này giống nhau nên các ma trận tham số nội của chúng là tương tự nhau:

$$\mathcal{K}_L = \mathcal{K}_R = \mathcal{K} = \begin{bmatrix} f_x & 0 & x_0 \\ 0 & f_y & y_0 \\ 0 & 0 & 1 \end{bmatrix}.$$

Cùng với đó, ta có thể coi hệ tọa độ của camera trái trùng với hệ tọa độ 3D thực, khi đó ta có ma trận tham số xoay là đơn vị:

$$\mathbf{R}_L = \mathbf{R}_R = \mathbf{I}$$

và vector tịnh tiến của camera phải dịch chuyển 1 khoảng B theo trục x so với camera trái:

$$\mathbf{t}_L = [0 \ 0 \ 0]^T \text{ và } \mathbf{t}_R = [B \ 0 \ 0]^T.$$

Lúc này, phương trình ràng buộc (3.17) trở thành:

$$\left(\lambda_L \cdot \mathcal{K}^{-1} \cdot \begin{bmatrix} \mathbf{p}_L \\ 1 \end{bmatrix} \right) - \left(\lambda_R \cdot \mathcal{K}^{-1} \cdot \begin{bmatrix} \mathbf{p}_R \\ 1 \end{bmatrix} \right) = \begin{bmatrix} B \\ 0 \\ 0 \end{bmatrix}. \quad (3.29)$$

Với $\mathbf{p}_L$ và $\mathbf{p}_R$ là hai điểm là kết quả của phép chiếu của $\mathbf{P}$ lên hai mặt phẳng ảnh của stereo camera. Do hai cặp camera đã được căn chỉnh, nên 2 điểm này chỉ sai khác với nhau theo trục x , do đó có thể ký hiệu

$$\mathbf{p}_L = \begin{bmatrix} u \\ v \end{bmatrix} \text{ và } \mathbf{p}_R = \begin{bmatrix} u + d \\ v \end{bmatrix}, \quad (3.30)$$

trong đó d được gọi là thị sai (disparity).

Bên cạnh đó, do stereo camera đã được căn chỉnh nên $\lambda_L = \lambda_R = Z$ chính là khoảng cách từ camera tới điểm $\mathbf{P}$. Khi đó (3.22) được viết lại thành:

$$Z \begin{bmatrix} \frac{1}{f_x} & 0 & \frac{-x_0}{f_x} \\ 0 & \frac{1}{f_y} & \frac{-y_0}{f_x} \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} u \\ v \\ 1 \end{bmatrix} - Z \begin{bmatrix} \frac{1}{f_x} & 0 & \frac{-x_0}{f_x} \\ 0 & \frac{1}{f_y} & \frac{-y_0}{f_x} \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} u+d \\ v \\ 1 \end{bmatrix} = \begin{bmatrix} B \\ 0 \\ 0 \end{bmatrix}.$$

Chỉ lấy thành phần x , ta được:

$$Z \left(\frac{u}{f_x} - \frac{x_0}{f_x} \right) - Z \left(\frac{u+d}{f_x} - \frac{x_0}{f_x} \right) = B.$$

Ta thu được độ sâu theo công thức sau:

$$Z = \frac{f_x B}{d}. \quad (3.31)$$

Có thể thấy độ sâu tỉ lệ thuận với tiêu cự f_x , khoảng cách giữa cặp camera B và tỉ lệ nghịch với thị sai d . Trong đó, tiêu cự f_x và khoảng cách B là các giá trị đã biết từ thiết bị thu nhận ảnh. Giá trị thị sai d cần được ước lượng thông qua cặp ảnh stereo (tham khảo mục 4.5.6).

Kết chương

Chương này đã trình bày các nội dung cơ bản về thu nhận và hình thành hình ảnh, từ khái niệm ảnh đến quá trình chuyển đổi thông tin của thế giới thực thành dữ liệu số thông qua hệ thống camera. Các cơ chế nhận biết màu sắc và không gian cho thấy việc thu nhận ảnh chịu ảnh hưởng đồng thời của ánh sáng, cảm biến và mô hình biểu diễn.

Bên cạnh đó, chương đã giới thiệu các dạng biểu diễn ảnh như ảnh 2D, ảnh 3D, đám mây điểm và lưới hóa, làm rõ vai trò của không gian, thời gian và cường độ trong mô tả thông tin thị giác. Các mô hình camera, từ pinhole đến camera có thấu kính, cùng với tham số và bài toán xác định tham số camera, đã được trình bày như nền tảng cho việc liên hệ giữa không gian ba chiều và ảnh hai chiều.

Tổng hợp lại, chương cung cấp cơ sở lý thuyết cần thiết cho các bước xử lý và phân tích ảnh ở các chương tiếp theo, nơi các kỹ thuật xử lý ảnh số và thị giác máy tính sẽ được xây dựng trực tiếp trên các mô hình và biểu diễn đã giới thiệu.

Tài liệu tham khảo

Hartley, R. I. (1997). *In defense of the eight-point algorithm*. IEEE Transactions on Pattern Analysis and Machine Intelligence, 19(6), 580–593. <https://doi.org/10.1109/34.601246>.

Hartley, R. I. (1997b). Kruppa's equations derived from the fundamental matrix. IEEE Transactions on Pattern Analysis and Machine Intelligence, 19(6), 593–600.

Hartley, R., & Zisserman, A. (2004). *Multiple View Geometry in Computer Vision* (2nd ed.). Cambridge University Press.

- 1831 Lê, T. H. (2016). Giáo trình Xử lý ảnh. Nhà xuất bản Đại học Quốc gia Hà Nội.
1832 Lê, T. H. (2025). Giáo trình Truyền thông đa phương tiện. Nhà xuất bản Đại
1833 học Quốc gia Hà Nội.
1834 Philipp Fechteler, P., Eisert, P., & Rurainsky, J. (2007). Fast and high resolution
1835 3D face scanning. Proceedings of ICIP 2007.

1836 **Bài tập**

- 1837 1. Âm thanh số là gì? Giải thích quá trình chuyển đổi từ tín hiệu âm thanh
1838 tương tự sang tín hiệu số.
1839

1841 Khái niệm về cấu trúc phân cấp của thị giác người được trình bày trong
1842 chương trước cho thấy mỗi khu vực xử lý thị giác phụ trách các chức năng thị giác
1843 riêng biệt. Ví dụ vùng V1 phát hiện cạnh, vùng V4 phát hiện góc và độ cong, V2
1844 phát hiện đường viền, ... Dựa trên cơ sở đó, chương này sẽ trình bày các phương
1845 pháp, kỹ thuật, thuật toán giúp phát hiện và mô tả các đặc trưng ảnh (Đặc trưng
1846 hình học cơ bản, đặc trưng kết cấu, đặc trưng ngữ nghĩa và đặc trưng sâu)

1847 **4.1. Khái niệm đặc trưng ảnh**

1848 Đặc trưng ảnh là một trong những khái niệm cốt lõi của thị giác máy. Nó là
1849 thành phần trung gian giữa biểu diễn dữ liệu thô của ảnh (Xem phần Biểu diễn ảnh
1850 trong chương trước) và thông tin được trích rút từ ảnh. Đặc trưng ảnh thường được
1851 biểu diễn dưới dạng vector, gọi là vector đặc trưng, thường được sử dụng kết hợp
1852 với các thuật toán học máy để phân tích đặc điểm của đối tượng, trích rút các thông
1853 tin trong ảnh.

1854 Dữ liệu ảnh được thu nhận bị tác động bởi nhiều yếu tố trong đó có các điều
1855 kiện môi trường như ánh sáng hoặc nhiễu và các điều kiện của camera như vị trí và
1856 hướng quay khiến cho dữ liệu ảnh của cùng một đối tượng có thể khác nhau. Trong
1857 khi các đặc trưng được trích rút để mô tả đối tượng trong ảnh phải phản ánh được
1858 các thông tin liên quan trực tiếp đến đối tượng mà không phụ thuộc vào các điều
1859 kiện môi trường và điều kiện thu nhận dữ liệu. Tóm lại, đặc trưng ảnh cần thỏa mãn
1860 các điều kiện sau:

1861 *Bất biến với ánh sáng (invariance to illumination):* Do đối tượng cần nghiên cứu
1862 có thể được thu nhận hình ảnh ở những thời điểm khác nhau, ánh sáng môi trường
1863 ở mỗi thời điểm tác động lên bề mặt vật thể là khác nhau. Vector đặc trưng cần được
1864 bảo toàn dưới các tác động ánh sáng của môi trường.

1865 *Bất biến với góc nhìn (invariance to view):* Trong hầu hết các trường hợp, các đối
1866 tượng thường có cấu trúc 3D. Vector đặc trưng cần được bảo toàn khi thu nhận đối
1867 tượng ở các góc nhìn khác nhau. Thực tế cho thấy điều kiện này khó đạt được nếu
1868 chỉ có dữ liệu ảnh màu 2 chiều vì thông tin đã bị mất mát trong quá trình chiếu phối
1869 cảnh từ 3 chiều xuống 2 chiều. Bên cạnh đó, chỉ một sự thay đổi hướng nhìn nhỏ
1870 tạo ra sự thay đổi mạnh trong kết cấu của ảnh.

1871 *Bất biến với xoay (invariance to rotation):* Vector đặc trưng cần được bảo toàn
1872 trong trường hợp này để chống lại tác động xoay (rotation) của đối tượng. Ở đây,

1873 xoay (rotation) muốn nói tới chuyển động xoay tròn của đối tượng có hướng vuông
1874 góc với hướng quay của camera.

1875 *Bất biến với tỉ lệ (invariance to scale):* Vector đặc trưng cần được bảo toàn trong
1876 trường hợp hình ảnh của đối tượng xuất hiện lớn hơn hoặc bé hơn trong hình ảnh
1877 được thu nhận.

1878 Phần tiếp theo sẽ trình bày chi tiết các đặc trưng và việc trích chọn các đặc
1879 trưng từ ảnh. Hầu hết các đặc trưng đều không đồng thời thỏa mãn tất cả các điều
1880 kiện trên. Tùy thuộc vào yêu cầu của ứng dụng mà mỗi loại đặc trưng sẽ được khai
1881 thác theo cách khác nhau.

1882 4.2. Đặc trưng sơ cấp

1883 Đặc trưng sơ cấp được đề cập trong phần này là ba nhóm kiểu hình cơ bản
1884 nhất để từ đó có thể dẫn xuất tới những đặc trưng có cấu trúc phức tạp và mang
1885 nhiều ngữ nghĩa hơn. Ba nhóm này gồm: cạnh (edge), góc (corner) và blob (blob).
1886 Cạnh (edge) chỉ đến vùng biên tạo sự chênh lệch độ sáng đáng kể ở hai bên thường
1887 là phân phân biệt giữa các đối tượng khác nhau trong ảnh. Góc (corner) cho biết
1888 điểm có gradient thay đổi mạnh theo nhiều hướng có thể được sử dụng để mô tả
1889 các điểm có tính “dễ nhớ” và dễ mô tả trong ảnh. Blob (blob) thường chỉ đến một
1890 vùng trong ảnh có cường độ tương đối đồng nhất, có thể sáng hơn hoặc tối hơn
1891 vùng xung quanh và tạo ra sự khác biệt với vùng xung quanh.


1892 4.2.1. Cạnh (Edge)

1893 4.2.1.1. Định nghĩa cạnh

1894 Nhiều thí nghiệm đã chỉ ra rằng, trong quá trình nhận thức thị giác, con người
1895 thường tập trung vị trí nhìn của mắt mình vào những khu vực có nhiều chi tiết
1896 (những vùng có biến đổi mạnh về độ sáng). Trong cuốn Giáo trình Xử lý ảnh (Lê
1897 2016), khái niệm điểm cạnh được định nghĩa thuần túy là những điểm ảnh có giá trị
1898 sáng tăng hoặc giảm đột biến so với các điểm ảnh lân cận và đã trình bày các bộ lọc
1899 tách cạnh cơ bản nhằm xác định các điểm cạnh. Việc phát hiện các điểm cạnh này
1900 chưa quan tâm đến tính ngữ nghĩa của điểm cạnh trong mối tương quan tới các
1901 điểm cạnh lân cận khác.

1902 Trong cuốn giáo trình Thị giác máy này, điểm cạnh được xem xét dưới góc
1903 nhìn ngữ nghĩa trong nhận thức thị giác. Tức là, khái niệm cạnh được mở rộng là
1904 tập hợp các điểm ảnh có thể tạo ra các hình hình học có ý nghĩa trong thị giác người.
1905 Đầu tiên, ta hãy xem xét các yếu tố có thể tạo ra các cạnh. Hình 4.1 cho thấy cạnh có
1906 thể được tạo ra bởi nhiều yếu tố khác nhau: (1) do sự gián đoạn của bề mặt (sinh do
1907 bề mặt của đối tượng), (2) sự gián đoạn của độ sâu (do sự chênh lệch độ sâu giữa
1908 đối tượng và nền), (3) sự gián đoạn của màu sắc (trên bề mặt của đối tượng) và (4)
1909 do sự gián đoạn của ánh sáng (bóng của vật thể in lên bề mặt đối tượng khác). Tập


1910 hợp các cạnh này đem lại thông tin nhất định. Ví dụ tập hợp các cạnh (1) tạo thành
 1911 cấu trúc không gian của vật thể, tập hợp các cạnh (2) giúp phân biệt vật thể với nền,
 1912 tập hợp các cạnh (3) cho biết thông tin mô tả đối tượng và các cạnh (4) đơn thuần là
 1913 bóng của vật thể để lại lên bề mặt một vật thể khác, nó không mang nhiều thông tin
 1914 thậm chí gây nhiễu.



Hình 4.1. Các yếu tố sinh ra cạnh.

1917 4.2.1.2. Phát hiện dựa trên gradient

1918 Để phát hiện các điểm cạnh (điểm có độ sáng đột biến với các điểm lân cận)
 1919 như được miêu tả trong Hình 4.2. Trong đó, hình bên trái là một phần nhỏ của ảnh,
 1920 phần này được trích ra từ một ảnh lớn. Trong hình này có hai cạnh thẳng đứng song
 1921 song. Hình giữa là một đồ thị trong đó trục hoành tương ứng với đường kẻ ngang
 1922 của đoạn thẳng cắt ngang ảnh và trục tung là giá trị của điểm ảnh tương ứng. Có
 1923 thể thấy vùng đồ thị trũng xuống tương ứng với vùng ảnh màu đen, hai bờ cao hơn
 1924 tương ứng với vùng ảnh trắng. Hình bên phải cho thấy hình ảnh của đạo hàm bậc
 1925 nhất. Có thể thấy đường đạo hàm này có hai cực trị tương ứng với vị trí của 2 điểm
 1926 cạnh trong ảnh. Do đó, các phương pháp tách cạnh thường được phát triển dựa trên
 1927 đạo hàm.




Hình 4.2. Cạnh và đạo hàm.

1930 Ký hiệu $I(x, y)$ là một ảnh 2 chiều, vector gradient của một ảnh được định nghĩa
 1931 như sau:

$$\nabla I(x, y) = \begin{bmatrix} \frac{\partial I(x, y)}{\partial x} \\ \frac{\partial I(x, y)}{\partial y} \end{bmatrix}. \quad (4.1)$$

Vector gradient $\nabla I(x, y)$ cho biết hướng tăng mạnh nhất của hàm tại vị trí (x, y) . Hình 4.3 cho thấy vector gradient của ảnh có cạnh dọc, cạnh ngang và cạnh chéo. Mỗi ảnh là một biến đổi đều từ giá trị bé (vùng tối) sang giá trị lớn (vùng sáng). Vector gradient có hướng chỉ từ vùng tối sang vùng sáng và vuông góc với cạnh của ảnh.



Hình 4.3. Vector gradient.

Cường độ cạnh được tính là độ dài của vector gradient:

$$\|\nabla I(x, y)\| = \sqrt{\left(\frac{\partial I(x, y)}{\partial x}\right)^2 + \left(\frac{\partial I(x, y)}{\partial y}\right)^2}. \quad (4.2)$$

Trong trường hợp ảnh là rời rạc, việc tính vector gradient được xấp xỉ bằng phép trừ giữa 2 điểm ảnh lân cận:

$$\begin{bmatrix} \frac{\partial I(x, y)}{\partial x} \\ \frac{\partial I(x, y)}{\partial y} \end{bmatrix} \approx \begin{bmatrix} I[x + 1, y] - I[x, y] \\ I[x, y + 1] - I[x, y] \end{bmatrix}. \quad (4.3)$$

Nói cách khác, đạo hàm của ảnh thu được bằng cách áp dụng hai cửa sổ lọc tuyến tính tương ứng với hai thành phần x và y như sau:


$$D_x = \begin{bmatrix} -1 & 1 \end{bmatrix} \text{ và } D_y = \begin{bmatrix} -1 \\ 1 \end{bmatrix}. \quad (4.4)$$

Tuy nhiên, các cửa sổ lọc ảnh thường yêu cầu có kích thước là phải là số lẻ để có tính đối xứng nên cửa sổ đạo hàm được bổ sung thêm số 0 vào chính giữa như sau:

$$D_x^0 = \begin{bmatrix} -1 & 0 & 1 \end{bmatrix} \text{ và } D_y^0 = \begin{bmatrix} -1 & 0 & 1 \end{bmatrix}^T. \quad (4.5)$$


4.2.1.3. Phát hiện cạnh trong ảnh có nhiễu

Khi ảnh có nhiễu (ví dụ nhiễu cộng – additive noise), phép trừ hai điểm ảnh có nhiễu làm tăng biên độ nhiễu và tác động đáng kể tới kết quả tách cạnh. Để dễ hình dung, ta sẽ minh họa bằng tín hiệu 1 chiều. Ở đây vẫn dùng từ cạnh để chỉ vị trí có sự thay đổi đột ngột của tín hiệu để người đọc thấy được sự tương ứng khi quay lại khái niệm ảnh 2 chiều. Hình 4.9 cho thấy ảnh hưởng của nhiễu vào quá trình phát hiện cạnh bằng đạo hàm. Hình 4.9 (a) cho thấy cạnh là một dốc đứng và nhiễu cộng được phân bố đều ở hai phía và Hình 4.9 (b) cho thấy đạo hàm đã làm tăng biên độ nhiễu khiến cho việc tìm cực trị trở nên khó khăn.




Hình 4.4. Ảnh hưởng của nhiễu đến phát hiện cạnh bằng đạo hàm.

Do đó, ảnh cần được khử nhiễu trước khi áp thực hiện tách cạnh. Hình 4.5 minh họa quá trình khử nhiễu bằng một bộ lọc Gaussian và làm cho việc tách cạnh khả thi. Bộ lọc này đã loại bỏ nhiễu của tín hiệu f bằng bộ lọc làm mượt g . Kết quả sau khi lọc ($f * g$) là nhiễu đã được loại bỏ. Cạnh cũng bị ảnh hưởng do phép lọc nhiễu (hơi nghiêng hơn cạnh gốc một chút) tuy nhiên lại thấy rõ điểm cực trị trên đường đạo hàm tương ứng với vị trí của cạnh.



Hình 4.5. Thực hiện lọc nhiễu trước khi lấy đạo hàm.

Ta lại có tính chất liên hợp của đạo hàm và tích chập như sau: đạo hàm của tích chập hai hàm bằng tích chập của một hàm với đạo hàm của hàm còn lại. Tức là $\frac{\partial(f*g)}{\partial x} = f * \frac{\partial(g)}{\partial x}$. Do đó để phát hiện được cạnh trong trường hợp tín hiệu có nhiễu, ta chỉ cần nhân chập tín hiệu gốc với đạo hàm của bộ lọc, Hình 4.6.



Hình 4.6. Tách cạnh bằng đạo hàm của bộ lọc.


Trong trường hợp 2 chiều, hàm lọc nhiễu Gaussian 2D có dạng:

$$G(x, y) = \frac{1}{2\pi\sigma^2} \exp\left(-\frac{x^2+y^2}{2\sigma^2}\right), \quad (4.6)$$

và các đạo hàm thành phần của $G(x, y)$ có dạng

$$\frac{\partial G(x, y)}{\partial x} = \frac{-x}{2\pi\sigma^4} \exp\left(-\frac{x^2+y^2}{2\sigma^2}\right) \text{ và } \frac{\partial G(x, y)}{\partial y} = \frac{-y}{2\pi\sigma^4} \exp\left(-\frac{x^2+y^2}{2\sigma^2}\right). \quad (4.7)$$

Hình 4.7 trực quan hóa Gaussian 2D. Trong đó (a) là hình ảnh các giá trị $G(x, y)$ được vẽ theo độ cao trên mặt phẳng (x, y) , (b) và (c) tương ứng là đạo hàm của theo thành phần x và thành phần y.



Hình 4.7. Hình ảnh trực quan của bộ lọc làm mờ Gaussian và các bộ lọc tách cạnh trục x và trục y.

Hàm lọc nhiễu Gaussian 2D cũng có thể tách thành tích của hai hàm một chiều:

$$G(x, y) = g(x) \cdot g(y) \quad (4.8)$$

với

$$g(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{x^2}{2\sigma^2}\right) \text{ và } g(y) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{y^2}{2\sigma^2}\right). \quad (4.9)$$

Khi đó đạo hàm thành phần được tính như sau:

$$\frac{\partial G(x, y)}{\partial x} = g(y) \cdot \frac{\partial g(x)}{\partial x} \text{ và } \frac{\partial G(x, y)}{\partial y} = g(x) \cdot \frac{\partial g(y)}{\partial y}. \quad (4.10)$$

1992 Công thức này giúp ta dễ dàng thiết kế các cửa sổ lọc tuyến tính hơn, theo
1993 công thức sau:

$$1994 \quad H = h \otimes h^T, \quad (4.11)$$

1995 trong đó cửa sổ làm mờ ảnh H có kích thước $n \times n$, $\otimes$ là toán tử tích ngoài (outer
1996 product) và h là vector có n phần tử có giá trị được lấy theo tỷ lệ Gaussian và
1997 $\sum_i h(i) = 1$. Đạo hàm của h (đạo hàm theo trục y) được tính xấp xỉ bằng cách nhân
1998 chập h với sử dụng cửa sổ D_y^0 (Ở đây ta sử dụng D_y^0 để đảm bảo tính đối xứng của hàm
1999 lọc), $h' = h * D_y^0$, và ta có cửa sổ tách cạnh theo trục y có dạng sau:

$$2000 \quad H'_y = (h \otimes h^T)'_y = (h * D_y^0) \otimes h^T. \quad (4.12)$$

2001 Tương tự như vậy, đạo hàm của h^T (đạo hàm theo trục x) được xấp xỉ bằng
2002 cách nhân chập h^T với cửa sổ D_x^0 , $(h^T)' = h^T * (D_x^0)^T = h^T * D_x^0$, và ta có cửa sổ tách
2003 cạnh theo trục x có dạng sau:

$$2004 \quad H'_x = (h \otimes h^T)'_x = h \otimes (h^T * D_x^0). \quad (4.13)$$

2005 Ví dụ với kích thước cửa sổ $n = 3$ và $\sigma = 0.85$, ta có $h \approx \frac{1}{4} \begin{bmatrix} 1 \\ 2 \\ 1 \end{bmatrix}$ và hàm lọc nhiễu

2006 Gaussian tương ứng là $H = h \otimes h^T \approx \frac{1}{16} \begin{bmatrix} 1 & 2 & 1 \\ 2 & 4 & 2 \\ 1 & 2 & 1 \end{bmatrix}$. Khi đó, cửa sổ tách cạnh theo
2007 thành phần x được tính như sau:

$$\begin{aligned} 2008 \quad H_x &= h \otimes (h^T * D_x^0) \approx \frac{1}{16} \begin{bmatrix} 1 \\ 2 \\ 1 \end{bmatrix} \otimes ([1 \ 2 \ 1] * [-1 \ 0 \ 1]) \\ &= \frac{1}{16} \begin{bmatrix} 1 \\ 2 \\ 1 \end{bmatrix} \otimes [2 \ 0 \ -2] \\ &= -\frac{1}{8} \begin{bmatrix} -1 & 0 & 1 \\ -2 & 0 & 2 \\ -1 & 0 & 1 \end{bmatrix} \\ &= -\frac{1}{8} S_x \end{aligned}$$


2009 và cửa sổ tách cạnh theo thành phần y được tính như sau:

$$\begin{aligned} 2010 \quad H_y &= (h * D_y^0) \otimes h^T \approx \frac{1}{16} \left(\begin{bmatrix} 1 \\ 2 \\ 1 \end{bmatrix} * \begin{bmatrix} -1 \\ 0 \\ 1 \end{bmatrix} \right) \otimes [1 \ 2 \ 1] \\ &= \frac{1}{16} \begin{bmatrix} 2 \\ 0 \\ -2 \end{bmatrix} \otimes [1 \ 2 \ 1] \\ &= -\frac{1}{8} \begin{bmatrix} -1 & -2 & -1 \\ 0 & 0 & 0 \\ 1 & 2 & 1 \end{bmatrix} \\ &= -\frac{1}{8} S_y. \end{aligned}$$

2011 Lọc tách cạnh được thực hiện bằng cách bỏ qua các $\left(-\frac{1}{8}\right)$ để sử dụng trực tiếp
2012 các cửa sổ:

2013
$$S_x = \begin{bmatrix} -1 & 0 & 1 \\ -2 & 0 & 2 \\ -1 & 0 & 1 \end{bmatrix} \text{ và } S_y = \begin{bmatrix} -1 & -2 & -1 \\ 0 & 0 & 0 \\ 1 & 2 & 1 \end{bmatrix}. \quad (4.14)$$

2014 Lúc này ta có S_x và S_y là cửa sổ lọc tách cạnh Sobel nổi tiếng. Do tính hiệu quả
2015 và đơn giản trong tính toán, cửa sổ Sobel thường xuyên được sử dụng trong các
2016 ứng dụng xử lý ảnh và thị giác máy.




Hình 4.8. Kết quả bộ lọc tách cạnh Sobel.

2019 Hình 4.8 cho thấy kết quả của bộ lọc Sobel trong đó ảnh gốc bên trái được thực
2020 hiện lọc bằng cửa sổ Sobel S_x và S_y và cường độ cạnh tổng hợp cho thấy trong ảnh
2021 bên phải. Có thể thấy rõ ảnh được lọc bởi S_x làm nổi rõ các điểm ảnh thuộc cạnh có
2022 hướng dọc và các ảnh được lọc bởi S_y làm nổi rõ các điểm ảnh thuộc cạnh có hướng
2023 ngang.

2024 4.2.1.4. Tách cạnh Canny


2025 Phần trước trình bày cách sử dụng hàm Gaussian giúp lọc nhiễu để phát hiện
2026 các điểm cạnh (điểm có giá trị sáng tăng/giảm đột biến so với các điểm lân cận). Khi
2027 xem xét kỹ lưỡng, ta gặp các vấn đề sau:

2028 Do ảnh luôn luôn có nhiễu, nên giải pháp là tăng phương sai (σ) của hàm
2029 Gaussian và tăng kích thước cửa sổ trượt để lọc nhiễu nhưng đồng thời làm mờ
2030 cạnh. Mức độ mờ của cạnh phụ thuộc vào độ lớn của cạnh trong sự tương quan với
2031 độ lớn của cửa sổ trượt để lọc nhiễu (Xem Hình 4.9) cùng với phương sai σ . Làm
2032 thế nào để xác định các cạnh với mức độ bị làm mờ khác nhau như vậy?



Hình 4.9. Độ mờ của cạnh phụ thuộc vào kích thước của cửa sổ lọc.

Các điểm lân cận với cạnh thực thường tạo ra cường độ gradient rất cao, khiến cho tập hợp các điểm cạnh tạo thành các đường biên có độ dày đáng kể (Hình 4.14). Làm thế nào để xác định chính xác vị trí của cạnh thực?



Hình 4.10. Các vấn đề khi tách cạnh.

Trong Hình 4.10, đường ô màu đỏ đại diện cho cạnh thực cần được phát hiện. Các ô còn lại trực quan hóa các lỗi xảy ra khi tách cạnh: Bị tác động mạnh bởi nhiễu nên đã không phát hiện ra một số cạnh thật và phát hiện nhầm cạnh; Xác định sai vị trí của cạnh; và Tạo ra quá nhiều cạnh (phản hồi không duy nhất).

Để giải quyết vấn đề trên, (J. Canny 1986) đã đề xuất thuật toán tách cạnh sử dụng một loạt các kỹ thuật tối ưu nhằm xác định được chính xác vị trí của cạnh, khả năng chống nhiễu tốt và phản hồi duy nhất. Thuật toán Canny nhận đầu vào là một ảnh đa cấp xám I cho đầu ra là một ảnh nhị phân (ảnh cạnh) E có kích thước bằng kích thước ảnh đầu vào. Thuật toán gồm gồm 5 bước chính sau:

Bước 1: Lọc nhiễu ảnh

$$I_S = I * H, \quad (4.15)$$

trong đó H là cửa sổ lọc Gaussian được xây dựng từ công thức (4.11) với độ lệch σ . Giá trị σ càng lớn càng lọc nhiễu nhiều nhưng càng làm ảnh mờ và mất các chi tiết cạnh nhỏ.

Bước 2: Tính vector gradient

Sử dụng bộ lọc Sobel trong công thức (4.14) để lần lượt tính thành phần x và thành phần y của vector gradient:


$$G_x = I_S * S_x \text{ và } G_y = I_S * S_y. \quad (4.16)$$

cùng với cường độ (độ lớn) của vector gradient:

$$M = \sqrt{G_x^2 + G_y^2}. \quad (4.17)$$

Bước 3: Làm mảnh đường cạnh

Mục đích của làm mảnh biên để tạo ra một phản hồi duy nhất cho một cạnh. Việc này được thực hiện bằng kỹ thuật non-maximum suppression để tìm và giữ lại điểm cực đại có cường độ gradient lớn nhất trong số các điểm lân cận được chỉ định bởi hướng của vector gradient. Hình 4.11 (a) cho thấy hình ảnh một cạnh cong màu trắng trên nền ảnh đen và hướng của một vector gradient của một điểm thuộc cạnh và Hình 4.11 (b) cho thấy vector gradient của điểm q . Từ vector gradient này có thể xác định hai điểm lân cận r và p gần với q nhất ở hàng trên và hàng dưới (hoặc cột trái và cột phải) tùy thuộc vào hướng của vector gradient. Cường độ gradient của điểm p và r có thể xác định bằng cách nội suy từ các điểm lân cận. Điểm q chỉ được giữ lại trong danh sách ứng cử viên cạnh nếu cường độ gradient tại q đều lớn hơn cường độ gradient tại p và r , tức là $M(q) > M(p)$ và $M(q) > M(r)$.




Hình 4.11. Vector gradient.

Bước 4: Lọc điểm cạnh với ngưỡng kép

Để tăng khả năng chống nhiễu và giảm việc phát hiện thiếu cạnh, thuật toán tách cạnh Canny sử dụng hai ngưỡng: ngưỡng trên T_{high} và ngưỡng dưới T_{low} . Những điểm có cường độ gradient lớn hơn T_{high} được xác định chắc chắn là cạnh (gọi là điểm cạnh mạnh) và những điểm có cường độ gradient nằm giữa T_{low} và T_{high} chưa xác định có phải là cạnh hay không (gọi là điểm cạnh yếu). Còn những điểm có cường độ gradient nhỏ hơn T_{low} không được coi là điểm cạnh.


Bước 5: Liên kết điểm cạnh

Dựa trên quan sát cạnh thực là những đường mảnh được nối liền mạch, thuật toán tìm cách mở rộng danh sách các điểm cạnh mạnh tới những điểm cạnh yếu kề với nó để tạo thành một đường cạnh liên tục (một đường cạnh liên tục bao gồm các điểm cạnh kề với nhau). Thuật toán dừng lại khi không còn điểm cạnh yếu nào có thể được sử dụng để kéo dài đường cạnh. Để đảm bảo đường cạnh mảnh (tạo phản hồi duy nhất tới cạnh thực, cạnh mảnh có độ rộng là 1 điểm), trong một số trường hợp, thuật toán cần lựa chọn một trong hai điểm cạnh kề nhau.



Hình 4.12. Lựa chọn điểm cạnh để kéo dài đường cạnh và đảm bảo đường cạnh mạnh.

Hình 4.12 cho thấy việc kéo dài đường cạnh từ một điểm cạnh mạnh p tới một trong hai điểm cạnh yếu s và r . Biết rằng, vector gradient tại p vuông góc với vector pháp tuyến của biên tại p . Khi đó, điểm tiếp theo được lựa chọn (s hoặc r) là điểm gần với vector pháp tuyến hơn.



Hình 4.13. Kết quả tách cạnh Canny của một ảnh có nhiễu với hai mức độ lọc nhiễu khác nhau.


Hình 4.13 cho thấy kết quả tách cạnh Canny của một ảnh (trái) bị tác động mạnh bởi nhiễu Gaussian. Kết quả cạnh (giữa) có nhiều lỗi cạnh vì khi lọc nhiễu với hệ số σ nhỏ, nhiễu không lọc hết tác động tiêu cực tới việc tách cạnh. Kết quả cạnh (phải) không còn lỗi cạnh do nhiễu ở ảnh gốc đã bị loại bỏ hết với hệ số σ lớn hơn. Tuy nhiên phần giao nhau giữa các cạnh bị bo tròn (khá khác biệt với hình ảnh gốc) do ảnh gốc đã bị làm quá mượt trong quá trình lọc nhiễu.

4.2.2. Điểm đặc trưng (Interesting point) và Góc (Corner)

4.2.2.1. Điểm đặc trưng

Khái niệm điểm đặc trưng (tiếng Anh là feature points hoặc key points) trong ảnh được định nghĩa là những điểm hoặc (vùng nhỏ) trong ảnh có sự khác biệt đủ lớn để phân biệt với các điểm lân cận khác, đồng thời có thể giữ ổn định khi ảnh bị biến đổi về ánh sáng, biến dạng tỉ lệ hoặc xoay. Việc xác định và mô tả được các đặc trưng đến mức điểm ảnh cho phép phát triển các kỹ thuật để giải nhiều bài toán ứng dụng thị giác máy trải rộng từ ghép ảnh, bám bắt đối tượng trong video, phát hiện và nhận dạng đối tượng, khôi phục 3D, ...

Ví dụ trực quan về điểm đặc trưng của ảnh khi liên hệ với hệ thị giác người có thể được thực hiện thông qua ví dụ sau: Hãy lựa chọn một vài điểm trong ảnh Hình 4.14 (a) và rời đi. Hình 4.14 (a) sau đó bị làm biến dạng (xoay, thu nhỏ đi một chút) để được Hình 4.14 (b). Năm phút sau quay lại, hãy tìm lại chính xác những điểm đã chọn lúc trước. Vậy sẽ chọn những điểm nào? Hiển nhiên những điểm được chọn cần có sự khác biệt đáng kể tới những điểm lân cận. Tốt nhất là những điểm giao nhau giữa hai đường thẳng vì sẽ dễ dàng tìm lại được chúng khi ảnh bị biến dạng.



Hình 4.14. Ảnh thí nghiệm điểm đặc trưng với thị giác người.

Để đáp ứng được các yêu cầu của ứng dụng, điểm đặc trưng cần đáp ứng được:

Tính ổn định (Repeatability): vẫn phát hiện được (hay không bị thay đổi, bất biến) khi ảnh bị quay, phóng to/thu nhỏ hoặc có nhiễu do ánh sáng.

Khả năng phân biệt cao (Distinctiveness): Khả năng nhận dạng được duy nhất trong ảnh.

Chính xác (Acurate localization): Vị trí được xác định một cách chính xác trong ảnh.

Hiệu quả tính toán (Computation efficiency): Dễ phát hiện và thuật toán cần được thực hiện nhanh.


Kỹ thuật phát hiện điểm đặc trưng hay được sử dụng là phát hiện góc (corner detection).

4.2.2.2. Phát hiện góc

Góc là nơi giao nhau giữa các đường thẳng đoạn thẳng. Do chúng có các đặc điểm đáp ứng được các yêu cầu của một điểm đặc trưng. Harris (Harris 1988) là một trong những người đầu tiên đề xuất phương pháp phát hiện góc đơn giản nhưng hiệu quả.

Ý tưởng tìm góc xuất phát từ trực giác hình học về một điểm đặc trưng là khi ta di chuyển nó theo bất cứ hướng nào, cường độ ảnh xung quanh điểm đó thanh đổi mạnh. Điểm ở tâm hình vuông trong Hình 4.20 (a) không phải là một điểm đặc

2145 trung do khi di chuyển theo bất cứ hướng nào, nó đều không tạo ra sự khác biệt.
 2146 Hình 4.15 (b) không phải là điểm đặc trưng do không tạo sự khác biệt khi di chuyển
 2147 theo chiều dọc. Hình 4.20 (c) là điểm đặc trưng do đều tạo ra sự khác biệt lớn khi di
 2148 chuyển theo tất cả các hướng.



Hình 4.15. Trục quan hình học về điểm đặc trưng.

2152 Sự thay đổi cường độ ảnh khi di chuyển có thể được hình thức hóa toán học
 2153 như sau. Xét một điểm ở tọa độ (x, y) trong ảnh I . Gọi $W_{x,y}$ là một cửa sổ lân cận
 2154 xung có tâm tại (x, y) và (u, v) là khoảng mà cửa sổ W di chuyển đến vị trí
 2155 $(x + u, y + v)$. Khi đó, mức độ thay đổi cường độ tính theo *tổng bình phương sai khác*
 2156 (Sum of Square Difference – SSD) có trọng số có thể được định nghĩa dưới dạng một
 2157 *hàm năng lượng dịch chuyển* như sau:

$$E(W_{x,y}, u, v) = \sum_{(x_k, y_k) \in W_{x,y}} g(x_k, y_k) (I(x_k, y_k) - I(x_k + u, y_k + v))^2, \quad (4.18)$$

2159 trong đó $g(x_k, y_k)$ là một hàm trọng số có giá trị lớn ở tâm $(x_k, y_k) = (x, y)$ và giảm
 2160 dần ra biên của cửa sổ để giảm nhiễu và giúp kết quả ổn định hơn. Thường sử dụng
 2161 hàm Gaussian trong trường hợp này.

2162 Sử dụng khai triển Taylor ta được $I(x_k + u, y_k + v) \approx I(x_k, y_k) + I_x(x_k, y_k) \cdot u +$
 2163 $I_y(x_k, y_k) \cdot v$ và thay thế vào (4.18) ta được:

$$E(W_{x,y}, u, v) \approx \sum_{(x_k, y_k) \in W_{x,y}} g(x_k, y_k) (I_x(x_k, y_k) \cdot u + I_y(x_k, y_k) \cdot v)^2 \quad (4.19)$$

2165 và viết lại dưới dạng nhân ma trận như sau:

$$E(W_{x,y}, u, v) \approx \begin{pmatrix} u & v \end{pmatrix} \cdot M_{x,y} \cdot \begin{pmatrix} u \\ v \end{pmatrix}, \quad (4.20)$$

2167 trong đó M là một tensor cấu trúc (người ta còn gọi là ma trận moment bậc 2):


$$M_{x,y} = \sum_{(x_k, y_k) \in W_{x,y}} g(x_k, y_k) \begin{bmatrix} I_x(x_k, y_k)^2 & I_x(x_k, y_k)I_y(x_k, y_k) \\ I_x(x_k, y_k)I_y(x_k, y_k) & I_y(x_k, y_k)^2 \end{bmatrix}. \quad (4.21)$$

2170 Để đơn giản trong trình bày, với một điểm (x, y) cho trước ta có hàm Ký hiệu
 2171 tóm tắt tensor có dạng $M = \begin{bmatrix} a & b \\ b & c \end{bmatrix}$, khi đó hàm năng lượng dịch chuyển tại điểm
 2172 (x, y) :

$$E(u, v) = \begin{pmatrix} u \\ v \end{pmatrix} \cdot \begin{bmatrix} a & b \\ b & c \end{bmatrix} \cdot \begin{pmatrix} u & v \end{pmatrix} \quad (4.22)$$


$$= au^2 + 2buv + cv^2.$$

là một hàm bậc hai có các đặc tính hình học được quyết định bởi các tham số a, b, c và hai giá trị riêng λ_1 và λ_2 của M .



Hình 4.16. Đặc điểm hàm năng lượng dịch chuyển $E(u, v)$.

Hình 4.16 mô tả đặc tính hình học của hàm năng lượng chuyển dịch phụ thuộc vào các giá trị λ_1 và λ_2 : Khi vùng ảnh xung quanh điểm (x, y) phẳng, mượt thì $E(u, v)$ phẳng theo mọi hướng và giá trị của λ_1 và λ_2 nhỏ; khi vùng ảnh là cạnh thì $E(u, v)$ tạo dốc cao theo 1 hướng (giá trị riêng lớn) và phẳng theo hướng còn lại (giá trị riêng nhỏ); khi vùng này là góc thì $E(u, v)$ tạo độ dốc theo cả hai hướng (cả 2 giá trị riêng λ_1 và λ_2 đều lớn).



Hình 4.17. Đặc điểm hình học của vùng ảnh tương ứng với các giá trị riêng của M .


Như vậy, ta sẽ tìm những điểm (x, y) có hai giá trị riêng λ_1 và λ_2 của ma trận M đều có giá trị lớn, xem Hình 4.17. Harris đề xuất phản hồi góc như sau:

$$R(x, y) = \lambda_1 \lambda_2 - k(\lambda_1 + \lambda_2)^2$$

$$= \det M_{x,y} - k \cdot [\text{trace } M_{x,y}]^2 \quad (4.23)$$

$$= (ac - b^2) - k(a + c)^2.$$

Phản hồi góc $R(x, y) > 0$ nếu có góc ở điểm (x, y) , $R(x, y) = 0$ nếu (x, y) thuộc vùng phẳng và $(x, y) < 0$ nếu có cạnh đi qua (x, y) .



Hình 4.18. Ảnh trực quan phản hồi góc Harris.

Hình 4.18 (b) trực quan hóa phản hồi góc Harris của ảnh đầu vào (a). Có thể thấy vùng ảnh màu tối sẫm $R(x, y) < 0$ tương ứng với vùng cạnh, vùng xám $R(x, y) = 0$ tương ứng với vùng phẳng và những chấm sáng $R(x, y) > 0$ chứa góc. Các điểm góc (điểm đặc trưng) có thể được xác định sử dụng thuật toán non-maximum suppression ở những vùng chấm sáng. Hình (c) hiển thị vị trí các điểm đặc trưng tìm được bằng phương pháp phát hiện góc Harris.

Liên quan đến phản hồi góc, nhóm tác giả Shi-Tomasi trong (Shi 1991) cũng đề xuất cách xác định điểm đặc trưng dựa trên hai giá trị riêng của tensor cấu trúc:


$$R(x, y) = \min(\lambda_1, \lambda_2). \quad (4.24)$$

Phương pháp của Shi-Tomasi phức tạp hơn của Harris do phải tính trực tiếp các giá trị riêng, nhưng nó có áp tốt hơn Harris trong các bài toán theo dõi đối tượng, vì trong các bài toán lựa chọn điểm để theo dõi cần giá trị riêng nhỏ phải đủ lớn.

4.2.3. Blob

4.2.3.1. Blob là gì?

Blob là một vùng/điểm sáng hoặc tối nổi bật so với vùng xung quanh. Khi quan sát trên ảnh, một blob thường có cấu trúc là một vùng nhỏ có cường độ tương đối đồng nhất, nhưng cường độ ở rìa blob có biến đổi mạnh và trung tâm blob có một điểm cực trị (cực đại hoặc cực tiểu). Xem Hình 4.19.



Hình 4.19. Mỗi hình tròn nhỏ trong ảnh có thể được coi là 1 blob.

Để giải quyết vấn đề khi kích thước các blob khác nhau một cách đáng kể trong ảnh, ta sử dụng không gian tỉ lệ theo công thức (P1.1). Ký hiệu $I(x, y)$ là một ảnh có biểu diễn đa tỉ lệ là $L(x, y; \sigma)$ và sử dụng hàm Signature $S_B(x, y; \sigma) = \sigma^2 \cdot \nabla^2 L(x, y; \sigma)$ (xem Bảng P1.1 giải thích chi tiết về hàm Signature để phát hiện blob trong không gian tỉ lệ) để phát hiện blob. Khi đó, giá trị σ để $S_B(x, y; \sigma)$ đạt cực trị sẽ tương ứng với kích thước tối ưu của blob.

4.2.3.2. Phát hiện blob điểm

Trong trường hợp tham số tỉ lệ $\sigma = 0$, biểu diễn đa tỉ lệ $L(x, y; \sigma)$ đồng nhất với $I(x, y)$ và hàm signature $S_B(x, y; \sigma)$ không có ý nghĩa, blob bị suy giảm về thành 1 điểm duy nhất (blob điểm – point blob). Khi đó, phát hiện blob được thực hiện trực tiếp trên Laplacian của ảnh (không thông qua Gaussian) như sau:

$$\nabla^2 L(x, y; \sigma) = \nabla^2 I(x, y) = \frac{\partial^2 I(x, y)}{\partial x^2} + \frac{\partial^2 I(x, y)}{\partial y^2}. \quad (4.25)$$


Với $I[x, y]$ là một ma trận các điểm ảnh rời rạc, hai điểm ảnh kề nhau cách nhau một đơn vị, Laplacian của ảnh $I(x, y)$ có thể được xấp xỉ như sau:

$$\begin{aligned} \nabla^2 I(x, y) &= \frac{\partial^2 I(x, y)}{\partial x^2} + \frac{\partial^2 I(x, y)}{\partial y^2} \\ &\approx (I[x+1, y] - 2I[x, y] + I[x-1, y]) \\ &\quad + (I[x, y+1] - 2I[x, y] + I[x, y-1]) \\ &\approx I[x+1, y] + I[x-1, y] + I[x, y+1] + I[x, y-1] \\ &\quad - 4I[x, y] \end{aligned} \quad (4.26)$$

Công thức (4.26) có thể được biểu diễn lại bằng cửa sổ lọc tuyến tính:

$$H = \begin{bmatrix} 0 & -1 & 0 \\ -1 & 4 & -1 \\ 0 & -1 & 0 \end{bmatrix}. \quad (4.27)$$


Mặc dù cửa sổ này có dấu đảo ngược so với công thức gốc, tuy nhiên hiệu ứng trên ảnh không đổi. Đây là cửa sổ lọc Laplace nổi tiếng trong xử lý ảnh. Bộ lọc này làm nổi bật các điểm sáng/tối đứng đơn lẻ và cũng phản ứng mạnh với các điểm ở cạnh (edge) nên trong nhiều trường hợp người ta cũng gọi đây là cửa sổ tách cạnh Laplace. Yếu điểm của cửa sổ này là khả năng kháng nhiễu kém do đã bỏ qua bộ lọc Gaussian. Hình 2.20 là một ví dụ sử dụng bộ lọc Laplace (4.27) để phát hiện các blob điểm trong ảnh. Các blob điểm xuất hiện liên tiếp ở biên của đối tượng tạo cảm giác chúng liền mạch như các cạnh.



Hình 2.20. Kết quả phát hiện blob điểm sử dụng bộ lọc Laplace.

4.2.3.3. Phát hiện blob lý tưởng

Blob lý tưởng là giá định ảnh $I(x, y)$ có dạng một Gaussian với phương sai σ_0 , tức là $I(x, y) = G(x, y; \sigma_0)$. Xem Hình ảnh trực quan của $I(x, y)$ trong hình 4.21.



Hình 4.21. Hình ảnh trực quan của $I(x, y)$ là một gaussian có $\sigma_0 = 4$.

Khi đó, biểu diễn đa tỉ lệ của ảnh:

$$\begin{aligned} L(x, y; \sigma) &= G(x, y; \sigma) * I(x, y) \\ &= G(x, y; \sigma) * G(x, y; \sigma_0) \\ &= G\left(x, y; \sqrt{\sigma^2 + \sigma_0^2}\right) \end{aligned} \quad (4.28)$$

cũng là một Gaussian có phương sai $\sqrt{\sigma^2 + \sigma_0^2}$ do tính tích chập của hai Gaussian cho kết quả là một Gaussian. Lúc này hàm Signature được viết như sau:

$$\begin{aligned} S_B(x, y; \sigma) &= \sigma^2 \cdot \nabla^2 L(x, y; \sigma) \\ &= \sigma^2 \cdot \frac{(x^2 + y^2 - 2(\sigma^2 + \sigma_0^2))}{\sigma^4} \cdot G\left(x, y; \sqrt{\sigma^2 + \sigma_0^2}\right) \\ &= \sigma^2 \cdot \frac{(x^2 + y^2 - 2(\sigma^2 + \sigma_0^2))}{2\pi(\sigma^2 + \sigma_0^2)^3} \cdot G\left(x, y; \sqrt{\sigma^2 + \sigma_0^2}\right) \end{aligned} \quad (4.29)$$

Do $S_B(x, y; \sigma)$ có cực trị toàn cục tại điểm ở tâm (chứng minh tính chất này bằng giải đạo hàm của $\frac{\partial S_B}{\partial r} = 0$ với $r = \sqrt{x^2 + y^2}$ là khoảng cách tới tâm), nên ta có:

$$S_B(0, 0; \sigma) = \sigma^2 \cdot \frac{-2(\sigma^2 + \sigma_0^2)}{2\pi(\sigma^2 + \sigma_0^2)^3} = \frac{-\sigma^2}{\pi(\sigma^2 + \sigma_0^2)^2}. \quad (4.30)$$

2251 Đạo hàm của nó:

$$2252 \quad \frac{\partial S_B(0,0;\sigma)}{\partial \sigma} = \frac{2\sigma(\sigma^2 - \sigma_0^2)}{\pi(\sigma^2 + \sigma_0^2)^3} \quad (4.31)$$

2253 có nghiệm tại $\sigma = 0$ và $\sigma = \sigma_0$. Với $\sigma = 0$ ta quay trở lại trường hợp blob điểm ở
 2254 phần trước và $\sigma = \sigma_0$ cho biết tham số tỉ lệ σ tìm được tìm chính xác bằng kích thước
 2255 của độ rộng σ_0 của đốm sáng trong ảnh $I(x, y)$.

2256 4.2.3.4. Phát hiện blob sử dụng Laplacian của Gaussian (Laplacian of Gaussian – LoG)


2257 Trong thực tế, $I(x, y)$ là một ảnh bất kỳ nên không thể có cực trị tại điểm tâm (0,0)
 2258 cũng như không thể ước lượng trực tiếp tham số tỉ lệ theo công thức (4.31). Ta có
 2259 hàm Signature để tìm blob như sau:

$$\begin{aligned} S_B(x, y; \sigma) &= \sigma^2 \cdot \nabla^2 L(x, y; \sigma) \\ 2260 \quad &= \sigma^2 \cdot \nabla^2 (G(x, y; \sigma) * I(x, y)) \\ &= \sigma^2 \cdot \nabla^2 G(x, y; \sigma) * I(x, y) \end{aligned} \quad (4.32)$$

2261 Ở đây, $\nabla^2 G(x, y; \sigma)$ là toán tử Laplace của hàm Gaussian (Laplace of Gaussian
 2262 – LoG):


$$2263 \quad \nabla^2 G(x, y; \sigma) = \frac{\partial^2 G(x, y; \sigma)}{\partial x^2} + \frac{\partial^2 G(x, y; \sigma)}{\partial y^2}. \quad (4.33)$$

2264 và được trực quan hóa trong hình 4.22.



2265
 2266 Hình 4.22. Hình ảnh trực quan của một LoG với $\sigma = 1$.

2267 Với ảnh $I(x, y)$ cho trước, các blob tìm được là các bộ (x^*, y^*, σ^*) ở các cực trị
 2268 địa phương của hàm Signature (4.32). Hình 4.23 hiển thị một kết quả thực nghiệm
 2269 với đầu vào là một ảnh bên trái. Các đốm sáng tìm được được hiển thị ở ảnh bên
 2270 phải bằng các đường tròn có tọa độ là (x^*, y^*) và có bán kính là σ^* .



Hình 4.23. Kết quả các blob sáng tìm được trên nền ảnh đen.

4.2.3.5. Phát hiện blob sử dụng Sai khác của Gaussian (Difference of Gaussian – DoG)

Sai khác của Gaussian (DoG) là một cách xấp xỉ và đơn giản hóa LoG cho việc cài đặt đơn giản hơn, hiệu quả hơn mà độ chính xác phát hiện blob là tương đương. Để xây dựng DoG, ta bắt đầu từ đạo hàm theo phương sai σ của Gaussian:

$$\frac{\partial G(x, y; \sigma)}{\partial \sigma} = \sigma \left(\frac{\partial^2 G(x, y; \sigma)}{\partial x^2} + \frac{\partial^2 G(x, y; \sigma)}{\partial y^2} \right) = \sigma \nabla^2 G(x, y; \sigma), \quad (4.34)$$

hay

$$\nabla^2 G(x, y; \sigma) = \frac{1}{\sigma} \cdot \frac{\partial G(x, y; \sigma)}{\partial \sigma} \quad (4.35)$$

Khi xấp xỉ đạo hàm bằng sai phân hữu hạn, ta có đạo hàm $\frac{\partial G(x, y; \sigma)}{\partial \sigma} \approx \frac{G(x, y; k\sigma) - G(x, y; \sigma)}{(k-1)\sigma}$ và thay vào (4.34) ta được:

$$\nabla^2 G(x, y; \sigma) \approx \frac{G(x, y; k\sigma) - G(x, y; \sigma)}{(k-1)\sigma^2}. \quad (4.36)$$

Thay vào (4.32) ta được:

$$S_B(x, y; \sigma) \approx \frac{G(x, y; k\sigma) - G(x, y; \sigma)}{(k-1)} \quad (4.37)$$

Điều đó có nghĩa hàm Signature để phát hiện blob có thể được thực hiện thông qua hai lần lọc Gaussian. Do tính chất của Gaussian có thể tách phép lọc theo từng thành phần nên chi phí tính toán của DoG giảm đi đáng kể so với LoG. Ví dụ, ảnh $I(x, y)$ có M điểm ảnh và cửa sổ lọc Gaussian có kích thước là n , ta có

- Số phép tính LoG cần là $O(M \cdot n^2)$: mỗi điểm ảnh của $I(x, y)$ cần thực hiện tối thiểu n^2 phép tính nhân trong cửa sổ Gaussian.
- Số phép tính DoG cần $O(2 \cdot M \cdot 2n)$: mỗi điểm ảnh của $I(x, y)$ cần thực hiện 2 lần lọc thành phần Gaussian theo trục x và thành phần Gaussian theo trục y, mỗi thành phần có n phép tính nhân. Đồng thời ta phải thực hiện 2 lần lọc Gaussian.

Có thể thấy độ phức tạp $O(M \cdot 2n)$ của DoG nhỏ hơn nhiều lần so với độ phức tạp $O(M \cdot n^2)$ của LoG. Nên trong thực tế, các phương pháp phát hiện và mô tả đặc trưng ảnh như SIFT hay SURF đều sử dụng DoG để phát hiện blob.

4.3. Đặc trưng hình dạng


Trong nhiều bài toán thị giác máy, một vật thể có thể có một màu đồng nhất và màu này tương đối khác biệt với phần nền còn lại, Hình 4.24 (a). Hình ảnh của riêng vật thể đó có thể được tách ra khỏi nền bằng kỹ thuật nhị phân hóa (binarization). Từ đó, đường bao và hình dạng của vật thể được phân tách và sử dụng để biểu diễn các đặc điểm của vật thể giúp cho việc phân tích và trích rút thông tin thể dàng hơn.

Ảnh đầu vào được nhị phân hóa với giá trị điểm ảnh là 1 nếu nó thuộc vật thể, và là 0 nếu nó thuộc nền. Với giả thiết vật thể có đồng sự đồng nhất về màu sắc và khác biệt với màu nền, ảnh nhị phân có thể thu được bằng kỹ thuật lấy ngưỡng:

$$I_B(x, y) = \begin{cases} 0, & th_1 < I(x, y) < th_2 \\ x, & \text{ngược lại} \end{cases} \quad (4.38)$$

trong đó $I(x, y)$ là ảnh đầu vào th_1 và th_2 là hai ngưỡng giới hạn màu của vật thể, xem Hình 4.24 (b).

Phần phần còn lại của mục này sẽ giới thiệu hai đặc trưng điển hình là đường bao (contour), Hình 4.24 (c), cho biết phần rìa ngoài của đối tượng và đặc trưng hình dạng (shape) cho thấy hình ảnh toàn thể của vật thể.



Hình 4.24. Đường bao và hình dạng của vật thể.

4.3.1. Trích rút đặc trưng đường bao

Đường bao của một vật thể rất quan trọng trong nhiều bài toán thị giác máy do nó giúp cho việc phân đoạn ảnh, phân tích và trích rút đặc trưng của các đối tượng trong ảnh. Đặc trưng đường bao chỉ quan tâm đến phần viền của vật thể và bỏ qua các chi tiết kết cấu bên trong vật thể.

4.3.1.1 Trích xuất đường bao


Giải thuật tìm đường bao do Suzuki đề xuất trong (Suzuki 1985) trong ảnh nhị phân hiện vẫn đang được sử dụng trong nhiều thư viện thị giác máy do tính đơn giản và hiệu quả. Cho trước ảnh nhị phân $I_B(x, y)$ như được hiển thị trong Hình 4.29

(b), thuật toán sẽ tìm ra tất cả các đường bao của các vùng vật thể bao gồm: đường bao ngoài (outer borders), đường bao trong (inner borders) và cấu trúc phân cấp giữa chúng. Giải thuật bao gồm 3 bước chính sau:

Bước 1 – Duyệt ảnh để phát hiện loại đường bao: Quét từng điểm ảnh từ trái sang phải và từ trên xuống, xem các đường mũi tên màu đỏ đứt đoạn ở Hình , cho đến khi gặp một điểm có giá trị là 1 và bên trái là 0 (gặp đường bao ngoài) hoặc gặp một điểm có giá trị là 0 và bên phải là 1 (gặp đường bao trong) và chuyển sang bước 2.

Bước 2 – Theo vết đường bao: Lăn theo từng điểm liên tiếp để tạo thành đường bao khép kín theo nguyên tắc 8-láng giềng. Giả sử, hiện tại tìm đến điểm q trong Hình 4.25 (a). Điểm trước đó là p tương ứng với ô số 8 trong mẫu 8-láng giềng trong Hình 4.25 (b). Điểm tiếp theo sau điểm q được xác định bằng cách quét 8 lân cận quanh điểm q bắt đầu từ vị trí sau vị trí của điểm q (bắt đầu từ số 1). Trong ví dụ này, điểm n là điểm tiếp theo để tạo thành đường bao sẽ ở vị trí số 3. Cứ thực hiện như vậy cho đến khi đường bao được khép kín thì chuyển sang bước 3.

Bước 3 – Gán nhãn cho đường bao vừa khép kín vừa tìm được ở bước 2 và xây dựng cấu trúc phân cấp của các đường bao dựa vị trí phát hiện của các đường bao.




Hình 4.25. Ví dụ về giải thuật tìm đường bao.

Như vậy, kết quả của giải thuật phát hiện đường bao là danh sách các dãy liên tiếp các điểm ảnh. Mỗi dãy tương ứng với một đường bao khép kín (điểm đầu và điểm cuối chùng nhau). Cấu trúc phân cấp cho biết một đường bao ngoài có thể chứa trong nó một hoặc nhiều đường bao trong, và một đường bao trong cũng có thể chứa một hoặc nhiều đường bao ngoài.

4.3.2.2. Hàm Signature hình dạng (shape signature)

Đường bao sau khi được trích xuất là một danh sách liên tiếp các điểm ảnh 2 chiều và không tiện cho các pha xử lý tiếp theo. Do đó, chúng được chuyển đổi

2351 thành một hàm 1D (đi men theo đường bao), gọi là hàm signature, để dễ xử lý cho
2352 các tác vụ thị giác máy (nhận dạng, so khớp, so sánh, ...).



2353

2354 **Hình 4.26. Hàm signature “khoảng cách từ tâm đến biên” của hình quả táo.**

2355 Có một số loại hàm signature như sau: Khoảng cách từ tâm đến biên (centroid
2356 distance) (Xem Hình 4.26), góc tiếp tuyến dọc biên (turning angle), độ cong tại từng
2357 điểm (curvature), tọa độ phức của từng điểm biên (complex coordinate), ... Hàm
2358 signature thường được chuẩn hóa để giúp chúng bất biến với các thao tác tịnh tiến
2359 (shift invariant) và co giãn (scale invariant). Bên cạnh đó, hàm signature khá nhạy
2360 với nhiễu, một sự thay đổi nhỏ ở phần đường bao của đối tượng cũng tác động
2361 mạnh tới hàm. Do đó, người ta không làm việc trực tiếp với hàm mà cần có thêm
2362 một bước xử lý nữa.

2363 4.3.2.3. Moment của đường bao (Boundary moment)

2364 Moment của đường bao là một cách để giảm số chiều cần thiết để biểu diễn
2365 đường bao. Gọi $c(i)$ là hàm signature hình dạng một đường bao có độ dài N .
2366 Moment bậc r và moment trung tâm bậc r của $c(i)$ được định nghĩa như sau:

$$2367 m_r = \frac{1}{N} \sum_{i=1}^N [c(i)]^r \quad (4.39)$$

2368 và

$$2369 \mu_r = \frac{1}{N} \sum_{i=1}^N [c(i) - m_1]^r. \quad (4.40)$$

2370 Các moment chuẩn hóa $\bar{m}_r = \frac{m_r}{(\mu_2)^{\frac{r}{2}}}$, $\bar{\mu}_r = \frac{\mu_r}{(\mu_2)^{\frac{r}{2}}}$ là bất biến với các biến đổi xoay,
2371 co giãn và tịnh tiến. Ngoài ra có thể sử dụng thêm các mô tả đường bao $F_1 = \frac{(\mu_2)^{\frac{1}{2}}}{m_1}$,
2372 $F_2 = \frac{\mu_3}{(\mu_2)^{\frac{3}{2}}}$ và $F_3 = \frac{\mu_4}{(\mu_2)^2}$. So với hàm signature, các mô tả này ít nhạy cảm với nhiễu
2373 hơn.

2374 Như vậy, với $r = 4$, ta có thể xây dựng vector đặc trưng cho một đường biên
2375 gồm có 11 phần tử là:

$$2376 F_{BM} = (\bar{m}_1, \bar{m}_2, \bar{m}_3, \bar{m}_4, \bar{\mu}_1, \bar{\mu}_2, \bar{\mu}_3, \bar{\mu}_4, F_1, F_2, F_3). \quad (4.41)$$

2377 4.3.2. Trích rút đặc trưng Hu moments (Hu moments)

2378 Với mỗi hình dạng của vật thể trong Hình 4.29 (b) có thể được tách riêng biệt
2379 như trong Hình 4.27 và được biểu diễn bằng một bộ vector mô tả.



Hình 4.27. Ảnh hình dạng của một số vật thể.

Ký hiệu $I(x, y)$ là ảnh nhị phân của một vật thể. Khái niệm moment ảnh coi ảnh $I(x, y)$ một phân bố khối lượng, giá trị điểm ảnh càng lớn thì khối lượng chất điểm đó càng lớn và ngược lại. Moment của ảnh mô tả các đặc trưng vật lý của ảnh và được tính theo công thức sau:

$$M_{p,q} = \sum_x \sum_y x^p y^q I(x, y), \quad (4.42)$$

với $p \geq 0$ và $q \geq 0$ là hai bậc theo từng chiều của ảnh.

Có thể diễn giải cách moment mô tả ảnh như sau:

- $M_{0,0}$ là tổng khối lượng của ảnh.
- $M_{1,0}$ và $M_{0,1}$ cho biết trọng tâm của ảnh.
- $M_{2,0}$ cho biết mức độ kéo dãn theo trục x của ảnh.
- $M_{0,2}$ cho biết mức độ kéo dãn theo trục y của ảnh.
- $M_{1,1}$ cho biết mức độ kéo dãn theo cả trục x và trục y của ảnh.

Dễ dàng nhận thấy các moment $M_{p,q}$ phụ thuộc vào vị trí, góc xoay và kích thước lớn nhỏ của đối tượng trong ảnh nên khó có thể sử dụng trực tiếp để mô tả ảnh. Do đó, Hu đề xuất trong (Hu 1962) một phương pháp tính toán các đặc trưng ảnh dựa trên các image moments sao cho chúng bất biến vị trí (dịch chuyển), xoay và tỉ lệ.

Đầu tiên moment trung tâm được tính lại từ image moment bằng cách dịch chuyển toàn bộ điểm ảnh về điểm trung tâm của ảnh để loại bỏ ảnh hưởng vị trí tịnh tiến (translation):

$$\mu_{p,q} = \sum_x \sum_y (x - \bar{x})^p (y - \bar{y})^q I(x, y), \quad (4.43)$$

trong đó $(\bar{x}, \bar{y})$ là tọa độ tâm của ảnh. Tiếp theo là chuẩn hóa để loại bỏ ảnh hưởng của tỉ lệ:

$$\eta_{p,q} = \frac{\mu_{p,q}}{(\mu_{0,0})^{1+\frac{p+q}{2}}}. \quad (4.44)$$

Cuối cùng, các Hu moment được tính theo các công thức sau:

$$\phi_1 = \eta_{2,0} + \eta_{0,2}, \quad (4.45)$$

đo mức độ phân tán của hình theo cả hai trục, hình tròn phân bố đều ϕ_1 nhỏ, hình dẹt hoặc kéo dài ϕ_1 lớn;

$$\phi_2 = (\eta_{2,0} - \eta_{0,2})^2 + 4\eta_{1,1}^2, \quad (4.46)$$

2411 đo mức độ khác biệt giữa hai trục, hình đối xứng tròn thì ϕ_2 nhỏ, hình dẹt theo một
2412 hướng thì ϕ_1 lớn;

$$2413 \quad \phi_3 = (\eta_{3,0} - 3\eta_{1,2})^2 + (3\eta_{2,1} - \eta_{0,3})^2, \quad (4.47)$$

2414 đo độ bất đối xứng ở phần đuôi của đối tượng, ϕ_3 tăng nếu hình có phần đuôi
2415 hướng ra ngoài rõ rệt (ví dụ hình số 6 hoặc số 9), ϕ_3 giảm nếu hình có dạng tròn;

$$2416 \quad \phi_4 = (\eta_{3,0} + \eta_{1,2})^2 + (\eta_{2,1} + \eta_{0,3})^2, \quad (4.48)$$

2417 phát hiện hai thùy cong đối xứng của hình;

$$2418 \quad \phi_5 = (\eta_{3,0} - 3\eta_{1,2})(\eta_{3,0} + \eta_{1,2}) \left[(\eta_{3,0} + \eta_{1,2})^2 - 3(\eta_{2,1} + \eta_{0,3})^2 \right] + (3\eta_{2,1} -$$

$$2419 \quad \eta_{0,3})(\eta_{2,1} + \eta_{0,3}) \left[3(\eta_{3,0} + \eta_{1,2})^2 - (\eta_{2,1} + \eta_{0,3})^2 \right], \quad (4.49)$$

2420 phát hiện hình có nhiều nhánh;

$$2421 \quad \phi_6 = (\eta_{2,0} - \eta_{0,2}) \left[(\eta_{3,0} + \eta_{1,2})^2 - (\eta_{2,1} + \eta_{0,3})^2 \right] + 4\eta_{1,1}(\eta_{3,0} + \eta_{1,2})(\eta_{2,1} +$$

$$2422 \quad \eta_{0,3}), \quad (4.50)$$

2423 phát hiện độ cong mạnh và không thẳng hàng với trục chính (ví dụ chữ P, chữ G)
2424 và

$$2425 \quad \phi_7 = (3\eta_{2,1} - \eta_{0,3})(\eta_{3,0} + \eta_{1,2}) \left[(\eta_{3,0} + \eta_{1,2})^2 - 3(\eta_{2,1} + \eta_{0,3})^2 \right] - (\eta_{3,0} -$$

$$2426 \quad 3\eta_{1,2})(\eta_{2,1} + \eta_{0,3}) \left[3(\eta_{3,0} + \eta_{1,2})^2 - (\eta_{2,1} + \eta_{0,3})^2 \right], \quad (4.51)$$

2427 phát hiện hình đối xứng gương.

2428 Tóm lại, với mỗi ảnh $I(x, y)$ chứa hình dạng của một vật thể, ta có vector đặc
2429 trưng Hu như sau:

$$2430 \quad F_{HU} = (\phi_1, \phi_2, \phi_3, \phi_4, \phi_5, \phi_6, \phi_7). \quad (4.52)$$

2431 Hu moment đã được chứng minh là có khả năng biểu diễn hình ảnh bất biến
2432 với các phép tịnh tiến, tỉ lệ và xoay và có thể được sử dụng làm đặc trưng để nhận
2433 dạng ảnh. Người đọc tham khảo thêm một nghiên cứu của tác giả được trình bày
2434 trong (Nguyen 2013). Nghiên cứu này đã đề xuất việc sử dụng đặc trưng Hu
2435 moment để mô tả phần biên của bàn tay để nhận dạng cử chỉ bàn tay với độ chính
2436 xác cao.

2437 Đặc trưng Hu moment đã được đề xuất từ năm 1962 bằng các phép tính đơn
2438 giản phù hợp với các hệ thống máy tính thời đó. Dựa trên nền tảng này, nhiều tác
2439 giả đã tiếp tục kế thừa và phát triển. (Abu-Mostafa 1984) đã giới thiệu ý tưởng sử
2440 dụng moment phức (complex moments) để tính toán các đại lượng bất biến
2441 (invariants). Cách tiếp cận này sau đó được Flusser (Flusser 2000, 2002) tiếp tục phát
2442 triển và đề xuất một lý thuyết tổng quát về việc xây dựng các moment bất biến đối
2443 với phép quay.

4.4. Đặc trưng kết cấu (Texture)

Phần trước chúng ta đề cập đến đặc trưng hình dạng. Những đặc trưng này chỉ quan tâm đến đường bao và hình dạng tổng thể của một vật thể trong ảnh mà bỏ qua các chi tiết trên bề mặt vật. Đặc trưng kết cấu (texture) được trình bày trong phần này tập trung vào mô tả vật thể dựa vào các chi tiết bề mặt đó.



Hình 4.28. Kết cấu (texture) trong ảnh.

Có thể hiểu kết cấu (texture) là sự sắp xếp trong không gian trong vùng ảnh các cường độ sáng phản ánh các mẫu lặp lại có tính cấu trúc của bề mặt vật thể. Ví dụ, Hình 4.28 (a) một ảnh của một tấm thảm đang trải trên một mặt có chất liệu gỗ. Các Hình 4.28 (b), (c) và (d) là các vùng ảnh nhỏ được trích ra từ ảnh lớn đại diện cho các kết cấu khác nhau.

Đặc trưng kết cấu có thể được sử dụng để mô tả các đặc trưng hình học (cạnh, điểm hoặc blob) giúp nhận biết và phân biệt các vùng có bề mặt hoặc chất liệu khác nhau trong ảnh dưới dạng các vector, gọi là vector đặc trưng kết cấu. Các vector này sẽ được sử dụng để đối sánh các đặc trưng hình học giữa nhiều ảnh với nhau để thực hiện các chức năng nhận thức cấp cao.


4.4.1. Mẫu nhị phân cục bộ (local binary patterns - LBP)

Mẫu nhị phân cục bộ (local binary patterns - LBP) là một trong những kỹ thuật để mô tả kết cấu bề mặt vật thể đơn giản nhưng khá hiệu quả. Bộ mô tả có khả năng bất biến với chiếu sáng cục bộ (invariant to local illumination) (Ojala 1996).

Cho ảnh đa cấp xám $I(x, y)$, để đơn giản, ta ký hiệu I_c là giá trị của điểm ảnh tại vị trí tọa độ c . Để trích xuất đặc trưng LBP, ta bắt đầu với thiết lập mô tả cục bộ dựa trên một bộ các giá trị xám của P điểm ảnh lân cận với một điểm cho trước có tọa độ c :

$$T(P, R) = (I_c, I_0, I_1, \dots, I_{P-1}), \quad (4.53)$$

2470 4.4.1.1. Mẫu cục bộ (local pattern)



2471 Hình 4.29. Lân cận để tính LBP theo P và R .

2472 trong đó các điểm ảnh $I_0, I_1, \dots, I_{P-1}$ được lấy ở các vị trí cách đều nhau trên đường
 2473 tròn có tâm ở điểm I_c và có bán kính R . Hình 4.29 hiển thị các vị trí các điểm ảnh
 2474 này với các giá trị P và R khác nhau. Trong đó điểm I_c là điểm ảnh ở chính giữa
 2475 đường tròn. Các dấu x màu đỏ nằm trên đường tròn là điểm lân cận thực và các
 2476 điểm dấu x màu xanh là các điểm ảnh $I_c, I_0, I_1, \dots, I_{P-1}$ được lấy xấp xỉ tương ứng.

2477 Ở đây, các giá trị P và R nhỏ tăng tập trung mô tả chi tiết cục bộ và bị tác động
 2478 bởi nhiễu, ngược lại P là R lớn mô tả cấu trúc tổng thể và chống nhiễu tốt hơn. Chi
 2479 tiết xem trong Bảng 4.2.

2480 Bảng 4.2. Sử dụng P và R để mô tả kết cấu.

Trường hợp	Ưu điểm	Nhược điểm
P nhỏ, R nhỏ (8,1)	Tính toán đơn giản, chống nhiễu và phù hợp cho texture mịn	Không mô tả được cấu trúc lớn hoặc hướng phức tạp
P lớn, R nhỏ (16,1)	Bắt được hướng chi tiết hơn	Nhạy với nhiễu vì vùng quan sát hẹp
P nhỏ, R lớn (8,3)	Mô tả cấu trúc tổng thể, chống nhiễu tốt	Bỏ sót chi tiết mịn
P lớn, R lớn (24,3)	Mô tả đa hướng và cấu trúc lớn	Phức tạp trong tính toán

2481 4.4.1.2. Nhị phân hóa để bất biến với ánh sáng

2482 Để làm cho bộ mô tả bất biến với ánh sáng, ta giả sử điểm trung tâm I_c là mức
 2483 sáng trung bình trong lân cận của nó, khi đó bộ mô tả cục bộ của I_c chỉ cần quan
 2484 tâm đến sai khác về độ sáng giữa các điểm lân cận và điểm trung tâm, khi đó:

$$2485 \quad T(P, R) \approx (I_0 - I_c, I_1 - I_c, \dots, I_{P-1} - I_c). \quad (4.54)$$

2486 $T(P, R)$ mô tả mức độ sáng hơn hoặc tối hơn của các điểm lân cận so với điểm
 2487 trung tâm. Nếu đây là một vùng đúng đồng đẳng thì $T(P, R)$ chỉ gồm các giá trị 0,

2488 nếu đây là một vùng dốc của cạnh thì các giá trị lớn nhất cho biết hướng của vector
2489 gradient.

2490 Giả sử ảnh bị tác động do chiếu sáng tuyến tính: $I' = a \cdot I + b$, với $a > 0$ và b
2491 là các hệ số tuyến tính. Khi đó

$$2492 \quad I'_p - I'_c = a(I' - I). \quad (4.55)$$

2493 Tức là độ lệch giá trị sáng phụ thuộc tuyến tính vào hệ số chiếu sáng. Tuy nhiên do
2494 $a > 0$ nên ta có:

$$2495 \quad \text{Sign}(I'_p - I'_c) = \text{sign}(a(I' - I)). \quad (4.56)$$

2496 Tức là dấu của sự sai khác không phụ thuộc vào hệ số chiếu sáng.

2497 Do đó, để bất biến với ánh sáng (invariant to illumination):

$$2498 \quad T(P, R) \approx (s(I_0 - I_c), s(I_1 - I_c), \dots, s(I_{P-1} - I_c)), \quad (4.57)$$

2499 trong đó $s(x) = 1$ nếu $x \geq 0$ và $s(x) = 0$ nếu $x < 0$.

2500 Bằng việc gán các hệ số nhị thức với thừa số 2^p cho mỗi $s(I_p - I_c)$ và tính tổng
2501 cho tất cả các điểm lân cận, ta được mẫu nhị phân cục bộ cho điểm I_c :

$$2502 \quad LBP(P, R, I_c) = \sum_{p=0}^{P-1} s(I_p - I_c) \cdot 2^p. \quad (4.58)$$

2503 4.4.1.3. Vector đặc trưng LBP

2504 Để xây dựng vector đặc trưng kết cấu ta phải xét một vùng ảnh và tính LBP
2505 cho tất cả các điểm ảnh trong vùng này. Vùng ảnh này có thể bao gồm toàn bộ hình
2506 dạng vật thể như trong Hình 4.32 hoặc một phần nhỏ có kết cấu (texture) thống nhất
2507 như Hình 4.33 (a)(b)(c).

2508 Tiếp theo, ta xây dựng lược đồ histogram của H theo các giá trị LBP của các
2509 điểm trong vùng đang xét hay
2510 $H(k) = \{I_c | LBP(P, R, I_c) = k\}$
2511 . Cuối cùng, vector đặc trưng LBP có thể thu được từ lược đồ xám sau khi chuẩn
2512 hóa (có tổng bằng 1):

$$2513 \quad F_{LBP}(k) = \frac{H(k)}{\sum H(k)}. \quad (4.59)$$

2514 Ở cùng 1 vùng ảnh, ta có tạo ra nhiều mẫu nhị phân cục bộ với số điểm P và
2515 bán kính R khác nhau để tạo ra các nhiều lược đồ historam. Vector đặc trưng LBP
2516 được xây dựng bằng cách nối tiếp các historam đó.


2517 Hình 4.30 hiển thị kết quả LBP với $P = 8$ và $R = 1$ dưới dạng ảnh đen trắng
2518 của hai kết cấu vật liệu vải (a) và vật liệu gỗ (b). Trong ảnh LBP (a), các vùng có thay
2519 đổi cường độ sáng tương tự nhau được mã hoá thành các mẫu nhị phân gần giống
2520 nhau. Điều này cho phép mô tả hoa văn và độ nhám cục bộ của vật liệu mà không
2521 phụ thuộc vào độ sáng tuyệt đối. Ảnh LBP (b) mã hóa các vùng sáng tối cục bộ,

2522 trong đó thấy xuất hiện các đường song song rõ nét tương ứng với hướng kết cấu
2523 của vật liệu.



2524 Hình 4.30. Kết quả *LBP* với $P = 8$ và $R = 1$ cho kết cấu vật liệu vải (a)
2525 và vật liệu gỗ (b).

2526 Hình 4.31 là đồ thị của hai véc tơ đặc trưng (trong trường hợp này là lược đồ
2527 xám) *LBP*. Có thể thấy, đồ thị màu nâu nhạt (vải) phân bố tương đối rộng, cho thấy
2528 kết cấu không định hướng và đồ thị màu nâu đậm (gỗ) có đỉnh nổi bật hơn các giá
2529 trị thấp xung quanh, phản ánh cấu trúc định hướng và lặp lại mạnh (vân gỗ song
2530 song).



2531
2532 Hình 4.31. Vector *LBP* của hai mẫu vật liệu vải và gỗ.

2533 4.4.2. Ma trận đồng xuất hiện mức xám (GLCM)

2534 (Haralick 1973) đưa ra giả định rằng thông tin kết cấu được thể hiện qua mối
2535 quan hệ không gian tổng quát giữa các mức xám trong ảnh và thông tin này có thể
2536 được mô tả bằng một ma trận đồng xuất hiện mức xám (gray-level co-occurrence
2537 matrix – GLCM). Ma trận này được tính toán từ các góc định hướng khác nhau và
2538 các khoảng cách giữa các cặp điểm lân cận trên ảnh.

2539 4.5.2.1. Xây dựng ma trận GLCM

2540 GLCM mô tả mối quan hệ không gian giữa các giá trị xám trong ảnh giống
2541 như một bộ histogram được tính cho một cặp độ sáng theo một góc cho trước. Nói

một cách khác, nếu hai điểm ảnh có độ xám là i và j và cách nhau một khoảng d theo hướng θ thì ta đếm tần suất xuất hiện của cặp độ xám (i, j) .

Cho ảnh $I(x, y)$ cùng với d và θ là khoảng cách và góc xác định hướng giữa 2 điểm lân cận. Ở đây, d và θ được sử dụng để tính khoảng cách tịnh tiến giữa hai điểm là $(d \cdot \cos \theta, d \cdot \sin \theta)$. Từ đó, tần suất xuất hiện cặp xám (i, j) như sau:

$$P(i, j) = \{ (x, y) | I(x, y) = i, I(x + d \cdot \cos \theta, y + d \cdot \sin \theta) = j \} \quad (4.60)$$


Chú ý rằng, d là khoảng cách giữa hai điểm để tính mối tương quan mức xám, d nhỏ phân tích chi tiết cục bộ, d lớn phân tích cấu trúc tổng thể. Hướng θ cần được xác định để bao phủ toàn bộ mặt phẳng và cân bằng được độ chính xác và chi phí tính toán. Thực tiễn, θ được lấy theo bốn hướng chuẩn: $0^\circ, 45^\circ, 90^\circ$ và 135° .

Sau đó, ma trận GLCM thu được từ việc chuẩn hóa $P(i, j)$:

$$p(i, j) = \frac{P(i, j)}{\sum_{i, j} P(i, j)}. \quad (4.61)$$

Lúc này $p(i, j)$ là xác suất để hai điểm ảnh có giá trị là i và j có quan hệ không gian (d, θ) .

Ta lấy ảnh trong Hình 4.33 (b) để làm ví dụ. Ảnh màu được chuyển thành đa cấp xám bằng cách lấy trung bình giá trị điểm ảnh của cả ba kênh màu. Để đơn giản trong việc trình bày, ta đưa ảnh đa cấp xám về 5 mức xám:



và lấy một vùng ảnh 8×8 ở góc trái trên:

$$I = \begin{bmatrix} 255 & 192 & 64 & 0 & 0 & 64 & 128 & 192 \\ 255 & 255 & 128 & 64 & 0 & 0 & 64 & 128 \\ 255 & 255 & 255 & 192 & 64 & 64 & 0 & 0 \\ 255 & 255 & 255 & 192 & 192 & 128 & 64 & 64 \\ 192 & 192 & 192 & 192 & 192 & 192 & 128 & 64 \\ 192 & 128 & 64 & 64 & 128 & 128 & 64 & 64 \\ 64 & 64 & 64 & 64 & 128 & 128 & 64 & 64 \\ 64 & 64 & 64 & 128 & 128 & 128 & 128 & 64 \end{bmatrix}$$

Có thể thấy ảnh có 5 mức xám là 0, 64, 128, 192 và 255.

Tiếp theo, ta tính ma trận GLCM, $P(i, j)$, với $d = 1$ và $\theta = 45^\circ$, tức là tính histogram của các cặp độ xám (i, j) với độ xám i ở tọa độ (x, y) thì độ xám j ở tọa độ $(x + 1, y - 1)$:

$P(i, j)$	0	64	128	192	255
0	0	1	2	0	0

64	3	8	2	3	0
128	2	4	4	2	0
192	1	3	1	3	2
255	0	2	1	3	3

Sau khi chuẩn hóa, ta được ma trận xác suất $p(i, j)$ được trình bày trong Bảng 4.2.

Bảng 4.2. Ma trận xác suất GLCM $p(i, j)$ cùng với phân bố xác suất theo thành phần thứ nhất $p_x(i)$ và thứ hai $p_y(j)$.

$p(i, j)$	0	64	128	192	255	$p_x(i)$
0	0	0.0204	0.0408	0	0	0.0612
64	0.0612	0.1633	0.0408	0.0612	0	0.3265
128	0.0408	0.0816	0.0816	0.0408	0	0.2448
192	0.0204	0.0612	0.0204	0.0612	0.0408	0.2040
255	0	0.0408	0.0204	0.0612	0.0612	0.1836
$p_y(j)$	0.1224	0.3673	0.2040	0.2244	0.1020	

4.5.2.2. Đặc trưng Haralick

Vẫn dựa trên giả định ban đầu là toàn bộ thông tin về kết cấu ảnh được chứa trong ma trận GLCM, Haralick tiếp tục đưa ra một bộ các phép đo đặc trưng kết cấu dựa trên các giá trị của ma trận này. Một số phép đo liên quan đến những đặc tính kết cấu cụ thể của ảnh như tính đồng nhất (homogeneity), độ tương phản (contrast) và sự hiện diện của các cấu trúc có tổ chức bên trong ảnh. Các phép đo khác mô tả mức độ phức tạp và các chuyển tiếp mức xám xảy ra trong ảnh.

Để xây dựng các phép đo đặc trưng, ta thiết lập một số ký hiệu sau:

- Phân bố của mức xám ở vị trí thứ nhất và vị trí thứ hai trong cặp (i, j) được định nghĩa là:

$$p_x(i) = \sum_j p(i, j) \text{ và } p_y(j) = \sum_i p(i, j). \quad (4.62)$$

- Giá trị trung bình của mức xám ở vị trí thứ nhất và vị trí thứ hai:

$$\mu_x = \sum_i i \cdot p_x(i) \text{ và } \mu_y = \sum_j j \cdot p_y(j). \quad (4.63)$$

- Phương sai của mức xám ở vị trí thứ nhất và vị trí thứ hai:

$$\sigma_x = \sqrt{\sum_i (i - \mu_x)^2 \cdot p_x(i)} \text{ và } \sigma_y = \sqrt{\sum_j (j - \mu_y)^2 \cdot p_y(j)}. \quad (4.64)$$

- Phân bố của tổng và hiệu mức xám:

$$p_{x+y}(k) = \sum_{i+j=k} p(i, j) \text{ và } p_{x-y}(k) = \sum_{i-j=k} p(i, j). \quad (4.65)$$

2589 - Entropy kết hợp:

$$2590 \quad H_{XY} = -\sum_{i,j} p(i,j) \cdot \log(p(i,j)). \quad (4.66)$$

2591 - Entropy của mức xám thứ nhất và mức xám thứ hai:

$$2592 \quad H_X = \sum_i p_x(i) \cdot \log(p_x(i)) \text{ và } H_Y = \sum_j p_y(j) \cdot \log(p_y(j)). \quad (4.67)$$

2593 - Entropy giả định độc lập:

$$2594 \quad H_{XY1} = -\sum_{i,j} p(i,j) \cdot \log[p_x(i) \cdot p_y(j)]. \quad (4.68)$$

2595 - Entropy độc lập hoàn toàn:

$$2596 \quad H_{XY1} = -\sum_{i,j} p_x(i) \cdot p_y(j) \cdot \log[p_x(i) \cdot p_y(j)]. \quad (4.69)$$

2597

2598 Bảng 4.3. Các phép đo đặc trưng Haralick.

STT	Phép đo	Ý nghĩa
1	Moment góc bậc 2: $h_1 = \sum_{i,j} [p(i,j)]^2.$	Đo độ đồng đều, giá trị cao cho biết ảnh có cấu trúc lặp lại, ít ngẫu nhiên.
2	Độ tương phản: $h_2 = \sum_n n^2 (\sum_{ i-j =n} p(i,j)).$	Đo độ tương phản trung bình.
3	Tương quan: $h_3 = \frac{\sum_{i,j} (i-\mu_x)(j-\mu_y)p(i,j)}{\sigma_x \sigma_y}.$	Đo mức độ tương quan tuyến tính giữa các giá trị mức xám, giá trị cao cho biết mức xám phụ thuộc lẫn nhau.
4	Độ lệch: $h_4 = \sum_{i,j} (i - \mu)^2 p(i,j).$	Đo độ phân tán của mức xám quanh trung bình, thể hiện độ phong phú của mức xám trong ảnh.
5	Moment khác biệt đảo ngược (inverse different moment): $h_5 = \sum_{i,j} \frac{p(i,j)}{1+(i-j)^2}.$	Đo tính đồng nhất, cao nếu các giá trị mức xám lân cận gần nhau.
6	Trung bình tổng (sum average): $h_6 = \sum_n n \cdot p_{x+y}(n).$	Đo xu hướng sáng/tối trung bình của các cặp điểm.
7	Độ lệch tổng (sum variance): $h_7 = \sum_n (n - h_6) \cdot p_{x+y}(n).$	Đo độ biến thiên của phân bố tổng mức xám (mức độ thay đổi của độ sáng trung bình).
8	Entropy tổng (sum entropy): $h_8 = -\sum_n p_{x+y}(n) \log(p_{x+y}(n)).$	Đo độ phức tạp của phân bố tổng mức xám, giá trị cao cho biết ảnh chứa nhiều dạng mẫu khác nhau.

9	Entropy: $h_9 = HXY.$	Đo mức độ ngẫu nhiên tổng thể của kết cấu, giá trị cao cho biết kết cấu phức tạp, không đồng nhất.
10	Độ lệch khác biệt (difference variance): $h_{10} = \text{variance của } p_{x-y}(n).$	Đo tính tương phản (thay đổi) cục bộ thông qua độ biến thiên của phân bố hiệu mức xám.
11	Entropy khác biệt (difference entropy): $h_{11} = -\sum_n p_{x-y}(n)\log(p_{x-y}(n)).$	Đo độ phức tạp của chuyển tiếp mức xám.
12	Độ đo thông tin tương quan 1 (information measure of correlation 1 - IMC1): $h_{12} = \frac{HXY - HXY1}{\max\{HX, HY\}}$	Đo mức độ phụ thuộc thông tin giữa i và j .
13	Độ đo thông tin tương quan 2 (information measure of correlation 2 - IMC2): $h_{13} = (1 - e^{-2 \cdot (HXY2 - HXY)})^{\frac{1}{2}}$	Đo mức độ phụ thuộc thông tin, giá trị cao cho biết mức xám có tính cấu trúc.
14	Hệ số tương quan cực đại: h_{14} là giá trị riêng lớn thứ nhì (second largest eigenvalue của): $Q(i, j) = \sum_k \frac{p(i, k)p(j, k)}{p_x(i)p_y(j)}.$	Đo mức độ tương quan phi tuyến giữa các mức xám, giá trị cao phản ánh cấu trúc phức tạp.

2599

2600 Bộ các phép đo kết cấu được mô tả thông qua 14 công thức được liệt kê trong
 2601 Bảng 4.3. Mỗi phép đo cho biết một tính chất kết cấu chứa trong ma trận GLCM.
 2602 Như vậy, một ảnh I cho trước, với mỗi khoảng d và hướng θ , ta thu được một ma
 2603 trận GLCM. Vector đặc trưng kết cấu Haralick được thiết lập từ các giá trị trung
 2604 bình và phương sai của các phép đo kết cấu theo 4 hướng (0° , 45° , 90° và 135°).

2605

Bảng 4.3. Ví dụ xây dựng vector đặc trưng kết cấu GLCM.

Phép đo thứ i	h_i theo hướng 0°	h_i theo hướng 45°	h_i theo hướng 90°	h_i theo hướng 135°	Trung bình μ_i	Phương sai σ_i
1	0.0976	0.0721	0.0874	0.1029	0.0900	0.0117
2	0.3124	0.2684	0.2956	0.3207	0.2993	0.0200

3	0.6429	1.7959	0.9286	0.7143	1.0204	0.4599
4	0.7957	0.3984	0.6960	0.7874	0.6694	0.1612
5	1.5175	1.4219	1.4078	1.2520	1.3998	0.0952
6	0.7429	0.5918	0.6857	0.7408	0.6903	0.0613
7	5.7857	5.8776	5.9286	5.8980	5.8724	0.0533
8	12.6924	13.2482	13.6883	13.4462	13.2688	0.3675
9	3.0168	2.8340	3.0044	3.0252	2.9701	0.0789
10	3.5533	4.0275	3.7678	3.4779	3.7066	0.2136
11	0.3559	0.8363	0.4681	0.4107	0.5177	0.1882
12	1.2417	1.7912	1.4183	1.3102	1.4403	0.2121
13	-0.3569	-0.1435	-0.2646	-0.3832	-0.2871	0.0938
14	0.8909	0.6813	0.8312	0.9058	0.8273	0.0888

2606

2607 Bảng 4.4 liệt kê kết quả tính toán 14 độ đo kết cấu Haralick theo 4 hướng (0°,
2608 45°, 90° và 135°) cùng với các giá trị trung bình và phương sai tương ứng. Cuối cùng,
2609 vector đặc trưng kết cấu Haralick có tổng cộng 28 thành phần:

2610
$$F_{GLCM} = (\mu_1, \sigma_1, \mu_2, \sigma_2, \dots, \mu_{14}, \sigma_{14}). \quad (4.70)$$

2611 4.4.3. Hệ bộ lọc Gabor (Gabor filter banks)

2612 Hệ bộ lọc Gabor (Gabor filter banks) là tập hợp các bộ lọc tuyến tính được xây
2613 dựng bằng cách nhân một sóng điều hòa phức (complex sinusoid) với hàm
2614 Gaussian. Đây là một phương pháp kinh điển mô tả đặc trưng kết cấu do nó có
2615 những đặc điểm đặc biệt như: đạt giới hạn tối ưu không gian – tần số, có tính tương
2616 đồng với thị giác người, tương thích với không gian tỉ lệ (scale space), ...

2617 4.4.3.1. Tối ưu không gian – tần số

2618 Giả sử ta có một hàm lọc hai chiều $h(x, y)$ có độ phân tán (phương sai) là σ_t^2 .
2619 Biến đổi Fourier của $h(x, y)$ sang miền tần số ta được $H(x, y)$ có độ phân tán
2620 (phương sai) là σ_f^2 . Có thể thấy σ_t^2 càng nhỏ, bộ lọc có tính cục bộ càng cao nhạy với
2621 các chi tiết nhỏ, cạnh sắc nét. Tức là bộ lọc tập trung mạnh vào tính cục bộ của không
2622 gian. Trong khi đó, σ_f^2 càng nhỏ, bộ lọc chỉ tập trung và giữ lại một dải tần hẹp. Tức
2623 là bộ lọc tập trung mạnh vào một tần số.

2624 Tuy nhiên, cả hai phương sai này đều không cùng nhỏ do bị ràng buộc bởi bất
2625 đẳng thức Heisenberg (Stein 2007):

2626
$$\sigma_t^2 \sigma_f^2 \geq \frac{1}{16\pi^2}. \quad (4.71)$$

Tức là một bộ lọc ảnh không thể đồng thời vừa nhạy với các chi tiết nhỏ trong không gian điểm ảnh và vừa nhạy với một tần số cụ thể trong không gian tần số. Một bộ lọc đạt được dấu bằng trong bất đẳng thức Heisenberg (4.71) được gọi là bộ lọc tối ưu không gian-tần số do nó có thể cân bằng được độ nhạy giữa chi tiết ảnh và tần số của ảnh.

Heisenberg trong (Heisenberg 1927) đã chứng minh hàm lọc Gaussian (công thức 4.19) là hàm duy nhất đạt được dấu bằng trong bất đẳng thức (4.71) và do đó nó là bộ lọc duy nhất đạt được tối ưu không gian-tần số.

4.4.3.2. Hàm Gabor cơ bản

Hàm lọc Gaussian thuần nhất mặc dù đạt được tối ưu không gian-tần số, nhưng nó chỉ có tính chất làm mờ ảnh mà chưa tập trung vào tần số. Do đó, Gabor đã đề xuất trong (Gabor 1946) bộ lọc vừa tập trung được vào chi tiết của ảnh, vừa tập trung vào tần số và hướng của tần số trong không gian hai chiều bằng cách nhân Gaussian với một hàm sinusoid. Gabor cũng đã chứng minh được, việc nhân với hàm sinusoid không làm mất tính chất tối ưu không gian-tần số của bộ lọc.

Hàm lọc Gabor cơ bản (Basic) có dạng sau:

$$\begin{aligned}\psi_B(x, y; \sigma, \gamma, \theta, \lambda, \phi) &= \exp\left(-\frac{x'^2}{2\sigma_x^2} - \frac{y'^2}{2\sigma_y^2}\right) \cdot \exp\left(i \cdot \left(2\pi \frac{x'}{\lambda} + \phi\right)\right) \\ &= \exp\left(-\frac{x'^2}{2\sigma_x^2} - \frac{y'^2}{2\sigma_y^2}\right) \cdot \left(\cos\left(2\pi \frac{x'}{\lambda} + \phi\right) + i \cdot \sin\left(2\pi \frac{x'}{\lambda} + \phi\right)\right)\end{aligned}\quad (4.72)$$

trong đó:

- x' và y' là tọa độ sau khi quay một góc θ :

$$x' = x \cos \theta + y \sin \theta \text{ và } y' = -x \sin \theta + y \cos \theta. \quad (4.73)$$


- σ_x và σ_y là độ rộng của hàm Gaussian nhằm điều khiển độ rộng của cục bộ không gian. Khi $\sigma_x = \sigma_y$ ta có Gaussian có dạng tròn, và khi $\sigma_x \neq \sigma_y$ thì Gaussian có hình elip.

- λ là bước sóng để điều khiển tần số của bộ lọc ($f = \frac{1}{\lambda}$).

- θ là góc xác định hướng của tần số.

- ϕ là pha của tần số.

Hình 4.32 cho thấy hình ảnh trực quan của một bộ lọc Gabor. Hình 4.32 (c) là ảnh trực quan của thành phần Gaussian (độ rộng $\sigma_x = \sigma_y = 2.0$). Hình bên trái là phần thực (cos) và hình ở giữa là phần ảo (sin) của thành phần tần số (góc định hướng $\theta = \frac{\pi}{4}$ (45°) và tần số $\lambda = 0.25$). Có thể thấy trong Hình 4.32 (a), thành phần thực (cos) có thể phát hiện được các sóng đối xứng chẵn (even-symmetric) tương ứng với các vùng sáng tối đối xứng, rất tốt để mô tả kết cấu (texture). Trong Hình 4.32 (b), thành phần ảo (sin) có thể phát hiện được các sóng đối xứng lẻ (odd-symmetric) tương ứng với các vùng cạnh và biên của đối tượng.



Hình 4.32. Hình ảnh trực quan của một bộ lọc Gabor.

4.4.3.3. Bộ mô tả kết cấu đồng nhất của MPEG-7

Có thể thấy hai thành phần thực (cos và thành phần ảo (sin) trong hàm Gabor cơ bản lệch pha nhau một khoảng $\phi = \frac{\pi}{2}$. Do đó, chỉ cần điều chỉnh tham số pha ψ , có thể chuyển qua lại giữa hai thành phần này. Bên cạnh đó, nếu ta loại bỏ thành phần ảo khỏi hàm Gabor cơ bản sẽ giảm độ phức tạp tính toán. Khi đó, ta có hàm Gabor thu gọn (Reduced) như sau:

$$\psi_R(x, y; \sigma_x, \sigma_y, \gamma, \theta, \lambda, \phi) = \exp\left(-\frac{x'^2}{2\sigma_x^2} - \frac{y'^2}{2\sigma_y^2}\right) \cdot \cos\left(2\pi \frac{x'}{\lambda} + \phi\right). \quad (4.74)$$

Như vậy, với mỗi bộ giá trị $(\sigma_x, \sigma_y, \gamma, \theta, \lambda, \phi)$ ta sẽ thu được một bộ lọc Gabor khác nhau và tập hợp các bộ lọc Gabor với các tham số khác nhau được gọi là hệ bộ lọc Gabor (Gabor filter bank).

Dù đã đơn giản hơn hàm Gabor đơn giản, nhưng Gabor thu gọn vẫn ẩn chứa những hạn chế khi áp dụng thực tế. Việc lựa chọn bộ tham số $(\sigma_x, \sigma_y, \gamma, \theta, \lambda, \phi)$ là rất khó và do không có quy tắc tối ưu chung cho việc lựa chọn. Các tham số này không có cơ sở trực giao nên có sự chồng lấn giữa các bộ lọc dẫn đến sự dư thừa thông tin giữa các vector đặc trưng khi được trích rút từ các bộ lọc. Hơn nữa, một hệ bộ lọc Gabor có thể có tới vài chục bộ lọc. Phép toán nhân chập cho phép lọc trên miền điểm ảnh đòi hỏi tài nguyên tính toán lớn. Do đó, hàm Gabor trong miền tần số được sử dụng.

Hàm Gabor (4.74) được chuyển đổi Fourier sang miền tần số và chuyển sang hệ tọa độ. Chi tiết các bước chuyển đổi tham khảo trong tài liệu (Movellan 2002). Ta được:

$$\Psi(\omega, \theta; s, r) = \exp\left(-\frac{(\omega - \omega_s)^2}{2\sigma_\rho^2}\right) \cdot \exp\left(-\frac{(\theta - \theta_r)^2}{2\sigma_\theta^2}\right), \quad (4.75)$$

trong đó:

$$\omega_s = \frac{2\pi}{\lambda}, \sigma_\rho = \frac{1}{2\pi\sigma_x} \text{ và } \sigma_\theta = \frac{1}{2\pi\sigma_y\omega_s}.$$

Trong thực tiễn, kỹ thuật mô tả kết cấu bằng bộ lọc Gabor đã được chuẩn hóa công nghiệp (ISO/IEC 2002) để được sử dụng rộng rãi. Trong đó ω_s và σ_θ được thiết lập bằng các giá trị cụ thể từ trước:


$$\theta_r = \frac{r\pi}{6}, \omega_s = \frac{3}{4} \cdot 2^{-s}, \sigma_\rho = \frac{\sqrt{2}-1}{\sqrt{2}\ln 2} \omega_s \text{ và } \sigma_\theta = \frac{\pi}{6\sqrt{2}\ln 2}.$$

Với 6 giá trị của r ($0 \leq r \leq 5$) và 5 giá trị của s ($0 \leq s \leq 4$), ta có một hệ gồm 30 bộ lọc Gabor $\Psi(\omega, \theta; s, r)$. Sử dụng biến đổi Fourier ngược ta sẽ có 30 hàm lọc trên miền điểm ảnh $\psi(x, y; s, r) = \mathcal{F}^{-1}\{\Psi(\omega, \theta; s, r)\}$. Hình 4.33 trực quan hóa hình ảnh của 30 bộ lọc $\psi(x, y; s, r)$ trên miền điểm ảnh. Có thể quan sát thấy sự thay đổi về góc, độ lớn của hàm Gaussian cũng như tần số sóng mà bộ lọc cần biểu diễn.


Với một ảnh $I(x, y)$, ta có thể thu được 30 phiên bản phản hồi lọc $R(x, y; s, r)$ bằng cách áp dụng bộ lọc Gabor:

$$R(x, y; s, r) = \psi(x, y; s, r) * I(x, y). \quad (4.76)$$

Hình 4.34 là kết quả sau khi sử dụng 30 bộ lọc Gabor lên ảnh 4.28 (c). Có thể thấy rõ ràng hướng các cạnh được nổi rõ tùy vào hướng r và tỉ lệ s của bộ lọc.



Hình 4.33. Hàm lọc Gabor theo chuẩn MPEG-7 – HDT.



Hình 4.34. Kết quả áp dụng bộ lọc Gabor theo chuẩn MPEG-7 – HDT lên một ảnh nhỏ ở Hình 4.28 (c).

Để mô tả kết cấu đồng nhất, đầu tiên cần tính mức năng lượng trung bình của mỗi phản hồi:

$$E_{s,r} = \frac{1}{N} \sum_{x,y} R(x, h; s, r), \quad (4.77)$$

và mức độ không đồng nhất của phản hồi:

$$\sigma_{s,r} = \sqrt{\frac{1}{N} (R(x, h; s, r) - E_{s,r})^2}. \quad (4.78)$$

Cuối cùng, vector đặc trưng mô tả kết cấu đồng nhất dựa trên bộ lọc Gabor được xây dựng từ các mức năng lượng và mức độ không đồng nhất đã được chuẩn hóa:

$$F_{Gabor} = (E_{0,0}, \dots, E_{4,5}, \sigma_{0,0}, \dots, \sigma_{4,5}). \quad (4.79)$$

Do có 30 giá trị mức năng lượng trung bình và 30 mức độ không đồng nhất, nên kích thước của vector đặc trưng mô tả kết cấu đồng nhất có kích thước 60.

4.4.4. Dựa trên gradient (SIFT, HoG)

Nhóm các kỹ thuật mô tả kết cấu dựa trên gradient thường được dùng rộng rãi trong các bài toán so khớp, bám đuôi và nhận dạng đối tượng do có việc cài đặt đơn giản và tốc độ tính toán nhanh. Đặc điểm cơ bản của chúng là dựa vào độ lớn và hướng của các vector gradient để mô tả một vùng ảnh. Mỗi kỹ thuật đều có ưu

2723 và nhược điểm riêng, giáo trình này chỉ trình bày hai kỹ thuật nổi tiếng và được sử
2724 dụng nhiều nhất là SIFT và HoG.

2725 4.4.4.1. Scale-Invariant Feature Transform (SIFT)


2726 SIFT mô tả kết cấu ảnh dựa trên phân bố hướng của các vector gradient xung
2727 quanh một điểm trung tâm (Lowe 2004) gọi là điểm đặc trưng. Điểm đặc trưng được
2728 phát hiện trong không gian tỉ lệ (tham khảo mục 4.2.2. Điểm đặc trưng và 4.2.3.
2729 Blob) ở tỉ lệ tối ưu σ , sau đó việc mô tả kết cấu được thực hiện trên ảnh ở tỉ lệ σ này.

2730 Để đơn giản, gọi $I[x, y]$ ($-8 \leq x, y < 8$), là ma trận ảnh kích thước 16×16 có
2731 tâm là điểm đặc trưng, Hình 4.34 (trái). Vector gradient $\nabla I[x, y]$ được tính theo công
2732 thức (4.16) được trực quan hóa dưới dạng ảnh trường vector Hình 4.35 (a). Trong
2733 đó đó mỗi mũi tên tương ứng với một vector gradient $\nabla I[x, y]$. Độ lớn từng vector
2734 gradient là độ dài của vector và cũng là độ sáng trong điểm ảnh tương ứng trong
2735 Hình 4.34 (b).



Hình 4.35. Ảnh trái kích thước 16×16 có tâm là một điểm đặc trưng và ảnh phải là biên độ gradient.

2736 Hình 4.36 (a) trực quan hóa độ dài của vector gradient $\nabla I[x, y]$ dưới dạng
2737 cường độ sáng của điểm ảnh. Có thể quan sát thấy hình ảnh của 2 đường thẳng giao
2738 nhau (góc Harris).



Hình 4.36. Trường vector gradient (a) và lưới tích lũy gradient (b).

Hình 4.36 (b) biểu diễn 4×4 phân bố gradient được thu được từ mảng 16×16 vector gradient ở hình bên phải. Mỗi phân bố gradient (được xác định bởi vị trí của nó trong mảng 4×4) là một mảng 8 giá trị tương ứng với 8 hướng của vector gradient. Mỗi giá trị được tính tích lũy từ 256 vector gradient của ảnh.

Ký hiệu $H[i, j, k]$, với $0 \leq i, j \leq 3$ và $0 \leq k \leq 7$, là lưới tích lũy chứa phân bố gradient. Từng giá trị trong mảng được cập nhật tích lũy theo từng các vector gradient $\nabla I[x, y]$ với $(-8 \leq x, y < 8)$.

Đầu tiên, có thể thấy rằng điểm (x, y) càng gần điểm đặc trưng $(0,0)$ thì nó có vai trò càng lớn đối với các phân bố gradient và ngược lại. Do đó, trọng số ban đầu được thiết lập như sau:

$$\omega = \|\nabla I[x, y]\| \cdot \exp\left(-\frac{x^2+y^2}{2\sigma^2}\right), \quad (4.80)$$

trong đó $\|\nabla I[x, y]\|$ là độ dài của vector gradient tại (x, y) , tham khảo công thức (4.2). Toán tử Gaussian giúp giảm trọng số khi (x, y) cách xa điểm đặc trưng $(0,0)$. Tiếp theo, ω sẽ được phân bố vào lưới tích lũy sử dụng kỹ thuật tri-linear.

Bộ ba (x, y, θ) trong lưới tích lũy có tọa độ là $(x_c, y_c, \theta_c) = \left(\frac{x}{4} - 0.5, \frac{y}{4} - 0.5, \frac{\theta}{\pi}\right)$. Tách thành phần nguyên::

$$i = \lfloor x_c \rfloor, j = \lfloor y_c \rfloor \text{ và } k = \lfloor \theta_c \rfloor$$

và phần thập phân tương ứng là:

$$\alpha = x_c - i, \beta = y_c - j, \text{ và } \gamma = \theta_c - k.$$

Tiếp theo, trọng số ω sẽ được chia thành 8 phần trong khối $2 \times 2 \times 2$ dựa theo hệ số như sau:

Bảng 4.4. Phân bố trọng số vào lưới tích lũy.

t	Tọa độ nhận trọng số p_i	Hệ số h_i
1	(i, j, k) : ô gốc	$(1 - \alpha)(1 - \beta)(1 - \gamma)$
2	$(i + 1, j, k)$: ô kề phải	$\alpha(1 - \beta)(1 - \gamma)$
3	$(i, j + 1, k)$: ô kề trái	$(1 - \alpha)\beta(1 - \gamma)$
4	$(i + 1, j + 1, k)$: ô chéo	$\alpha\beta(1 - \gamma)$
5	$(i, j, k + 1)$: ô ở hướng kế tiếp	$(1 - \alpha)(1 - \beta)\gamma$
6	$(i + 1, j, k + 1)$: ô kề phải ở hướng kế tiếp	$\alpha(1 - \beta)\gamma$
7	$(i, j + 1, k + 1)$: ô kề trái ở hướng kế tiếp	$(1 - \alpha)\beta\gamma$
8	$(i + 1, j + 1, k + 1)$: ô chéo ở hướng kế tiếp	$\alpha\beta\gamma$
	Tổng	1

Cuối cùng, các tọa độ p_i của lưới tích lũy được cập nhật thêm phần trong số ω của điểm (x, y) theo hệ số h_i như được

$$H(p_i) \leftarrow H(p_i) + h_i \cdot \omega. \quad (4.81)$$

Sau khi phân bố trọng số của toàn bộ 256 điểm ảnh cho lưới tích lũy, ta xây dựng vector đặc trưng mô tả kết cấu từ các phần tử của lưới tích lũy:

$$F_{SIFT} = (H(0,0,0), H(0,0,1), \dots, H(3,3,7)). \quad (4.82)$$

Vector đặc trưng sau đó được chuẩn hóa vector hai lần để giảm ảnh hưởng của ánh sáng mạnh hoặc thay đổi cục bộ như sau:

$$F_{SIFT} \leftarrow \frac{F_{SIFT}}{\|F_{SIFT}\|_2},$$

sau đó cắt ngưỡng cho từng thành phần để loại bỏ nhiễu:

$$F_{SIFT}(i) \leftarrow \min(F_{SIFT}(i), 0.2),$$

và chuẩn hóa lại một lần nữa:

$$F_{SIFT} \leftarrow \frac{F_{SIFT}}{\|F_{SIFT}\|_2}.$$

Cuối cùng, vector đặc trưng F_{SIFT} với 128 chiều được chuẩn hóa để bất biến với ánh sáng và nhiễu.

4.4.4.2. Histogram of gradients (HoG)

Khi phân tích đặc điểm thị giác của đối tượng trong ảnh, một vật thể (ví dụ hình người) bao gồm các thành phần như đầu, vai, chân, tay, ... tạo thành một hình dáng ổn định. Ở đây tập hợp các vector gradient trong và xung quanh vật thể có thể cho ta biết đặc trưng khác biệt của nó. Do đó, phương pháp lược đồ gradient (histogram of gradients - HoG) được Dalal (Dalal 2005) đề xuất phương pháp mô tả kết cấu trong một vùng ảnh có hình dạng bất kỳ.

Ký hiệu ảnh đầu vào $I[x, y]$, gradient $\nabla I[x, y]$ và góc gradient. Ảnh $I[x, y]$ được chia thành lưới các cell (kích thước $8 \times 8 = 64$ điểm ảnh), $C[i, j]$, với $i = \left\lfloor \frac{x}{8} \right\rfloor$, $j = \left\lfloor \frac{y}{8} \right\rfloor$ (Trong Hình 4.36, cell là những ô được tạo ra bởi lưới màu vàng.). Với mỗi cell, một HoG có 9 bin $H[i, j, k]$, $0 \leq k < 9$, được thiết lập từ 64 vector gradient của mỗi điểm ảnh trong cell, mỗi bin tương ứng với một góc 20° (trong khoảng từ 0° đến 180°).

Ở đây, việc phân bố trọng số (gradient $\nabla I[x, y]$) vào HoG được dựa trên phương pháp tuyến tính như sau:


Với mỗi điểm $(x, y) \in C[i, j]$, có độ dài vector gradient là $m = \|\nabla I[x, y]\|$ và góc của vector này là θ , ta cập nhật các trọng số vào HoG như sau:

$$H[i, j, k] \leftarrow H[i, j, k] + (1 - \alpha) \cdot m \quad (4.83)$$

và

$$H[i, j, k + 1] \leftarrow H[i, j, k] + \alpha \cdot m, \quad (4.84)$$

2796 trong đó $k = \left\lfloor \frac{\theta}{20^\circ} \right\rfloor$ và $\alpha = \frac{\theta}{20^\circ} - k$. Như vậy, ở mỗi điểm (x, y) , ta sẽ phân bố trọng số
 2797 có độ dài bằng vector gradient của điểm này vào hai bin liên tiếp của HoG sao theo
 2798 nguyên tắc tuyến tính, θ gần bin nào hơn sẽ được phân bố nhiều hơn.



2799
 2800 Hình 4.37. Hình ảnh trực quan chia ảnh đầu vào thành các cell (màu vàng) và
 2801 các khối (màu xanh).

2802 Tiếp theo, vector đặc trưng cho các block (hình vuông màu xanh trong Hình
 2803 4.37) được hình thành bởi 2×2 cell kề nhau được thiết lập bằng cách nối HoG 9 bin
 2804 của mỗi cell tạo thành một vector đặc trưng cho block dài 36 phần tử:

$$2805 \quad F_B = (H[i, j, 0], H[i, j, 1], \dots, H[i + 1, j + 1, 8]). \quad (4.85)$$

2806 Mục đích của các block này để chuẩn hóa nhằm giúp vector đặc trưng ổn định giữa
 2807 các vùng lân cận, giảm nhạy cảm với ánh sáng:

$$2808 \quad F_B \leftarrow \frac{F_B}{\|F_B\|_2},$$

2809 sau đó cắt ngưỡng cho từng thành phần để loại bỏ nhiễu:

$$2810 \quad F_B(i) \leftarrow \min(F_B(i), 0.2),$$

2811 và chuẩn hóa lại một lần nữa:

$$2812 \quad F_B \leftarrow \frac{F_B}{\|F_B\|_2}.$$

2813 Thực tế, block được trượt trên lưới qua từng cell theo cột và theo hàng. Vector
 2814 đặc trưng cho toàn bộ ảnh $I(x, y)$ là ghép nối của n vector đặc trưng của từng block:

$$2815 \quad F_{HoG} = (F_{B_1}, F_{B_2}, \dots, F_{B_n}). \quad (4.86)$$

2816 Ví dụ một ảnh kích thước 32×64 tạo ra lưới 4×8 cell, do đó sẽ tạo ra $n =$
 2817 $(4 - 1) \times (8 - 1) = 21$ block. Độ dài của vector đặc trưng cuối cùng là $21 * 36 = 756$
 2818 phần tử. Như vậy, kích thước ảnh lớn tạo ra vector đặc trưng HoG rất lớn.

2819 4.5. Khai phá ngữ nghĩa thị giác

2820 Các phương pháp khai phá ngữ nghĩa thị giác đóng vai trò là cầu nối giữa các
 2821 đặc trưng mức thấp (hình học, hình dạng, kết cấu, ...) và nhận thức mức cao với các
 2822 nhiệm vụ chính như (được trình bày trong cuốn giáo trình này): gom nhóm đặc

2823 trung và so khớp mô hình, bám theo đối tượng (tracking), căn chỉnh/phân loại ảnh,
2824 phát hiện/nhận dạng đối tượng trong ảnh, tái tạo cấu trúc 3D từ ảnh.

2825 4.5.1. So khớp mô hình (model fitting)

2826 So khớp mô hình (model fitting) là một trong những phương pháp giúp khai
2827 phá ngữ nghĩa ở mức độ đơn giản nhất, khi mà thông tin mà con người truy xuất
2828 từ ảnh có thể được biểu diễn dưới dạng các mô hình toán học với số lượng các tham
2829 số cần ước lượng là đủ nhỏ, ví dụ: đường thẳng, hình tròn, ...


2830 Để dễ hiểu trong trình bày, các đặc trưng ảnh được giới hạn là các điểm (điểm
2831 đặc trưng, góc Harris, tâm Blob, đường bao (contour), ...) trên mặt phẳng ảnh. Ký
2832 hiệu $F_P = \{(x_i, y_i)\}_{i=1}^n$ là tọa độ của n điểm cần được mô hình hóa.

2833 Mô hình trong ngữ cảnh này được hiểu là một cách kết hợp toán học giữa hai
2834 biến (x, y) với một bộ tham số và được ràng buộc bởi phương trình mô hình có m
2835 tham số:

$$2836 \quad f(x, y, a_1, a_2, \dots, a_m) = 0. \quad (4.87)$$

2837 trong đó $a_1, a_2, \dots, a_m$ là các tham số mô hình. Ví dụ phương trình mô hình cho
2838 đường thẳng có thể là $a_1 \cdot x + a_2 \cdot y = 0$.

2839 So khớp mô hình (model fitting) là việc tìm các tham số mô hình $a_1, a_2, \dots, a_m$
2840 từ các điểm đặc trưng F_P nhằm tối ưu phương trình mô hình (4.87). Bên cạnh đó, so
2841 khớp mô hình không giới hạn chỉ tìm một bộ tham số. Tức là nhiều bộ tham số có
2842 thể được đề xuất, mỗi bộ tham số tối ưu một tập con của F_P . Ví dụ, ta có thể tìm
2843 thấy nhiều đường thẳng đi qua các điểm đặc trưng. Hình 4.38 trực quan hóa việc so
2844 khớp mô hình đường thẳng với các điểm trên mặt phẳng ảnh.



2845
2846 Hình 4.38. Ví dụ trực quan so khớp mô hình: (trái) một mô hình đường thẳng
2847 được so khớp, (phải) hai mô hình đường thẳng được so khớp.

2848 4.5.1.1. Sai số bình phương tối thiểu (least square error – LSE)

2849 A) Phát triển lý thuyết

2850 Do dữ liệu luôn có nhiễu nên phương trình mô hình (4.87) không thỏa mãn và
2851 ta có:

$$e_i = f(x_i, y_i, a_1, a_2, \dots, a_m), \quad (4.88)$$

sai số tại điểm thứ i , (x_i, y_i) . Phương pháp sai số bình phương tối thiểu (least square error – LSE) tìm bộ tham số $(a_1, a_2, \dots, a_m)$ để tổng bình phương sai số là nhỏ nhất. Tức là:

$$(a_1^*, a_2^*, \dots, a_m^*) = \min_{(a_1, a_2, \dots, a_m)} \sum_{i=1}^n e_i^2 = \min_{(a_1, a_2, \dots, a_m)} S. \quad (4.89)$$

Điểm cực trị của S theo từng tham số thu được bằng cách giải đạo hàm theo tham số:

$$\frac{\partial S}{\partial a_k} = 2 \sum_{i=1}^n e_i \cdot \frac{\partial e_i}{\partial a_k} = 0, \quad (4.90)$$

với $k \in \{j\}_{j=1}^m$.

Nếu e_i là phi tuyến, ta có thể giải bằng các phương pháp Gauss–Newton, Levenberg–Marquardt, gradient descent, v.v. tham khảo trong (Madsen 2004).

Nếu e_i là tuyến tính với các tham số ta có thể viết lại hàm sai số như sau:

$$e_i = b_i - \sum_{t=1}^m a_t \cdot f_t(x_i, y_i) = \mathbf{b} - \mathbf{F} \cdot \mathbf{a}, \quad (4.91)$$

trong đó $f_k(x, y)$ là một hàm ràng buộc giữa biến x và biến y mà không có sự tham gia của các tham số, $\mathbf{F}$ là ma trận

$$\mathbf{F} = \begin{bmatrix} f_1(x_1, y_1) & f_2(x_1, y_1) & \dots & f_m(x_1, y_1) \\ f_1(x_2, y_2) & f_2(x_2, y_2) & \dots & f_m(x_2, y_2) \\ \dots & \dots & \dots & \dots \\ f_1(x_n, y_n) & f_2(x_n, y_n) & \dots & f_m(x_n, y_n) \end{bmatrix}$$

và

$$\mathbf{a} = \begin{bmatrix} a_1 \\ a_2 \\ \dots \\ a_m \end{bmatrix} \text{ và } \mathbf{b} = \begin{bmatrix} b_1 \\ b_2 \\ \dots \\ b_n \end{bmatrix}.$$

Khi đó:

$$S(\mathbf{a}) = \sum_{i=1}^n e_i^2 = (\mathbf{b} - \mathbf{F} \cdot \mathbf{a})^T (\mathbf{b} - \mathbf{F} \cdot \mathbf{a}),$$


và đạo hàm theo $\mathbf{a}$ và cho bằng không, ta được:

$$\nabla_{\mathbf{a}} S(\mathbf{a}) = -2\mathbf{F}^T \cdot (\mathbf{b} - \mathbf{F} \cdot \mathbf{a}) = \mathbf{0}, \quad (4.92)$$

cuối cùng ta thu được:

$$\mathbf{a} = (\mathbf{F}^T \mathbf{F})^{-1} \mathbf{F}^T \mathbf{b}. \quad (4.93)$$

B) Ví dụ tìm đường tròn



Hình 4.39. Ví dụ phát hiện đường tròn sử dụng sai số bình phương tối thiểu.

Ảnh Hình 4.39 (a) chứa một hình tròn có màu đồng nhất nằm trên nền tối hơn cũng có màu đồng nhất và bị làm nhiễu salt&pepper rất nặng (60%).

Sử dụng bộ lọc trung vị với kích thước 7×7 lên Hình 4.38 (a) thu được Hình 4.38 (b). Sau đó, sử dụng thuật toán trích xuất đường bao trình bày trong mục (4.3.1.1) và ta thu được danh sách $n = 215$ điểm biên $F_p = \{(x_i, y_i)\}_{i=1}^n = \{(133,68), (132,69), (130,69) \dots, (135,69), (134,68)\}$ trong Hình 4.38 (c).

Tiếp theo ta xây dựng phương trình tham số bắt đầu từ phương trình cơ bản của đường tròn như sau:

$$(x - a)^2 + (y - b)^2 = r^2,$$

trong đó (a, b) và r lần lượt là tâm và bán kính đường tròn. Biến đổi phương trình trên ta được:

$$x^2 + y^2 - 2ax - 2by + (a^2 + b^2 - r^2) = 0$$

và chuyển về dạng tham số được

$$a_1x + a_2y + a_3 - (x^2 + y^2) = 0$$

trong đó $a_1 = -2a$, $a_2 = -2b$ và $a_3 = a^2 + b^2 - r^2$.

Ta có ma trận:

$$\mathbf{F} = \begin{bmatrix} x_1 & y_1 & 1 \\ x_2 & y_2 & 1 \\ \dots & \dots & \dots \\ x_n & y_n & 1 \end{bmatrix}$$

và vector

$$\mathbf{a} = \begin{bmatrix} a_1 \\ a_2 \\ a_3 \end{bmatrix} \text{ và } \mathbf{b} = \begin{bmatrix} -(x_1^2 + y_1^2) \\ -(x_2^2 + y_2^2) \\ \dots \\ -(x_n^2 + y_n^2) \end{bmatrix}$$

Thay các điểm F_p ta có ma trận $\mathbf{F}$ và vector $\mathbf{b}$. Áp dụng công thức tính bình phương tối thiểu (4.93) $\mathbf{a} = (\mathbf{F}^T \mathbf{F})^{-1} \mathbf{F}^T \mathbf{b} \approx [-256.09 \quad -255.91 \quad 29249.08]$. Từ đó tính được tọa độ của đường tròn $(a, b) = \left(-\frac{a_1}{2}, -\frac{a_2}{2}\right) = (128.04, 127.95)$ và bán kính $r = \sqrt{a^2 + b^2 - a_3^2} \approx 59.32$.


Đường tròn với tâm $(128.04, 127.95)$ bán kính 59.32 được vẽ lên ảnh ban đầu và được trình bày trong Hình 4.38 (d).

C) Nhận xét


Phương pháp bình phương tối thiểu có ưu điểm là phân tích toán học tường minh, có nghiệm duy nhất trong trường hợp tuyến tính, tính toán nhanh. Tuy nhiên, phương pháp này khá nhạy với nhiễu ngoại lai và khó áp dụng trong trường hợp đa mô hình. Trong ví dụ tìm đường tròn trên, nếu đường biên tách ra có nhiều hơn 1 đường tròn khiến cho việc áp dụng bình phương tối thiểu rất khó khăn.

4.5.1.2. Biến đổi Hough

Biến đổi Hough (Hart, P. E. 2009) thường được sử dụng để phát hiện các mẫu hình đơn giản như các đường hình học (đường thẳng, đường tròn, đường elip, ...) trong ảnh thông qua một cơ chế voting trong không gian tham số.



(a)



(b)

Hình 4.40. Ví dụ một hình chứa nhiều đường thẳng.

Xuất phát từ phương trình mô hình m tham số (4.87): $f(x, y, a_1, a_2, \dots, a_m) = 0$, ta sẽ miêu tả chi tiết hoạt động của biến đổi Hough thông qua ví dụ tìm các đường thẳng trong ảnh được cho trong Hình 4.40 (a).

2916

2917 Đầu tiên, tách cạnh Canny được sử dụng để trích rút các đặc trưng cạnh, xem
2918 Hình 4.40 (b). Ký hiệu $F_p = \{(x_i, y_i)\}_{i=1}^n$ là tọa độ của n điểm cạnh Canny trong hình
2919 này. Phương trình tham số:


$$2920 \quad r + x \cos(\theta) + y \sin(\theta) = 0 \quad (4.94)$$

2921 được sử dụng để miêu tả m đường thẳng có thể tìm được ở trong ảnh, mỗi đường
2922 thẳng tương ứng với một bộ tham số (θ_k, r_k) . Có thể nhận thấy, mỗi đường thẳng
2923 (θ_k, r_k) có thể đi qua một số trong n điểm cạnh trên.

2924 Với mỗi điểm $(x_i, y_i) \in F_p$, ta có thể xác định được một quan hệ trong bộ tham
2925 số như sau:

$$2926 \quad r = -x_i \cos(\theta) - y_i \sin(\theta) \quad (4.95)$$

2927 và vẽ quan hệ này trên đồ thị của không gian tham số với trục hoành là biến θ và
2928 trục tung là r . Khi vẽ đồng thời n quan hệ bộ tham số thỏa mãn phương trình (4.95)
2929 ta được hình mô tả trong Hình 4.40.



2930

2931 Hình 4.41. Biểu diễn đường thẳng trong không gian tham số.

2932 Có thể thấy trong Hình 4.41, mỗi cặp điểm (x_i, y_i) tương ứng tạo ra một đường
2933 cong. Các đường cong này giao nhau ở m điểm (những điểm sáng) ở tọa độ (θ_k, r_k) ,
2934 $k \in \{1, \dots, m\}$. Thay (θ_k, r_k) vào công thức (4.94) ta được một phương trình đường
2935 thẳng trong không gian điểm ảnh:

$$2936 \quad \cos(\theta_k) \cdot x + \sin(\theta_k) \cdot y + r_k = 0. \quad (4.96)$$

2937 Số lượng đường cong trong không gian tham số đi qua điểm (θ_k, r_k) chính là
2938 số lượng điểm (x_i, y_i) trong không gian điểm ảnh mà đường thẳng (4.96) đi qua. Để
2939 dễ dàng nhận thấy rằng số lượng này càng lớn thì đường thẳng ta tìm được có độ tin
2940 cậy càng cao và ngược lại.

2941 Như vậy, thay bằng việc tìm các đường thẳng trên không gian ảnh, ta tìm các
2942 điểm nơi giao cắt của các đường cong trên không gian tham số và trở thành bài toán
2943 cực trị vì ta muốn tìm các điểm có càng nhiều đường con đi qua càng tốt.

2944 Để tìm kiếm các dạng hình khác ta cần định nghĩa phương trình mô tả dạng
2945 hình đó. Ví dụ hình tròn có phương trình tham số

$$2946 \quad (x - a_1)^2 + (y - a_2)^2 - a_3^2 = 0. \quad (4.97)$$

Trong đó tham số (a_1, a_2) là tọa độ tâm của đường tròn và a_3 là bán kính. Ở đây ta cần một không gian 3 chiều để biểu diễn không gian tham số. Mỗi bộ tham số (a_1, a_2, a_3) tìm được trong không gian tham số tương ứng với 1 đường tròn trong không gian điểm ảnh.

Tương tự như vậy, ta có thể tìm được các dạng hình phức tạp hơn, ví dụ hình elip với phương trình tham số như sau:

$$\frac{(x-a_1)^2}{a_3} + \frac{(y-a_2)^2}{a_4} - 1 = 0, \quad (4.98)$$

với tham số (a_1, a_2) là tọa độ tâm của đường elip và a_3, a_4 là độ dài hai trục. Mỗi bộ tham số (a_1, a_2, a_3, a_4) tìm được trong không gian tham số 4 chiều tương ứng với 1 đường elip trong không gian điểm ảnh. Ta cũng có thể bổ sung thêm 1 tham số độ xoay a_5 mô tả góc xoay của hình elip so với trục hoành. Khi đó số chiều của không gian tham số tăng lên 5.

Trong thực tế, do nhiễu và các quá trình thu nhận ảnh khiến cho các dạng hình không được hoàn hảo như được mô tả bằng phương trình tham số. Điều này dẫn tới các đường cong trên không gian tham số không cùng cắt nhau tại 1 điểm duy nhất làm cho việc tìm các điểm trở nên rất khó khăn nếu chỉ dựa trên phân tích hàm số.


Người ta giải quyết vấn đề này bằng cách chia lưới không gian tham số và thực hiện tìm kiếm dựa trên cơ chế voting. Ví dụ không gian tham số đường thẳng của phương trình (4.94) được chia thành lưới 2 chiều (gọi là lưới tham số), một chiều cho tham số θ và chiều còn lại cho tham số r . Mỗi ô của lưới là một giá trị số ban đầu được khởi tạo bằng 0, giá trị này được tăng lên 1 mỗi khi có 1 đường cong đi qua nó. Ở đây, có thể sử dụng giải thuật vẽ đồ thị hàm số được đề xuất bởi (Shier, D. R. 1988) để xác định các ô của lưới tham số mà đường cong đi qua. Cơ chế voting được sử dụng để lựa chọn ô nào trong lưới tham số có giá trị lớn nhất. Quan sát thực tế cho thấy, một đường thẳng trong không gian ảnh thường tạo ra một đám (gồm nhiều ô lân cận trong lưới tham số). Để tăng độ chính xác, ta có thể sử dụng các phương pháp nội suy để ước lượng các điểm trung gian giữa các ô của lưới và áp dụng thuật toán non-maximum suppression (Neuback 2006) để chọn được điểm tối ưu.

Ưu điểm của cơ chế voting cho phép chúng ta tìm được nhiều điểm tối ưu cục bộ trong lưới tham số đồng thời có thể bỏ qua những điểm nhiễu. Có nghĩa là, cơ chế voting đồng thời tìm được nhiều đường thẳng và có khả năng chống nhiễu tốt. Tuy nhiên, cơ chế voting phải được thực hiện trên lưới tham số có số chiều bằng với số lượng tham số trong phương trình mô tả tham số. Ví dụ phương trình tham số (4.98) giúp tìm hình elip có 4 tham số sẽ yêu cầu lưới tham số phải có 4 chiều để thực hiện cơ chế voting. Bên cạnh đó, mức độ chia lưới cũng ảnh hưởng tới độ chính xác của bộ tham số tìm được. Lưới được chia càng tinh thì độ chính xác càng cao. Tuy nhiên, kích thước bộ nhớ để tổ chức lưới tham số tăng theo hàm số mũ của số lượng các tham số và độ tinh của lưới. Do đó, biến đổi Hough chỉ được sử dụng để


2987 phát hiện các hình mẫu đơn giản (đường thẳng, đường tròn, hình elip, ...) với số
2988 lượng các tham số nhỏ.

2989 4.5.1.3. Đồng thuận mẫu ngẫu nhiên (RANSAC)

2990 Đồng thuận ngẫu nhiên (RANDOM Sample Consensus - RANSAC) được
2991 (Fischler 1981) đề xuất để khớp mô hình từ bộ đặc trưng có nhiễu nhiễu. Thay vì sử
2992 dụng toàn bộ dữ liệu để ước lượng mô hình như phương pháp LSE hoặc biến đổi
2993 Hough, RANSAC chỉ thực hiện ước lượng mô hình trên một tập đủ nhỏ và đánh
2994 giá sự phù hợp của mô hình. Thuật toán liên tục lặp lại để lựa chọn được mô hình
2995 tốt hơn qua mỗi bước lặp.



Hình 4.42. (a) Ảnh bị tác động bởi nhiễu Gaussian và (b) Ảnh cạnh Canny của (a).



Hình 4.43. Kết quả của một số bước lặp RANSAC.

2996 Ký hiệu $F_P = \{(x_i, y_i)\}_{i=1}^n$ là tọa độ của n điểm cạnh Canny trong Hình 4.42 (b).
2997 Các bước RANSAC được thực hiện như sau:

2998 Bước 1: Lấy ngẫu nhiên $F_P^R \subset F_P$, sao cho số lượng phần tử của F_P^R đủ lớn để
2999 xác định được bộ tham số mô hình. Ví dụ đường tròn cần 3 điểm, đường thẳng cần
3000 2 điểm, hình elip cần 5 điểm, ...

3001 Bước 2: Sử dụng LSE hoặc biến đổi Hough để ước lượng được một mô hình
3002 tối ưu $(a_1^*, a_2^*, \dots, a_m^*)$ cho $f(x, y, a_1, a_2, \dots, a_m) = 0$ trong tập đặc trưng F_P^R .

3003 Bước 3: Kiểm thử mô hình vừa tìm được và đếm số lượng các điểm $(x_i, y_i) \in$
3004 F_P sao cho nó thỏa mãn phương trình mô hình với tham số nhỏ gọi là số điểm hợp
3005 lệ (inliers).


Bước 4: Lưu lại các tham số mô hình có số điểm hợp lệ lớn và lặp lại bước 1 cho đến khi hết số lần lặp đã chỉ định hoặc không thể tìm được bộ tham số mô hình mới có số điểm hợp lệ lớn hơn.

Hình 4.42 cho thấy kết quả của một số bước lặp RANSAC trong đó ba điểm màu đỏ là F_p^R được lấy ngẫu nhiên từ F_p . Đường tròn màu xanh được ước lượng từ 3 điểm đó. Kết quả đường tròn trong Hình 4.43 (a) cho thấy đường tròn ước lượng được chỉ có 20 điểm hợp lệ, đường tròn Hình 4.43 (b) có 104 điểm hợp lệ, và đường tròn Hình 4.43 (c) có 1583 điểm hợp lệ và đường tròn này được chọn là mô hình phù hợp nhất.

Có thể thấy RANSAC có khả năng chống nhiễu ngoại lai rất tốt do cơ chế tạo động thuận mô hình (có số điểm hợp lệ lớn), có thể đồng thời tìm được nhiều bộ tham số cho một mô hình hoặc tìm được nhiều loại mô hình khác nhau tùy thuộc vào số lượng điểm F_p^R và mô hình muốn ước lượng. Bên cạnh đó, có thể thấy càng nhiều vòng lặp các mô hình tìm được càng có độ tin cậy cao. Tuy nhiên do tính chất ngẫu nhiên của lựa chọn các điểm ước lượng, RANSAC khó đạt được các yêu cầu về tốc độ thực hiện và độ ổn định.

4.5.2. Theo dõi đối tượng (tracking)

Theo dõi đối tượng (tracking) là bài toán xác định vị trí của đối tượng ở khung hình kế tiếp trong video. Đối tượng ở đây có thể hiểu là một điểm hoặc một vùng ở khung hình hiện tại. Do biến sự biến đổi hình ảnh giữa các khung hình, việc theo dõi đối tượng phải đối mặt với nhiều thách thức như: tìm ra đặc trưng nào có thể theo dõi được một cách hiệu quả giữa các khung hình, đối tượng có thể thay đổi diện mạo theo thời gian (do góc nhìn camera thay đổi, che khuất bởi đối tượng khác, ...), tích lũy sai số, các đối tượng có thể xuất hiện mới hoặc biến mất trong quá trình theo dõi.



Hình 4.44. Các điểm di chuyển giữa hai khung hình.

4.5.2.1. Ước lượng chuyển động

Các tác giả trong (Lucas 1981) đề xuất phương pháp để theo dõi điểm di chuyển giữa hai ảnh liên tiếp $I(x, y, t)$ và $I(x, y, t + 1)$, xem Hình 4.44, với các giả định:

- Độ sáng của điểm không thay đổi.
- Không di chuyển dài.

- Các điểm gần nhau có thể di chuyển cùng nhau.

Một cửa sổ vuông 5×5 (kích thước cửa sổ có thể lớn hơn) được sử dụng để theo dõi di chuyển của điểm ở trung tâm cửa sổ. Với giả định các điểm nằm trong cửa sổ đủ gần để cùng di chuyển, nên chúng có cùng vector chuyển động $\mathbf{v} = [v_x \ v_y]^T$. Với giả định độ sáng của điểm không thay đổi, ta có:

$$I(x, y, t) = I(x + v_x, y + v_y, t + 1), \quad (4.99)$$

và với giả định điểm không di chuyển dài, ta có thể khai triển Taylor và bỏ qua các hệ số bậc cao hơn:

$$I(x + v_x, y + v_y, t + 1) \approx I(x, y, t) + I_x(x, y, t) \cdot v_x + I_y(x, y, t) \cdot v_y + I_t(x, y, t). \quad (4.100)$$

Thay vào (4.99), ta được:

$$I_x(x, y, t) \cdot v_x + I_y(x, y, t) \cdot v_y + I_t(x, y, t) = 0. \quad (4.101)$$

Giả sử, ta cần ước lượng chuyển động tại điểm (x_B, y_B) , ta sử dụng một cửa sổ có W kích thước, ví dụ 5×5 , có tâm là điểm (x_B, y_B) . Với giả định các điểm gần nhau trong cửa sổ cùng di chuyển với nhau, nên ta có $n = 25$ phương trình:

$$\begin{bmatrix} I_x(x_1, y_1, t) & I_y(x_1, y_1, t) \\ I_x(x_2, y_2, t) & I_y(x_2, y_2, t) \\ \dots & \dots \\ I_x(x_n, y_n, t) & I_y(x_n, y_n, t) \end{bmatrix} \begin{bmatrix} v_x \\ v_y \end{bmatrix} + \begin{bmatrix} I_t(x_1, y_1, t) \\ I_t(x_2, y_2, t) \\ \dots \\ I_t(x_n, y_n, t) \end{bmatrix} = 0. \quad (4.102)$$

Đặt

$$\mathbf{F} = \begin{bmatrix} I_x(x_1, y_1, t) & I_y(x_1, y_1, t) \\ I_x(x_2, y_2, t) & I_y(x_2, y_2, t) \\ \dots & \dots \\ I_x(x_n, y_n, t) & I_y(x_n, y_n, t) \end{bmatrix} \text{ và } \mathbf{b} = - \begin{bmatrix} I_t(x_1, y_1, t) \\ I_t(x_2, y_2, t) \\ \dots \\ I_t(x_n, y_n, t) \end{bmatrix},$$

phương trình (4.102) trở thành

$$\mathbf{F} \cdot \mathbf{v} - \mathbf{b} = 0. \quad (4.103)$$

Biểu thức (4.103) không đồng thời thỏa mãn cho tất cả n phương trình nên cần sử dụng phương pháp tối thiểu hóa bình phương sai số tương tự như cho biểu thức sai số (4.91) và thu được vector vận tốc như sau:

$$\mathbf{M} \cdot \mathbf{v} = (\mathbf{F}^T \mathbf{F}) \cdot \mathbf{v} = \mathbf{F}^T \cdot \mathbf{b}. \quad (4.104)$$

Trong đó


$$\mathbf{M} = \mathbf{F}^T \mathbf{F} = \begin{bmatrix} \sum_i I_x^2(x_i, y_i, t) & \sum_i I_x(x_1, y_1, t) I_y(x_1, y_1, t) \\ \sum_i I_x(x_1, y_1, t) I_y(x_1, y_1, t) & \sum_i I_y^2(x_i, y_i, t) \end{bmatrix} \quad (4.105)$$

là ma trận cấu trúc (structure tensor).

Ta có thể theo dõi được điểm tại tâm của cửa sổ nếu $\mathbf{M}$ khả nghịch, khi đó có thể tính được vector chuyển động của nó theo công thức:

$$v = M^{-1} \cdot F^T \cdot b. \quad (4.106)$$

Tương tự như điều kiện góc Harris và Shi-Tomasi (xem mục 4.2.2.2), ta có điều kiện để M khả nghịch là 2 giá trị riêng của nó đều phải có giá trị lớn. Nếu cả 2 giá trị riêng đều nhỏ thì không theo dõi được điểm, nếu 1 giá trị riêng nhỏ thì khó theo dõi, nếu cả hai giá trị riêng đều lớn thì điểm ở tâm cửa sổ là điểm dễ theo dõi (gọi là *điều kiện theo dõi được*).



Hình 4.45. (a) ảnh gốc chứa các cửa sổ 5×5 , (b) điểm không theo dõi được, (c) điểm theo dõi khó và (d) điểm dễ theo dõi.

Hình 4.45 trực quan hóa các điểm để theo dõi (a), trong đó điểm có cửa sổ màu đỏ (b) không theo dõi được do đó là vùng phẳng có cả 2 giá trị riêng rất nhỏ, điểm có cửa sổ màu vàng (c) khó theo dõi do đó là vùng cạnh mờ có 1 giá trị riêng rất nhỏ và (d) dễ theo dõi do đó là vùng góc có hai giá trị riêng đều rất lớn.

4.5.2.2. Tăng độ chính xác vector chuyển động (thuật toán Lucas-Kanade - LK)

Độ chính xác của vector chuyển động ước lượng từ phương trình (4.103) giảm mạnh khi điểm (x_B, y_B) có chuyển động lớn. Để tăng độ chính xác, ta phải thực hiện ước lượng nhiều lần, mỗi lần vector chuyển động tiến gần hơn tới chuyển động thực. Thuật toán lặp được thực hiện để ước lượng vector chuyển động (v_x, v_y) cho điểm (x_B, y_B) như sau:


Khởi tạo: Thiết lập vector chuyển động ban đầu $(v_x, v_y) = (0, 0)$.

Bước 1: Thiết lập cửa sổ W có tâm là điểm $(x_B + v_x, y_B + v_y)$.

3086 Bước 2: Tính vector chuyển động (c_x, c_y) cho các điểm trong cửa sổ W theo
3087 công thức (4.103).

3088 Bước 3: Cập nhật vector chuyển động $(v_x, v_y) \leftarrow (v_x + c_x, v_y + c_y)$.

3089 Bước 4: Lặp lại bước 1 sau một số hữu hạn bước lặp hoặc vector (c_x, c_y) quá
3090 nhỏ.



Hình 4.46. Tăng độ chính xác ước lượng chuyển động.

Hình 4.46 (a) là ảnh $I[x, y, t]$, trong đó: hình vuông màu trắng kích thước 11×11 px, dấu x màu đỏ ở chính giữa tâm là điểm sẽ được theo dõi chuyển động và ô vuông nét đứt màu xanh là cửa sổ W kích thước 15×15 px để ước lượng chuyển động ở mỗi bước lặp. Hình 4.45 (b) là ảnh $I[x, y, t + 1]$, trong đó hình vuông được di chuyển theo vector chuyển động $(1.5, 0.8)$ px. Có thể thấy một số điểm ảnh mờ do ô vuông này di chuyển tới tọa độ điểm ảnh không nguyên. Dấu x nhỏ màu là tọa độ của tâm hình vuông trước khi di chuyển. Độ lệch giữa dấu x màu xanh vào dấu x màu đỏ trong Hình 4.45 (b) là chuyển động thực của hình vuông.

Bảng 4.5. Cập nhật giá trị vector chuyển động sau 15 lần lặp.


Bước lặp	v_x	v_y	c_x	c_y
0	0.1811	0.1133	0.1811	0.1133
1	0.3614	0.2211	0.1803	0.1078
2	0.5307	0.3216	0.1693	0.1005
3	0.6838	0.4111	0.1531	0.0895
4	0.8158	0.4865	0.1321	0.0754
5	0.9295	0.5453	0.1136	0.0588
6	1.0244	0.5983	0.0949	0.0530
7	1.1065	0.6393	0.0822	0.0410
8	1.1805	0.6744	0.0740	0.0351
9	1.2404	0.6974	0.0598	0.0230
10	1.2895	0.7205	0.0491	0.0231

11	1.3330	0.7376	0.0435	0.0171
12	1.3646	0.7488	0.0316	0.0113
13	1.3901	0.7601	0.0255	0.0113
14	1.4156	0.7713	0.0255	0.0113

Bảng 4.5. liệt kê giá trị vector chuyển động sau mỗi lần lặp của thuật toán tăng độ chính xác vector chuyển động. Có thể thấy, ở những bước đầu tiên (v_x, v_y) còn cách chuyển động thực $(1.5, 0.8)$ rất xa. Các bước lặp sau cập nhật dần (v_x, v_y) tiệm cận dần tới giá trị thực $(1.5, 0.8)$ với tốc độ giảm dần.

4.5.2.3. Theo dõi chuyển động dài (thuật toán Pyramid LK)

Một trong những giả định của (Lucas 1981) là độ chuyển động của điểm cần theo dõi giữa hai ảnh liên tiếp phải đủ ngắn (nhỏ hơn 3 px). Tuy nhiên trong thực tế đối tượng có thể chuyển động nhanh trong video, khiến vector chuyển động thực giữa hai ảnh liên tiếp rất dài (có thể vài chục px). Chuyển động quá dài phá vỡ điều kiện và làm công thức xấp xỉ (4.100) có sai số lớn dẫn đến không thể ước lượng được hoặc ước lượng sai vector chuyển động.



Hình 4.47. Ước lượng chuyển động sử dụng kim tự tháp ảnh.

Để giải quyết vấn đề với các chuyển động dài, việc ước lượng vector chuyển động được thực hiện ở kim tự tháp ảnh (image pyramid) có nhiều mức, xem Hình 4.47. Ở mức 0, ảnh $I^0 = I[x, y]$. Ảnh I^{l+1} thu được từ I^l bằng cách lọc làm mượt I^l và giảm độ phân giải xuống còn 1 nửa mỗi chiều. Thông thường trong bài toán theo dấu chuyển động, mức tối đa là 5. Với ảnh $I[x, y]$ ban đầu có kích thước $M \times N$ thì:

Mức 0: I^0 có kích thước $M \times N$.

Mức 1: I^1 có kích thước $\frac{M}{2} \times \frac{N}{2}$.

...

3112 Mức l : I^l có kích thước $\frac{M}{2^l} \times \frac{N}{2^l}$.

3113 Ký hiệu $p^0 = (x_B, y_B)$ là điểm neo cần theo dấu chuyển động ở mức 0. Tọa độ
3114 điểm này trong ảnh mức l là $p^l = \left(\frac{x_B}{2^l}, \frac{y_B}{2^l}\right)$.

3115 Việc ước lượng vector chuyển động được thực hiện từ mức cao nhất xuống
3116 mức 0. Ở mỗi mức thuật toán ước lượng và tăng độ chính xác vector chuyển động
3117 được áp dụng và vector chuyển động sẽ được chuyển sang mức sau để tiếp tục được
3118 làm mịn. Có thể tóm tắt thuật toán qua các bước sau:

3119 Bước 1 – Khởi tạo:

- 3120 - Điểm neo cần ước lượng vector chuyển động (x_B, y_B) .
- 3121 - Xác định số lượng mức của kim tự tháp ảnh lớn nhất L .
- 3122 - Khởi tạo dãy ảnh đa tầng $I_1^0, I_1^1, \dots, I_1^{L-1}$ và $I_2^0, I_2^1, \dots, I_2^{L-1}$. Chỉ số dưới cho
3123 biết ảnh thứ tự trong chuỗi video ví dụ ảnh I_1^0 ở liền trước ảnh I_2^0 .
- 3124 - Khởi tạo tầng đầu tiên thực hiện ước lượng $l \leftarrow L - 1$.
- 3125 - Khởi tạo vector chuyển động đa tầng $(v_x^l, v_y^l) \leftarrow (0, 0)$.

3126 Bước 2 – Ước lượng vector chuyển động ở từng mức cho đến mức thấp nhất:

- 3127 - Tính điểm neo ở tầng l có xét đến vector chuyển động đang ước lượng:
3128 $p^l = \left(\frac{x_B}{2^l} + v_x^l, \frac{y_B}{2^l} + v_y^l\right)$.
- 3129 - Thực hiện thuật toán Lucas-Kanade để tính vector chuyển động (v_x, v_y)
3130 cho cửa sổ quanh điểm p^l giữa hai ảnh I_1^l và I_2^l .
- 3131 - Cập nhật vector chuyển động đa tầng: $(v_x^l, v_y^l) \leftarrow (v_x^l + v_x, v_y^l + v_y)$.
- 3132 - Giảm chỉ số tầng: $l \leftarrow (l - 1)$.
- 3133 - Trong khi $l > 0$ thì lặp lại Bước 2.

3134 Bước 3 – Kết quả cuối cùng:

- 3135 - Vector chuyển động của điểm (x_B, y_B) được xác định là (v_x^l, v_y^l) .

3136 4.5.2.4. Theo dõi đối tượng trong chuỗi khung hình

3137 Theo dõi đối tượng trong chuỗi khung hình không đơn thuần là thực hiện
3138 thuật toán Pyramid LK cho từng cặp ảnh liên tiếp. Các đối tượng xuất hiện trong
3139 chuỗi video có thể biến đổi, bị che khuất và biến mất khỏi khung hình làm phá vỡ
3140 các điều kiện để ước lượng vector chuyển động khiến việc dõi theo đối tượng bị sai
3141 hoặc lẫn sang các đối tượng khác.

3142 Ký hiệu $I_0, I_1, \dots, I_n$ là chuỗi liên tiếp các khung hình trong một đoạn video.
3143 Việc theo dõi đối tượng trong chuỗi này có thể được thực hiện như sau:

3144 Bước 1 – khởi tạo tại $I_{i=0}$:

- 3145 - Sử dụng phát hiện điểm đặc trưng Shi-Tomasi để tìm các điểm góc nhằm
3146 đảm bảo các điểm này thỏa mãn điều kiện theo dõi được.

- 3147 - Có thể giới hạn các điểm đặc trưng trong một vùng ảnh cố định đại diện
3148 cho đối tượng cần theo dõi hoặc sử dụng các kỹ thuật phát hiện đối tượng
3149 để xác định vùng đại diện.
3150 - Tạo lập tập các điểm đặc trưng cần theo dõi chuyển động $P_0 = \{p_{0,1}, p_{0,2}, \dots\}$
3151 là danh sách các điểm góc vừa phát hiện.
3152 - Thiết lập một tập các ràng buộc R cho các điểm đặc trưng thuộc P_0 để đảm
3153 bảo tính toàn vẹn của đối tượng trong quá trình theo dõi. Ràng buộc R phụ
3154 thuộc vào đặc điểm và tính chất của đối tượng đang theo dõi.

3155 Bước 2 – theo dõi chuyển động qua từng khung hình $I_{i>0}$:

- 3156 - Sử dụng thuật toán Pyramid LK giữa hai ảnh I_{i-1} và I_i để tìm các vector
3157 chuyển động $V_{i-1} = \{v_{i-1,1}, v_{i-1,2}, \dots\}$ cho các điểm đặc trưng cần theo dõi
3158 P_{i-1} .
3159 - Tạo lập danh sách điểm cần theo dõi tại khung hình I_i là $P_i = \{p_{i,1}, p_{i,2}, \dots\}$
3160 bằng việc di chuyển các điểm đặc trưng ở khung hình I_{i-1} theo vector
3161 chuyển động của nó $p_{i,k} = p_{i-1,k} + v_{i-1,k}$.
3162 - Kiểm tra các điểm thuộc P_i để loại bỏ những điểm không thỏa mãn điều
3163 kiện theo dõi được và những điểm phá vỡ ràng buộc R (gây ra do
3164 nhiễu, bị che khuất, hoặc bị nhầm lẫn sang đối tượng khác).
3165 - Sử dụng phát hiện điểm đặc trưng Shi-Tomasi để phát hiện những điểm
3166 có thể theo dõi mới, và bổ sung các điểm này vào P_i nếu nó thỏa mãn điều
3167 kiện R. Điều này đảm bảo điểm thuộc đối tượng mới được đưa vào danh
3168 sách theo dõi nếu nó thỏa mãn điều kiện có thể theo dõi được và thỏa mãn
3169 ràng buộc R.

3170 Bước 3 – Mô hình hóa quỹ đạo chuyển động:

- 3171 - Khi đã có tập điểm đặc trưng $P_0, P_1, \dots$ ở từng khung hình và mối quan hệ
3172 chuyển động giữa các điểm ở 2 khung hình liên tiếp, có thể áp dụng các kỹ
3173 thuật so khớp mô hình (model fitting) để tìm quỹ đạo chuyển động của
3174 mỗi điểm, hoặc có thể khai thác các kỹ thuật căn chỉnh ảnh để xác định và
3175 mô hình hóa biến đổi của đối tượng trong chuỗi khung hình.

3176 Phần này chỉ giới thiệu khung thuật toán nói chung có thể áp dụng cho nhiều
3177 bài toán theo dõi đối tượng khác nhau. Mỗi điểm trong từng bước có thể được cài
3178 đặt phụ thuộc vào yêu cầu và đầu vào của bài toán theo dõi đối tượng cụ thể.

3179 4.5.3. Căn chỉnh ảnh

3180 Quá trình thu nhận ảnh làm cho một đối tượng xuất hiện trong các ảnh khác
3181 nhau bị lệch vị trí (translation), xoay (rotation), kích thước khác nhau (scale), hình
3182 dạng khác nhau do hướng nhìn, ... bên cạnh đó, bản thân hình dạng, màu sắc đối
3183 tượng cũng có sự biến đổi theo thời gian gây nên sự khác nhau trong các ảnh. Điều
3184 này khiến dữ liệu về đối tượng bị phân tán trong nhiều hình ảnh gây khó khăn cho
3185 phân tích và tổng hợp thông tin.

Căn chỉnh ảnh (image registration) là quá trình chuyển đổi các ảnh về cùng một hệ quy chiếu sao cho các điểm ở trong hai hay nhiều ảnh mô tả cùng đối tượng được căn chỉnh cùng tọa độ với nhau. Việc này giúp giải quyết nhiều bài toán thực tiễn như: so sánh biến động bề mặt trong ảnh vệ tinh, theo dõi bệnh trong ảnh MRI, ghép nhiều ảnh thành một ảnh lớn (panorama), tái tạo cấu trúc 3D của vật thể, ...

Luồng tác vụ thường thấy nhất trong căn chỉnh ảnh bao gồm: Phát hiện và mô tả điểm đặc trưng, ghép cặp điểm đặc trưng, ước lượng mô hình hình học và nắn ảnh theo mô hình tìm được.

4.5.3.1. Phát hiện và mô tả điểm đặc trưng

Để thuận tiện trong trình bày, ta sử dụng 2 ảnh mẫu để làm ví dụ trong Hình 4.48. Cả hai hình đều chụp một khung cảnh với tỉ lệ và độ xoay khác nhau.




Ảnh I_1



Ảnh I_2

Hình 4.48. Hai ảnh chụp ở hai góc nhìn.



Ảnh I_1



Ảnh I_2

Hình 4.49. Các blob với tỉ lệ tối ưu được tìm thấy và chuẩn hóa xoay.

Đầu tiên, sử dụng phương pháp phát hiện điểm đặc trưng DoG để phát hiện blob, tìm tỉ lệ tối ưu, chuẩn hóa xoay và SIFT để mô tả từng điểm của cả 2 ảnh. Hình 4.49 cho thấy các blob tìm thấy ở trong hai ảnh.

Mỗi điểm đặc trưng sau khi tìm được được biểu diễn bởi một bộ:

$$F_{IP} = \{x, y, \sigma, \theta, F_{SIFT}\}, \quad (4.107)$$


trong đó (x, y) là tọa độ của điểm đặc trưng trong ảnh, σ là tỉ lệ (Gaussian scale) điểm được lựa chọn, θ góc xoay được chuẩn hóa và F_{SIFT} là bộ mô tả kết cấu 128 phần tử SIFT theo công thức (4.83).

4.5.3.2. Ghép cặp điểm đặc trưng

Đầu tiên, khoảng cách giữa 2 điểm đặc trưng p và q được định nghĩa là khoảng cách Euclid giữa hai bộ mô tả kết cấu SIFT:

$$d(p, q) = \|F_{SIFT}(p) - F_{SIFT}(q)\|, \quad (4.108)$$

trong đó $F_{SIFT}(\cdot)$ là vector 128 chiều định nghĩa theo công thức (4.83). Khoảng cách càng bé hai điểm càng giống nhau (từ 1 đối tượng) và ngược lại.



Hình 4.50. Các cặp điểm đặc trưng của hai ảnh khớp được.

Ghép điểm đặc trưng tức là ta tìm một cặp điểm đặc trưng thuộc hai ảnh sao cho khoảng cách giữa chúng là nhỏ nhất so với tất cả các cặp khác. Với mỗi điểm đặc trưng p thuộc ảnh I_1 ta tìm hai điểm đặc trưng khác nhau m và n thuộc ảnh I_2 sao cho có $d(p, m)$ và $d(p, n)$ có giá trị bé nhất và bé thứ nhì. Cặp điểm (p, m) được coi là khớp được với nhau nếu nó thỏa mãn kiểm thử Lowe (Lowe 2004):


$$\frac{d(p, m)}{d(p, n)} < 0.75. \quad (4.109)$$

Điều kiện này đảm bảo loại bỏ đi các nhiễu và khẳng định việc khớp (p, m) là đúng do nó tách biệt với tất cả các cặp còn lại.


Hình 4.50 trực quan hóa các cặp điểm đặc trưng giữa hai ảnh I_1 và I_2 khớp được với nhau. Số lượng cặp điểm của hai ảnh cho thấy sự trùng hợp về nội dung ảnh, số cặp càng nhiều phần giao nhau giữa hai ảnh càng lớn và ngược lại. Cấu hình của các điểm đặc trưng cũng cho thấy mối quan hệ về mặt hình học giữa hai ảnh.

4.5.3.3. Ước lượng mô hình hình học và nắm ảnh

Với giả định các bức ảnh được chụp trên cùng một mặt phẳng 3D hoặc do di chuyển của máy ảnh quanh tâm hoặc do phóng to (zoom in)/thu nhỏ (zoom in), ta có thể thực hiện phép biến từng ảnh về một hệ tọa độ thống nhất thông qua phép biến đổi homography. Hình 4.51 cho thấy một số phép biến đổi giữa ảnh gốc và các ảnh bị biến đổi do chụp ảnh.



Hình 4.51. Các biến đổi thường thấy khi chụp ảnh.



Hình 4.52. Mô hình hóa chuyển đổi giữa các hệ quy chiếu ảnh.

Có thể thấy trong Hình 4.52 hai điểm màu đỏ thuộc cùng một đối tượng nhưng ở nó ở những tọa độ khác nhau trên hai ảnh. Có thể mô hình hóa các biến đổi (trong Hình 4.50) từ hệ quy chiếu của ảnh I_2 sang ảnh I_1 bằng một chuyển đổi tuyến tính trong không gian đồng cấu (homogeneous space) như sau:

$$\begin{bmatrix} x' \\ y' \\ 1 \end{bmatrix} \sim \begin{bmatrix} x'w' \\ y'w' \\ w' \end{bmatrix} = \begin{bmatrix} h_{11} & h_{12} & h_{13} \\ h_{21} & h_{22} & h_{23} \\ h_{31} & h_{32} & h_{33} \end{bmatrix} \begin{bmatrix} x \\ y \\ 1 \end{bmatrix} \quad (4.110)$$

hay

$$\begin{bmatrix} x' \\ y' \\ 1 \end{bmatrix} \sim \begin{bmatrix} x'w' \\ y'w' \\ w' \end{bmatrix} = \mathbf{H} \begin{bmatrix} x \\ y \\ 1 \end{bmatrix}. \quad (4.111)$$

Do $\mathbf{H}$ là ma trận homography (biến đổi phẳng đồng nhất), nên có thể chuẩn hóa $h_{33} = 1$ mà không làm mất tính chất của phép chuyển đổi trong không gian đồng cấu và $\mathbf{H}$ chỉ còn 8 ẩn số để ước lượng. Mỗi cặp điểm so khớp giữa hai ảnh I_1 và I_2 hình thành 2 phương trình, do đó sẽ cần tối thiểu 4 cặp điểm để có thể ước lượng được 8 giá trị còn lại của $\mathbf{H}$ trong công thức (4.11) bằng phương pháp DLT hoặc SVD (Szeliski 2022).

Thông thường số lượng cặp điểm đặc trưng có thể ghép được từ hai ảnh phải lớn để đảm bảo sự tin cậy. Tiếp theo phương pháp đồng thuận ngẫu nhiên (RANSAC) được sử dụng để ước lượng $\mathbf{H}$.


Ký hiệu $F_M = \{(p_1, q_1), (p_2, q_2), \dots, (p_n, q_n)\}$ là n cặp điểm đặc trưng ghép được từ 2 ảnh I_1 và I_2 (xem Hình 4.50). Các bước RANSAC được thực hiện như sau:

Bước 1: Lấy ngẫu nhiên 1 tập gồm 4 cặp cạnh $F_M^R \subset F_M$. Ở đây ta chỉ cần 4 cặp cạnh phải tạo thành một cấu hình không suy biến (không có 3 điểm thẳng hàng) để đủ điều kiện ước lượng $\mathbf{H}$.

Bước 2: Sử dụng phương pháp DLT để tính ma trận $\mathbf{H}$.

Bước 3: Chuyển tọa độ các điểm đặc trưng $p'_i = \mathbf{H} \cdot q_i$, ($i \in \{1, \dots, n\}$), và đếm các điểm p'_i phù hợp với mô hình $\mathbf{H}$. Điểm p'_i gọi là phù hợp nếu có khoảng cách tới p_i nhỏ hơn ngưỡng t (ví dụ có thể chọn $t = 3 \text{ px}$).

Bước 4: Lặp lại từ bước 1 đến bước 3 (n lần) và lưu lại F_M^R mà có nhiều điểm thỏa mãn nhất.



Hình 4.53. Nén ảnh và ghép thành ảnh lớn.


Sau khi ước lượng được $\mathbf{H}$, ta có thể chuyển toàn bộ điểm ảnh I_2 sang hệ tọa độ của ảnh I_1 , gọi là I'_1 . Khi ghép hai ảnh I'_1 với I_1 xuất hiện vùng chồng lấn (phần giao nhau giữa ảnh I_1 và I_2) và các vùng mở rộng. Hình 4.53 thể hiện kết quả ghép ảnh trong đó biên của các ảnh được làm rõ để thấy sự chồng lấn giữa hai ảnh. Các

điểm chấm màu xanh lá là những điểm phù hợp với H (inliers) và những điểm màu xanh lục là những điểm không phù hợp với H (có thể là kết quả của nhiễu).

Quá trình ghép ảnh ở trên cần chú ý sự không đồng nhất ở vùng giao nhau giữa các ảnh do sai số chuyển đổi ảnh và các vết rạn nứt bên trong ảnh là hệ quả của phép chuyển đổi ảnh trên các điểm ảnh rời rạc.

4.5.4. Phân loại ảnh

Phân loại ảnh giúp xác định xem ảnh này thuộc loại gì hoặc chứa những đối tượng chính nào. Nói một cách khác, phân loại ảnh nhằm gán cho mỗi ảnh một nhãn tùy thuộc vào nội dung của ảnh. Nhãn của mỗi ảnh có thể được sử dụng trực tiếp trong nhiều ứng dụng thực tiễn như: hệ thống gợi ý sản phẩm, hệ thống lọc ảnh, tìm kiếm theo hình ảnh ... hoặc được sử dụng gián tiếp trong các bài toán thị giác máy khác như phát hiện đối tượng, hiểu ảnh, truy xuất thông tin trong ảnh, ...



Hình 4.54. Luồng xử lý điển hình của phân loại ảnh.

Các bước thực hiện phân loại ảnh được trực quan hóa trong Hình 4.54. Trong đó các kỹ thuật như SIFT, HoG, LBP, GLCM, Gabor, ... được áp dụng để trích trồn *đặc trưng cục bộ* (local features) từ ảnh. Tùy vào từng bài toán và chiến lược thiết kế thuật toán mà có thể lựa chọn 1 hoặc một số loại đặc trưng cho phù hợp. Nhiều nghiên cứu cho thấy, đối với những bài toán phân loại ảnh tổng quát, việc kết hợp nhiều loại đặc trưng cục bộ làm tăng đáng kể hiệu năng phân loại. Các vector đặc trưng cục bộ sau đó được biến đổi tổng hợp thành đặc trưng toàn ảnh hay còn gọi là *đặc trưng toàn cục* (global features).


Vector đặc trưng toàn cục cho ảnh thường có kích thước rất lớn, nên cần được xử lý để thu gọn, cô đọng thông tin nhằm tăng hiệu quả cho bước phân loại phía sau. Cuối cùng, ảnh được gán nhãn thông qua bước phân loại ảnh xạ vector đặc trưng ảnh vào không gian nhãn.

4.5.4.1. Biểu diễn đặc trưng ảnh

Các vector đặc trưng cục bộ (mô tả một phần của ảnh) sau khi được trích chọn cần gom nhóm, mã hóa và tổng hợp để biểu diễn thành vector đặc trưng mô tả toàn bộ ảnh. Một số phương pháp biểu diễn đặc trưng ảnh hay được sử dụng nhất là: *Túi từ trực quan* (bag of visual words - BoVW) trong (Lazebnik 2006), *Vector Fisher* (Fisher vector) trong (Perronnin 2007) hoặc *Vector gộp cục bộ* (vector of locally aggregated descriptors) trong (Jégou 2010). Cuốn giáo trình này tập trung trình bày phương pháp BoVW để người học thấy được tổng thể về ý tưởng và hiệu năng sử dụng. Các phương pháp khác có thể được đọc trong các tài liệu tham khảo.

A) Từ điển trực quan

Từ trực quan (visual word) được định nghĩa là một đại diện trong không gian đặc trưng cục bộ của ảnh cho một nhóm các điểm đặc trưng thị giác tương tự nhau. Bản thân Từ trực quan có không có nghĩa là một khái niệm hoàn chỉnh và cũng không phải là đại lượng vật lý như điểm ảnh. Nó đại diện cho một mẫu hình thị giác có tính chất lặp đi lặp lại ở nhiều ảnh và sẽ tạo nên ý nghĩa thị giác khi được tổ hợp thành 1 nhóm.



Hình 4.55. Liên hệ giữa từ trực quan và đặc trưng cục bộ.

Từ điển trực quan (visual vocabulary) là một tập hợp các từ trực quan và được xây dựng từ một tập ảnh cho trước (bộ ảnh huấn luyện). Đầu tiên, các đặc trưng cục bộ được (SIFT, HoG, LBP, ...) được trích chọn từ tất cả ảnh trong tập ảnh huấn luyện. Chúng được gom lại thành một bộ tổng thể và được chia ra thành các cụm (sử dụng thuật toán phân cụm như k-means). Mỗi cụm tương ứng với một từ trực quan và tập hợp tất cả các từ trực quan (tất cả các cụm) hình thành từ điển trực quan cho bộ dữ liệu ảnh huấn luyện.

Hình 4.55 miêu tả một đồ thị liên hệ giữa từ trực quan với các đặc trưng cục bộ. Mặc dù số chiều không gian của đặc trưng cục bộ có thể rất lớn (128 chiều đối với đặc trưng SIFT), nhưng trong đồ thị này ta thu gọn thành 2 chiều để dễ theo dõi. Mỗi điểm màu hình tam giác, hình tròn, hình vuông đại diện cho một điểm đặc trưng. Thuật toán phân cụm k-means tìm thấy 6 cụm tương ứng với 6 từ trực quan. Mỗi từ trực quan được thể hiện là một dấu x màu đen trên đồ thị và nằm ở tâm của một cụm.

B) Biểu diễn từ điển đặc trưng

Ký hiệu $I_{train} = \{I_i\}_{i=1}^n$ là một tập gồm n ảnh được dùng để huấn luyện (để tìm ra từ điển trực quan). Sử dụng một phương pháp trích chọn đặc trưng cho tất cả ảnh trong I_{train} và gộp lại để được một bộ các vector đặc trưng cục bộ $F_{local} = \{f_i\}_{i=1}^m$, với $f_i \in R^d$ (nếu sử dụng đặc trưng SIFT thì $d = 128$). Hình 4.56 (b) hiển thị các điểm đặc trưng SIFT được trích chọn từ Hình 4.55 (a).

Xác định k là số từ trực quan trong từ điển và thực hiện phân cụm F_{local} bằng thuật toán k-means cho k cụm và ký hiệu $W = \{w_i\}_{i=1}^k$ là tập tâm các cụm tương ứng với k từ trực quan. Lúc này, W được gọi là từ điển trực quan (gọi tắt là từ điển) của I_{train} .


Với từ điển W có k từ trực quan, đặc trưng cục bộ có thể được lượng tử hóa về một từ trực quan nếu khoảng cách từ điểm đặc trưng tới từ trực quan là nhỏ nhất:

$$c_W(f) = \arg \min_i \|f - w_i\|, \quad (4.112)$$

trong đó $f \in R^d$ là vector mô tả điểm đặc trưng.

Hình 4.56 (c) hiển thị các điểm đặc trưng được lượng tử hóa vào 5 từ trực quan (5 từ trực quan thu được bằng việc áp dụng phân cụm k-mean lên các điểm đặc trưng trong Hình 4.56 (b) với số cụm $k = 5$). Có thể thấy rất rõ đặc điểm thị giác của từng cụm: một cụm bám quanh viền cửa sổ, một cụm phủ trên cột gạch giữa hai cửa, các cụm còn lại phân bố xen kẽ trên nền gạch và khung cửa. Hình 4.56 (d) là histogram BoVW của ảnh (a), nó cho biết kích thước của từng cụm (số lượng điểm đặc trưng được lượng tử hóa về từ trực quan tương ứng).

Lựa chọn giá trị k ảnh hưởng tới chất lượng của mô hình. Nếu k quá nhỏ, số lượng từ đặc trưng quá nhỏ làm giảm khả năng biểu diễn thông tin thị giác do có quá nhiều điểm đặc trưng cùng được lượng tử hóa về một từ trực quan. Ngược lại, nếu k quá lớn, mặc dù mô hình có thể phản ánh mức độ chi tiết của ảnh nhưng từ điển trở nên cồng kềnh và làm giảm khả năng khái quát hóa.



Hình 4.56. Lượng tử hóa điểm đặc trưng bằng từ trực quan.

Tùy từng ứng dụng để lựa chọn giá trị k cho phù hợp: từ 100 đến 1000 phù hợp với các bài toán phân loại ảnh, từ 1000 đến 5000 cho các ứng dụng truy vấn ảnh và lớn hơn 10000 cho các bài toán thị giác thực tiễn lớn.

C) Biểu diễn đặc trưng BoVW


Có thể thấy biểu diễn histogram BoVW biểu diễn được phân bố đặc trưng thị giác của ảnh theo từ điển trực quan nhưng nó làm mất đi toàn bộ thông tin không gian của các điểm đặc trưng. Do đó, biểu diễn BoVW được đề xuất trong (Lazebnik 2006) để giải quyết vấn đề này.

Ký hiệu $W = \{w_i\}_{i=1}^k$ là từ điển trực quan đã được xây dựng từ một tập ảnh huấn luyện I_{train} . Với một ảnh đầu vào mới I , biểu diễn đặc trưng BoVW cho ảnh này được xây dựng như sau:

Bước 1: Chia ảnh I thành lưới phân tầng nhiều mức (Xem Hình 4.57): Mức 0 là lưới 1×1 ô, mức 1 là lưới 2×2 ô, và mức 2 là lưới 4×4 ô (có thể sử dụng nhiều mức hơn nếu kích thước ảnh I lớn). Tổng số ô là $1 + 4 + 16 = 21$.

Bước 2: Tính histogram BoVW của từng ô trong lưới phân tầng ở Bước 1. Tổng số có 21 histogram cho ảnh I .

Bước 3: Nối các histogram đã tính ở bước 2 thành 1 vector đặc trưng duy nhất và có kích thước cố định của ảnh I , gọi là vector đặc trưng có *phân cấp không gian* (spatial pyramid matching – SPM) và viết ngắn gọn là vector SPM. Do số chiều của mỗi histogram là k , nên kích thước của vector đặc trưng là $21k$.



Hình 4.57. Mức chia lưới ảnh

4.5.4.2. Xử lý vector đặc trưng lớn

Trong các bài toán truy vấn ảnh thực tiễn, giá trị của k có thể là rất lớn, ví dụ $k = 10\,000$. Khi đó kích thước vector SPM cho một ảnh là $21k = 210\,000$ chiều. Kích thước vector SPM lớn làm phân tán thông tin trong nội tại vector làm gánh nặng khi lưu trữ cũng như các pha xử lý tiếp theo. Do đó, nhiệm vụ của xử lý vector SPM là giảm số chiều của vector nhưng vẫn phải giữ được phần lớn thông tin trong nó.

Phân tích thành phần chính (principle component analysis - PCA) (Hotelling 1933) là một trong những cách hiệu quả để giảm số chiều vector SPM. PCA không những giúp giảm số chiều, nó còn lọc được nhiễu và loại bỏ sự tương quan giữa các vector đầu vào, nhờ đó làm tăng hiệu quả của pha phân lớp phía sau.

Ký hiệu $\mathbf{X} = [\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n]^T \in R^{n \times d}$ là ma trận chứa các vector SPM của các ảnh trong tập huấn luyện, trong đó $\mathbf{x}_i \in R^d$ là vector SPM của ảnh $I_i \in I_{train}$, n là số ảnh trong tập huấn luyện, $d = 21k$ là số chiều của vector SPM.

Do các ảnh khác nhau có thể có sự chênh lệch lớn về màu sáng và các vector SPM có thể chứa thành phần có độ lớn bất thường lẫn át các thành phần khác, nên bước chuẩn hóa cần phải được thực hiện:

$$\bar{\mathbf{x}} = \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i \text{ và } \mathbf{z}_i = \mathbf{x}_i - \bar{\mathbf{x}},$$

và

$$\mathbf{z}_i \leftarrow \frac{\mathbf{z}_i}{\|\mathbf{z}_i\|_2}.$$

Tiếp theo, ta tính ma trận hiệp phương sai:

$$\mathbf{C} = \frac{1}{n} \mathbf{Z}^T \mathbf{Z} \in \mathbf{R}^{d \times d}, \quad (4.113)$$

trong đó $\mathbf{Z}$ là ma trận các vector SMP đã được chuẩn hóa, $\mathbf{Z} = [\mathbf{z}_1, \mathbf{z}_2, \dots, \mathbf{z}_n]$ và tìm nghiệm bài toán trị riêng:

$$\mathbf{C} \cdot \mathbf{p}_j = \lambda_j \cdot \mathbf{p}_j. \quad (4.114)$$

Với $\mathbf{p}_j$ là vector riêng và λ_j là giá trị riêng cho biết phương sai của $\mathbf{C}$ khi chiếu lên thành phần chính $\mathbf{p}_j$. λ_j càng lớn thì thành phần chính thứ j càng quan trọng và dữ liệu của thành phần này mang theo càng chứa nhiều thông tin. Do đó, độ quan trọng của các thành phần chính có thể được sắp xếp giảm dần theo độ lớn của các giá trị riêng, không mất tính tổng quát, ta có thể coi:

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_d.$$

Ta sẽ giữ lại r thành phần quan trọng nhất tương ứng với r giá trị riêng lớn nhất. Thông thường r sẽ được lựa chọn sao cho:

$$\frac{\sum_j^r \lambda_j}{\sum_j^d \lambda_j} \approx 90\% - 95\%.$$

Tức là các thành phần chính còn lại vẫn chứa từ 90% – 95% lượng thông tin. Như vậy, sau khi được học từ bộ dữ liệu ảnh huấn luyện I_{train} , ta có ma trận PCA:

$$\mathbf{P}_r = [\mathbf{p}_1, \mathbf{p}_2, \dots, \mathbf{p}_r]^T. \quad (4.115)$$

Với một ảnh I bất kỳ, ta tính được vector SPM là $\mathbf{x}_{new} \in \mathbf{R}^d$ và thực hiện chuẩn hóa $\mathbf{z}_{new} = \mathbf{x}_{new} - \bar{\mathbf{x}}, \mathbf{z}_{new} \leftarrow \frac{\mathbf{z}_{new}}{\|\mathbf{z}_{new}\|_2}$.

Sau cùng, vector SPM của ảnh I được giảm chiều bằng cách:

$$\mathbf{x}_r = \mathbf{P}_r^T \cdot \mathbf{z}_{new}. \quad (4.116)$$

Ta được vector SPM $\mathbf{x}_{new}$ có d chiều sau khi giảm số chiều sử dụng PCA được $\mathbf{x}_r$ có r chiều, trong đó $r \ll d$. Ví dụ: $d = 21k = 210\,000, r = 20\,000$.

Lúc này $\mathbf{x}_r$ được gọi là vector đặc trưng của ảnh I . Do bước giảm số chiều có nhiệm vụ chính là giảm kích thước vector biểu diễn ảnh I , một số bài toán phân loại ảnh có thể bỏ qua bước này mà không làm ảnh hưởng tới hiệu suất hoạt động.

4.5.4.2. Phân loại

Sau khi ảnh được biểu diễn thành vector đặc trưng có chiều dài cố định, vector đặc trưng một bộ phân lớp học máy có thể được sử dụng để xác định nhãn cho ảnh.

Bộ phân lớp (classifier) thường là một mô hình học máy được huấn luyện (train) từ một tập dữ liệu cho trước. Trong bài toán phân loại ảnh, tập dữ liệu bao gồm các cặp ảnh và nhãn $D = \{(I_i, l_i)\}_{i=1}^n$. Các ảnh trong tập dữ liệu được trích chọn đặc trưng và giảm số chiều để thu được bộ dữ liệu huấn luyện:

$$D_{train} = \{(x_i, l_i)\}_{i=1}^n, \quad (4.117)$$

trong đó x_i là vector đặc trưng của ảnh I_i .

Hình 4.58 minh họa tập dữ liệu ảnh huấn luyện gồm 2 nhãn ảnh là *Xe máy* và *Ghế*, mỗi nhãn có 3 ảnh được lấy từ bộ dữ liệu Caltech 101 (Fei Fei 2004).



(a) Ảnh thuộc lớp: Xe máy



(b) Ảnh thuộc lớp: Ghế

Hình 4.58. Ví dụ về bộ dữ liệu ảnh huấn luyện


Có nhiều bộ phân lớp học máy (learning machine classifier) có thể được sử dụng cho để phân loại ảnh như: cây quyết định, logistic, mạng neuron nhân tạo, máy vector hỗ trợ (SVM), ... Trong số đó SVM tỏ ra là bộ phân lớp hiệu quả nhất (trước kỷ nguyên học sâu deep learning) trong nhiều bài toán thị giác máy. Chi tiết về SVM và các bộ phân lớp học máy khác có thể được tham khảo trong (Long 2025).

Ban đầu, một bộ phân loại như SVM có nhiều tham số nội tại (vector hỗ trợ) chưa xác định. Để có thể sử dụng được, các vector hỗ trợ của SVM phải được thiết lập các giá trị thông qua một *thuật toán học* (learning algorithm) lấy đầu vào từ bộ dữ liệu huấn luyện D_{train} . Thuật toán huấn luyện sẽ tối ưu bộ tham số để có thể dự đoán một cách chính xác nhất nhãn của một vector đặc trưng. Sau khi huấn

luyện, bộ tham số này tiếp tục được sử dụng để dự đoán nhãn của vector đặc trưng khác (được trích chọn từ một ảnh khác). Đây là quá trình phân loại ảnh.

4.5.5. Phát hiện và nhận dạng đối tượng trong ảnh

Phát hiện và nhận dạng đối tượng trong ảnh có điểm giống với phân loại ảnh là cùng là bài toán gán nhãn cho ảnh. Tuy nhiên, phân loại ảnh là gán một nhãn cho toàn bộ ảnh, phát hiện và nhận dạng đối tượng là gán nhãn (có thể nhiều hơn một nhãn) cho một vùng trong ảnh. Phát hiện đối tượng gán nhãn cho biết sự có mặt/xuất hiện/tồn tại của đối tượng trong vùng ảnh, nhận dạng đối tượng gán nhãn cho biết định danh của đối tượng.



Hình 4.59. Phát hiện và nhận dạng mặt người.

Hình 4.59 cho thấy một ví dụ về phát hiện và nhận dạng đối tượng mặt người. Trong đó nhãn ô vuông màu xanh cho được gán cho vùng ảnh có mặt người (phát hiện đối tượng) và nhãn chữ màu vàng được gán cho vùng ảnh xác định định danh của mặt người.

Đối tượng xuất hiện trong ảnh có thể có kích thước khác nhau (scale), có thể xoay theo các góc khác nhau (rotation), ở những vị trí khác nhau (translation). Do đó, một phần nhỏ của ảnh trong cửa sổ $W(p_1, p_2)$ có dạng hình chữ nhật được xác định bởi tọa độ 2 góc đối diện $p_1 = (x_1, y_1)$, $p_2 = (x_2, y_2)$ được xem xét phát hiện và nhận dạng đối tượng. Lúc này, bài toán phát hiện và nhận dạng đối tượng được quy về việc xác lập tập nhãn tương tự như bài toán Phân loại ảnh nhưng được thực hiện cho ảnh trong cửa sổ $W(p_1, p_2)$.

Bài toán phát hiện đối tượng thiết lập tập nhãn chỉ bao gồm 2 nhãn $\{none, face\}$, $\{none, car\}$, ... trong đó nhãn *none* cho biết không có sự xuất hiện của đối tượng (negative) và nhãn còn lại cho biết có sự xuất hiện của đối tượng mặt người (*face*), xe ô tô (*car*), ... trong vùng ảnh đang xét. Bài toán nhận dạng đối tượng giả định vùng ảnh đã được gán nhãn định danh một đối tượng cụ thể ví dụ *face* hoặc *car*, ... Việc nhận dạng nhằm xác định định danh tên hoặc các đặc tính khác của đối tượng bằng cách thiết lập tập nhãn tương ứng ví dụ $\{Mai, Tạ, Cường, \dots\}$ để định danh cho

3459 đối tượng mặt người, $\{Happy, Sad, Afraid, \dots\}$ để mô tả biểu cảm của khuôn mặt
3460 người.


3461 Để xác định được đối tượng ở mọi vị trí, kích thước và góc quay, mọi cửa sổ
3462 $W(p_1, p_2)$ cần được xem xét và dẫn đến chi phí tính toán rất lớn để duyệt trên toàn
3463 bộ không gian tham số. Do đó một số phương án giảm không gian tìm kiếm được
3464 đề xuất.

3465 4.5.5.1. Phát hiện đối tượng bằng cửa sổ trượt trong kim tự tháp ảnh

3466 Kim tự tháp ảnh (image pyramid) được tạo ra bởi nhiều phiên bản với độ phân
3467 giải khác nhau của ảnh đầu vào I :

$$3468 \quad I_s = \text{resize}\left(I * G_{\frac{s}{2}}, s\right), \quad (4.118)$$

3469 trong đó s là tỉ lệ co giãn ảnh, $G_{\frac{s}{2}}$ là Gaussian với $\sigma = \frac{s}{2}$ để loại bỏ các tần số cao trong
3470 ảnh tránh alias. Tùy thuộc vào ứng dụng mà người sử dụng có thể lựa chọn các giá
3471 trị s khác nhau.



3472

3473 Hình 4.60. Cửa sổ trượt trong kim tự tháp ảnh.


3474 Hình 4.60 trực quan hóa kim tự tháp ảnh với các tỷ lệ 0, 1 và 2. Cửa sổ có kích
3475 thước cố định $W(p_1, p_2)$ trượt ở các vị trí ảnh ở mỗi tỉ lệ s . Giá trị s nhỏ giúp phát
3476 hiện và nhận dạng các đối tượng có kích thước lớn và giá trị s lớn giúp phát hiện
3477 các đối tượng có kích thước nhỏ.

3478 Có thể thấy kích thước cửa sổ $W(p_1, p_2)$ cố định giúp cho việc thiết kế bộ trích
3479 chọn đặc trưng hoạt động ổn định hơn nhờ chuẩn hóa được kích thước ảnh của bộ
3480 dữ liệu huấn luyện.

3481 4.5.5.2. Phát hiện vùng nổi bật (salient)

3482 Mục tiêu của phát hiện vùng nổi bật là xác định những khu vực trong ảnh mà
3483 người quan sát thường tập trung nhờ đó có thể giảm được không gian tìm kiếm đối

3484 tượng. Phương pháp (Itti 1998) là một trong những đề xuất để phát hiện vùng nổi
 3485 bật dựa vào mô phỏng thị giác người với giả định rằng con người thường tập trung
 3486 vào những điểm khác biệt rõ rệt so với vùng xung quanh.



3487

3488

Hình 4.61. Lưu đồ phương pháp phát hiện vùng nổi bật.

3489

3490

Hình 4.61 trình bày lưu đồ phương pháp phát hiện vùng nổi bật dựa trên mô phỏng thị giác người. Với các thành phần được diễn giải như sau:

3491

1. Đầu vào là một ảnh màu, Hình 4.62 (a).

3492

2. Tách các thành phần màu R (red), G (green) và B (blue) đồng thời chuẩn hóa.

3493

3494

3. Tính thành phần độ sáng I là trung bình cộng của 3 thành phần màu, Hình 4.62 (b).

3495

3496

3497

4. Tính các thành phần màu đối lập RG (red-green, Hình 4.62 (c), và BY (blue-yellow, Hình 4.62 (d)) mô phỏng chức năng phân tách độ sáng/sắc độ của thị giác người (xem mục 2.3.2).

5-6. Tạo kim tự tháp ảnh cho I , RG và BY (xem mục 4.5.2.1) với 9 giá trị tỉ lệ $s = [0,1, \dots, 8]$ để mô phỏng tế bào thị giác vùng V1. Thị giác người có các tế bào nhạy với vùng nhỏ (fine detail), vùng trung bình và vùng lớn (coarse structure). Tương ứng với các mức tỉ lệ của kim tự tháp ảnh, với tỉ lệ nhỏ ($s = 0$), ảnh có độ phân giải cao chứa nhiều chi tiết nhỏ, với tỉ lệ lớn ($s = 8$), ảnh rất mờ chỉ còn chứa các vùng lớn.

7. Lọc Gabor cho 4 hướng ($0^\circ, 45^\circ, 90^\circ, 135^\circ$) để mô phỏng độ nhạy theo hướng của thị giác người (xem mục 2.3.3). Trong vùng V1, có những tế bào nhạy với các hướng khác nhau của cạnh (edge) hoặc của thanh (bar). Lọc Gabor giúp làm nổi bật vùng theo một hướng cụ thể. Ví dụ hướng 0° làm nổi bật vùng có cạnh ngang và hướng 90° làm nổi bật vùng có cạnh dọc.


8-9-10. Mô phỏng phản ứng (response) trường cảm thụ (receptive field) trong thị giác người (xem mục 2.3.1) bằng việc trừ ảnh ở các tầng khác nhau trong kim tự tháp ảnh:

$$CS(c, s) = |I_c - I_s| \uparrow. \quad (4.119)$$

Trong đó ký hiệu $\uparrow$ để tăng độ phân giải của I_s bằng với độ phân giải của I_c để phép thực hiện phép trừ. Cặp (c, s) để mô phỏng vùng *center* và *surround* của trường cảm thụ (receptive field): (2,5) và (2,6) làm nổi bật cạnh nhỏ (tần số cao); (3,6) và (3,7) làm nổi bật cạnh trung bình; và (4,7) và (4,8) làm nổi bật cạnh lớn (tần số thấp). O_{bar} (Hình 4.62 (e)) được tổng hợp cho 4 hướng bộ lọc Gabor trên ảnh kim tự tháp I , I_{bar} (Hình 4.62 (f)) tổng hợp trên ảnh kim tự tháp I và C_{bar} (Hình 4.62 (g)) tổng hợp ảnh kim tự tháp của RG và BY .

11. Cuối cùng, bản đồ vùng nổi bật (salient map, Hình 4.62 (h)) được tạo ra bằng cách kết hợp các phản ứng (response) của hướng O_{bar} , độ sáng I_{bar} và màu sắc C_{bar} . Phủ vùng nổi bật lên ảnh gốc sử dụng bản đồ nhiệt ta được Hình 4.62 (i) và tách ngưỡng để tạo ảnh nhị phân thu hẹp vùng tìm kiếm và phát hiện đối tượng được Hình 4.62 (j).

Phương pháp phát hiện vùng nổi bật của Itti mô phỏng khá tốt một số chức năng của thị giác người như đa tỉ lệ, center/surround của trường cảm thụ, phân biệt cạnh và hướng các cạnh giúp thu hẹp đáng kể không gian cần tìm kiếm và phát hiện đối tượng.



Hình 4.62. Các kết quả phương pháp phát hiện vùng nổi của Itti.

4.5.6. Tái tạo cấu trúc 3D


Nguyên lý cơ bản của tái tạo 3D từ ảnh là việc sử dụng một hoặc nhiều ảnh 2D để ước lượng cấu trúc hình học 3D của cảnh. Các điểm trong không gian 3 chiều đồng thời xuất hiện ở nhiều ảnh ở cho phép ước lượng được khoảng cách từ các camera tới các điểm ảnh đó. Tham khảo mục 3.4 để nắm được các lý thuyết căn bản về các mô hình camera.

Tùy thuộc vào cấu hình hệ thống chụp ảnh mà các kỹ thuật tái tạo cấu trúc 3D có thể khác nhau, nhưng chúng đều có chung một luồng xử lý:

1. Phát hiện điểm đặc trưng (ví dụ SIFT).
2. So khớp điểm đặc trưng.
3. Ước lượng tham số camera.
4. Ước lượng độ sâu.
5. Tái tạo cấu trúc 3D của cảnh.

3545 4.5.6.1. Tái tạo 3D từ ảnh stereo


3546 **Mục 3.4.4.2** đề cập tới cấu hình của stereo camera, trong đó các trục của hai
 3547 thấu kính camera được đặt song song với nhau và có tâm cách nhau một khoảng B
 3548 (baseline). Hình 4.63 là một ví dụ cặp ảnh stereo trong đó (a) là ảnh bên trái I_L , (b)
 3549 là ảnh bên phải I_R . Quan sát cho thấy có sự sai khác về vị trí của các đối tượng trong
 3550 ảnh (lọ hoa, ghế gỗ, tủ, ...) theo chiều ngang (trục x của hai thấu kính).



Hình 4.63. Cặp ảnh stereo: (a) là ảnh trái, (b) là ảnh phải.

Công thức (3.23) cho biết cách tính độ sâu Z (trong hệ quy chiếu của thấu kính bên trái) của một điểm P trong cảnh 3D. Độ sâu này tỉ lệ nghịch với thị sai (disparity) của cặp điểm trên ảnh stereo. Do đó, cấu trúc 3D của cảnh có thể được tái tạo thông qua thị sai. Ở đây ta đề cập đến hai phương pháp ước lượng thị sai sử dụng đặc trưng SIFT và sử dụng so khớp khối (block matching).


A) Ước lượng thị sai sử dụng đặc trưng SIFT



Hình 4.64. Các đặc trưng SIFT khớp được giữa hai ảnh.

Hình 4.64 cho thấy kết quả so khớp các điểm đặc trưng sử dụng bộ mô tả SIFT (xem thêm mục 4.5.3. Căn chỉnh ảnh). Trong đó, các đường thẳng ngang nối một cặp điểm giữa hai ảnh cho biết cặp điểm đặc trưng SIFT được so khớp. Do ảnh stereo đã được nắn chỉnh theo trục y nên cặp điểm chỉ khác nhau tọa độ theo trục x. Sai khác này là giá trị thị sai của cặp điểm.

Hình 4.65 (a) minh họa thị sai của các cặp điểm dưới dạng các vector có gốc là điểm đặc trưng thuộc ảnh trái và mũi tên là điểm đặc trưng được so khớp bên ảnh phải. Trong hình cũng in hai nhãn độ dài của 2 vector 28 px (điểm ảnh) và 43.3 px có màu tương ứng với màu của vector.



Hình 4.65. Cấu trúc 3D: (a) thị sai và (b) độ sâu.

Giả sử các tham số của stereo camera như sau: Baseline $B = 0.065\text{ m}$ (tương tự khoảng cách giữa 2 mắt người) và tiêu cự $f_x = f_y = 230\text{ px}$. Áp dụng công thức tính độ sâu (3.23) ta được độ sâu của từng cặp điểm đặc trưng. Hình 3.65 (b) minh họa một số điểm đặc trưng có giá trị độ sâu được chỉ định bởi thanh màu bên phải.

Phương pháp ước lượng thị sai chỉ cho biết giá trị độ sâu tại những điểm đặc trưng (thường là rất thưa) nên khó sử dụng trong các bài toán thực tiễn. Để ước lượng độ sâu cho nhiều điểm ảnh hơn ta có thể sử dụng kỹ thuật so khớp khối (block matching).


B) Ước lượng thị sai sử dụng so khớp khối

Nếu coi hai ảnh I_L và I_R của ảnh stereo là hai khung hình liên tiếp ta có thể áp dụng kỹ thuật ước lượng chuyển động (mục 4.5.2.1) để tìm vector thị sai tương tự như tìm vector chuyển động. Khi đó, một điểm có thể ước lượng được thị sai bằng cách áp dụng thuật toán Lucas-Kanade (LK). Tuy nhiên, thuật toán LK chỉ có thể ước lượng được thị sai rất nhỏ ($2\text{-}3\text{ px}$) và khi kết hợp với giải thuật kim tự tháp

để tăng độ lớn của thị sai đòi hỏi tài nguyên tính toán rất lớn. Một giải pháp thay thế để ước lượng thị sai là sử dụng so khớp khối.

Khối ảnh (block) là một mảng vuông các điểm ảnh có kích thước $n \times n$. Ký hiệu $B_{x,y}^L$ là khối ảnh thuộc ảnh bên trái ở tọa độ (x,y) , thuật toán so khớp khối cần tìm một khối ảnh $B_{x+\Delta x,y}^R$ sao cho sự sai khác giữa hai khối ảnh là nhỏ nhất. Khi đó giá trị thị sai được xác định bằng công thức sau:

$$d(x,y) = \underset{\Delta x}{\operatorname{argmin}} |B_{x,y}^L - B_{x+\Delta x,y}^R|. \quad (4.12)$$



Hình 4.66. Cấu trúc 3D thu được: (a) ảnh thị sai, (b) ảnh độ sâu.


Hình 4.66 (a) cho thấy kết quả ước lượng thị sai $d(x,y)$ theo công thức trên. Có thể thấy các vùng giá trị thị sai hình dạng các vật thể trong ảnh: nền nhà, ghế gỗ, một nửa lọ hoa và bức tường phía. Mảng đen lớn bên trái là vùng không có thị sai do không có sự giao nhau giữa hai ảnh I_L và I_R . Các vùng màu đen khác cho biết thị sai ở đó không thể ước lượng được do cấu trúc ảnh cục bộ ở đó quá mờ và không đủ chi tiết để đảm bảo độ tin cậy của thị sai. (Tham khảo ma trận cấu trúc trong mục 4.5.2.1).

Hình 4.66 (b) cho thấy kết quả độ sâu của từng điểm ảnh được tính trực tiếp từ các giá trị thị sai (theo cấu hình camera với $B = 0.065 \text{ m}$ và tiêu cự $f_x = f_y = 230 \text{ px}$). Các giá trị độ sâu tạo thành các mảng màu phản ánh cấu trúc 3D của các vật thể trong ảnh. Có thể thấy, ghế và lọ hoa gần với camera hơn phần tường phía sau. Phần nền có độ sâu tăng dần từ dưới lên trên.

Nhược điểm tái tạo 3D từ ảnh stereo là yêu cầu hai camera phải được cấu hình cố định đặc biệt từ trước. Việc này làm tăng chi phí phần cứng cũng như phức tạp khi triển khai ứng dụng thực tiễn. Một cách tiếp cận khả thi hơn đó là khai thác chuỗi ảnh từ duy một camera duy nhất (SfM).

4.5.6.2. Chuỗi ảnh video (structure from motion - SfM)

Kỹ thuật tái tạo 3D từ chuỗi ảnh video (structure from motion – SfM) nhận đầu vào là một đoạn video quay cảnh hoặc một tập hợp nhiều ảnh được chụp cảnh ở các vị trí khác nhau.



Hình 4.67. Các bước chính trong kỹ thuật tái tạo 3D SfM.

Hình 4.67 cho thấy các bước chính trong kỹ thuật tái tạo 3D theo phương pháp SfM. Phương pháp nhận đầu vào là một tập các ảnh hoặc một chuỗi video được chụp hoặc quay từ các hướng khác nhau tới một vật thể hoặc khung cảnh cần tái tạo 3D.

Ký hiệu $\{I_1, I_2, \dots, I_n\}$ là tập gồm n ảnh đầu vào, bộ tham số camera của ảnh I_i là $\mathcal{M}_i = \mathcal{K}_i[\mathbf{R}_i \quad \mathbf{t}_i]$, ma trận Fundamental $\mathbf{F}_{ij}$ và Essential $\mathbf{E}_{ij}$ liên hệ giữa camera của cặp ảnh (I_i, I_j) . Hình 4.68 là ví dụ một tập 3 ảnh trong bộ dữ liệu Middlebury Multiview Stereo dataset (Seitz 2006). Mỗi ảnh được chụp từ một góc khác nhau tới một vật thể có dạng con khủng long để tái tạo mô hình 3D.

Bước 1 - Phát hiện & khớp đặc trưng:

Tương tự như bước 1 và bước 2 trong kỹ thuật tái tạo 3D từ ảnh stereo, ở đây kỹ thuật SIFT có thể được sử dụng để phát hiện, mô tả và so khớp các điểm đặc trưng giữa tất cả các cặp ảnh trong chuỗi ảnh đầu vào. Hình 4.68 hiển thị các đoạn thẳng nối các điểm đặc trưng được so khớp giữa 2 cặp cạnh. Do có sự biến động khá mạnh của góc nhìn, có thể quan sát thấy một số lỗi so khớp.


Bước 2 - Ước lượng ma trận F/E và bộ tham số camera:

Với mỗi cặp ảnh (I_i, I_j) , các ma trận Fundamental $\mathbf{F}_{ij}$ và Essential $\mathbf{E}_{ij}$ được ước lượng sử dụng các cặp điểm đặc trưng đã được so khớp (Tham khảo mục 3.4.4.1) cùng với các bộ tham $\mathcal{M}_i = \mathcal{K}_i[\mathbf{R}_i \quad \mathbf{t}_i]$ của từng ảnh I_i .

Chú ý rằng, nếu bộ ảnh cùng được chụp bởi một camera (chuỗi ảnh động từ video) bộ tham số camera nội là như nhau đối tất cả các ảnh $\mathcal{K}_i = \mathcal{K}$. Bộ tham số ngoại $[\mathbf{R}_i \quad \mathbf{t}_i]$ được xây dựng dựa trên hệ quy chiếu của một ảnh gọi là hệ tọa độ gốc, ví dụ ảnh I_0 . Khi đó ma trận quay $\mathbf{R}_0$ là một ma trận đơn vị và vector tịnh tiến $\mathbf{t}_0$ là vector không, tức là:

$$[R_0 \quad t_0] = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \end{bmatrix}.$$

Chọn cặp ảnh (I_i, I_j) đồng thời có khoảng cách giữa hai tâm (độ dài vector e trong phần 3.4.4.1) và n cặp điểm so khớp $(p_{i,k}, p_{j,k})$. Ở đây, khoảng cách tâm ảnh e lớn và số lượng cặp điểm so khớp n đủ nhiều để giảm nhiễu. Sử dụng công thức (3.17), (3.18) và (3.21) để xác định điểm $P_{i,j,k}$ trong không gian 3 chiều. Chú ý rằng, $P_{i,j,k}$ là một điểm 3D tái tạo được từ một cặp điểm so khớp được của hai ảnh (I_i, I_j) . Tập hợp những điểm 3D này tạo thành một đám mây điểm thô đầu tiên của mô hình 3D: $C = \{P_{i,j,1}, P_{i,j,2}, \dots, P_{i,j,n}\}$ của tập ảnh đã xét $I = \{I_i, I_j\}$. Ràng buộc đám mây điểm C theo hệ quy chiếu toàn cục O duy nhất.



Hình 4.68. Chuỗi ảnh tái tạo 3D.

Bước 3 - Đăng ký các ảnh mới:

Mục tiêu của bước này là mở rộng đám mây điểm C bằng cách xác định một ảnh mới $I_{new} \notin I$ có nhiều điểm đặc trưng khớp với C nhất. Tái tạo các điểm 3D mới và bổ sung vào đám mây điểm $C \leftarrow C \cup \{P_{new,t,1}, P_{new,t,2}, \dots\}$ trong đó t là chỉ số của ảnh thuộc tập đã xét ($I_t \in I$). Sau đó đưa ảnh I_{new} vào tập đã xét $I = I \cup \{I_{new}\}$. Ràng buộc hệ quy chiếu của các điểm 3D mới cùng các tham số camera của ảnh I_{new} theo hệ quy chiếu toàn cục O .

Lặp lại bước này sau khi xử lý hết các ảnh trong tập ảnh đầu vào.

Bước 4 - Tinh chỉnh toàn cục (bundle adjustment):

Sau bước 4, ta thu được đám mây điểm C cùng với các bộ tham số camera $\mathcal{M}_i = \mathcal{K}_i[\mathbf{R}_i \quad \mathbf{t}_i]$ của từng ảnh I_i được ràng buộc về cùng một hệ quy chiếu toàn cục. Ở bước tinh chỉnh toàn cục, tọa độ của các điểm ảnh 3D, các bộ tham số được điều chỉnh sao cho sai số của các phép chiếu là nhỏ nhất.

Sau khi thực hiện bước 2 và bước 3, ta luôn thu được cặp (P_t, p_t) trong đó P_t là điểm 3D thuộc đám mây điểm C được tái tạo từ điểm 2D p_t thuộc ảnh I_i . Sử dụng phép chiếu (3.11) để xác định hình chiếu p'_t của điểm P_t trong ảnh I_i :

$$\begin{bmatrix} p'_t \\ 1 \end{bmatrix} = \begin{bmatrix} x \\ z \\ y \\ z \\ 1 \end{bmatrix} \sim \begin{bmatrix} x \\ y \\ z \end{bmatrix} = \mathcal{K}_i[\mathbf{R}_i \quad \mathbf{t}_i] \begin{bmatrix} P_t \\ 1 \end{bmatrix}.$$

Ta ký hiệu phép chiếu này là $p'_t = \pi(P_t; \mathcal{K}_i, \mathbf{R}_i, \mathbf{t}_i)$, khi đó độ lệch giữa điểm 2D gốc và điểm tái tạo là:

$$\mathbf{p}_t - \pi(\mathbf{P}_t; \mathcal{K}_i, \mathbf{R}_i, \mathbf{t}_i). \quad (4.212)$$

Khi đó các điểm P_t và bộ tham số camera $\mathcal{K}_i, \mathbf{R}_i, \mathbf{t}_i$ cần được điều chỉnh để sai số tổng thể của phép tái tạo 3D là tối thiểu:

$$(\mathbf{P}_t^*, \mathcal{K}_i^*, \mathbf{R}_i^*, \mathbf{t}_i^*) = \arg \min_{\mathbf{P}_t, \mathcal{K}_i, \mathbf{R}_i, \mathbf{t}_i} \sum_t \|\mathbf{p}_t - \pi(\mathbf{P}_t; \mathcal{K}_i, \mathbf{R}_i, \mathbf{t}_i)\|^2. \quad (4.122)$$

Bài toán tối ưu phi tuyến này có thể được giải sử dụng phương pháp Gauss-Newton hoặc Levenberg–Marquardt (Hartley 2004). Chú ý, kỹ thuật tối ưu toàn cục này cũng có thể được sử dụng trong bước 2 và 4 để tối ưu cục bộ khi tái sinh các điểm 3D mới vào đám mây điểm.

Như vậy, sau 4 bước của SfM, với đầu vào là một chuỗi ảnh 2D chụp các góc của một vật thể trong không gian, ta thu được đám mây điểm 3D thưa C cùng với bộ tham số camera của từng ảnh $\mathcal{M}_i = \mathcal{K}_i[\mathbf{R}_i \quad \mathbf{t}_i]$. Để tái tạo được mô hình 3D hoàn chỉnh của vật thể, kỹ thuật tái tạo 3D mật độ cao (Seitz 2006) được sử dụng theo sau SfM.

Kết chương

Chương này đã trình bày một cách hệ thống các phương pháp tiêu biểu của thị giác máy kinh điển, với trọng tâm là biểu diễn và khai thác đặc trưng ảnh nhằm phục vụ các bài toán nhận thức thị giác. Từ việc làm rõ khái niệm đặc trưng ảnh, chương đã đi sâu vào các nhóm đặc trưng quan trọng phản ánh những khía cạnh khác nhau của thông tin thị giác.

Ở mức thấp, các đặc trưng sơ cấp như cạnh, điểm đặc trưng, góc và blob cho phép phát hiện những cấu trúc cơ bản trong ảnh. Trên cơ sở đó, các đặc trưng hình dạng và đặc trưng kết cấu tiếp tục khai thác thông tin ở mức cao hơn thông qua đường bao, moment, mẫu nhị phân cục bộ, ma trận đồng xuất hiện và các bộ lọc

định hướng. Các phương pháp dựa trên gradient như SIFT và HoG thể hiện rõ tư duy kết hợp giữa mô hình toán học và cảm hứng từ thị giác sinh học. Phần cuối của chương đã tổng hợp các bài toán nhận thức thị giác điển hình, bao gồm so khớp mô hình, theo dõi đối tượng, căn chỉnh ảnh, phân loại, phát hiện – nhận dạng và tái tạo cấu trúc 3D. Các bài toán này minh họa cách các đặc trưng thị giác được sử dụng như những khối xây dựng cơ bản cho các hệ thống thị giác máy hoàn chỉnh.

Tổng thể, chương này đặt nền móng quan trọng cho việc hiểu các phương pháp thị giác máy trước thời kỳ học sâu, đồng thời cung cấp cơ sở khái niệm và kỹ thuật để so sánh, đánh giá và tiếp cận các mô hình thị giác máy dựa trên học máy và học sâu sẽ được trình bày trong các chương tiếp theo.

Tài liệu tham khảo

Abu-Mostafa, Y. S., & Psaltis, D. (1984). Recognitive aspects of moment invariants. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 6(6), 698–706. <https://doi.org/10.1109/TPAMI.1984.4767585>

Canny, J. (1986). A computational approach to edge detection. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 8(6), 679–714.* <https://doi.org/10.1109/TPAMI.1986.4767851>

Dalal, N., & Triggs, B. (2005). Histograms of Oriented Gradients for Human Detection. In *Proceedings of the IEEE Computer Society Conference on Computer Vision and Pattern Recognition (CVPR 2005)* (Vol. 1, pp. 886–893). IEEE. <https://doi.org/10.1109/CVPR.2005.177>

Fei-Fei, L., Fergus, R., & Perona, P. (2004). Learning generative visual models from few training examples: An incremental Bayesian approach tested on 101 object categories. *Caltech Technical Report CNS-TR-2004-004*.

Fischler, M. A., & Bolles, R. C. (1981). Random Sample Consensus: A Paradigm for Model Fitting with Applications to Image Analysis and Automated Cartography. *Communications of the ACM*, 24(6), 381–395.

Flusser, J. (2000). On the independence of rotation moment invariants. *Pattern Recognition*, 33(9), 1405–1410.* [https://doi.org/10.1016/S0031-3203\(99\)00167-2](https://doi.org/10.1016/S0031-3203(99)00167-2)

Flusser, J. (2002). On the inverse problem of rotation moment invariants. *Pattern Recognition*, 35(12), 3015–3017.* [https://doi.org/10.1016/S0031-3203\(01\)00232-8](https://doi.org/10.1016/S0031-3203(01)00232-8)

Gabor, D. (1946). Theory of communication. *Journal of the Institution of Electrical Engineers – Part III: Radio and Communication Engineering*, 93(26), 429–457.* <https://doi.org/10.1049/ji-3-1946-0023>

- 3702 Harris, C., & Stephens, M. (1988). A combined corner and edge detector.
3703 Proceedings of the Alvey Vision Conference, 15, 147–151.
3704 <https://doi.org/10.5244/C.2.23>
- 3705 Haralick, R. M., Shanmugam, K., & Dinstein, I. (1973). Textural features for
3706 image classification. IEEE Transactions on Systems, Man, and Cybernetics, SMC-
3707 3(6), 610–621.* <https://doi.org/10.1109/TSMC.1973.4309314>
- 3708 Hart, P. E. (2009). How the Hough transform was invented. IEEE Signal
3709 Processing Magazine, 26(6), 18–22.* <https://doi.org/10.1109/MSP.2009.934181>
- 3710 Hartley, R., & Zisserman, A. (2004). Multiple view geometry in computer
3711 vision (2nd ed.). Cambridge University Press.
- 3712 Heisenberg, W. (1927). Über den anschaulichen Inhalt der
3713 quantentheoretischen Kinematik und Mechanik [On the perceptual content of
3714 quantum theoretical kinematics and mechanics]. Zeitschrift für Physik, 43(3–4),
3715 172–198.* <https://doi.org/10.1007/BF01397280>
- 3716 Hotelling, H. (1933). Analysis of a complex of statistical variables into principal
3717 components. Journal of Educational Psychology, 24(6), 417–441.
- 3718 Hu, M.-K. (1962). Visual pattern recognition by moment invariants. IRE
3719 Transactions on Information Theory, 8(2), 179–187.*
3720 <https://doi.org/10.1109/TIT.1962.1057692>
- 3721 ISO/IEC. (2002). Information technology — Multimedia content description
3722 interface — Part 3: Visual (ISO/IEC 15938-3:2002(E)), Section 11.3. International
3723 Organization for Standardization, Geneva, Switzerland.
- 3724 Itti, L., Koch, C., & Niebur, E. (1998). A model of saliency-based visual
3725 attention for rapid scene analysis. IEEE Transactions on Pattern Analysis and
3726 Machine Intelligence, 20(11), 1254–1259.
- 3727 Jégou, H., Douze, M., Schmid, C., & Pérez, P. (2010). Aggregating local
3728 descriptors into a compact image representation. CVPR.
- 3729 Lazebnik, S., Schmid, C., & Ponce, J. (2006). Beyond bags of features: Spatial
3730 pyramid matching for recognizing natural scene categories. CVPR.
- 3731 Lê, T. H. (2016). Giáo trình Xử lý ảnh. Nhà xuất bản Đại học Quốc gia Hà Nội.
- 3732 Lê, T. H. (2025). Giáo trình Truyền thông đa phương tiện. Nhà xuất bản Đại
3733 học Quốc gia Hà Nội.
- 3734 Lindeberg, T. (1998). Feature detection with automatic scale selection.
3735 International Journal of Computer Vision, 30(2), 79–116.
3736 <https://doi.org/10.1023/A:1008045108935>
- 3737 Long, T. Q., Cuong, T.V. (2025). Giáo trình học máy thống kê. Nhà xuất bản
3738 Đại học Quốc gia Hà Nội.

- 3739 Lowe, D. G. (2004). Distinctive image features from scale-invariant keypoints.
3740 International Journal of Computer Vision, 60(2), 91–110.
3741 <https://doi.org/10.1023/B:VISI.0000029664.99615.94>
- 3742 Lucas, B. D., & Kanade, T. (1981). An Iterative Image Registration Technique
3743 with an Application to Stereo Vision. In Proceedings of the 7th International Joint
3744 Conference on Artificial Intelligence (IJCAI '81), pp. 674–679.
- 3745 Madsen, K., Nielsen, H.B., Tingleff, O. (2004). Methods for Non-Linear Least
3746 Squares Problems (2nd ed.). Technical University of Denmark.
- 3747 Movellan, J. R. (2002). Tutorial on Gabor Filters. University of California, San
3748 Diego, MPLab. Retrieved from <https://mplab.ucsd.edu/tutorials/Gabor.pdf>
- 3749 Neubeck, A., & Van Gool, L. (2006). Efficient non-maximum suppression.
3750 Proceedings of the 18th International Conference on Pattern Recognition (ICPR'06),
3751 3, 850–855.* <https://doi.org/10.1109/ICPR.2006.479>
- 3752 Nguyen, L. T., Do, T. C., Nguyen, B. T., Ta, V. C., & Le, T. H. (2013). Contour-
3753 based hand gesture recognition using depth data. In Proceedings of the
3754 International Conference on Signal and Image Processing (SIP 2013) (pp. 60–64).
3755 Jeju, Korea.
- 3756 Ojala, T., Pietikäinen, M., & Harwood, D. (1996). A comparative study of
3757 texture measures with classification based on feature distributions. Pattern
3758 Recognition, 29(1), 51–59.* [https://doi.org/10.1016/0031-3203\(95\)00067-4](https://doi.org/10.1016/0031-3203(95)00067-4)
- 3759 Perronnin, F., & Dance, C. (2007). Fisher kernels on visual vocabularies for
3760 image categorization. CVPR.
- 3761 Seitz, S. M., Curless, B., Diebel, J., Scharstein, D., & Szeliski, R. (2006). A
3762 comparison and evaluation of multi-view stereo reconstruction algorithms. IEEE
3763 Computer Society Conference on Computer Vision and Pattern Recognition
3764 (CVPR), 1, 519–528.
- 3765 Shi, J., & Tomasi, C. (1993). Good Features to Track. Technical Report TR-93-
3766 1399, Department of Computer Science, Cornell University.
- 3767 Shier, D. R., & Vignaux, G. A. (1988). Adaptive methods for graphing
3768 functions. Brazilian Journal of Probability and Statistics, 2(1), 41–61.*
- 3769 Stein, E. M., & Shakarchi, R. (2007). Fourier analysis: An introduction.
3770 Princeton University Press.
- 3771 Suzuki, S., & Abe, K. (1985). Topological structural analysis of digitized binary
3772 images by border following. Computer Vision, Graphics, and Image Processing,
3773 30(1), 32–46.* [https://doi.org/10.1016/0734-189X\(85\)90016-7](https://doi.org/10.1016/0734-189X(85)90016-7)
- 3774 Szeliski, R. – Computer Vision: Algorithms and Applications, 2nd ed.,
3775 Springer, 2022.

3776 **Bài tập**

3777 1. Hãy thiết kế lại phương pháp tách cạnh Canny giúp nó bất biến với tỉ lệ. Gọi
3778 ý: Thiết kế lại hàm lọc (4.17) sử dụng hàm Signature trong không gian tỉ lệ.

3779

DRAFT


3780

CHƯƠNG 5. THỊ GIÁC MÁY DỰA TRÊN HỌC SÂU

3781 5.1. Giới thiệu học sâu

3782 Trong chương trước, chúng ta đã thấy được nhiều kỹ thuật trích rút thông tin
 3783 từ ảnh, trong đó mỗi lớp lý thuyết được áp dụng dành riêng cho một hoặc một vài
 3784 kỹ thuật nhất định. Các nhà nghiên cứu thị giác máy thời kỳ “kinh điển” thường
 3785 tập trung vào phát triển và tối ưu các mô hình cụ thể như: góc Harris, Hu moments,
 3786 bộ mô tả SIFT, ... và bỏ qua một yếu tố rất quan trọng là dữ liệu ảnh.

3787 Nhận ra tầm quan trọng của dữ liệu ảnh cho các bài toán thị giác máy, Fei-fei
 3788 li và cộng sự đã công bố trong (Deng 2009) một bộ dữ liệu ảnh có quy mô cực lớn
 3789 ImageNet. Bộ dữ liệu bao gồm 14 triệu ảnh được gán nhãn cho 14.000 đối tượng.
 3790 Các ảnh được thu thập từ Internet và được gán nhãn thủ công nhờ các cộng tác viên
 3791 toàn cầu. Sau đó Fei-fei li tiếp tục cùng cộng sự dẫn dắt cuộc thi ILSVRC (ImageNet
 3792 large scale visual recognition challenge) thúc đẩy sự phát triển của thị giác máy như
 3793 các mô hình phân loại ảnh, phát hiện và nhận dạng đối tượng.




3794

3795 Hình 5.1. Kết quả cuộc thi ILSVRC trong 8 năm liên tiếp (Li 2017).

3796 Kết quả cuộc thi trong 8 năm liên tiếp, xem Hình 5.1, cho thấy trong 2 năm đầu
 3797 tiên, các nhóm dự thi đạt vị trí cao nhất sử dụng các kỹ thuật thị giác máy kinh điển
 3798 như Từ điển trực quan (BOVW), vector Fishers cho bài toán phân loại ảnh đạt sai
 3799 số thấp nhất là 25.8%. Kể từ năm 2012, với sự xuất hiện của kiến trúc mạng học sâu
 3800 đầu tiên AlexNet (Alex 2012), sai số phân loại ảnh có một sự cải thiện đáng kể (10%)
 3801 và liên tục giảm cho đến năm 2015 trở đi thì đã xuống dưới sai số nhận dạng ảnh


3802 của con người. Điều đó có nghĩa là lần đầu tiên thị giác máy được ghi nhận vượt
3803 hiệu năng nhận dạng ảnh của con người trên tập ImageNet.



3804
3805 Hình 5.2. Số lượng công trình khoa học công bố liên quan đến mạng học sâu.

3806 Liên quan đến số lượng các công bố khoa học về mạng học sâu (Hình 5.2), ấn
3807 phẩm đầu tiên xuất hiện vào năm 2007, cho đến 2014 số lượng ấn phẩm chưa vượt
3808 quá 100. Kể từ 2015 số lượng ấn phẩm bắt đầu gia tăng mạnh mẽ. Khi đối chiếu với
3809 sự xuất hiện của các kiến trúc mạng học sâu, thời điểm AlexNet xuất hiện làm tăng
3810 tốc lượng bài báo. Khi ResNet vượt khả năng nhận dạng của người (năm 2015), làm
3811 bùng nổ số công bố khoa học về mạng học sâu và thu hút được rất nhiều đầu tư
3812 công nghiệp cho các ứng dụng vào y tế, xe tự hành, robot, ...

3813 5.1.1. Khái niệm học máy



3814
3815 **Hình 5.3. Thị giác máy dựa trên học sâu.**

3816 Hình 5.3 minh họa sự liên quan giữa các khái niệm trong lĩnh vực Trí tuệ nhân
3817 tạo. Trong đó, thị giác máy và học máy là một thành phần của trí tuệ nhân tạo, học
3818 sâu là một phần của học máy.

Các kỹ thuật trích rút đặc trưng ảnh (được trình bày trong chương 3) được thiết kế “thủ công” bằng các công thức/thuật toán tường minh nhằm biến đổi các giá trị ảnh thành các vector đặc trưng có mật độ thông tin lớn hơn. Mỗi kỹ thuật có mục đích sử dụng, ưu điểm, nhược điểm khác nhau. Tùy thuộc vào yêu cầu của từng bài toán thị giác máy mà một hoặc một vài đặc trưng cùng được sử dụng, hiệu chỉnh và tối ưu hóa. Khi một phương pháp trích chọn đặc trưng đã được sử dụng, nó thường gắn chặt với ứng dụng và rất khó thay đổi để thích nghi với các yêu cầu mới, ràng buộc mới, dữ liệu mới.


Học máy (machine learning) là một lĩnh vực của trí tuệ nhân tạo, trong đó thuật toán (máy) tự học ra các quy luật từ dữ liệu thay vì được lập trình một cách tường minh bằng các quy luật cố định. Cụ thể là cần tìm một hàm:

$$f_{\theta}: \mathcal{X} \rightarrow \mathcal{Y}, \quad (5.1)$$

trong đó $\mathcal{X}$ là không gian đầu vào (ví dụ một vùng điểm ảnh), $\mathcal{Y}$ là không gian đầu ra (ví dụ vector đặc trưng hoặc nhãn của ảnh) và θ là bộ trọng số được lựa chọn sao cho tối thiểu hóa sai số dựa trên bộ dữ liệu quan sát được $\{(x_i, y_i) \in \mathcal{X} \times \mathcal{Y}\}_{i=1}^n$ (ví dụ bộ dữ liệu D_{train} trong công thức (1.117)). Quá trình lựa chọn θ để đạt được mục đích này được gọi là huấn luyện.

5.1.2. Mạng neuron nhân tạo

Mạng neuron nhân tạo (artificial neuron network – ANN) là một trong những mô hình học máy được đề xuất từ rất sớm nhằm mô phỏng cách thức hoạt động của mạng neuron não người. Hình 5.4 minh họa mô phỏng neuron sinh học bằng neuron nhân tạo. Một ANN gồm nhiều neuron, được gọi là perceptron, được liên kết thành các cụm/các tầng thông qua các kết nối có trọng số.



Hình 5.4. Minh họa perceptron và neuron sinh học.


5.1.2.1. Cấu trúc mạng neuron nhân tạo

Mạng neuron nhân tạo là một liên kết của nhiều neuron nhân tạo gọi là perceptron (mô phỏng theo neuron sinh học) thông qua các kết nối có trọng số. Một perceptron gồm có thực hiện phép ánh xạ cơ bản nhất trọng mạng ANN:

$$\mathbf{y} = \mathbf{f}(\mathbf{w}^T \mathbf{x} + \mathbf{b}), \quad (5.2)$$

trong đó

- $\mathbf{x} = (x_1, x_2, \dots, x_n)$ là vector đầu vào (input), nó có thể là giá trị các điểm ảnh, là một vector đặc trưng đã được trích chọn từ ảnh hoặc là đầu ra từ các perceptron khác.
- $\mathbf{w} = (w_1, w_2, \dots, w_n)$ là vector trọng số (weight) và giá trị trọng số w_i cho biết độ quan trọng của thành phần x_i của đầu vào.
- $\mathbf{b}$ là độ lệch (bias) giúp dịch chuyển ngưỡng quyết định của hàm kích hoạt.
- $f(\cdot)$ là hàm kích hoạt thiết lập mối quan hệ phi tuyến giữa đầu vào với đầu ra.




Hình 5.5. Một số ví dụ ánh xạ phân lớp của perceptron.

Hình 5.5 cho thấy khả năng phân lớp của một perceptron với vector đầu vào 2 chiều. Dữ liệu đầu vào có thể chia thành 2 lớp (điểm tròn và điểm vuông). Hình (a) (b) và (c) cho thấy với các lựa chọn trọng số w , độ lệch b và hàm kích hoạt, perceptron có thể phân lớp chính xác dữ liệu đầu vào thành hai nửa bằng một đường tuyến tính. Tuy nhiên, ví dụ Hình (d) cho thấy một perceptron không có khả năng phân lớp vì không thể tìm được bộ trọng số và độ lệch nào cho phép tách biệt dữ liệu đầu vào.


Ta có thể kết nối nhiều perceptron bằng cách lấy nối đầu ra của perceptron này thành đầu vào của một perceptron khác, từ đó thiết lập nên một kết nối liên kết nhiều perceptron thành một kiến trúc mạng cụ thể. Ví dụ Hình 5.6 (a) là một mạng của kết nối 3 perceptron tạo thành một kiến trúc 3 tầng:

- Tầng input là vector đầu vào: $\mathbf{x} = (x_1, x_2)$.
- Tầng ẩn: $\mathbf{h}_1 = \mathbf{f}(\mathbf{W}_1^T \mathbf{x} + \mathbf{b}_1)$.
- Tầng output: $\mathbf{y} = \mathbf{f}(\mathbf{W}_2^T \mathbf{h}_1 + \mathbf{b}_2)$.

Với lựa chọn bộ trọng số: $\mathbf{W}_1 = \begin{bmatrix} -2 & 2 \\ -2 & 2 \end{bmatrix}$, $\mathbf{b}_1 = \begin{bmatrix} 3 \\ -1 \end{bmatrix}$, $\mathbf{W}_2 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$ và $\mathbf{b}_2 = [-1]$, ta được kết quả phân lớp phi tuyến có thể được thấy trong Hình 5.6 (b).



Hình 5.6. Phân lớp phi tuyến sử dụng mạng nơron.



Hình 5.7. Mạng neuron đa tầng.

Mạng neuron đa tầng cho phép biểu diễn mối quan hệ phi tuyến phức tạp giữa đầu vào và đầu ra của mạng. Hình 5.7 cho thấy thông tin được truyền theo cấu trúc phân cấp từ tầng input, lần lượt qua từng tầng ẩn rồi tới tầng output. Cấu trúc phân cấp này cho phép mạng chỉ giữ lại các thông tin quan trọng, loại bỏ nhiễu và các chi tiết không cần thiết. Với mạng có L tầng, đầu tiên là đầu vào (input), tiếp theo là các tầng ẩn và tầng cuối cùng là tầng đầu ra (output). Tầng ẩn đầu tiên được tính như sau:

$$\mathbf{h}_1 = \mathbf{f}(\mathbf{W}_1 \mathbf{x} + \mathbf{b}_1), \quad (5.3)$$

tầng thứ $l > 1$ được tính như sau:

$$\mathbf{h}_l = \mathbf{f}(\mathbf{W}_l \mathbf{h}_{l-1} + \mathbf{b}_l) \quad (5.4)$$

và tầng output được định nghĩa là tầng thứ L và được tính truy ngược từ input như sau:

$$\mathbf{y} = \mathbf{f}(\mathbf{W}_L \mathbf{h}_{L-1} + \mathbf{b}_L). \quad (5.5)$$

Lúc này mạng đa tầng là một ánh xạ theo định nghĩa của một hàm học máy f_θ (xem công thức (5.1)) có bộ trọng số:




3895
$$\theta = \{(\mathbf{W}_l, \mathbf{b}_l)\}_{l=1}^L. \tag{5.6}$$






3896 Mạng neuron đa tầng không chỉ là nhiều perceptron ghép lại, mà là một cơ
3897 chế học biểu diễn phân cấp, trong đó mỗi tầng dần loại bỏ thông tin không liên quan
3898 khỏi dữ liệu đầu vào và giữ lại cấu trúc cần thiết cho thông tin đầu ra.

3899 Một điểm quan trọng cần lưu ý là *hàm kích hoạt* (activation function) $f(\cdot)$ là một
3900 thành phần bắt buộc trong một mạng neuron đa tầng vì nếu không có nó, dù có bao
3901 nhiêu tầng đi chăng nữa, toàn bộ mạng cũng chỉ là một ánh xạ tuyến tính. Hàm kích
3902 hoạt cho phép mạng neuron nhân tạo có thể xấp xỉ một hàm phi tuyến bất kỳ
3903 (Hornik 1989).

3904 Bảng 5.1 liệt kê một số hàm kích hoạt thường được sử dụng cho một số bài
3905 toán thị giác máy dựa trên mạng học sâu. Người đọc cũng có thể tham khảo tài liệu
3906 (Kunc 2024) tổng hợp và hệ thống hóa hơn 400 hàm kích hoạt đã được đề xuất cho
3907 nhiều bài toán học máy khác nhau.

3908 Bảng 5.1. Một số hàm kích hoạt thường thấy trong thị giác máy học sâu.

STT	Hàm kích hoạt $f(\cdot)$	Hình trực quan	Mục đích
1	$Sigmoid(x) = \frac{1}{1+e^{-x}}$		Diễn giải xác suất và cho bài toán phân loại nhị phân.
2	$tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}$		Mô tả đặc trưng có dấu trong các mạng CNN/MLP trước đây.
3	$Softmax(x_i) = \frac{e^{x_i}}{\sum e^{x_i}}$		Đưa ra phân phối xác suất giữa các lớp ở tầng output giúp phân loại lớp.

4	$ReLU(x) = \max(0, x)$		Mô tả các đặc trưng thừa trong các mạng CNN chuẩn.
5	$LeakyReLU(x) = \begin{cases} x, & x > 0 \\ \alpha x, & x \leq 0 \end{cases}$		Tránh các neuron chết (đầu ra luôn bằng 0) trong các mạng GAN và GAN và Detector.
6	$ELU(x) = x.Sigmoid(x)$		Hỗ trợ hội tụ tốt cho các mạng AE và CNN.
7	$GELU(x) = x.\Phi(x)$, trong đó $\Phi(x)$ là phân bố tích lũy (CDF) của Gaussian.		Tạo ra các xác suất kích hoạt trong mạng ViT
8	$Swish(x) = x.Sigmoid(x)$		Làm mượt hiệu quả các đặc trưng trong mạng EfficientNet

3909

3910

5.1.2.2. Hàm mất mát

Hàm mất mát (loss function) là cơ chế để điều khiển toàn bộ quá trình huấn luyện mạng neuron nhân tạo. Nói cách khác, việc huấn luyện mạng neuron là quá trình giải bài toán tối ưu với hàm mục tiêu là hàm mất mát trong không gian trọng số. Một mạng được huấn luyện khi lựa chọn được bộ tham số:

$$\theta^* = \arg \min_{\theta} \mathcal{L}(f_{\theta}(X), Y). \quad (5.7)$$

Trong đó:

- $\mathcal{L}(f_{\theta}(X), Y)$ là hàm mất mát.
- (X, Y) là bộ dữ liệu huấn luyện:


$$(X, Y) = \mathbf{D}_{train} = \{(x_i, y_i)\}_{i=1}^n. \quad (5.8)$$

- θ là bộ trọng số của mạng.
- $f_{\theta}(\cdot)$ là mô hình mạng dự đoán đầu ra dựa trên bộ trọng số.

Hiệu năng dự đoán của một mạng không chỉ hoạt động tốt cho những điểm quan sát được (trong bộ dữ liệu huấn luyện), mà nó phải có khả năng khái quát hóa cho những điểm chưa quan sát được (nằm ngoài bộ dữ liệu huấn luyện). Có hai vấn đề chính dẫn đến khả năng khái quát kém của một mạng là underfit và overfit.

Underfit được nhắc đến khi mạng chưa đủ khả năng để nắm được quy luật của dữ liệu (ngay cả trong tập huấn luyện). Vấn đề này xuất hiện khi mạng quá đơn giản, bộ trọng số của mạng quá yếu để giúp mô hình dự đoán.

Overfit được nhắc đến khi mạng có khả năng mô tả quá tốt các quy luật của dữ liệu trong bộ huấn luyện (học cả những bất thường và nhiễu trong dữ liệu huấn luyện), nhưng không tốt với dữ liệu nằm ngoài tập huấn luyện. Vấn đề này xuất hiện khi cấu trúc mạng quá phức tạp, bộ trọng số của mạng quá mạnh làm giảm khả năng khái quát hóa của mạng.



Hình 5.8. Ví dụ trực quan về Underfit, Overfit.

Do đó, hàm mất mát được thiết kế để cân bằng giữa khả năng dự đoán của mạng trong tập dữ liệu huấn luyện cùng với khả năng khái quát hóa thông qua độ phức tạp của bộ trọng số thông qua một cơ chế gọi là regularization như sau:

$$\mathcal{L}(\theta) = \mathcal{L}_D(\theta) + \lambda R(\theta). \quad (5.9)$$

Trong đó:

- $\mathcal{L}_D(\theta)$ đo sai số trung bình giữa giá trị dự đoán của mô hình với giá trị trong dữ liệu huấn luyện được định nghĩa như sau:

$$\mathcal{L}_D(\theta) = \frac{1}{n} \sum_{i=1}^n \mathcal{L}_D(f_\theta(x_i), y_i). \quad (5.10)$$

Chú ý rằng, $\mathcal{L}_D(\theta)$ chỉ được đo trên bộ dữ liệu huấn luyện và chỉ phản ánh được khả năng dự đoán của mô hình trong bộ dữ liệu huấn luyện. Một số độ đo thường thấy có thể sử dụng cho $\mathcal{L}_D(\theta)$ là Cross-entropy, MSE, ...

- $R(\theta)$ đo độ phức tạp của mạng thông qua bộ trọng số θ , điều này gián tiếp đo khả năng khái quát hóa của mạng để sao cho bộ trọng số không quá đơn giản và cũng không quá phức tạp nhằm tránh underfit và overfit.
 - o Chuẩn L1 $R(\theta) = \sum_i |w_i|$: làm thưa bộ trọng số, tức là sẽ có nhiều trọng số bằng 0. Hay không có kết nối giữa các neuron.
 - o Chuẩn L2 $R(\theta) = \sum_i w_i^2$: làm trọng số có giá trị nhỏ (nhưng khác 0) làm cho độ lệch trọng số giảm giúp mô hình hoạt động mượt hơn.
- λ là hệ số đánh đổi (trade-off) giữa hiệu năng của mạng trong bộ dữ liệu huấn luyện $\mathcal{L}_D(\theta)$ và khả năng khái quát hóa $R(\theta)$. Khi λ lớn hàm mất mát phạt độ phức tạp mạng mạnh hơn khiến mô hình đơn giản hơn dẫn tới underfit, với λ nhỏ hàm mất mát phạt sai số dự đoán mạnh hơn khiến mô hình dự đoán tốt hơn đối với dữ liệu huấn luyện dẫn tới overfit. Tùy thuộc vào đặc điểm của dữ liệu, lựa chọn hệ số λ phù hợp cho phép mạng học hiệu quả và có tính khái quát tốt.

5.1.2.3. Tối ưu huấn luyện


A) Gradient decent

Như đã đề cập ở phần trước, huấn luyện mạng là quá trình giải bài toán tối ưu (5.7). Phương pháp cơ bản nhất để giải bài toán tối ưu này là GD (gradient decent), trong đó trọng số θ_{t+1} (ở bước $t + 1$) được điều chỉnh dựa vào gradient của hàm mất mát được tính trên bộ trọng số θ_t (ở bước t) với công thức tổng quát như sau:

$$\theta_{t+1} = \theta_t - \eta \nabla_{\theta} \mathcal{L}(\theta_t), \quad (5.11)$$

trong đó $\nabla_{\theta} \mathcal{L}(\theta_t)$ là gradient của hàm mất mát theo θ và η là tốc độ học (learning rate).

Quá trình huấn luyện mạng neuron được thực hiện với một bộ dữ liệu huấn luyện $(\mathbf{X}, \mathbf{Y})$. Ở mỗi bước thứ t , dữ liệu đầu vào X được tính lan truyền từ tầng thấp nhất đến tầng cao nhất của mạng để tạo ra một dự đoán $\hat{Y}_t$ (được gọi là lan truyền xuôi), xem công thức (5.3), (5.4) và (5.5). Sau đó, hàm mất mát $\mathcal{L}(\theta_t)$ được tính dựa trên công thức (5.9). Mục tiêu của huấn luyện mạng là hiệu chỉnh bộ trọng số θ_t với mục tiêu giảm được giá trị hàm mất mát $\mathcal{L}(\theta_t)$ bằng cách áp dụng công thức (5.11). Ở đây, thuật toán *lan truyền ngược tham số* (backprop) (Rumelhart 1986) được sử dụng để chỉnh sửa ma trận trọng số $\mathbf{W}_l$ và $\mathbf{b}_l$ lần lượt từ tầng output ($l = L$) ngược trở về tầng ẩn thứ nhất ($l = 1$).



Hình 5.9. Quỹ đạo bộ trọng số được điều chỉnh theo các bước lặp t .

Hình 5.9 trực quan hóa quá trình cập nhật trọng số theo các phương pháp tối ưu huấn luyện. Do gradient được tính trên toàn bộ tập dữ liệu huấn luyện nên quỹ đạo đường GD mượt và chậm chạp (khoảng cách giữa các bước t là rất nhỏ).

B) Stochastic gradient decent (SGD)

Nhược điểm của phương pháp huấn luyện GD là tốc độ phụ thuộc kích thước bộ dữ liệu huấn luyện. Khi huấn luyện các mạng học sâu với bộ dữ liệu huấn luyện có kích thước lớn đòi hỏi tài nguyên tính toán rất lớn do số lần phải tính lan truyền xuôi bằng với số lượng mẫu trong bộ dữ liệu huấn luyện. Để giải quyết vấn đề này, kỹ thuật SGD (stochastic gradient decent) thực hiện cập nhật trọng số ở bước thứ t bằng việc ước lượng gradient từ một mẫu hoặc một tập nhỏ các mẫu (mini-batch) lấy ngẫu nhiên từ tập huấn luyện $B_t \subset D_{train}$:

$$\theta_{t+1} = \theta_t - \eta g_t, \quad (5.11)$$

với

$$g_t = \nabla_{\theta} \mathcal{L}_{B_t}(\theta_t) \quad (5.12)$$

là gradient của hàm mất mát được tính trên bộ dữ liệu huấn luyện B_t .

Kích thước của B_t nhỏ làm giảm đáng kể tài nguyên tính toán nhưng tiềm ẩn chứa nhiều với cường độ lớn khiến bước gradient dài và dao động mạnh. Có thể thấy trong Hình 5.9, quỹ đạo SGD dao động với những bước gradient dài và đuổi kịp GD với số bước t thấp hơn nhiều.

4004 C) SGD với động lượng (momentum)

4005 Các bước nhảy zig-zag của SGD dễ bị khóa vào hai sườn dốc của một rãnh cực
4006 trị. Mặc dù mỗi bước gradient đều lớn chuyển qua lại giữa hai sườn dốc nhưng quỹ
4007 đạo tiến tới điểm cực trị lại rất chậm. Do đó, cơ chế động lượng (momentum) được
4008 bổ sung hỗ trợ SGD nhằm tích lũy gradient theo thời gian để giảm dao động và tăng
4009 tốc theo hướng ổn định, trong đó vận tốc ở bước đầu tiên $v_0 = 0$ và tại bước $t > 0$
4010 được cập nhật như sau:

$$4011 \quad v_t = \mu v_{t-1} + g_t. \quad (5.13)$$

4012 Ở đây, gradient $\nabla_{\theta} \mathcal{L}_{B_t}(\theta_t)$ đóng vai trò như lực gia tăng thêm cho vận tốc và μ
4013 đóng vai trò như quán tính của vận tốc ở bước $t - 1$. Với μ lớn khả năng duy trì
4014 theo vận tốc lớn (khó đổi hướng) và μ nhỏ dễ bị tác động bởi lực gradient mới.
4015 Thường chọn $\mu = 0.9$.

4016 Sau đó, trọng số được cập nhật theo vận tốc:

$$4017 \quad \theta_{t+1} = \theta_t - \eta v_t. \quad (5.14)$$

4018 Hình 5.9 miêu tả quỹ đạo SGD với động lượng với các bước gradient rất lớn
4019 được định hướng bởi vận tốc v_t ở mỗi bước nhanh chóng thoát ra khỏi rãnh cực trị.
4020 SGD hiện đang được sử dụng nhiều

4021

4022 D) Adam (adaptive moment estimation)

4023 Phương pháp tối ưu huấn luyện Adam ước lượng đồng thời moment bậc 1 và
4024 bậc 2 của gradient để tạo ra hướng cập nhật thích nghi theo từng thành phần của
4025 bộ trọng số.

4026 Moment bậc 1:

$$4027 \quad m_{1,t} = \beta_1 m_{1,t-1} + (1 - \beta_1) g_t \quad (5.15)$$

4028 tương đương với vận tốc v_t trong (5.13) và hệ số β_1 (thường chọn $\beta_1 = 0.9$) cho biết
4029 khả năng “nhớ” gradient trong quá khứ.

4030 Moment bậc 2:

$$4031 \quad m_{2,t} = \beta_2 m_{2,t-1} + (1 - \beta_2) g_t^2 \quad (5.15)$$

4032 ước lượng được độ biến theo từng chiều của gradient và hệ số β_2 (thường chọn $\beta_2 =$
4033 0.999) để làm mượt mạnh gradient bậc 2 (Kingma 2015).

4034 Do các giá trị khởi tạo $m_{1,0} = m_{2,0} = 0$ dẫn đến các moment này bị thiên lệch về 0 ở
4035 các bước t có giá trị nhỏ, do đó cần hiệu chỉnh độ lệch này theo thời gian đảm bảo
4036 chúng phản ánh đúng kỳ vọng của gradient ở ngay thời kỳ đầu của quá trình huấn
4037 luyện:

$$4038 \quad \hat{m}_{1,t} = \frac{m_{1,t}}{1 - \beta_1^t} \text{ và } \hat{m}_{2,t} = \frac{m_{2,t}}{1 - \beta_2^t} \quad (5.16)$$

với các bước $t \geq 1$.

Cuối cùng, bộ trọng số được cập nhật như sau:

$$\theta_{t+1} = \theta_t - \eta \frac{\hat{m}_{1,t}}{\sqrt{\hat{m}_{2,t} + \epsilon}}, \quad (5.14)$$

trong đó thường chọn $\epsilon = 10^{-8}$ để tránh chia cho 0. Ở đây, phép chia cho $\sqrt{\hat{m}_{2,t}}$ giúp xác lập tốc độ học theo từng chiều (giảm bước ở chiều có độ dốc lớn, và tăng bước ở chiều phẳng).

Hình 5.9 cho thấy quỹ đạo của Adam rất mượt khi so sánh với SGD và có thể tiếp cận tới điểm cực trị nhanh hơn.

E) AdamW (Adam với suy giảm trọng số - Adam with decoupled weight decay)

Suy giảm trọng số (weight decay) đóng vai trò quan trọng quá trình huấn luyện trong việc kết hợp với kỹ thuật regularization để ưu tiên các bộ trọng số của mạng có tính đơn giản (5.9). Tuy nhiên, công thức cập nhật trọng số của Adam (5.14) gộp cả thành phần làm suy giảm trọng số trong $\hat{m}_{1,t}$ để phân phối phụ thuộc vào các hướng chiếm ưu thế trong $\sqrt{\hat{m}_{2,t}}$, do đó mất ý nghĩa của kỹ thuật suy giảm trọng số. Do đó, AdamW (Loshchilov 2019) khắc phục điều này bằng cách tách riêng thành phần suy giảm trọng số khỏi quá trình ước lượng moment.

Bộ trọng số được cập nhật theo AdamW như sau:

$$\theta_{t+1} = \theta_t - \eta \frac{\hat{m}_{1,t}}{\sqrt{\hat{m}_{2,t} + \epsilon}} - \eta \lambda \theta_t. \quad (5.15)$$

Có thể thấy trong Hình 5.9, so với Adam, AdamW có thêm thành phần suy giảm trọng số tách rời, nên quỹ đạo không chỉ theo gradient mà còn bị “kéo” về vùng tham số nhỏ hơn, giúp hội tụ ổn định và tổng quát hóa tốt hơn.

5.1.3. Khái niệm học sâu


Học sâu (deep learning) là một bộ phận của học máy (Hình 5.3) mà không đơn thuần ám chỉ việc sử dụng mạng neuron nhiều tầng, mà còn phản ánh cách học biểu diễn tri thức thông qua nhiều mức trừu tượng khác nhau. Mỗi tầng mạng, đóng vai trò như một cách tái biểu diễn: dữ liệu dưới dạng ảnh thô từ đầu vào được truyền tuần tự qua các lớp mạng, các đặc trưng dần dần được trích xuất, khái quát và tiến gần đến các khái niệm có ý nghĩa đối với bài toán cần giải quyết. Khác với việc trích xuất các đặc trưng từ ảnh được thiết kế bởi con người như được trình bày ở Chương 4, trong mạng học sâu, kiến trúc các tầng mạng cho phép nó tự học cách trích rút các đặc trưng cần thiết cho bài toán từ dữ liệu huấn luyện và được chỉ dẫn bởi phương pháp huấn luyện mạng.

5.2. Mạng neuron sâu

5.2.1. Mạng tích chập (convolutional neuron network - CNN)

Ý tưởng đầu tiên sử dụng mạng neuron tích chập nhiều tầng cho thị giác máy xuất hiện từ lâu như Neocognitron (Fugushima 1981) với 6 tầng, tác giả đã tìm cách tự tay thiết kế các bộ trọng số nhằm mô phỏng nhận thức thị giác người. Ý tưởng tiếp tiếp theo (LeCun 1988) đặt nền móng cho việc sử dụng CNN cùng với thuật toán huấn luyện backprop. Mười năm sau, LeNet-5 (LeCun 1998) xuất hiện, trong đó CNN được mô tả như một thành phần trung tâm cho thị giác máy (bài toán nhận dạng ký tự), đồng thời thảo luận các cách tiếp cận ghép nối các module thực tế trong hệ thống ứng dụng.

5.2.1.1. LeNet (Mạng cổ điển)



Hình 5.10. Mạng LeNet-5 (LeCun 1998).

LeNet-5 được thiết kế nhằm xây dựng một mô hình học sâu để nhận dạng ký tự viết tay thông qua trích rút đặc trưng và phân loại ảnh hoàn toàn dựa trên quá trình học của mạng (thay cho việc trích rút đặc trưng thủ công). Mạng LeNet-5 được coi là mạng học sâu đầu tiên minh chứng được việc học đặc trưng phân cấp từ ảnh là khả thi và hiệu quả được thực hiện trong một mô hình học máy thống nhất.

Hình 5.10 cho thấy kiến trúc mạng LeNet-5 được thiết kế để nhận dạng ký tự chữ viết tay. Tư duy thiết kế mạng theo kiểu liên kết đa tầng (multi layers). Mỗi tầng có thể bao gồm một hoặc nhiều khối chức năng: Khối ảnh đầu vào → nhiều nhóm tích chập (convolution) + lấy mẫu gộp (pooling) → Khối biểu diễn đặc trưng toàn cục → Khối phân loại.

1. Khối đầu vào:

Khối ảnh đầu vào được ký hiệu dưới dạng một tensor:


$$\mathbf{I} \in \mathbb{R}^{N \times H \times W \times C}, \quad (5.16)$$

trong đó N là kích thước batch mỗi lần huấn luyện (xem Mục 5.1.2.3), C là số kênh màu, H và W là kích thước chiều cao và chiều rộng của ảnh. LeNet-5 nhận ảnh 1

4102 kênh màu được chuẩn hóa về kích thước 32×32 nhưng chưa xác định rõ kích thước
 4103 batch cụ thể. Để tiện cho trình bày, ta bỏ qua N trong phần này. Khi đó, tensor ảnh
 4104 đầu vào của LeNet-5 là $I \in \mathbb{R}^{32 \times 32 \times 1}$.

4105


4106 2. Khối C1 – Khối tích chập (convolution) 1



4107

4108 Hình 5.11. Khối tích chập. (Vẽ lại cho đúng với mạng LeNet-5).

4109 Có thể nói, khối tích chập (convolution block) là thành phần cốt lõi của CNN,
 4110 hoạt động giống như cửa sổ lọc tuyến tính trong xử lý ảnh, tham khảo Mục 3.1 trong
 4111 (Lê 2016). Khối này được thiết kế để trích xuất các đặc trưng cục bộ thông qua cửa
 4112 sổ lọc trượt trên toàn bộ không gian ảnh, xem Hình 5.11. Các hệ số của mỗi bộ lọc
 4113 được khởi tạo ngẫu nhiên và được xác định thông qua quá trình huấn luyện mạng.
 4114 Nhờ có cơ chế chia sẻ trọng số, một bộ lọc có thể phát hiện cùng một mẫu đặc trưng
 4115 xuất hiện ở những vị trí khác nhau của ảnh.



4116

4117 Hình 5.12. Trường cảm thụ.

4118 Có sự liên hệ giữa khối tích chập trong CNN với hệ thị giác sinh vật. **Mục 2.3**
 4119 của cuốn giáo trình này đề cập đến một số chức năng của thị giác người trong đó
 4120 cho biết một số tế bào ở phần vỏ não sơ cấp (V1) chỉ phản ứng mạnh với một số kích
 4121 thích có hình dạng hoặc hướng nhất định trong trường cảm thụ (receptive field).
 4122 Các tế bào này được tổ chức theo dạng phân cấp để phát hiện các đặc trưng đơn
 4123 giản ở tầng thấp đến các cấu trúc phức tạp ở tầng cao. Khối tích chập trong các tầng
 4124 của CNN cũng hoạt động tương tự như vậy. Hình 5.12 minh họa tổ chức phân cấp
 4125 của các khối tích chập trong mạng CNN. Các neuron ở tầng sâu hơn (hướng đến

đầu ra output) có trường cảm thụ rộng dần. Đặc trưng cơ bản ở các khối tích chập trước được lựa chọn, biểu diễn ở mức độ trừu tượng ở các tầng sâu.

Về kỹ thuật, khối tích chập được ký hiệu tensor như sau:

$$\mathbf{K} \in \mathbb{R}^{H_k \times W_k \times C_{in} \times C_{out}}, \quad (5.17)$$

trong đó H_k và W_k là kích thước của cửa sổ trượt, C_{in} là số kênh đầu vào và C_{out} số kênh đầu ra. LeNet-5 có hai tầng tích chập. Tầng đầu có kích thước 5×5 nhận đầu vào là 1 kênh của ảnh và đầu ra là 6 kênh đặc trưng $\mathbf{K}_1 \in \mathbb{R}^{5 \times 5 \times 1 \times 6}$.

Biểu diễn đặc trưng (feature map) thu được bằng phép nhân chập tensor ảnh đầu vào với tensor tích chập:

$$\mathbf{F} = \mathbf{I} * \mathbf{K}. \quad (5.18)$$

Biểu diễn đặc trưng $\mathbf{F} \in \mathbb{R}^{N \times H' \times W' \times C}$ có kích thước batch N bằng với tensor ảnh $\mathbf{I}$, số kênh C bằng C_{out} của tensor tích chập $\mathbf{K}$ và có kích thước phụ thuộc vào cách ‘trượt’ của cửa sổ lọc.

Vấn đề biên phát sinh khi áp dụng các bộ lọc cửa sổ trượt kích thước không gian của biểu diễn đặc trưng bị co lại so với kích thước đầu vào. Do đó, người ta thực hiện bù biên (padding) để bổ sung vào phía ngoài điểm đầu vào một lượng p điểm ảnh và điền giá trị 0 hoặc copy giá trị điểm ảnh gần nhất. Hình 5.13 cho thấy bù biên kích thước $p = 1$ điểm ảnh có giá trị bằng 0 vào rìa ngoài của ảnh đầu vào.

0	0	0	0	0	0	0	0	0
0								0
0								0
0								0
0								0
0								0
0								0
0								0
0	0	0	0	0	0	0	0	0

Hình 5.13. Bù biên (padding) và bước trượt (stride). (Vẽ lại để mô tả cho chính xác hơn)

Việc thực hiện nhân chập cũng được bổ sung thêm khái niệm bước trượt (stride) để xác định khoảng dịch chuyển của sổ trên ảnh đầu vào. Tham số stride s này quyết định tần suất lấy mẫu của tích tích chập ảnh hưởng trực tiếp đến kích thước không gian của biểu diễn đặc trưng đầu ra cũng như mức độ chi tiết của đặc trưng được trích chọn. Nếu $s = 1$, cửa sổ trượt qua từng điểm ảnh, lấy mẫu dày và giữ nhiều chi tiết không gian. Nếu $s = 2$, cửa sổ dịch chuyển mỗi lần 2 điểm ảnh, lấy mẫu thưa hơn và ít chi tiết được giữ lại.


Ta có công thức tính kích thước biểu diễn đặc trưng như sau:

$$W' = \frac{W - W_k + 2p}{s} + 1 \text{ và } H' = \frac{H - H_k + 2p}{s} + 1. \quad (5.19)$$

Với LeNet-5, tầng tích chập đầu tiên sử dụng cửa sổ 5×5 , 6 kênh đầu ra, bước trượt $s = 1$ và không sử dụng bù biên. Do đó, tensor của biểu diễn đặc trưng của tầng tích chập này là $F_{C1} \in \mathbb{R}^{28 \times 28 \times 6}$.

3. Khối S1 – Khối lấy mẫu gộp (pooling) 1

Trong CNN, khái niệm lấy mẫu gộp (pooling) làm giảm kích thước ảnh đầu vào hoặc biểu diễn đặc trưng bằng cách gộp thông tin các vùng lân cận. Pooling thường được cài đặt bằng việc kết hợp cửa sổ lọc với các bước trượt (stride) hợp lý. Hình 5.14 minh họa 2 kỹ thuật pooling với cửa sổ trượt là 2×2 và stride $s = 2$. Hình (a) là max pooling 2×2 , $s = 2$ với giá trị đại diện đầu ra cho cửa sổ là giá trị cực đại, Hình (b) là average pooling 2×2 , $s = 2$ với giá trị đại diện đầu ra cho cửa sổ là giá trị trung bình.




Hình 5.14. Lấy mẫu gộp (pooling).

LeNet-5 sử dụng max pooling 2×2 , $s = 2$, do đó biểu diễn đặc trưng sau khi lấy mẫu gộp là $F_{S1} \in \mathbb{R}^{14 \times 14 \times 6}$.

4. Khối C2 – Khối tích chập 2: LeNet-5 sử dụng tensor tích chập $K_2 \in \mathbb{R}^{5 \times 5 \times 6 \times 16}$. Có nghĩa là cửa sổ tích chập có kích thước là 5×5 , số kênh vào $c_{in} = 6$ và số kênh ra $c_{out} = 16$. Với stride $s = 1$, padding $p = 0$, ta có biểu diễn đặc trưng ở tầng này là $F_{C2} \in \mathbb{R}^{10 \times 10 \times 16}$.

5. Khối S2 – Khối lấy mẫu gộp 2: LeNet-5 sử dụng average pooling 2×2 , stride $s = 2$, nên biểu diễn đặc trưng ở tầng này là $F_{S2} \in \mathbb{R}^{5 \times 5 \times 16}$.

- 4181 6. Khối C3 – Khối tích chập 3: LeNet-5 sử dụng tensor tích chập $\mathbf{K}_3 \in \mathbb{R}^{5 \times 5 \times 16 \times 120}$
 4182 để thu được biểu diễn đặc trưng $\mathbf{F}_{C3} \in \mathbb{R}^{1 \times 1 \times 120}$.
 4183
 4184 7. Khối kết nối đầy đủ (Fully connected) 1: Kết nối đầy đủ 120 neuron ở lớp C3 tới
 4185 84 neuron ở tầng này để được biểu diễn đặc trưng $\mathbf{F}_{FC1} \in \mathbb{R}^{1 \times 1 \times 84}$.
 4186
 4187 8. Khối kết nối đầy đủ 2 – đầu ra: Kết nối 84 neuron ở lớp FC1 tới 10 neuron ở tầng
 4188 này sử dụng khoảng cách Gaussian để được biểu diễn đặc trưng $\mathbf{F}_{FC1} \in \mathbb{R}^{1 \times 1 \times 10}$. Số
 4189 10 tương ứng với 10 chữ số cần nhận dạng.



4190

4191

Hình 5.15. Sơ đồ tổng hợp mạng LeNet-5.

4192

4193

4194

4195

Hình 5.15 là sơ đồ tổng hợp diễn giải mạng LeNet-5 trong đó các lớp được xếp chồng từ dưới lên trên. Mỗi lớp được biểu thị bằng một hình chữ nhật bo góc, trong đó dòng text phía trên mô tả phép chuyển đổi từ lớp dưới và dòng text dưới là kích thước của tensor.

4196

4197

4198


4199

4200

Kiến trúc LeNet-5 có lớp ra dùng RBF (Gaussian/radial basic function) để giúp phân loại 10 chữ số viết tay và chưa dùng đến cơ chế Softmax như các mạng CNN sau này. Mạng này được huấn luyện bởi bộ dữ liệu MNIST (LeCun 1998) và kết quả cho thấy tỉ lệ lỗi phân loại rất nhỏ, thấp hơn nhiều so với các thiết kế đặc trưng thủ công khi được thử nghiệm trên cùng bộ dữ liệu.

Do các mạng CNN có tính kế thừa lớp lớn, nên các mạng VGG và ResNet sau này được trình bày dưới dạng sơ đồ tổng quát và chỉ tập trung trình bày chi tiết những lớp mới.

5.2.1.2. VGG (Mạng sâu)



Hình 5.16. Sơ đồ tổng hợp mạng VGG-19.

Kể từ khi AlexNet xuất hiện và chiến thắng tuyệt đối các mô hình thiết kế đặc trưng thủ công khác, học sâu với dữ liệu lớn đã được chứng minh là hướng đi hiệu quả cho các bài toán thị giác máy. Câu hỏi đặt ra là, có phải kiến trúc mạng càng sâu thì mạng càng hoạt động hiệu quả? Và cái giá phải trả cho sự hiệu quả do độ sâu của mạng đem lại là gì?

VGG-16 và VGG-19 (Simonyan 2015) là mạng học sâu do nhóm Visual Geometry Group) của đại học Oxford đề xuất với mục tiêu phân loại ảnh tự nhiên 1000 của bộ dữ liệu ImageNet (Deng 2009) thông qua việc thiết kế tăng cường độ sâu, số kênh hướng tới giải các bài toán thị giác lớn hơn nhiều. Về cơ bản, mặc dù là một kiến trúc mạng sâu hơn với quy mô tham số tham số lớn hơn, nhưng VGG không đưa ra các khái niệm mới mà chỉ mở rộng tư duy thiết kế đã có trong LeNet-5, xem Bảng 5.2.

Bảng 5.2. Cải tiến của VGG-19 so với LeNet-5.


Tiêu chí	LeNet-5 (Hình 5.15)	VGG-19 (Hình 5.16)
Kiến trúc mạng	Mạng nông với 2 lớp tích chập và 2 lớp kết nối đầy đủ. Cấu trúc mạng cố định (hoặc rất khó tùy biến).	Mạng rất sâu với 16 lớp tích chập và 3 lớp kết nối đầy đủ. Cấu trúc mạng uyển chuyển, có thể tăng số lượng các khối lặp tùy ý.
Dung lượng biểu diễn đặc trưng theo độ sâu	Mức độ tăng dung lượng biểu diễn đặc trưng hạn chế: $6 \rightarrow 16 \rightarrow 120$	Mức độ tăng dung lượng biểu diễn đặc trưng có tính hệ thống: $64 \rightarrow 128 \rightarrow 256 \rightarrow 512$
Trường cảm thụ	Sử dụng cửa sổ lọc tích chập 5×5 trong khi số tích chập ít, trường cảm thụ tối đa là 32×32 cho biểu diễn đặc trưng $1 \times 1 \times 120 = 120$ chiều sau đó thu gọn thành 10 lớp khái niệm.	Sử dụng cửa sổ lọc tích chập 3×3 với rất nhiều lớp tích chập liên tiếp, trường cảm thụ tối đa 32×32 cho biểu diễn đặc trưng $7 \times 7 \times 512 = 25088$ chiều sau đó thu gọn thành 1000 lớp khái niệm.
Hàm kích hoạt	Các lớp tích chập đều sử dụng hàm kích hoạt <i>tanh</i> . Mặc dù hàm tanh đưa tính phi tuyến vào mạng, nhưng có nhược điểm lớn là hiện tượng bão hòa dẫn đến mất gradient khiến cho việc huấn luyện mạng học sâu trở nên khó khăn.	Các lớp tích chập đều sử dụng hàm kích hoạt <i>ReLU</i> . Hàm này tuyến tính một phần giúp thuật toán huấn luyện lan truyền ngược qua nhiều tầng hoạt động hiệu quả, giúp huấn luyện mạng rất sâu. Việc tính toán hàm <i>ReLU</i> cũng đơn giản hơn nhiều so với <i>tanh</i> .
Chiến lược huấn luyện	Kỹ thuật huấn luyện đơn giản: - Bộ dữ liệu ảnh nhỏ (~ 60 nghìn mảnh ảnh 28×28). - Cơ chế tăng cường dữ liệu thô sơ. Sử dụng MSE (mean square error) cho khoảng cách Gaussian giữa 10 lớp để phân loại. Thiết kế này yêu cầu các siêu tham số mang tính thủ công như số	Chiến lược huấn luyện có tính hệ thống: - SGD với động lượng (Xem Mục 5.1.2.3). - Bộ dữ liệu ImageNet (~1.28 triệu ảnh $224 \times 224 \times 3$) lớn và cơ chế tăng cường dữ liệu mạnh mẽ. - Sử dụng Softmax để tính xác suất và cross entropy cho hàm mất mát. Hàm mất mát được bổ sung thêm regularization L_2 để điều chỉnh độ phức tạp của bộ

	prototype, vị trí và độ rộng của Gaussian.	trong số và giảm overfit (Xem Mục 5.1.2.2).
Số lượng tham số	Nhỏ: $\sim 6 \times 10^4$ tham số	Cực lớn: $\sim 4.3 \times 10^8$ tham số
Thời gian huấn luyện	Vài giây cho đến 1 phút với cấu hình phần cứng trung bình hiện nay.	1 đến 2 tuần với cấu hình phần cứng RTX/A100.
Thời gian suy luận	$<1ms/ảnh$ với cấu hình phần cứng trung bình hiện nay.	CPU: Vài chục mili giây đến hàng trăm mili giây mỗi ảnh. GPU: Vài mili giây đến vài chục mili giây mỗi ảnh.

Với những cải tiến mạnh mẽ ở nhiều khía cạnh, VGG-19 đã giảm được sai số phân loại ảnh xuống còn 7.3% (Hình 5.1) và vượt rất xa mạng tiền nhiệm AlexNet 16.4% và tiệm cận với thị giác người 5.1%.

Kiến trúc VGG cho thấy chi phí tính toán tăng rất mạnh khi chiều sâu của mạng tăng và kích thước của sổ tích chập cố định (3×3) không phù hợp cho mọi cấu trúc của ảnh. Mặc dù mạng có thể rất sâu (số lớp mạng lên tới hàng trăm), nhưng chỉ có duy nhất 1 đường biến đổi từ đầu vào (ảnh input) đến đầu ra. Mỗi lớp chỉ nhận đầu vào duy nhất từ lớp trước đó. Các đặc trưng chi tiết (điểm, cạnh, ...) trộn lẫn với đặc trưng ngữ cảnh (đối tượng, hình dạng, ...) và bị đánh đổi lẫn nhau dọc theo chiều sâu của mạng và mạng buộc phải lựa chọn ưu tiên chi tiết hay ngữ cảnh và việc lựa chọn này ảnh hưởng trực tiếp tới các lớp tiếp theo.

Bên cạnh đó, các tầng có số lượng kênh lớn (512) được xếp liên tiếp cùng với 3 tầng kết nối đầy đủ ở phía cuối mạng khiến cho độ phức tạp tính toán của mạng trở nên khổng lồ làm tiêu tốn tài nguyên để huấn luyện và sử dụng mạng.



Hình 5.17. Cấu trúc Inception: (a) Inception cơ sở và (b) Inception giảm chiều.

5.2.1.3. GoogLeNet (Mạng rộng)

Các tác giả đã đề xuất trong (Szegedy 2015) một kiến trúc mạng mới cho phép cân bằng chiều sâu và độ rộng của mạng bằng cách để mạng tự lựa chọn kích thước của sổ tích chập theo một cơ chế song song, được gọi là Inception. Cơ chế song song của Inception này cho phép một lớp mạng có thể lựa chọn kích thước lọc nhân chập

phù hợp. Nó cũng cho phép tạo ra rất nhiều chuỗi biến đổi từ đầu vào đến đầu ra của toàn mạng khi nối liên tiếp các Inception với nhau.

A) Cấu trúc Inception

Hình 5.17 (a) là mẫu Inception cơ sở, trong đó lớp tích chập được mở rộng với nhiều loại cửa sổ tích chập khác nhau (1×1 , 3×3 và 5×5). Chúng đều nhận đầu vào từ lớp trước và đầu ra được nối với nhau theo chiều kênh để tạo ra một biểu diễn đặc trưng duy nhất. Ví dụ đầu vào là một biểu diễn đặc trưng dưới dạng tensor $\mathbf{F}_{in} \in \mathbb{R}^{H \times W \times C}$ có C kênh và cùng được xử lý song bởi 4 nhánh: nhánh 1×1 tạo ra C_1 kênh, nhánh 3×3 tạo ra C_3 kênh, nhánh 5×5 tạo ra C_5 kênh và nhánh max pooling tạo ra C_p kênh. Ta có biểu diễn đặc trưng đầu ra $\mathbf{F}_{out} \in \mathbb{R}^{H \times W \times (C_1 + C_3 + C_5 + C_p)}$ có $(C_1 + C_3 + C_5 + C_p)$ kênh.

Cấu trúc Inception cơ sở không được ứng dụng trong thực tiễn do, trong Inception cơ sở, các phép tích chập tác động lên toàn bộ số kênh đầu vào. Ví dụ với biểu diễn đặc trưng đầu vào $\mathbf{F}_{in} \in \mathbb{R}^{H \times W \times C}$, nhánh 5×5 với tensor tích chập $\mathbf{K}_5 \in \mathbb{R}^{H \times W \times C \times C_5}$ yêu cầu độ phức tạp tính toán là

$$\mathcal{O}(5 \times 5 \times H \times W \times C \times C_5)$$

và có số lượng tham số là (bỏ qua bias vì không đáng kể):

$$5 \times 5 \times C \times C_5.$$

Ở các tầng sâu, C thường rất lớn khiến độ phức tạp tính toán tăng rất nhanh. Việc bổ sung thêm các khối tích chập song song càng làm trầm trọng vấn đề khiến mạng không khả thi về tài nguyên và thời gian tính toán. Do đó, cấu trúc Inception giảm chiều (reduced) được đề xuất để giải quyết vấn đề này.

Cấu trúc Inception giảm chiều được trực quan hóa trong Hình 5.17 (b). Trong đó, các khối tích chập 1×1 nối tiếp trước các khối 3×3 và 5×5 . Giả sử khối 1×1 với tensor là $\mathbf{K}_1 \in \mathbb{R}^{H \times W \times C \times C_1}$ nối tiếp trước khối 5×5 với $\mathbf{K}_5 \in \mathbb{R}^{H \times W \times C_1 \times C_5}$. Cả hai khối yêu cầu độ phức tạp tính toán là (floating-point operations - FLOPs):

$$\begin{aligned} &\mathcal{O}(1 \times 1 \times H \times W \times C \times C_1) + \mathcal{O}(5 \times 5 \times H \times W \times C_1 \times C_5) \\ &= \mathcal{O}(H \times W \times C_1 \times (C + 25 \times C_5)) \end{aligned}$$

và có số lượng tham số là (bỏ qua bias vì không đáng kể):

$$(1 \times 1 \times C \times C_1) + (5 \times 5 \times C_1 \times C_5)$$


Tỉ lệ FLOPs là:

$$\frac{H \times W \times C_1 \times (C + 25 \times C_5)}{5 \times 5 \times H \times W \times C \times C_5} = \frac{C_1}{25 \times C_5} + \frac{C_1}{C} \approx \frac{C_1}{C}, \quad (5.20)$$

và tỉ lệ tham số là:

$$\frac{(1 \times 1 \times C \times C_1) + (5 \times 5 \times C_1 \times C_5)}{5 \times 5 \times C \times C_5} = \frac{C_1}{25 \times C_5} + \frac{C_1}{C} \approx \frac{C_1}{C}. \quad (5.21)$$

Điều đó có nghĩa là việc sử dụng khối 1×1 với C_1 kênh giảm cả FLOPs và số lượng tham số đi $\frac{C_1}{C}$ lần. Điều này cho phép khối Inception giảm chiều có thể được sử dụng trong thực tiễn.



(a)

softmax	1×1×1000			
linear	1×1×1000			
dropout (40%)	1×1×1024			
avg pool	1×1×1024			
inception (5b)	7×7×1024			
	384	384	128	128
		192	48	832
inception (5a)	7×7×832			
	256	320	128	128
		160	32	832
max pool	7×7×832			
inception (4e)	14×14×832			
	256	320	128	128
		160	32	528
inception (4d)	14×14×528			
	112	288	64	64
		144	32	512
inception (4c)	14×14×512			
	128	256	64	64
		128	24	512
inception (4b)	14×14×512			
	160	224	64	64
		112	24	512
inception (4a)	14×14×512			
	192	208	48	64
		96	16	480
max pool	14×14×480			
inception (3b)	28×28×480			
	128	192	96	64
		128	32	256
inception (3a)	28×28×256			
	64	128	32	32
		96	16	192
max pool	28×28×192			
convolution	56×56×192			
max pool	56×56×64			
convolution	112×112×64			
image	224×224×3			

Hình 5.18. Kiến trúc mạng GoogLeNet.

B) Kiến trúc mạng GoogLeNet

Hình 5.18 (a) miêu tả cách trình bày một Inception, trong đó khối $H \times W \times C$ biểu thị biểu diễn đặc trưng đầu ra $\mathbf{F}_{out} \in \mathbb{R}^{H \times W \times (C1d+C3+C5+C1)}$, và $C1d$, $C3$, $C5$ và $C1$ là kích thước kênh đầu ra tương ứng của:

+ khối tích chập 1×1 bên trái cùng, xem Hình 5.18 (b), khối này nhận đầu vào trực tiếp từ tầng trước.

+ khối tích chập 3×3 , khối này nhận đầu vào từ khối tích chập 1×1 (C13).


+ khối tích chập 5×5 , khối này nhận đầu vào từ khối tích chập 1×1 (C15).

+ khối tích chập 1×1 bên phải cùng, khối này nhận đầu vào từ khối max pooling (Cp).

Hình 5.19 (b) diễn giải kiến trúc mạng GoogLeNet, trong đó các tầng màu xám (không phải lớp Inception) có chức năng tương tự như các tầng của các mạng VGG và ResNet. Inception màu xanh nhận đầu vào là biểu diễn đặc trưng ở lớp dưới và cho ra biểu diễn đặc trưng cho lớp tiếp theo. Có thể thấy, các Inception tăng dần chiều rộng một cách có kiểm soát tạo sự cân bằng giữa các khối tích chập 1×1 , 3×3 , 5×5 và max pooling bên trong.

Mặc dù GoogLeNet có bổ sung các khối tích chập 1×1 , 3×3 , 5×5 đặt song song trong Inception, nhưng nhờ có các khối tích chập 1×1 được đặt trước các khối này nên FLOPs và kích thước tham số giảm mạnh theo tỉ lệ trong công thức (5.20) và (5.21). Bên cạnh đó, GoogLeNet chỉ sử dụng một tầng kết nối đầy đủ rất nhỏ để phân loại nên mạng tổng thể giảm đáng kể độ phức tạp. So với VGG-19 (143.7 triệu tham số), GoogLeNet chỉ có 6.6 triệu tham số nhưng hiệu năng phân loại ảnh có phần nhỉnh hơn, xem Hình 5.1.

5.2.1.4. ResNet (Mạng sâu có kiểm soát)




Hình 5.19. Vấn đề của mạng học sâu: mạng càng sâu thì tỷ lệ lỗi càng cao trên cả tập huấn luyện và tập kiểm thử (He 2016).

Mặc dù mạng VGG đã trả lời được câu hỏi về tính hiệu quả của mạng khi tăng chiều sâu và độ phức tạp của mạng CNN. Tuy nhiên, khi tăng độ sâu của mạng đến một ngưỡng thì tỷ lệ lỗi của mạng tăng lên. Hình 5.19 cho thấy hiện tượng quan trọng trong huấn luyện mạng học sâu: khi độ sâu tăng lên quá lớn, việc huấn luyện trở nên khó khăn hơn. Cụ thể, mạng 56 lớp không những có lỗi kiểm thử (test error) cao hơn mạng 20 lớp, mà đáng chú ý hơn, lỗi huấn luyện (training error) cũng cao hơn trong suốt quá trình lặp. Điều này cho thấy vấn đề không nằm ở khả năng khái quát hóa, mà nằm ở khó khăn tối ưu hóa (optimization difficulty): mạng quá

sâu không học được ánh xạ mong muốn, mặc dù về mặt lý thuyết nó có năng lực biểu diễn lớn hơn mạng nông. Hiện tượng này được gọi là vấn đề suy giảm hiệu năng, trái với kỳ vọng khi tăng độ sâu mạng.

Mạng ResNet (residual net) được đề xuất bởi (He 2016) với mục đích khắc phục vấn đề suy giảm hiệu năng khi tăng độ sâu mạng tăng thông qua cơ chế học phần dư (residual).



Hình 5.20. Khối học phần dư.

A) Khối học phần dư

Hình 5.20 miêu tả nguyên tắc *khối học phần dư* (residual learning block), trong đó hai lớp tích chập được sử dụng để học ánh xạ $\mathcal{F}(x)$ và đầu vào x được nối tắt để kết hợp với đầu ra để tạo ra $\mathcal{F}(x) + x$.

Trong trường hợp không có kết nối tắt, khối này học ánh xạ $H(x) = \mathcal{F}(x)$ và trong tầng sâu của mạng, $\mathcal{F}(x)$ suy biến khiến $H(x)$ cũng suy biến dẫn đến sai số học tăng.

Khi thực hiện kết nối tắt, ta yêu cầu khối học ánh xạ tổng hợp $H(x) = \mathcal{F}(x) + x$. Trong trường hợp $\mathcal{F}(x)$ suy biến, thì $H(x)$ tiến tới x . Trong trường hợp này, mặc dù mạng không học thêm được gì mới nhưng cũng không khiến sai số học tăng. Ký hiệu y là biểu diễn đặc trưng đầu ra của khối, khi đó $\mathcal{F}(x) = y - x$ là phần dư (phần chênh lệch giữa biểu diễn đặc trưng đầu vào và đầu ra của khối). Quá trình huấn luyện yêu cầu các lớp tích chập học được phần dư $\mathcal{F}(x)$. Do đó, nó được gọi tên là Khối học phần dư.

Chú ý trong khối học phần dư, thành phần BN (Batch normalization) được sử dụng sau mỗi lớp tích chập (conv) giúp ổn định quá trình lan truyền gradient (Ioffe 2015). Với mỗi kênh x , BN thực hiện chuẩn hóa như sau:

$$y = \gamma \hat{x} + \beta, \hat{x} = \frac{x - \mu_{batch}}{\sqrt{\sigma_{batch}^2 + \epsilon}} \quad (5.22)$$

Trong đó, γ và β là các tham số cho mỗi kênh học được, μ_{batch} và σ_{batch}^2 là giá trị trung bình và phương sai trên tập dữ liệu mini-batch ($B_t \subset D_{train}$ của SGD trong mục 5.1.2.3).


B) Kiến trúc mạng ResNet-34

Để dễ dàng so sánh và kiểm chứng kết quả thực nghiệm kết quả, (He 2016) đề xuất 2 kiến trúc: *mạng thuần* (plain network) và *mạng nổi tắt* (residual network).

Kiến trúc mạng thuần lấy cảm hứng chủ yếu từ nguyên lý của mạng VGG. Hình 5.18 (a) là có cấu trúc nổi thẳng (plain baseline). Các lớp tích chập có kích thước cửa sổ 3×3 với 2 quy tắc thiết kế sau:

- Những lớp biểu diễn đặc trưng có cùng kích thước không gian ($H \times W$) thì có cùng số lượng bộ lọc tích chập và do đó có cùng số kênh C . Ví dụ $4 \times 2 = 8$ lớp biểu diễn đặc trưng kích thước $H \times W = 28 \times 28$ đều có cùng số kênh $C = 128$ là kết quả của 128 bộ lọc tích chập 3×3 .
- Nếu lớp biểu diễn đặc trưng có kích thước không gian giảm đi một nửa, thì số bộ lọc tích chập tăng gấp đôi để duy trì độ phức tạp tính toán của mỗi lớp.

Mạng thuần có 34 lớp (layers) viết tắt là plain-34 có đầu vào là ảnh màu kích thước $224 \times 224 \times 3$ và đầu ra là phân loại 1000 lớp (class) để phù hợp với bộ dữ liệu huấn luyện ImageNet (Deng 2009). Giảm mẫu được thực hiện giữa các lớp tích chập sử dụng bước trượt $stride = 2$. So với VGG-19, ResNet-34 tăng đáng kể độ sâu dưới dạng các lớp tích chập. Hình 5.21 cho thấy có đến $6 \times 2 = 12$ lớp tích chập cho biểu diễn đặc trưng $14 \times 14 \times 256$ cùng với các lớp tích chập khác khiến tổng số các lớp tích chập là 33 và 1 lớp kết nối đầy đủ FC.



Hình 5.21. Kiến trúc mạng Resnet: (a) mạng sâu thuần, (b) mạng sâu nổi tắt.

Mạng nổi tắt 34 lớp viết tắt là ResNet-34 được xây dựng bằng cách bổ sung thêm các kết nối tắt dựa trên kiến trúc của mạng thuần. Nối tắt đồng nhất (identity shortcut) có thể được thực hiện cho một số lớp liên tiếp nhau khi đầu vào và đầu ra có cùng số chiều theo công thức sau:

$$y = \mathcal{F}(x, \{W_i, b_i\}) + x, \quad (5.23)$$

Trong đó W_i và b_i là trọng số và bias của lớp thứ i , hàm $\mathcal{F}(x, \{W_i, b_i\})$ là phần dư cần được học. Với ví dụ trong Hình 5.20, hai lớp tích chập có thể cho hàm $\mathcal{F}(x, \{W_i\}) = W_2 * \text{ReLU}(W_1 * x + b_1) + b_2$.

Trong trường hợp số chiều đầu vào lớn hơn đầu ra (thường là gấp đôi), ta cần bổ sung thêm bộ trọng số W_s để tạo ánh xạ cho 2 chiều này. Khi đó, nối tắt đồng nhất có công thức sau:

$$y = \mathcal{F}(x, \{W_i, b_i\}) + w_s x, \quad (5.24)$$

C) Kiến trúc ResNet-18

Kiến trúc mạng thuần 18 lớp (plain-18) và mạng nổi tắt (ResNet-18) có cấu trúc tương tự như kiến trúc ResNet-34 nhưng có số lượng các lớp tích chập nhỏ hơn. Bảng 5.3 liệt kê sự sai khác về số lớp lặp của ResNet-18 và ResNet-34.

4388


Bảng 5.3. Số lớp của ResNet-18 và ResNet-34.

Khối	Plain-18 và ResNet-18	Plain-34 và ResNet-34
FC 1000	1	1
3×3 conv, 512	$2 \times 2 = 4$	$3 \times 2 = 6$
3×3 conv, 256	$2 \times 2 = 4$	$6 \times 2 = 12$
3×3 conv, 128	$2 \times 2 = 4$	$4 \times 2 = 8$
3×3 conv, 64	$2 \times 2 = 4$	$3 \times 2 = 6$
7×7 conv, 64,/2	1	1
Tổng số lớp	18	34

4389

4390 D) Đánh giá hiệu năng

4391 Trong Hình 5.21, các *nối tắt đồng nhất* được thực hiện cho các cặp lớp tích chập
 4392 liên tiếp và tổng số có 16 nối tắt trong mạng ResNet-34.



4393

4394

4395 Hình 5.22. Hiệu năng mạng ResNet khi huấn luyện với bộ dữ liệu ImageNet:

4396 Hình 5.22 (He 2016) so sánh hiệu năng giữa hai mạng thuần plain-18 và plain-
 4397 34 được huấn luyện trên bộ dữ liệu ImageNet, trong đó đường mảnh là hiệu năng
 4398 trên tập huấn luyện và đường đậm là hiệu năng trên tập kiểm thử. Tương tự như
 4399 ví dụ trong Hình 5.19. Hình (a) cho thấy việc tăng độ sâu mạng thuần từ 18 lớp lên
 4400 34 lớp không những không cải thiện mà còn làm hiệu năng hoạt động trên cả tập
 4401 huấn luyện và tập kiểm thử. Trong khi đó, kết quả thể hiện trong (b) cho thấy
 4402 ResNet-34 luôn có lỗi thấp hơn ResNet-18 trên cả hai tập huấn luyện và kiểm thử.
 4403 Đường huấn luyện của ResNet-34 thấp và ổn định không thấy dấu hiệu của suy
 4404 giảm. Do đó, có thể kết luận nối tắt (identity shortcuts) giúp việc tăng độ sâu từ 18
 4405 lên 34 tầng mang lại hiệu quả rõ rệt.

4406 Kết quả thực nghiệm ở trên chỉ ra rằng việc tăng độ sâu mạng CNN không
 4407 những không cải thiện mà còn làm giảm hiệu năng. Với kiến trúc ResNet, độ sâu

lớn hơn giúp mô hình học được biểu diễn tốt hơn, chứng minh vai trò quyết định của kết nối tắt cho phép mạng học được phần dư (residual learning).

5.2.1.5. EfficientNet (Mạng tối ưu sâu-rộng-độ phân giải)

Trong việc thiết kế các mạng CNN, chiều sâu mạng, chiều rộng mạng và độ phân giải ảnh đầu vào có thể được xem là các trục mở rộng cho mô hình mạng. Trục độ sâu mạng quyết định mức độ trừu tượng của biểu diễn đặc trưng (tham khảo hai mạng VGG và ResNet), trục chiều rộng mạng quyết định năng lực biểu diễn tại mỗi tầng (tham khảo mạng GoogLeNet) và trục độ phân giải quyết định lượng thông tin không gian đầu vào. Rất nhiều thực nghiệm đã cho thấy, việc tăng chiều sâu, tăng chiều rộng hoặc tăng độ phân giải có thể giúp cải thiện hiệu năng của mạng và trực tiếp ảnh hưởng tới tài nguyên tính toán và lưu trữ. Câu hỏi đặt ra, nếu cho trước một ràng buộc về tài nguyên tính toán và lưu trữ, việc tăng ba trục này nên được thực hiện thế nào để mạng hoạt động hiệu quả nhất? EfficientNet (Tan 2019) được đề xuất để trả lời câu hỏi này.

A) Ý tưởng trung tâm của EfficientNet

Các tác giả của EfficientNet đã đưa ra hai nhận định:

- Việc mở rộng bất kỳ trục nào của mạng (chiều rộng, chiều sâu hoặc độ phân giải) đều giúp cải thiện độ chính xác, tuy nhiên mức tăng độ chính xác này giảm dần khi mô hình trở nên lớn hơn.
- Để đạt được độ chính xác và hiệu quả tốt hơn, việc cân bằng đồng thời tất cả các chiều của mạng (chiều rộng, chiều sâu và độ phân giải) là yếu tố then chốt trong quá trình mở rộng quy mô mạng tích chập.

Từ đó họ đã đề xuất chiến lược *mở rộng phối hợp* (compound scaling) nhằm tối ưu hóa đồng thời chiều sâu, chiều rộng và độ phân giải của mạng, trong đó sử dụng *hệ số phối hợp* (compound coefficient) ϕ để mở rộng đồng đều chiều rộng, chiều sâu và độ phân giải một cách có hệ thống.

Ký hiệu d là hệ số mở rộng theo chiều sâu, w là hệ số mở rộng theo chiều rộng và r là hệ số mở rộng độ phân giải. Các hệ số này chịu ràng buộc thông qua hệ số phối hợp như sau:

$$d = \alpha^\phi, w = \beta^\phi, r = \gamma^\phi, \quad (5.24)$$


trong đó $\alpha \geq 1$, $\beta \geq 1$, $\gamma \geq 1$ và $\alpha \cdot \beta^2 \cdot \gamma^2 \approx 2$. Các giá trị α, β, γ được xác định cố định ($\alpha = 1.2, \beta = 1.1, \gamma = 1.15$) và hệ số phối hợp ϕ được xác định trong tập $\phi \in \{0, 1, 2, 3, 4, 5, 6, 7\}$ để tạo ra các phiên bản EfficientNet-B0, EfficientNet-B1, ..., EfficientNet-B7.

Khi ϕ tăng, mạng được mở rộng đồng thời theo ba trục: số khối lặp lại tăng độ sâu theo d , số kênh trong mỗi khối tăng (độ rộng) theo w , và kích thước ảnh đầu vào tăng (độ phân giải) theo r . Cấu trúc tổng thể của mạng được giữ nguyên.

4446 B) Kiến trúc mạng EfficientNet-B0

Tầng		Độ phân giải (kích thước không gian)	Chiều rộng (số kênh)	Chiều sâu (số tầng)
11	FC (1000 lớp)	-	1000	-
10	Global average pool	-	<u>1280</u>	<u>1</u>
9	Conv1×1	<u>7×7</u>	<u>1280</u>	<u>1</u>
8	MBConv6, k3×3	<u>7×7</u>	<u>320</u>	<u>1</u>
7	MBConv6, k5×5, s=2	<u>7×7</u>	<u>192</u>	<u>4</u>
6	MBConv6, k5×5	<u>14×14</u>	<u>112</u>	<u>3</u>
5	MBConv6, k3×3, s=2	<u>14×14</u>	<u>80</u>	<u>3</u>
4	MBConv6, k5×5, s=2	<u>28×28</u>	<u>40</u>	<u>2</u>
3	MBConv6, k3×3, s=2	<u>56×56</u>	<u>24</u>	<u>2</u>
2	MBConv1, k3×3	<u>112×112</u>	<u>16</u>	<u>1</u>
1	Conv 3×3, s=2	<u>112×112</u>	<u>32</u>	<u>1</u>
0	Ảnh màu	<u>224 × 224</u>	3	-

4447
 4448 Hình 5.23. Kiến trúc mạng EfficientNet-B0



4449
 4450 Hình 5.24. Cấu trúc khối MBConv.

Kiến trúc mạng EfficientNet-B0 về cơ bản gồm các khối được kế thừa từ các mạng trước đó (Xem Hình 5.23). Tầng 0 (đầu vào là ảnh màu) và tầng 11 (kết nối đầy đủ - FC) thích nghi với bài toán phân loại ảnh (Deng 2009), các tầng Conv 3×3 , Conv 1×1 , Global average pool được sử dụng lại từ các mạng CNN trước đây. MBConv1 và MBConv6 các khối được thiết kế mới bằng cách kế thừa khối *inverted residual* của MobileNetV2 (Sandler 2018) và tích hợp thêm cơ chế SE của SENet (Hu 2018) cho phép đạt hiệu quả tính toán cao đồng thời tăng khả năng chọn lọc đặc trưng theo kênh.

Cấu trúc khối MBConv được trình bày trong Hình 5.24. Trong MBConv, các khối *Mở rộng* (expansion), *Depthwise* và *Thu hẹp tuyến tính* (projection) được kế thừa từ mạng MobileNetV2 (Sandler 2018).

Khối Mở rộng sử dụng Conv 1×1 để tăng số kênh lên t lần (MBConv3 sử dụng $t = 3$ và MBConv5 sử dụng $t = 5$) giúp không gian đặc trưng rộng để các tổ hợp đặc trưng phức tạp có thể hình thành. Tiếp theo là BN (batch normalization, xem Khối học phần dư mục 5.2.1.4) giúp ổn định phân bố đặc trưng và hàm kích hoạt *Swish* giúp phi tuyến mềm đầu ra (xem Bảng 5.1).

Sau khối Mở rộng, khối Depthwise là một phiên bản thu gọn của khối tích chập truyền thống, xem công thức (5.17). Depthwise cho phép học cấu trúc không gian với chi phí tối thiểu với tensor 2 chiều cho mỗi kênh riêng biệt. Khi được sử dụng cùng với khối *Thu hẹp tuyến tính* (project) hay còn gọi là Pointwise, hiệu quả biểu diễn đặc trưng đạt tương đương thậm chí nhỉnh hơn so với khối tích chập truyền thống sử dụng tensor 3 chiều, trong khi chi phí tính toán được giảm đi rất nhiều lần.

MBConv bổ sung thêm khối SE (squeeze-and-excitation) (Hu 2018) để tái cân bằng các kênh đặc trưng. SE không thay đổi kích thước biểu diễn đặc trưng đầu vào, chỉ thay đổi tầm quan trọng của từng kênh. Cấu trúc khối SE gồm 3 bước chính là bước GAP và 2 bước FC.

Ký hiệu $U \in \mathbb{R}^{H' \times W' \times t \cdot C_{in}}$ là tensor của biểu diễn đặc trưng đầu vào khối SE. GAP (global average pool) lấy trung bình toàn cục cho tất cả các kênh nhằm tập trung quan sát vào từng kênh và bỏ qua thành phần không gian:

$$\mathbf{z} = \frac{1}{H' \times W'} \sum_{i=1}^{H'} \sum_{j=1}^{W'} \mathbf{U}(i, j) \text{ và } \mathbf{z} \in \mathbb{R}^{t \cdot C_{in}}, \quad (5.25)$$

vector các giá trị toàn cục của $t \cdot C_{in}$ kênh đầu vào khối SE. 2 bước FC (fully connected) giúp xác định tầm quan trọng của từng kênh:

$$\mathbf{s} = \text{sigmoid}(\mathbf{W}_2 \cdot \text{ReLU}(\mathbf{W}_1 \cdot \mathbf{z})), \quad (5.25)$$

trong đó W_1 và W_2 là trọng số của hai tầng kết nối đầy đủ (fully connected – FC). Ở tầng FC1, giảm kích thước kênh đi ($r = 4$) lần ($\frac{t \cdot C_{in}}{r}$) nhằm giúp khối SE chỉ tập trung vào độ quan trọng của kênh mà không cần phải học thêm các biểu diễn mới đồng thời giảm tối đa kích thước trọng số cần thiết.

Cuối cùng, các kênh được điều chỉnh theo tầm quan trọng:

$$\hat{U}(:, :, c) = s(c) \cdot U(:, :, c), \quad (5.26)$$

với c là chỉ số kênh $0 \leq c < t \cdot C_{in}$.

Thực nghiệm cho thấy, bằng việc kế thừa *inverted residual* của MobileNetV2 cộng với SE của SENet, khối MBConv đạt được cải thiện đáng kể trong biểu diễn đặc trưng và tối ưu hóa chi phí tính toán FLOPs và kích thước tham số cần lưu trữ.

C) Dòng mạng EfficientNet

Một trong những đặc điểm nổi trội của EfficientNet so với các mạng CNN khác là khả năng mở rộng mạng theo các trục chiều sâu, chiều rộng và độ phân giải ảnh đầu vào tùy thuộc vào tài nguyên tính toán.


Dựa trên kiến trúc cơ sở EfficientNet-B0, các phiên bản EfficientNet-Bx, x từ 1 đến 7, được xây dựng dựa trên hệ số phối hợp (compound coefficient) ϕ . Độ lớn các chiều sâu, chiều rộng và độ phân giải ảnh đầu vào được xác định như trong công thức (5.24) và được làm tròn để có thể áp dụng trong thực tiễn.

Bảng 5.4. Dòng mạng EfficientNet-Bx

Dòng mạng	ϕ	$r(\phi)$	Độ phân giải ảnh đầu vào (chuẩn)	$w(\phi)$	Độ rộng kênh ở tầng 7	$d(\phi)$	Chiều sâu ở tầng 7	Số tham số	FLOPs
B0	0	224.0	224×224	1.000	192	1.000	4	5.3M	0.39B
B1	1	257.6	240×240	1.100	208	1.200	5	7.8M	0.70B
B2	2	296.2	260×260	1.210	232	1.440	6	9.2M	1.00B
B3	3	340.7	300×300	1.331	256	1.728	7	12M	1.80B
B4	4	391.8	380×380	1.464	280	2.074	9	19M	4.20B
B5	5	450.5	456×456	1.611	312	2.488	10	30M	9.90B
B6	6	518.1	528×528	1.772	344	2.986	12	43M	19.00B
B7	7	595.8	600×600	1.949	376	3.583	15	66M	37.00B

D) Đánh giá hiệu năng

Mục này trình bày việc so sánh hiệu năng của các dòng mạng được trình bày chi tiết trong giáo trình. Mỗi dòng mạng là một mô hình cụ thể với quy mô khác nhau. Dòng VGG từ 11 đến 19, dòng ResNet từ 18 đến 101 và dòng EfficientNet từ B0 đến B7. Việc so sánh được thực hiện trên bộ dữ liệu ImageNet, độ chính xác Top-1 tính theo % và dung lượng tính toán (GFLOPs) cần thiết của mỗi mạng.



Hình 5.25. So sánh hiệu năng giữa một số mạng CNN.

Hình 5.25 cho thấy sự khác biệt rõ rệt giữa các dòng mạng CNN. VGG là dòng mạng kém hiệu quả nhất, khi tiêu tốn GFLOPs rất lớn nhưng độ chính xác tăng chậm, cho thấy cách tiếp cận tăng độ sâu thuần túy không phù hợp. GoogLeNet (Inception) đánh dấu bước tiến quan trọng khi với độ chính xác cao hơn VGG với chi phí tính toán thấp hơn nhiều nhờ kiến trúc đa nhánh và giảm chiều hiệu quả. ResNet tiếp tục cải thiện đáng kể hiệu năng–chi phí bằng cơ chế nối tắt, cho phép huấn luyện mạng sâu hơn và đạt độ chính xác cao ở mức GFLOPs trung bình. EfficientNet thể hiện hiệu quả vượt trội nhất, khi đạt độ chính xác cao hơn rõ rệt tại cùng mức GFLOPs. Các phiên bản EfficientNet nhỏ đã vượt ResNet và Inception về hiệu năng, trong khi các phiên bản lớn tiếp tục nâng trần độ chính xác. Điều này cho thấy chiến lược mở rộng cân bằng đồng thời độ sâu, chiều rộng và độ phân giải ảnh đầu vào mang lại lợi thế rõ rệt.

5.2.2. Vision transformers

Như được trình bày ở phần trước, các mạng CNN sử dụng các bộ lọc với kích thước cửa sổ nhỏ 3×3 , 5×5 , ... để miêu tả các đặc điểm có tích cục bộ từ ảnh đầu

vào dưới dạng trường cảm thụ (receptive field) và trường cảm thụ có thể được mở rộng nhờ cơ chế mạng sâu (nhiều tầng mạng), Hình 5.12. Tuy nhiên, trong rất nhiều trường hợp, vẫn tồn tại những thông tin toàn cục (từ mức thấp đến mức trừu tượng) cần được chia sẻ giữa các trường cảm thụ (receptive field) và các mạng CNN tỏ ra khá hạn chế trong yêu cầu này nên khó nắm bắt được các quan hệ xa (long range dependency). Nhằm khắc phục các hạn chế của CNN trong việc mô hình hóa thông tin toàn cục, kiến trúc Transformer (vốn có thể mạnh trong xử lý dữ liệu dạng chuỗi và được xây dựng dựa trên cơ chế attention) đã được mở rộng và áp dụng cho miền thị giác và được gọi là Vision Transformers.

5.2.2.1. Vision Transformers (ViT)

Trong Vision Transformer (Dosovitskiy 2021), hình ảnh đầu vào không được xử lý trực tiếp dưới dạng lưới điểm ảnh như trong mạng tích chập, mà trước hết được chia thành các patch có kích thước cố định. Mỗi patch đóng vai trò tương đương với một token trong các mô hình Transformer xử lý chuỗi. Mỗi token mang thông tin của một vùng không gian cục bộ trong ảnh, đồng thời được coi là một phần tử trong chuỗi đầu vào của Transformer. Thông qua cơ chế self-attention, các token có thể tương tác trực tiếp với nhau, cho phép mô hình học được quan hệ toàn cục giữa các patch khác nhau, thay vì chỉ dựa vào quan hệ lân cận như trong phép tích chập.

Đóng vai trò đặc biệt quan trọng trong Vision Transformers là cơ chế Attention, chiến lược cho phép xử lý thông tin toàn cục một cách hiệu quả, bằng cách tập trung vào những thành phần ảnh có mức độ liên quan và quan trọng nhất đối với tác vụ đang thực hiện.

A) Mạng token


Token là một khái niệm trong attention chứa đựng một lượng thông tin nhất định. Nội dung thông tin trong token có thể được suy cập hoặc thay đổi dựa trên các toán tử (operators). Trong cấu trúc dữ liệu và giải thuật, có thể coi token là một kiểu dữ liệu. Trong toán học, có thể ký hiệu token bằng một vector cột:

$$\mathbf{t} \in \mathbb{R}^{d \times 1}. \quad (5.27)$$

Bước đầu tiên trong việc xử lý dữ liệu dưới dạng token là thực hiện quá trình token hóa dữ liệu đầu vào từ ảnh. Sau đó, tất cả các tầng xử lý tiếp theo sẽ hoạt động trên các token cho đến tầng đầu ra. Mô hình đưa ra quyết định hoặc dự đoán dựa trên tập token cuối cùng. Để làm điều này, ảnh đầu vào có kích thước $H \times W \times C$ được chia nhỏ thành N patch, mỗi patch là một tensor $\mathbf{X}_i \in \mathbb{R}^{p \times p \times C}$, rồi được làm phẳng thành N vector 1 chiều $\mathbf{x}_i \in \mathbb{R}^{p^2 C}$. Mỗi vector $\mathbf{x}_i$ được token hóa thành một token $\mathbf{t}_i$ như sau:

$$\mathbf{t}_i = \mathbf{x}_i \mathbf{W}_t + \mathbf{b} \text{ với } \mathbf{W}_t \in \mathbb{R}^{(p^2 C) \times d}, \quad (5.28)$$

4568 trong đó d là số chiều của token, $\mathbf{W}_t$ và $\mathbf{b}$ là ma trận trọng số và vector bias của phép
 4569 token hóa. Về bản chất toán học, đây là lớp kết nối đầy đủ (fully connected) Conv
 4570 $p \times p$, với stride $s = p$ thì các patch không chồng lấp (overlap) lên nhau và $s < p$ thì
 4571 các patch chồng lấp và gây dư thừa cục bộ giữa các patch.



Hình 5.26. Token hóa ảnh $\rightarrow$ patch $\rightarrow$ token.

4572
 4573 Chuỗi N token $\{\mathbf{t}_i\}_{i=1}^N$ có thể được biểu diễn bằng một ma trận $\mathbf{T} \in \mathbb{R}^{N \times d}$, trong
 4574 đó mỗi token được chuyển thành một hàng của ma trận:


$$\mathbf{T} = \begin{bmatrix} \mathbf{t}_1^T \\ \vdots \\ \mathbf{t}_N^T \end{bmatrix}. \quad (5.29)$$

4577 Giờ ta có thể định nghĩa một tầng kết nối đầy đủ (FC) của N token đầu vào và
 4578 tới N' token đầu ra thông qua phép biến đổi tuyến tính sau:

$$\mathbf{T}_{out} = \mathbf{W}\mathbf{T}_{in} + \mathbf{b} \text{ trong đó } \mathbf{W} \in \mathbb{R}^{N' \times N} \text{ và } \mathbf{b} \in \mathbb{R}^{N'} \quad (5.30)$$

4580 Để trang bị cho khả năng biểu diễn phi tuyến của mạng token, ta có thể áp
 4581 dụng một hàm phi tuyến (tương tự như hàm kích hoạt của mạng CNN):

$$\mathbf{T}_{out} = \begin{bmatrix} f(\mathbf{T}_{in}(1,:)) \\ \vdots \\ f(\mathbf{T}_{in}(n,:)) \end{bmatrix} = f(\mathbf{T}_{in}). \quad (5.31)$$



Hình 5.27. Mạng token.

Cuối cùng, tương tự như mạng neuron nhiều tầng, ta xây dựng mạng token, bằng cách ghép chồng nhiều tầng kết nối với các hàm kích hoạt:

$$\mathbf{T}_{out} = \mathbf{f}(\mathbf{W}_2 \cdot \mathbf{f}(\mathbf{W}_1 \cdot \mathbf{T}_{in} + \mathbf{b}_1) + \mathbf{b}_2), \quad (5.32)$$

trong đó mỗi tầng có một bộ trọng số $\{\mathbf{W}_i, \mathbf{b}_i\}$ riêng.

Công thức (5.32) và Hình 5.27 là ví dụ của một mạng token 2 tầng, trong thực tế ta có thể xây dựng kiến trúc mạng token nhiều tầng tương tự như mạng neuron và sử dụng lại các khái niệm về hàm kích hoạt, hàm mất mát các thuật toán lan truyền ngược và tối ưu huấn luyện tương tự như mạng neuron nhân tạo.

B) Tầng Attention

Tầng Attention (Attention layer) định nghĩa một cách kết hợp tuyến tính giữa các token. Khác với việc sử dụng một ma trận trọng số bất kỳ $\mathbf{W}$, Attention sử dụng ma trận $\mathbf{A}$ (ma trận Attention) được xây dựng từ dữ liệu sao cho nó chỉ tập trung (chú ý) vào một số token hữu ích cho bài toán hiện tại. Tương tự như hệ số xác định tầm quan trọng của kênh trong khối SE của mạng EfficientNet, công thức (5.25) và (5.26).

Ở đây, Transformers sử dụng một loại Attention đặc biệt dựa trên khái niệm truy vấn (query – Q), khóa (key – K) và giá trị (value – V). Trong Attention QKV, mỗi token $\mathbf{t} \in \mathbb{R}^{d \times 1}$ được biểu diễn bởi vector truy vấn $\mathbf{q} \in \mathbb{R}^{d \times 1}$, vector khóa $\mathbf{k} \in \mathbb{R}^{d \times 1}$ và vector giá trị $\mathbf{v} \in \mathbb{R}^{d \times 1}$ như sau:

$$\mathbf{q} = \mathbf{W}_q \mathbf{t}, \mathbf{k} = \mathbf{W}_k \mathbf{t} \text{ và } \mathbf{v} = \mathbf{W}_v \mathbf{t}, \quad (5.33)$$

trong đó $\mathbf{W}_q, \mathbf{W}_k, \mathbf{W}_v \in \mathbb{R}^{d \times d}$ là ma trận chuyển truy vấn, ma trận chuyển khóa và ma trận chuyển giá trị.

Khi vào tầng Attention, mỗi token tạo ra một truy vấn $\mathbf{q}$ và sử dụng nó để so khớp với các khóa $\mathbf{k}_i$ của các token còn lại. Độ tương đồng giữa truy vấn và khóa sẽ quyết định trọng số “chú ý” mà truy vấn đó gán cho token tương ứng với khóa ấy và phép đo tương đồng thường dùng nhất giữa truy vấn truy vấn $\mathbf{q}$ và khóa $\mathbf{k}$ là tích vô hướng $\mathbf{q}^T \mathbf{k}$.

Khi đó, việc truy vấn mỗi token trong một tập các token đầu vào $\mathbf{T}_{in}$ trả về một vector độ tương đồng:

$$\mathbf{s} = [\mathbf{s}_1, \mathbf{s}_2, \dots, \mathbf{s}_N]^T = [\mathbf{q}^T \mathbf{k}_1, \mathbf{q}^T \mathbf{k}_2, \dots, \mathbf{q}^T \mathbf{k}_N]^T, \quad (5.34)$$

trong đó N là số token của $\mathbf{T}_{in}$. Tiếp theo, vector độ tương đồng $\mathbf{s}$ được chuẩn hóa bằng hàm softmax để được vector trọng số attention $\mathbf{a} \in \mathbb{R}^{N \times 1}$:

$$\mathbf{a} = \text{softmax}(\mathbf{s}). \quad (5.35)$$

Cuối cùng, đầu ra của lớp attention được tính như sau:


4620

$$\mathbf{T}_{out} = \begin{bmatrix} a_1 \mathbf{v}_1^T \\ \vdots \\ a_n \mathbf{v}_n^T \end{bmatrix}. \quad (5.36)$$

4621

Vấn đề tiếp theo là, với một tập token đầu vào $\mathbf{T}_{in}$, những token nào sẽ đóng vai trò là truy vấn và những token nào sẽ đóng vai trò được truy vấn? *Self-Attention* là kiến trúc được thiết kế để trả lời câu hỏi này. Ý tưởng là trong tầng Self-Attention, với $\mathbf{T}_{in}$ là một tập gồm n token đầu vào, từng token trong số n token đó sẽ được sử dụng để truy vấn và ta sẽ có n truy vấn để tạo ra n tổng có trọng số và n token đầu ra để tạo thành $\mathbf{T}_{out}$.

4626



4627

4628

Hình 5.28. Kiến trúc Self-Attention.

4629

Đầu tiên, ta chuyển các biểu diễn truy vấn, khóa và giá trị trong (5.33) của $\mathbf{T}_{in}$ thành dạng ma trận:

4630

4631

$$\mathbf{Q} = \begin{bmatrix} \mathbf{q}_1^T \\ \vdots \\ \mathbf{q}_N^T \end{bmatrix} = \begin{bmatrix} (\mathbf{W}_q \mathbf{t}_1)^T \\ \vdots \\ (\mathbf{W}_q \mathbf{t}_N)^T \end{bmatrix} = \mathbf{T}_{in} \mathbf{W}_q^T,$$

4632

$$\mathbf{K} = \begin{bmatrix} \mathbf{k}_1^T \\ \vdots \\ \mathbf{k}_N^T \end{bmatrix} = \begin{bmatrix} (\mathbf{W}_k \mathbf{t}_1)^T \\ \vdots \\ (\mathbf{W}_k \mathbf{t}_N)^T \end{bmatrix} = \mathbf{T}_{in} \mathbf{W}_k^T, \quad (5.37)$$

$$\mathbf{V} = \begin{bmatrix} \mathbf{v}_1^T \\ \vdots \\ \mathbf{v}_N^T \end{bmatrix} = \begin{bmatrix} (\mathbf{W}_v \mathbf{t}_1)^T \\ \vdots \\ (\mathbf{W}_v \mathbf{t}_N)^T \end{bmatrix} = \mathbf{T}_{in} \mathbf{W}_v^T,$$

trong đó $\mathbf{Q}, \mathbf{K} \in \mathbb{R}^{N \times d}$ là ma trận truy vấn và ma trận khóa, $\mathbf{V} \in \mathbb{R}^{N \times d}$ là ma trận giá trị. Từ đó, ta xây dựng ma trận Attention như sau:

$$\mathbf{A} = \text{softmax}\left(\frac{\mathbf{Q}\mathbf{K}^T}{\sqrt{N}}\right), \quad (5.38)$$

phép chia cho $\sqrt{N}$ giúp chuẩn hóa theo số chiều đặc trưng để giữ cho độ lớn (phương sai) của các giá trị đưa vào softmax không phụ thuộc vào chiều không gian của các vector truy vấn và vector khóa. Cuối cùng, ma trận token đầu ra được tính như sau:

$$\mathbf{T}_{out} = \mathbf{A}\mathbf{V}. \quad (5.39)$$

Hình 5.28 mô tả luồng thông tin của Self-Attention trong đó N token dưới dạng các vector được gom lại thành ma trận token đầu vào $\mathbf{T}_{in}$. Với sự tham gia của bộ trọng số $(\mathbf{W}_q, \mathbf{W}_k, \mathbf{W}_v)$, ma trận token đầu ra $\mathbf{T}_{out}$ được tính toán theo lan truyền xuôi mạng từ dưới lên trên.

Có thể thấy bộ trọng số $(\mathbf{W}_q, \mathbf{W}_k, \mathbf{W}_v)$ cho phép biểu diễn một độ đo tương đồng giữa các token trong tập token đầu vào $\mathbf{T}_{in}$. Cụ thể, token thứ i và token thứ j có sự tương đồng được suy ra từ công thức (5.34) như sau:

$$s_{ij} = \mathbf{q}_i^T \mathbf{k}_j = (\mathbf{W}_q \mathbf{t}_i)^T \mathbf{W}_k \mathbf{t}_j = \mathbf{t}_i^T \mathbf{W}_q^T \mathbf{W}_k \mathbf{t}_j = \mathbf{t}_i^T \mathbf{S} \mathbf{t}_j. \quad (5.40)$$

Điều đó có nghĩa $\mathbf{W}_q$ và $\mathbf{W}_k$ định nghĩa ma trận $\mathbf{S} = \mathbf{W}_q^T \mathbf{W}_k$ là một độ đo duy nhất giữa token $\mathbf{t}_i$ và token $\mathbf{t}_j$.

Để đồng thời thực hiện nhiều độ đo (độ tương tự về màu sắc, độ tương tự về kết cấu, ...), ta có thực hiện song song h Self-Attention attn^i với $i \in \{1, \dots, h\}$. Mỗi attn^i có số chiều d_k được gọi là 1 head và toàn bộ kiến trúc này được gọi là Multihead Self-Attention. Các ma trận truy vấn, khóa và giá trị của attn^i là $\mathbf{Q}_i, \mathbf{K}_i, \mathbf{V}_i \in \mathbb{R}^{N \times d_k}$, ở đây các giá trị h và d_k được xác định sao cho $hd_k = d$ (Dosovitskiy 2021). Các ma trận này được tách ra từ các ma trận gốc như sau:

$$\begin{aligned} \mathbf{Q} &= [\mathbf{Q}_1 \quad \mathbf{Q}_2 \quad \dots \quad \mathbf{Q}_h], \\ \mathbf{K} &= [\mathbf{K}_1 \quad \mathbf{K}_2 \quad \dots \quad \mathbf{K}_h], \\ \mathbf{V} &= [\mathbf{V}_1 \quad \mathbf{V}_2 \quad \dots \quad \mathbf{V}_h]. \end{aligned} \quad (5.41)$$

Đầu ra thứ i của attn^i được tính như sau:

$$\mathbf{T}_{out}^i = \text{softmax}\left(\frac{\mathbf{Q}_i \mathbf{K}_i^T}{\sqrt{d_k}}\right) \cdot \mathbf{V}_i. \quad (5.42)$$


Sau đó được gộp lại để thu được ma trận đầu ra $\bar{\mathbf{T}}_{out} \in \mathbb{R}^{N \times d}$ (chú ý $d = hd_k$):

$$\bar{\mathbf{T}}_{out} = [\mathbf{T}_{out}^1 \quad \mathbf{T}_{out}^2 \quad \dots \quad \mathbf{T}_{out}^h]. \quad (5.43)$$

Cuối cùng, tập token đầu ra T_{out} thu được bằng cách ánh xạ token multihead $\bar{T}_{out}$:

$$T_{out} = \bar{T}_{out} W_{MSA}, \quad (5.42)$$


trong đó $W_{MSA} \in \mathbb{R}^{d \times d}$ là ma trận trọng số, v là độ lớn của vector giá trị (value), d là độ lớn của vector token. Hình 5.29 trực quan hóa kiến trúc mạng Multihead self-attention.



Hình 5.29. Kiến trúc Multihead Self-Attention.

Trong Multihead Self-Attention, (W_q, W_k, W_v) và W_{MSA} là các tham số được xác định thông qua quá trình huấn luyện mạng.

C) Transformer dựa trên Attention



Hình 5.30. Kiến trúc ViT (Dosovitskiy 2021).

Hình 5.30 trực quan hóa kiến trúc của Vision Transformer (ViT) dựa trên Multi-Head Self-Attention (MSA) được chia thành 3 khối chính: khối token hóa, khối Transform Encoder và khối phân loại.

Khối token hóa:

Ảnh đầu vào kích thước $H \times W$ được chia thành các patch kích thước cố định $P = 16$ (H và W chia hết cho P), số patch của ảnh là: $\frac{H}{P} \cdot \frac{W}{P}$. Mỗi patch được làm phẳng và tuyến tính hóa thành một token theo công thức (5.28). Một token đặc biệt (có thể học được) để tổng hợp thông tin toàn cục phục vụ bài toán phân loại tên là CLS (classification token) được bổ sung thêm vào chuỗi token và tạo là mối liên hệ với tất cả các token trong chuỗi đó. Như vậy tổng số token là:

$$N = \frac{H}{P} \cdot \frac{W}{P} + 1 \quad (5.43)$$

và chuỗi token gồm có CLS token (t_0) và các token được thiết lập từ các patch của ảnh:

$$[t_0, t_1, t_2, \dots, t_{N-1}]. \quad (5.44)$$

Do đặc điểm của kiến trúc Self-Attention là không có khả năng lưu nhớ vị trí các patch, ViT không thể phân biệt được patch bắt đầu từ đâu trong ảnh dẫn đến mất cấu trúc không gian. Do đó, khái niệm positional embedding được ViT sử dụng để cung cấp thông tin không gian cho Multihead Self-Attention. Với token thứ i , một embedding vị trí (học được) $E_{pos}[i] \in \mathbb{R}^d$, d là số chiều của token, được thiết lập và được cộng trực tiếp vào token:

$$z_i = t_i + E_{pos}[i]. \quad (5.45)$$

Như vậy chuỗi token được chuẩn bị để đưa vào tầng Transformer Encoder (bao gồm 1 CLS token (học được), $N - 1$ token là chuyển đổi tuyến tính các patch ảnh đầu vào cùng với N positional embedding (học được) được cộng trực tiếp vào vector của N token) là:

$$[\mathbf{z}_{CLS}, \mathbf{z}_1, \mathbf{z}_2, \dots, \mathbf{z}_{N-1}]. \quad (5.46)$$

Khôi Transformer Encoder:

Khôi TE (transformer encoder) là thành phần cốt lõi của ViT nhận đầu vào là một chuỗi token và biến đổi chúng thành biểu diễn giàu ngữ nghĩa hơn thông qua cơ chế MSA (multi-head self-attention) và MLP (multi-layer perceptron) kết hợp với kết nối dư (residual connection) và chuẩn hóa đặc trưng (normalization layer).

Chuẩn hóa đặc trưng NL (normalization layer) được thực hiện trước MSA và MLP. NL áp dụng cho từng token nhằm ổn định phân phối đặc trưng trong quá trình huấn luyện:

$$\hat{\mathbf{z}} = \frac{\mathbf{z} - \boldsymbol{\mu}}{\sqrt{\sigma^2 + \epsilon}}, \mathbf{y} = \gamma \hat{\mathbf{z}} + \boldsymbol{\beta}, \quad (5.47)$$

trong đó $\mathbf{z}$ là một token (trong chuỗi token đang xét), $\boldsymbol{\mu}$ và σ^2 là giá trị trung bình và phương sai được tính trên vector token $\mathbf{z}$, γ và $\boldsymbol{\beta}$ là các tham số học.

MSA giúp ViT học quan hệ toàn cục nhờ vào sự tương tác của tất cả các token trong chuỗi (5.46). Trong khi CNN phải mở rộng dần trường cảm thụ (receptive field) theo chiều sâu của mạng, MSA giúp ViT nhìn toàn cục ngay từ bước đầu tiên.

Sau MSA, mỗi token được biến đổi phi tuyến bằng MLP sử dụng hàm kích hoạt GELU (Bảng 5.1):

$$MLP(\mathbf{z}) = \mathbf{W}_2 GELU(\mathbf{W}_1 \mathbf{z} + \mathbf{b}_1) + \mathbf{b}_2, \quad (5.48)$$

trong đó bộ trọng số $(\mathbf{W}_1, \mathbf{b}_1, \mathbf{W}_2, \mathbf{b}_2)$ của một MLP được chia sẻ cho tất cả token đi qua. MLP bổ sung cho TE khả năng học biểu diễn hỗ trợ cho MSA.

Kết nối dư (residual connection) cho phép nối tắt qua MSA hoặc MLP giúp ổn định và làm sâu mạng (xem phần 5.2.1.5. ResNet).

Thông thường, ViT xếp chồng L tầng TE cho phép mô hình học biểu diễn ngày càng trừu tượng và giàu ngữ nghĩa. Các tầng đầu học quan hệ patch cục bộ–trung gian, các tầng sau học cấu trúc toàn cục và ngữ nghĩa cấp cao và CLS token dần trở thành biểu diễn toàn ảnh.

Khôi phân loại MLP Head:

Trong ViT, sau khi đi qua các khối Transformer Encoding, chỉ có token $\mathbf{z}_{CLS}$ được sử dụng cho phân loại vì nó đã được thiết kế như một đại diện toàn cục phản ánh nội dung của toàn bộ ảnh. MLP Head nhận $\mathbf{z}_{CLS}$ và thực hiện phép ánh xạ tuyến tính:

$$\mathbf{y} = \mathbf{W}_{head} \mathbf{z}_{cls} + \mathbf{b}_{head} \quad (5.49)$$

trong đó ma trọng trọng số $\mathbf{W}_{head} \in \mathbb{R}^{c \times d}$, c là số lượng nhãn cần phân loại. Ví dụ với bộ dữ liệu ImageNet thì $c = 1000$.

Các biến thể của ViT:

Có thể thấy, tham số như: kích thước patch (P), số lượng token trong chuỗi đầu vào (N), kích thước/số chiều của một token (d) và số lượng khối Transformer Encoder (L) quyết định quy mô của mạng ViT. Mạng ViT có quy mô càng lớn thì hiệu năng hoạt động càng cao nhưng mạng càng cồng kềnh và tốn nhiều chi phí tính toán. Bảng 5.5 liệt kê 4 biến thể của ViT, trong đó các thông số được đo với độ phân giải ảnh đầu vào 224×224 .

Bảng 5.5. Các biến thể của ViT.

Biến thể	Patch	Số token (N)	Kích thước token (D)	Số tầng TE (L)	Params (M)	Số phép tính (GMACs)
ViT-B/16	16	197	768	12	~86.6	~16.9
ViT-B/32	32	50	768	12	~104.3	~4.4
ViT-L/16	16	197	1024	24	~303.3	~59.7
ViT-H/14	14	257	1280	32	~630.8	~162.0

5.2.2.2. Swin transformer

Kiến trúc ViT có hai hạn chế lớn là ảnh đầu vào có độ phân giải cao dẫn đến số lượng token N lớn làm tăng mạnh độ phức tạp của MSA $\sim \mathcal{O}(N^2)$ và khả năng xử lý cục bộ ảnh kém khiến khó áp dụng cho các bài toán thị giác máy (ngoài phân loại ảnh) là phát hiện (detection) và phân vùng (segmentation).


A) Kiến trúc tổng thể

Kiến trúc Swin (Shifted Window) transformer (Liu 2021) được thiết kế để đưa khả năng xử lý cục bộ của CNN vào transformer nhưng vẫn giữ được tính chất của attention. Hình 5.31 (a) miêu tả kiến trúc tổng thể của swin transformer, trong đó nhận ảnh 3 kênh màu đầu vào với kích thước $H \times W$.

Tầng Patch partition chia ảnh thành các patch không chồng lấn kích thước không gian $p \times p = 4 \times 4$, mỗi patch có độ dài $4 \times 4 \times 3 = 48$.

Tiếp theo là 4 tầng tương ứng với 4 stage. Stage 1 bao gồm khối Linear embedding để tensor hóa từng patch (48 chiều) thành một token có số chiều tiêu

chuẩn là C , xem công thức (5.28) và 2 khối Swin transformer. Các stage 2, 3 và 4 bao gồm khối Patch merging và theo sau là các khối Swin transformer hai pha.



(a) Kiến trúc phân tầng Swin transformer. (b) Cấu trúc khối Swin transformer.

Hình 5.31. Kiến trúc Swin transformer.

Patch merging (PM) đóng vai trò là phân chuyển tiếp giữa các khối swin transformer (ST) với mục đích làm giảm độ phân giải không gian của chuỗi token và tăng số chiều của token (tương tự như pooling trong CNN). Giả sử PM nhận đầu vào là mảng token kích thước $H_t \times W_t$, mỗi token có số chiều là C , đầu tiên PM gom 2×2 token lân cận $\{t_{2i,2j}, t_{2i+1,2j}, t_{2i,2j+1}, t_{2i+1,2j+1}\}$ và nối lại để tạo ra token mới $t_{cat} \in \mathbb{R}^{4C}$, sau đó áp dụng giảm số chiều tuyến tính:

$$\hat{t}_{i,j} = W_{merge} t_{cat}, \quad (5.50)$$

với $W_{merge} \in \mathbb{R}^{2C \times 4C}$ là ma trận trọng số cần học. Cuối cùng ta được đầu ra là mảng token kích thước $\frac{H_t}{2} \times \frac{W_t}{2}$, mỗi token có số chiều là $2C$.

Trong mỗi stage, nhiều khối ST thực hiện liên tiếp. Stage 1, 2 và 4 có 2 khối ST, stage 3 có 6 khối ST. Mỗi khối ST bao gồm 2 pha transformer encoding, xem Hình 5.31 (b).

4778

4779 B) Cấu trúc Swin transformer hai pha

Hai pha transformer encoding của ST hoạt động tương tự như transformer encoding của ViT, chúng chỉ khác phần multihead self-attention (MSA). Pha đầu tiên là W-MSA (window multihead self-attention) và pha thứ hai là SW-MSA (shifted window multihead self-attention).


W-MSA nhận đầu vào là một mảng token kích thước $H_t \times W_t$ và chia thành các cửa sổ token có kích thước $M \times M$ (thường chọn $M = 7$) không chồng lấn. Mỗi cửa sổ tạo thành chuỗi gồm $N = M \times M = 7 \times 7 = 49$ token, chuỗi này được biến đổi sử dụng MSA thuần như trong ViT, sau đó được sắp xếp lại đúng vị trí từng token trong cửa sổ và dựng lại đúng vị trí của cửa sổ trong mảng token $H_t \times W_t$.

Cách làm này của W-MSA vừa duy trì được tính không gian của các token vừa giảm được độ phức tạp tính toán so với ViT:

- ViT đưa toàn bộ chuỗi gồm $H_t \times W_t$ token vào MSA và có độ phức tạp tính toán là $\mathcal{O}((H_t W_t)^2)$.
- W-MSA đưa $\frac{H_t \times W_t}{M \times M}$ (số lượng cửa sổ) chuỗi token, mỗi chuỗi gồm có $M \times M$ token vào MSA. W-MSA có độ phức tạp tính toán là $\mathcal{O}\left(\frac{H_t \times W_t}{M \times M} \cdot (M \times M)^2\right) = \mathcal{O}(M^2 H_t W_t)$, nhỏ hơn nhiều lần so với độ phức tạp tính toán của ViT.

Ở pha 1. W-MSA là chỉ cho phép các token trong cùng một cửa sổ $M \times M$ tương tác với nhau. Hai token mặc dù ở cạnh nhau về không gian nhưng thuộc 2 cửa sổ khác nhau thì không biết gì về nhau do chúng được MSA xử lý một cách độc lập. Do đó, ở pha 2, SM-MSA được thiết kế để giải quyết vấn đề này.

Trong SW-MSA, mảng token $H_t \times W_t$ được thực hiện phép dịch vòng (cyclic shift) với độ lệch $\left\lfloor \frac{M}{2} \right\rfloor$ theo hai chiều để làm lệch lưới cửa sổ so với mảng token đưa vào W-MSA trước đó. Từ đó tạo ra các cửa sổ mới chứa token từ nhiều cửa sổ cũ và cho phép tương tác token liên cửa sổ.



Hình 5.32. Phép dịch vòng (cyclic shift) trong SW-MSA. (Vẽ lại)

Mảng token sau khi thực hiện phép dịch vòng được chia thành các cửa sổ $M \times M$ và thực hiện tương tự như W-MSA. Ở đây có vấn đề là một số cửa sổ ở biên chứa đồng thời một số token lân cận cùng với một số token có vị trí ở xa (phía kia của mảng token). Để giải quyết vấn đề này, kỹ thuật attention masking được sử dụng để đánh dấu cho MSA chỉ cho phép các token trong vùng lân cận tương tác với nhau và ngăn chặn các token ở xa tương tác mạnh với nhau.


C) Các biến thể của Swin transformer

Một số tham số quyết định đến quy mô của kiến trúc swin transformer như số chiều tiêu chuẩn (số chiều của token vào stage 1) và số khối swin transformer được thực hiện trong mỗi stage. Bảng 5.5 liệt kê một số biến thể của swin transformer.

Bảng 5.5. Các biến thể của Swin transformer.

Biến thể	Chiều tiêu chuẩn (C)	Số ST cho mỗi stage	Số tham số	Mục tiêu
Swin-T (Tiny)	96	[2, 2, 6, 2]	~28M	Nhẹ
Swin-S (Small)	96	[2, 2, 18, 2]	~50M	Hiệu năng tốt
Swin-B (Base)	128	[2, 2, 18, 2]	~88M	Tiêu chuẩn
Swin-L (Large)	192	[2, 2, 18, 2]	~197M	Độ chính xác cao

5.2.2.3. MaxViT



Hình 5.32. Kiến trúc mạng MaxViT.

ViT mang lại khả năng mô hình hóa thông tin toàn cục mạnh mẽ nhưng gặp hạn chế lớn do độ phức tạp tính toán. Swin transformer cải thiện hiệu quả tính toán nhờ cơ chế attention theo cửa sổ, tuy nhiên thông tin toàn cục chỉ được truyền một cách gián tiếp. MaxViT được đề xuất nhằm khắc phục những hạn chế này bằng cách

tích hợp đồng thời attention cục bộ và attention toàn cục đồng thời vẫn duy trì độ phức tạp tính toán tuyến tính.

A) Kiến trúc tổng thể

Kiến trúc MaxViT, Hình 5.32 (a), kế thừa khả năng biểu diễn đa tỉ lệ vốn hiệu quả trong các mạng CNN và Swin transformer. MaxViT nhận vào một ảnh màu 3 kênh với độ phân giải không hạn chế. Tầng stem gồm 2 khối tích chập 3×3 để trích xuất đặc và biến đổi đặc trưng mức thấp để phù hợp cho các tầng tiếp theo

Tiếp theo là 4 stage, stage i là việc thực hiện lặp lại khối MaxViT L_i lần. Độ phân giải không gian và số kênh của biểu diễn đặc trưng được thay đổi theo từng stage thông qua các phép tích chập có stride, mỗi lần độ phân giải giảm một nửa theo hai chiều và số kênh C_i tăng lên.

B) Cấu trúc khối MaxViT


Hình 5.32 (b) là khối trung tâm của kiến trúc MaxViT, nó cho phép mô hình đồng thời khai thác thông tin cục bộ và toàn cục ngay trong mỗi khối thay vì chỉ truyền ngữ cảnh toàn cục một cách gián tiếp qua nhiều tầng.

Đầu tiên, khối MBConv kế thừa trực tiếp từ EfficientNet (xem mục 5.2.1.5) giúp mô hình học cấu trúc không gian mức thấp tốt và ổn định hơn. Hai pha tiếp theo của MaxViT có khá nhiều đặc điểm tương tự với swin transformer như attention, MLP, nomalization, residual, ...

Điểm khác biệt của MaxViT so với swin transformer nằm ở pha thứ 2 là khối Grid-SA (grid selft attention). Thay vì thực hiện với toàn bộ token (như trong ViT phiên bản gốc) hoặc một nhóm token trong lân cận một cửa sổ (như W-MSA của swin transformer hoặc Block-SA), Grid-SA gom các token ở cùng vị trí tương đối của các khối kích thước $B \times B$ (thường là 7×7) khác nhau thành một lưới các token (token grid), rồi thực hiện self-attention trên các grid này. Cách làm này cho phép mô hình hóa ngữ cảnh toàn cục với chi phí tính toán không phụ thuộc vào độ phân giải ảnh.

Hình 5.33 trực quan hóa cách thức mà Block-SA và Grid-SA gom các token để đưa vào self-attention. Trong đó biến đổi đặc trưng được chia thành các khối kích thước $B \times B$ (để dễ trình bày, Hình 5.33 sử dụng kích thước 3×3 , thực tế MaxViT sử dụng kích thước 7×7). Trong Block-SA, tất cả các token có cùng số trong 1 khối được đưa vào self-attention nên có khả năng biểu diễn cục bộ cao. Với biến đổi đặc trưng có kích thước $H_t \times W_t$, Block-SA có độ phức tạp tính toán là $\mathcal{O}(B^2 H_t W_t)$, phụ thuộc vào kích độ phân giải ảnh đầu vào. Trong Grid-SA, tất cả các token có cùng số ở các khối khác nhau được gom thành một chuỗi để đưa vào self-attention. Grid-SA có độ phức tạp tính toán $\mathcal{O}(B^2)$ không phụ thuộc vào độ phân giải ảnh đầu vào.

4862



Hình 5.33. Cách gom token để đưa vào Self-attention.

4863 C) Các biến thể của MaxViT

4864 Bộ tham số $[L_1, L_2, L_3, L_4]$ (độ sâu/số lần lặp của khối MaxViT ở các stage) và
 4865 bộ tham số $[L_1, L_2, L_3, L_4]$ (số kênh của biểu đặc trưng ở mỗi stage) xác định hiệu
 4866 năng và độ phức tạp của kiến trúc MaxViT và là cơ sở để xây dựng các biến thể của
 4867 MaxViT.


4868 Bảng 5.6. Các biến thể của MaxViT

Biến thể	$[L_1, L_2, L_3, L_4]$	$[L_1, L_2, L_3, L_4]$	Mục đích sử dụng
MaxViT-T (tiny)	[2, 2, 5, 2]	[64, 128, 256, 512]	Nhẹ, hiệu quả, tài nguyên hạn chế
MaxViT-S (small)	[2, 2, 5, 2]	[96, 192, 384, 768]	Cân bằng
MaxViT-B (base)	[2, 6, 14, 2]	[96, 192, 384, 768]	Chuẩn backbone để nghiên cứu
MaxViT-L (large)	[2, 6, 14, 2]	[128, 256, 512, 1024]	Hiệu năng cao nhất

4869

4870 D) So sánh hiệu năng các transformers

4871 Các mô hình ViT, Swin và MaxViT được so sánh sử dụng bộ dữ liệu ảnh
 4872 ImageNet-1K, độ chính xác của bài toán phân loại ảnh (top-1) theo tỉ lệ phần trăm
 4873 đúng. Kết quả được trình bày trong Hình 5.34. Biểu đồ cho thấy MaxViT duy trì
 4874 hiệu năng nhất quán so với ViT và Swin trên toàn bộ dải GFLOPs. Nhờ kết hợp
 4875 đồng thời đặc điểm của CNN, attention cục bộ và attention toàn cục trong mỗi
 4876 block, MaxViT đạt được hiệu quả tính toán cao hơn và khả năng mở rộng tốt hơn
 4877 khi tăng kích thước mô hình.



Hình 5.34. So sánh hiệu năng giữa

5.2.3. Mạng hồi quy

5.2.3.1. RNN

5.2.3.2. LSTM

5.2.3.3. Mamba

5.2.4. Huấn luyện mạng học sâu

5.2.4.1. Supervised learning

➔ Hàm mất mát

5.2.4.2. Unsupervised learning

➔ Hàm mất mát

5.2.4.3. Contrastive learning và self-supervised learning

➔ Hàm mất mát

4895 5.2.4.4. *Disentangled learning*

4896 → Hàm mất mát

4897 5.2.4.5. *Deep reinforcement learning*

4898 → Rewards

4899 **5.3. Một số mạng chức năng**

4900 **5.3.1. Mạng so khớp mô hình**

4901 DSAC/DSAC++ (Differentiable RANSAC)

4902 **5.3.2. Mạng bám theo đối tượng**

4903 SiamFC

4904 **5.3.3. Mạng căn chỉnh ảnh**

4905 SuperPoint

4906 **5.3.4. Mạng phân loại ảnh**

4907 VGGNet

4908 **5.3.5. Mạng phát hiện và nhận dạng đối tượng**

4909 Faster R-CNN

4910 **5.3.6. Mạng tái tạo cấu trúc 3D**

4911 MVSNet

4912 **5.3.7. Mạng sinh ảnh**

4913 VAE

4914 **5.4. Mô hình nền thị giác (vision foundation models)**

4915 World model – Li fei fei

4916 **Kết chương**

4917 Chương này đã giới thiệu các nền tảng và phương pháp chủ đạo của thị giác
4918 máy dựa trên học sâu, từ các khái niệm cơ bản về học máy và mạng neuron đến các
4919 kiến trúc mạng sâu tiêu biểu trong thị giác máy hiện đại. Trọng tâm của chương là

4920 sự chuyển dịch từ các phương pháp dựa trên đặc trưng thủ công sang học biểu diễn
4921 trực tiếp từ dữ liệu.

4922 Các kiến trúc như mạng tích chập (CNN) và Vision Transformers cho phép xây
4923 dựng các biểu diễn phân cấp hiệu quả, trong khi quá trình huấn luyện mạng học
4924 sâu đóng vai trò quyết định đến hiệu năng và khả năng tổng quát hóa. Trên cơ sở
4925 đó, nhiều mạng chức năng đã được trình bày để giải quyết các bài toán thị giác quan
4926 trọng như phân loại, phát hiện–nhận dạng, theo dõi, căn chỉnh ảnh và tái tạo cấu
4927 trúc 3D.

4928 Cuối cùng, các mô hình nền thị giác (vision foundation models) cho thấy xu
4929 hướng phát triển của thị giác máy hướng tới các hệ thống có khả năng thích nghi và
4930 mở rộng trên nhiều nhiệm vụ. Những nội dung trong chương này tạo nền tảng cho
4931 việc tiếp cận các ứng dụng và hướng nghiên cứu nâng cao trong thị giác máy hiện
4932 đại.

4933 Tài liệu tham khảo

4934 Alex, K., Ilya, S., Hinton, G. (2012). ImageNet Classification with Deep
4935 Convolutional Neural Networks. *Advances in Neural Information Processing*
4936 *Systems (NeurIPS)*, 25, 1097–1105.

4937 Chen, L.-C., Steiner, A., Soricut, R., Garcia, X., Shlens, J., & Adam, H. (2022).
4938 MaxViT: Multi-Axis Vision Transformer. In *Proceedings of the European*
4939 *Conference on Computer Vision (ECCV 2022)*.

4940 Deng, J., Dong, W., Socher, R., Li, L.-J., Li, K., & Fei-Fei, L. (2009). ImageNet: A
4941 Large-Scale Hierarchical Image Database. In *Proceedings of the IEEE Conference on*
4942 *Computer Vision and Pattern Recognition (CVPR)* (pp. 248–255).

4943 Dosovitskiy, A., Beyer, L., Kolesnikov, A., Weissenborn, D., Zhai, X.,
4944 Unterthiner, T., Dehghani, M., Minderer, M., Heigold, G., Gelly, S., Uszkoreit, J., &
4945 Houlsby, N. (2021). An image is worth 16x16 words: Transformers for image
4946 recognition at scale. In *International Conference on Learning Representations*
4947 *(ICLR)*.

4948 Fukushima, K. (1980). Neocognitron: A self-organizing neural network model
4949 for a mechanism of pattern recognition unaffected by shift in position. *Biological*
4950 *Cybernetics*, 36(4), 193–202.

4951 He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep residual learning for image
4952 recognition. In *Proceedings of the IEEE Conference on Computer Vision and Pattern*
4953 *Recognition (CVPR)* (pp. 770–778).

4954 Hornik, K., Stinchcombe, M., & White, H. (1989). Multilayer feedforward
4955 networks are universal approximators. *Neural Networks*, 2(5), 359–366.

- 4956 Hu, J., Shen, L., & Sun, G. (2018). Squeeze-and-Excitation Networks. In
4957 Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern
4958 Recognition (CVPR) (pp. 7132–7141).
- 4959 Ioffe, S., & Szegedy, C. (2015). Batch normalization: Accelerating deep network
4960 training by reducing internal covariate shift. In Proceedings of the 32nd
4961 International Conference on Machine Learning (ICML 2015) (pp. 448–456).
- 4962 Kingma, D. P., & Ba, J. (2015). Adam: A Method for Stochastic Optimization.
4963 International Conference on Learning Representations (ICLR).
- 4964 Kunc, V., & Kléma, J. (2024). Three Decades of Activations: A Comprehensive
4965 Survey of 400 Activation Functions for Neural Networks. arXiv:2402.09092.
- 4966 Lê, T. H. (2016). Giáo trình Xử lý ảnh. Nhà xuất bản Đại học Quốc gia Hà Nội.
- 4967 LeCun, Y., Boser, B., Denker, J. S., Henderson, D., Howard, R. E., Hubbard, W.,
4968 & Jackel, L. D. (1989). Backpropagation applied to handwritten zip code recognition.
4969 Neural Computation, 1(4), 541–551.
- 4970 LeCun, Y., Bottou, L., Bengio, Y., & Haffner, P. (1998). Gradient-Based
4971 Learning Applied to Document Recognition. Proceedings of the IEEE, 86(11), 2278–
4972 2324.
- 4973 Li, F.-F., Johnson, J., & Yeung, S. (2017). CS231n: Convolutional Neural
4974 Networks for Visual Recognition. Stanford University. Retrieved from
4975 <https://cs231n.stanford.edu/>
- 4976 Li, Y., Xu, Z., Wang, X., & Wang, X. (2020). A bibliometric analysis on deep
4977 learning during 2007–2019. International Journal of Machine Learning and
4978 Cybernetics.
- 4979 Liu, Z., Lin, Y., Cao, Y., Hu, H., Wei, Y., Zhang, Z., Lin, S., & Guo, B. (2021).
4980 Swin Transformer: Hierarchical Vision Transformer using Shifted Windows. In
4981 Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV
4982 2021) (pp. 10012–10022).
- 4983 Loshchilov, I., & Hutter, F. (2019). Decoupled Weight Decay Regularization.
4984 In International Conference on Learning Representations (ICLR).
- 4985 Sandler, M., Howard, A., Zhu, M., Zhmoginov, A., & Chen, L.-C. (2018).
4986 MobileNetV2: Inverted Residuals and Linear Bottlenecks. In Proceedings of the
4987 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR) (pp.
4988 4510–4520).
- 4989 Simonyan, K., & Zisserman, A. (2015). Very deep convolutional networks for
4990 large-scale image recognition. International Conference on Learning
4991 Representations (ICLR).
- 4992 Szegedy, C., Liu, W., Jia, Y., Sermanet, P., Reed, S., Anguelov, D., Erhan, D.,
4993 Vanhoucke, V., & Rabinovich, A. (2015). Going deeper with convolutions. In

4994 Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition
4995 (CVPR) (pp. 1–9).

4996 Tan, M., & Le, Q. V. (2019). EfficientNet: Rethinking Model Scaling for
4997 Convolutional Neural Networks. Proceedings of the 36th International Conference
4998 on Machine Learning (ICML 2019), PMLR 97:6105–6114.

4999 Rumelhart, D. E., Hinton, G. E., & Williams, R. J. (1986). Learning
5000 representations by back-propagating errors. *Nature*, 323(6088), 533–536.

5001 Russakovsky, O., Deng, J., Su, H., Krause, J., Satheesh, S., Ma, S., Huang, Z.,
5002 Karpathy, A., Khosla, A., Bernstein, M., Berg, A. C., & Fei-Fei, L. (2015). ImageNet
5003 Large Scale Visual Recognition Challenge. *International Journal of Computer Vision*
5004 (IJCV), 115(3), 211–252.

5005 **Bài tập**

5006


5007

5008

PHỤ LỤC 1. NỀN TẢNG TOÁN HỌC

5009 **P1.1. Không gian tỉ lệ**


5010 Trong các yêu cầu mà đặc trưng ảnh cần thỏa mãn thì đặc điều kiện bất biến
 5011 với góc nhìn và bất biến với tỉ lệ là khó thực hiện hơn hai điều kiện còn lại. Bất biết
 5012 góc nhìn đòi hỏi hệ thống thị giác máy phải có thông tin về cấu trúc 3D của đối
 5013 tượng và chưa được bao gồm trong nội dung của cuốn giáo trình này. Để đạt được
 5014 điều kiện về bất biến tỉ lệ, ảnh gốc cần được biểu diễn để mô phỏng được cách mà
 5015 người quan sát hoặc camera chụp ảnh ở các cự ly khác nhau. Ở khoảng cách gần,
 5016 nhiều chi tiết được bộ lộ, khi di chuyển ra xa, các chi tiết nhỏ biến mất và thay vào
 5017 đó là các cấu trúc hình học có tính khái quát hơn.



5018

5019

Hình P1.1. Tỉ lệ ảnh tác động tới đặc trưng ảnh.



(a)



(b)

5020

5021

5022

Hình P1.2. Khó khăn trong chọn kích thước cửa sổ mô tả điểm.

5023 Hình P1.1 trực quan hóa sự tác động của tỉ lệ ảnh tới đặc trưng ảnh. Trong
 5024 hình bên trái, hầu hết các điểm có thể được coi là cạnh trong khi đó chúng có thể coi
 5025 là 1 góc ở hình bên phải. Hình 1.2 (a) và (b) là của cùng một hình ảnh với tỉ lệ khác
 5026 nhau. Lần lựa chọn kích thước cửa sổ của điểm ảnh mỗi bên là bao nhiêu để chúng
 5027 cùng cung cấp một lượng dữ liệu đồng nhất cho quá trình mô tả hai điểm tương
 5028 đồng này? Không gian tỉ lệ có thể được sử dụng để giải quyết vấn đề này.

P1.1.1. Định nghĩa gian tỉ lệ là gì

Không gian tỉ lệ (scale-space) là một biểu diễn đa tỉ lệ (multi-scale presentation) của ảnh. Trong đó, hai trục không gian có kích thước bằng kích thước ảnh gốc, trục còn lại gọi là gọi là trục tỉ lệ. Ký hiệu $L(x, y; \sigma)$ là biểu diễn đa tỉ lệ của ảnh $I(x, y)$ và được xây dựng như sau:

$$L(x, y; \sigma) = G(x, y; \sigma) * I(x, y), \quad (\text{P1.1})$$

trong đó $G(x, y; t)$ là hàm Gaussian hai chiều

$$G(x, y; \sigma) = \frac{1}{2\pi t} \exp\left(-\frac{x^2+y^2}{2\sigma^2}\right), \quad (\text{P1.2})$$

với σ là phương sai của phân bố Gaussian và được gọi là *tham số tỉ lệ* (scale parameter) trong không gian tỉ lệ. Ở đây, $L(x, y; \sigma)$ là phiên bản mờ (blur) của $I(x, y)$ khi sử dụng một bộ lọc Gaussian, $L(x, y; \sigma) = I(x, y)$ khi tham số tỉ lệ $\sigma = 0$.



Hình P1.3. Không gian tỉ lệ $L(x, y; \sigma)$ với các tham số tỉ lệ $\sigma = 0, 1, 2$ và 3 lần lượt từ trái sang phải.

Nói cách khác, không gian tỉ lệ $L(x, y; \sigma)$ chứa các thay đổi từ mức chi tiết (chứa nhiều chi tiết nhỏ khi ta nhìn ảnh ở cự ly gần) với σ nhỏ đến mức tổng quan (các chi tiết nhỏ biến mất, chỉ còn các cấu trúc lớn khi ta nhìn ảnh ở khoảng cách xa) với σ lớn, xem Hình P1.3. Do đó, có thể thấy cùng một đối tượng dù xuất hiện với kích thước khác nhau trong ảnh, ta vẫn có thể được biểu diễn trong không gian tỉ lệ với một giá trị σ thích hợp.

P1.1.2. Chuẩn hóa đạo hàm

Trong hầu hết các kỹ thuật trích rút đặc trưng (đặc biệt là đặc trưng hình học), các toán tử đạo hàm bậc 1 bậc 2, gradient của ảnh gốc đều được khai thác. Khi biểu diễn ảnh trong không gian tỉ lệ, bộ lọc làm mượt Gaussian làm độ dốc của các kết cấu trong ảnh (độ lớn của vector gradient) bị giảm. Dẫn tới các toán tử đạo hàm của chúng cũng bị thay đổi và không thể so sánh trực tiếp với nhau trong không gian tỉ lệ. Do đó đạo hàm của các ảnh sau khi được làm mượt bởi Gaussian cần được chuẩn hóa. Để dễ minh họa, ta lần lượt xét trường hợp co giãn ảnh.

Khi co giãn ảnh với một hệ số s , tức là ta tăng kích thước cả hai chiều s lần với $s > 1$ hoặc giảm kích thước mỗi chiều của ảnh lên s lần với $s < 1$. Sau khi co giãn ảnh với tỉ lệ s , tọa độ của ảnh mới là:

$$x' = s \cdot x \text{ và } y' = s \cdot y. \quad (\text{P1.3})$$

Ảnh mới thu được có cường độ không đổi so với ảnh gốc và lượng thông tin giữa 2 ảnh là như sau. Ta có:

$$I'(x', y') = I(x, y) = I\left(\frac{x'}{s}, \frac{y'}{s}\right). \quad (\text{P1.4})$$

Phép toán mờ ảnh đều làm mất một lượng thông tin nhất định trong ảnh bản đầu. Vì I và I' có kích thước khác nhau, nên nếu sử dụng cùng một Gaussian để làm mờ 2 ảnh này thì lượng thông tin mất đi ở hai ảnh không đồng đều. *Định luật đổi thang* (shift/rescaling property) cho biết làm mờ ảnh gốc $I(x, y)$ với một Gaussian có phương sai σ làm mất một lượng thông tin tương đương với mờ ảnh sau khi co giãn $I'(x', y')$ với một Gaussian có phương sai $s \cdot \sigma$. Do đó, để bảo toàn thông tin giữa hai phiên bản ta cần:

$$\sigma' = s \cdot \sigma. \quad (\text{P1.5})$$

Bên cạnh đó, toán tử co giãn ảnh bảo toàn cường độ sáng của ảnh, nên ta có:

$$L'(x', y'; \sigma') = L(x, y; \sigma). \quad (\text{P1.6})$$

Khi lấy đạo hàm của $L'(x', y'; \sigma')$ theo thành phần x' ta được:

$$\frac{\partial L'(x', y'; \sigma')}{\partial x'} = \frac{\partial L(x, y; \sigma)}{\partial x'} = \frac{1}{s} \frac{\partial L(x, y; \sigma)}{\partial x}. \quad (\text{P1.7})$$

Tức là biên độ của đạo hàm của ảnh sau co giãn với tỉ lệ s , giảm s lần so với đạo hàm ảnh ban đầu. Để chuẩn hóa, ta nhân đạo hàm của ảnh sau co giãn với s để nó biên độ đồng bộ với đạo hàm của ảnh gốc.

Trong trường hợp quát, khi ta thực hiện đạo hàm theo cả thành phần x và thành phần y ở bậc cao hơn, ta thu được:

$$\frac{\partial^{q+p} L'(x', y'; \sigma')}{\partial (x')^q \partial (y')^p} = \frac{\partial^{q+p} L(x, y; \sigma)}{\partial (x')^q \partial (y')^p} = \frac{1}{s^{q+p}} \frac{\partial^{q+p} L(x, y; \sigma)}{\partial (x)^q \partial (y)^p}. \quad (\text{P1.8})$$


Điều này có nghĩa là đạo hàm bậc q theo thành phần x và đạo hàm bậc p theo thành phần y của ảnh sau co giãn giảm s^{q+p} lần so với đạo hàm cùng bậc của ảnh ban đầu. Do đó để chuẩn hóa ta nhân đạo hàm này với s^{q+p} :

$$\frac{\partial_{norm}^{q+p} L'(x', y'; \sigma')}{\partial (x')^q \partial (y')^p} = s^{q+p} \cdot \frac{\partial^{q+p} L'(x', y'; \sigma')}{\partial (x')^q \partial (y')^p}. \quad (\text{P1.9})$$

Hình P1.4 mô phỏng quá trình chuẩn hóa đạo hàm cho phép co giãn ảnh với hệ số co giãn $s = 2$. Hình (a) là ảnh I gốc, (b) là phiên bản của I với kích thước tăng s lần (ảnh I'). Hình (c) (I_b) và (e) (I'_b) thu được bằng cách làm mờ I và I' với bộ lọc Gaussian có độ lệch $\sigma = 3$ và $\sigma = 6$. Ở đây, σ được lựa chọn sao cho thông tin trong I_b và I'_b là tương đương.


Hình P1.4 (c) (I_y) và (f) (I'_y) là đạo hàm theo thành phần y của I_b và I'_b . Có thể thấy, tác động của đạo hàm làm cho độ tương phản của I'_y nhỏ hơn độ tương phản của I_y nhiều. Cụ thể giá trị trung bình tuyệt đối của I'_y ($|I'_y| = 0.00382$) bằng một nửa giá trị trung bình tuyệt đối của I_y ($|I_y| = 0.0067$).

5095 Cuối cùng, Hình P1.4 (c) là đạo hàm chuẩn hóa $I'_{norm} = s * I'_y = 2 * I'_y$ có độ
 5096 tương phản tương đồng với I_y và hiển nhiên là các giá trị độ lớn của đạo hàm cũng
 5097 tương tự nhau.



Hình P1.4. Chuẩn hóa đạo hàm trong không gian tỉ lệ.

5098 P1.1.3. Tự động chọn tham số tỉ lệ



Hình P1.5. Lựa chọn σ là cực đại địa phương.

5101 Với mỗi điểm (x, y) trong ảnh, cần phải chọn được t sao cho có thể tìm lại được
 5102 điểm đó trong một ảnh khác. Hình P1.5 cho biết ví dụ về việc cách lựa chọn σ_1 và
 5103 σ_2 là cực đại địa phương của một hàm để cùng mô tả một điểm góc ở hai ảnh có tỉ
 5104 lệ khác nhau. Trong không gian tỉ lệ, hàm được sử dụng trong trường hợp này phải
 5105 có khả năng mô tả được đặc trưng của cấu trúc ảnh tại một điểm dưới tác động của
 5106 phép làm mờ Gaussian với các tham số tỉ lệ khác nhau.

5107 Hàm này được gọi là Signature và được định nghĩa như sau:

$$5108 \quad S(x, y; \sigma) = \Phi(L(x, y; \sigma), \nabla L, \nabla^2 L, \dots). \quad (P1.10)$$

5109 Trong đó $\Phi(\cdot)$ là phép biến đổi đặc trưng hình học của điểm ảnh dựa vào biểu
 5110 diễn tỉ lệ cùng các dẫn suất của nó như đạo hàm, gradient, ... Ở đây, hàm Signature
 5111 cho biết dấu hiệu nhận dạng đặc trưng của một điểm khi nhìn ảnh ở các tỉ lệ nhất
 5112 định. Với điểm (x, y) cho trước nếu ta tìm được cực trị theo tham số tỉ lệ, tức là:

5113
$$\frac{\partial S(x,y;\sigma)}{\partial \sigma} = 0, \quad (P1.11)$$

5114 thì ta được một giá trị tham số tỉ lệ là một mô tả tự nhiên của phép biến đổi đặc
5115 trưng $\Phi(\cdot)$ và không phụ thuộc vào mức độ làm mờ ảnh của Gaussian và cũng
5116 không phụ thuộc vào độ co giãn của ảnh. Khi đó phép biến đổi đặc trưng $\Phi(\cdot)$ tại
5117 điểm (x, y) là bất biến với tỉ lệ.

5118 Mỗi đặc phương pháp trích chọn đặc trưng có thể sử dụng hàm Signature phù
5119 hợp. Xem Bảng P1.1 liệt kê hàm Signature được sử dụng trong phát hiện đặc trưng
5120 và sẽ được đề cập trong các phần tiếp theo của giáo trình.

5121 Bảng P1.1. Một số hàm Signature được sử dụng trong phát hiện đặc trưng.

TT	Hàm Signature	Diễn giải mục đích
1	$S_E(x, y; \sigma) = \sigma \cdot \ \nabla L\ $	Được dùng cho các phương pháp phát hiện cạnh, trong đó $\ \nabla L\ $ là độ dài của vector gradient
2	$S_{C1}(x, y; \sigma) = \sigma^4 (L_{xx}L_{yy} - L_{xy}^2)$	Được dùng để phát hiện điểm giao (hay còn gọi là góc) giữa các đường cong theo phương pháp Hessian, trong đó L_{xx} , L_{yy} và L_{xy} là đạo hàm bậc 2 theo thành phần x, theo thành phần y và theo cả hai thành phần.
3	$S_{C2}(x, y; \sigma) = \sigma^2 (\det M + k \cdot \text{trace}^2 M)$	Được dùng để phát hiện điểm đặc trưng (hay còn gọi là góc) theo phương pháp Harris, trong đó M là ma trận moment.
4	$S_B(x, y; \sigma) = \sigma^2 \cdot \nabla^2 L$	$\nabla^2 L = \frac{\partial^2 L}{\partial x^2} + \frac{\partial^2 L}{\partial y^2}$ là toán tử Laplace được định nghĩa là tổng đại số của đạo hàm bậc hai. Thường dùng trong các phương pháp phát hiện blob (đốm sáng hoặc đốm tối).

5122

5123 P1.2. Không gian đẳng cấu

5124

PHỤ LỤC 2. DỰ ÁN THỰC HÀNH

5125 **P2.1.**

5126 **P1.2.**

5127 **P1.3.**

DRAFT